

DOUTORADO EM CIÊNCIA DA COMPUTAÇÃO

SAC-FTOPSIS: Um Modelo de Decisão para o Descarregamento de Tarefas em Redes Veiculares

Antônio Sérgio de Sousa Vieira

sergio.vieira@ifce.edu.br

sergio.vieira@aluno.uece.br


Orientador: Prof. Dr. Joaquim Celestino Júnior (UECE)
Coorientador: Prof. Dr. Alisson Barbosa de Souza (UFC)

29 de maio de 2026

1. Introdução e Motivação
2. Trabalhos Relacionados e Lacunas
3. Metodologia e Proposta
4. Resultados e Análise
5. Conclusões e Cronograma
6. Referências


Sistemas Inteligentes de Transporte (ITS)

- **Objetivo:** Uso inteligente e coordenado da infraestrutura de rede.
- **Benefícios:** Trânsito mais seguro, usuários bem informados e economia de tempo, dinheiro e combustível.



Demandas e Perfis de Aplicação

- **Exemplos:** Direção autônoma, Realidade Aumentada (AR) e visão computacional.
- **Perfil Crítico:** Tarefas com **poucos bytes** de entrada, mas com **altíssima complexidade** de cálculo, exigindo muitos ciclos de CPU e alto gasto energético.



O Gargalo da Computação Local

- **Restrições:** As Unidades de Bordo (OBUs) possuem restrições físicas (bateria, dissipação térmica e CPU).
- **Consequência:** A computação puramente local não consegue atender aos requisitos de tempo, gerando falhas.



A viabilização do ITS depende também da superação das limitações computacionais locais.

Heterogeneidade e Cooperação


- **Capacidades:** As OBUs possuem hardware e níveis de bateria distintos.
- **Compartilhamento:** Veículos vizinhos podem ceder recursos ociosos.

A Estratégia de Offloading

Essencial para superar gargalos locais de processamento em tarefas complexas e sensíveis ao atraso.

O Desafio da Não-estacionariedade

Decisão: Como e onde descarregar em topologias altamente dinâmicas e imprevisíveis (cargas e recursos variáveis)?



O descarregamento de tarefas é uma necessidade para viabilizar aplicações de ITS em tempo real.

TAREFA


D	Tamanho	$\sim 1.5 \text{ kB}$
C	Complexidade	10^8 CPU
τ	Prazo	$\leq 100 \text{ ms}$

Total (Full)



- Envio integral de uma única tarefa indivisível para o servidor.

Parcial

- Divisão da tarefa em múltiplas subtarefas ou lotes.




Descarregamento: Total vs. Parcial — Trade-offs



Foco deste Trabalho


- **Natureza:** Tarefas indivisíveis com **alta complexidade** computacional.
- **Carga:** *Payload* com poucos bytes, mas cálculo pesado (CPU intensiva).
- **Prazos:** Curtos ($\leq 100\text{ms}$). Transmissão rápida + processamento potente na borda.
- **Vantagem:** Poupa consumo energético na transmissão.
- **Exemplos:** Controle de veículos autônomos e alertas de segurança.

FLUXO DE DESCARREGAMENTO TOTAL



Limitações das Abordagens Tradicionais


- **Convergência:** Iterações excessivas (GA, PSO) podem violar prazos.
- **Baixa Adaptabilidade:** Cenários estáticos falham sob alta mobilidade, canal variante e não-estacionariedade.
- **Ótimos Locais:** Heurísticas gulosas (*Greedy*) falham na otimização global.
- **Custo Elevado:** Busca intensiva pode sobrecarregar os recursos da borda e/ou veículos.
- **Escalabilidade:** Sofrem com **explosão combinatória** com o aumento de veículos.



Em redes veiculares, uma decisão "ótima" que chega atrasada é, na prática, uma decisão inútil.

Características e Limitações do DRL em Redes Veiculares

- **Model-Free:** Aprende por tentativa e erro diretamente com o ambiente, dispensando modelagem matemática exata.
- **Inferência Rápida:** Decisões de descarregamento em milissegundos.
- **Não-estacionariedade:** Adapta-se a mudanças, mas pode exigir retreinamento.
- **Ótimos Locais:** Risco de convergência prematura para decisões subótimas.
- **Baixa Eficiência Amostral:** Podem exigir grandes volumes de dados para treino.



O DRL desloca o peso computacional para a fase de treinamento (offline), permitindo que a OBU tome decisões complexas de forma quase instantânea.

Como tomar decisões de descarregamento de tarefas, utilizando DRL, em redes VEC/V2X, com número variável de candidatos ao processamento, não-estacionariedade, de forma confiável e adaptativa, cumprindo restrições de prazo e minimizando latência e consumo energético, sem necessidade de retreinamento diante de variações na densidade veicular?

FOFF: An Energy-Efficient Task Offloading in VEC-Enabled Vehicular Networks Using Fuzzy TOPSIS

Antônio Sérgio de Sousa Vieira^{1,2*}, Alisson Barbosa de Souza^{1,3} and
Joaquim Celestino Júnior¹

^{1*}Intelligent Networks and Systems Group (INETSYS), State University of Ceará, Av.
Dr. Silas Munguba, 1700, Fortaleza, 60714-903, CE, Brazil.

^{2*}Federal Institute of Education, Science and Technology, Av. da Universidade, 102,
Itapipoca, 62500-000, CE, Brazil.

³Federal University of Ceará, Av. José F. Queiroz, 5003, Quixadá, 63902-580, CE, Brazil.

*Corresponding author(s). E-mail(s): sergio.vieira@ifce.edu.br;
Contributing authors: alisson@ufc.br; joaquim.celestino@uece.br;

Abstract

In modern vehicular network environments, the demand for efficient data processing is crucial. However, this demand can exceed the computational capacity of the vehicles' On-Board Unit Inter-connected (OBUI). One way to overcome these limitations is through edge devices with high computational capacity. Vehicular Edge Computing (VEC) facilitates the execution of these processing demands; however, latency remains a critical challenge. With advancements in 5G technology, research efforts have increasingly focused on determining whether tasks should be processed locally or offloaded to edge servers. Beyond latency considerations, energy consumption presents a significant concern for both OBUI and edge devices. This study introduces Fuzzy Offloading (FOFF), an innovative approach designed to balance these competing factors. Experiments show that FOFF reduces energy consumption and latency, achieving 72.11% energy savings and 0.61% lower processing time compared to the best greedy offloading approach considered. These results highlight FOFF's efficiency in vehicular environments.

Fuzzy Offloading (FOFF)

Vantagens:

- **1. Zero Treinamento:** Decisão instantânea (*one-shot*) baseada em regras lógicas.
- **2. Eficiência:** Baixa complexidade computacional e menor consumo de energia.

Desvantagens:

- **1. Miopia Temporal:** Não possui aprendizado sequencial. Toma decisões sem antecipar o estado futuro.
- **2. Adaptação a Drifts :** Carece de aprendizado sequencial para mudanças abruptas.

DRL Padrão (Ex: DQN, DDPG)

Vantagens:

- **1. Visão de Longo Prazo:** Aprende políticas sequenciais, antecipando estados futuros.
- **2. Model-Free:** Adapta-se à dinâmica do ambiente via tentativa e erro.

Desvantagens:

- **1. Engenharia de Recompensa:** Exige ajuste manual de pesos multiobjetivo.
- **2. Rigidez Dimensional:** Vulnerável a mudanças na topologia (entradas fixas).

Deep learning approaches for computation offloading in edge computing: A critical review

Sapthagiri Miriyala¹ · Venkata Ramireddy Chirra¹

Received: 21 June 2025 / Accepted: 11 February 2026 / Published online: 24 February 2026

© The Author(s), under exclusive licence to Springer Science+Business Media, LLC, part of Springer Nature 2026

Abstract

The paradigm shift from centralized cloud computing to Multi-Access Edge Computing (MEC) has been necessitated by the exponential growth of the Internet of Things (IoT) and the stringent latency requirements of 5G/6G applications. However, the inherent dynamism of edge environments, characterized by fluctuating channel conditions, heterogeneous device capabilities, and finite energy budgets, renders traditional static optimization techniques insufficient. This survey provides a critical review of Deep Learning (DL) and Deep Reinforcement Learning (DRL) as pivotal enablers for autonomous computation offloading. This work systematically dissects the algorithmic trade-offs between Value-Based (e.g., DQN) and Policy-Gradient (e.g., PPO, SAC, A3C) architectures, evaluating their suitability for continuous control, multi-agent coordination, and resource-constrained inference. We further bridge the gap between theoretical algorithms and practical telecommunications deployment by mapping DRL strategies to European Telecommunications Standards Institute (ETSI) MEC specifications and Open Radio Access Network (O-RAN) architectural standards. The review analyzes the "optimization trade-offs" inherent in offloading, specifically the conflict between service immediacy (latency) and resource conservation (energy/security). Finally, we synthesize key challenges hindering large-scale adoption, including the need for lightweight "extreme edge" models, robustness against non-stationary environments, and privacy-preserving federated learning, thereby providing a rigorous roadmap for the evolution of self-optimizing, intelligent edge ecosystems.

Keywords Multi-Access Edge Computing · Deep Reinforcement Learning · Computation Offloading · Resource Allocation · Federated Learning · IoT

Como a Nossa Proposta (Fuzzy-TOPSIS+DRL) Preenche as Lacunas de [Miriya & Chirra, 2026]

Limitações Mapeadas na Literatura

- 1. Topologia Variável:** Vetores fixos de estados são inadequados para topologias dinâmicas.
- 2. Não-Estacionariedade:** Políticas entram em colapso sob alta mobilidade (*drifts*).
- 3. Perturbações:** Sensibilidade a ruído ou falhas nas observações.
- 4. Complexidade do Modelo:** Faltam modelos leves para hardware restrito.
- 5. Continual Learning:** Falha ao tentar aprender de forma incremental e online.

Respostas da Nossa Proposta

- Invariância à Escala:** O Fuzzy-TOPSIS processa os candidatos e gera um vetor fixo representativo.
- Adaptação Contínua:** O uso do agente SAC (Model-Free) lida naturalmente com as mudanças do ambiente.
- Atenuação de Ruído:** Normalização via Fuzzy-TOPSIS amortece o impacto de *outliers*.
- Leve e Enxuta:** Arquitetura com baixa latência de inferência.
- Atualização Off-Policy:** O *Replay Buffer* dinâmico evita o esquecimento catastrófico.

Miriya & Chirra (2026) mapearam os principais gargalos do DRL no Edge Computing. Nossa abordagem híbrida ataca diretamente essas vulnerabilidades estruturais.

O objetivo do agente é **maximizar a taxa de tarefas concluídas dentro do prazo**, minimizando latência e energia.

$$\max_{\pi} J(\pi) = \mathbb{E}_{\pi} \left[\underbrace{w_s \cdot \mathbb{1}(\widehat{\text{JCT}}_t \leq D_t)}_{\text{taxa de sucesso}} - \underbrace{w_c \cdot \frac{1}{2} \left(\frac{\widehat{\text{JCT}}_t}{\text{JCT}_t^{\max}} + \frac{E_t}{E_t^{\max}} \right)}_{\text{custo normalizado} \in [0,1]} \right] \quad (1)$$

$$\text{JCT}_t^{\max} = \max(\widehat{\text{JCT}}_t^{\ell}, \widehat{\text{JCT}}_t^{\text{vec}} \cdot \mathbb{1}_{\text{viável}}, \widehat{\text{JCT}}_t^{\text{v2v}} \cdot \mathbb{1}_{\text{viável}}) \quad (2)$$

$$E_t^{\max} = \max(E_t^{\ell}, E_t^{\text{vec}} \cdot \mathbb{1}_{\text{viável}}, E_t^{\text{v2v}} \cdot \mathbb{1}_{\text{viável}}) \quad (3)$$

Problema

- O número de nós candidatos para descarregamento de tarefas pode variar, exigindo **retreinamento** em abordagens clássicas de DRL.

Solução: Invariância à Escala

- Propõe-se montar uma representação de dimensão fixa do estado atual percebido pelo agente por meio do ranqueamento (TOPSIS¹/Fuzzy-TOPSIS²), independentemente do número de candidatos.

¹Versão intermediária.

²Versão final.

Tabela de Vizinhança

Nó 1 (Tipo: Veículo, Freq: 1.0 GHz, Dist: 50m, Fila: 3)

Nó 2 (Tipo: Edge, Freq: 4.0 GHz, Dist: 10m, Fila: 1)

⋮

Nó n (Tipo, Freq, Dist, Fila)


Dinâmica da Tabela de Vizinhança:

- Montada periodicamente via recepção de características dos dispositivos vizinhos.
- Cada nó possui um **TTL** (*Time-to-Live*).
- Sem *refresh* (ex: Nó 1) dentro do limite, o dispositivo é removido.

Funcionamento do Ranqueamento:

- Realizado em função da **tarefa** a ser processada (requisitos de CPU, latência, etc.).
- Baseia-se nas **características** (**multicritério**) dos nós candidatos da vizinhança.

Ranqueamento - TOPSIS/Fuzzy-TOPSIS



Problema

- Em redes veiculares, a carga de tarefas, tempo de processamento, tempo de transmissão e a qualidade do canal podem sofrer variações dinâmicas, gerando colapsos em políticas rígidas.

Solução: Adaptação Contínua (SAC)

Maximização da Recompensa e da Entropia:

$$J(\pi) = \mathbb{E} \left[\sum_t r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t)) \right]$$


- Incentiva o agente a manter alternativas ativas, impedindo a convergência prematura para ótimos locais.
- A política estocástica se reajusta autonomamente a flutuações rápidas de carga sem regras estáticas rígidas.

Problema

- A alta mobilidade e atenuações do canal causam oscilações nas estimativas de estado (latência, distância, filas etc).
- Avaliar candidatos usando métricas brutas e instáveis pode provocar inversões na ordem de preferência dos nós candidatos, dificultando o aprendizado do agente.

Solução: Atenuação de Ruído

- Valores numéricos ruidosos são mapeados em Números Fuzzy Triangulares (ex: "Baixo", "Médio") [1], absorvendo pequenas flutuações e incertezas do ambiente, deixando o ranqueamento estável.




Problema

- OBUs com restrições severas de CPU e energia [2].
- Mudanças na topologia exigem arquitetura flexível como GNN, necessitando de mais recursos computacionais.
- Baixo poder computacional pode inviabilizar decisões em tempo real [3].

Solução: Arquitetura Leve e Enxuta

- **Treino Offline:** Fase pesada ocorre isolada do veículo (simulador), poupando a OBU.
- **Fuzzy-TOPSIS:** Ranqueamento com baixa complexidade computacional $O(n \log n)$ [1].
- **Leveza:** Inferência ultrarrápida (complexidade $O(1)$) em microssegundos [3].
- **Compactação:** Representação do ambiente e ações compactadas, diminuindo o custo de treinamento do agente.




Problema: Esquecimento

- **Vício Temporal:** Experiências sequenciais fortemente correlacionadas [4].
- **Instabilidade:** Focar em dados recentes causa o esquecimento catastrófico [3].
- **Divergência:** Inviabiliza o aprendizado contínuo em ambientes dinâmicos.

Solução: Replay Buffer (SAC)

- **Memória:** Armazena transições (s_t, a_t, r, s_{t+1}) para reuso *off-policy* [4].
- **Amostragem:** Sorteio de mini-lotes aleatórios quebra a correlação temporal [4].
- **Estabilidade:** Garante que estados raros permaneçam representados no gradiente [3].

Sequência de Transições Correlacionadas





$$r_t = \begin{cases} 1,0 - \frac{1}{4} \left(\frac{JCT_t}{D_t} + \frac{E_t}{E_t^{\text{máx}}} \right), & \text{se } JCT_t \leq D_t \text{ (Sucesso)} \\ -1,0 - \text{mín} \left(1,0, \frac{JCT_t - D_t}{D_t} \right), & \text{se } JCT_t > D_t \text{ (Falha)} \end{cases}$$


Fundamentação do Design

- **Penalidade QoS (Falha):** Incorpora restrições críticas aplicando multas severas e progressivas caso a tarefa viole o tempo limite estipulado [3].
- **Otimização Multiobjetivo (Sucesso):** Uma vez garantido o prazo, a função foca em equilibrar de forma adaptativa a minimização da latência e do consumo de energia [2].
- **Estabilidade de Gradiente (Normalização):** A divisão pelos limites máximos (D_t e $E_t^{\text{máx}}$) evita que variáveis com grandezas distintas (Segundos vs. Joules) afetem desproporcionalmente a otimização da rede neural [2].


Design da Função de Recompensa




Treinamento do Modelo (Offline)



Inferência (Modelo Treinado)



Resultados Preliminares



Variantes Avaliadas em 658 Cenários de Teste

Avaliação do impacto de cada componente (TOPSIS, Ação Binária e Recompensa *Deadline-aware*) no desempenho global.

Variante	Estado	Ação	Recompensa	Taxa de Sucesso (%)	SWQ	JCT (s)
SAC-Base	11D bruto	Ternária	WSM	4,52	0,0119	57,075
SAC-A1	11D bruto	Binária	WSM	39,11	0,1256	13,722
SAC-S1	6D	Ternária	WSM	28,69	0,1122	39,298
SAC-R1	11D bruto	Ternária	<i>Deadline-aware</i>	38,26	0,1223	13,353
SAC-T1	6D TOPSIS	Ternária	<i>Deadline-aware</i>	32,96	0,1270	11,487
SAC-FTOPSIS	6D TOPSIS	Binária	<i>Deadline-aware</i>	45,21	0,1484	6,547

- **Destaque:** A proposta completa (**SAC-FTOPSIS**) alcançou o melhor equilíbrio entre taxa de sucesso e tempo de conclusão (*JCT*).
- **Observação:** A transição para ação binária e o uso de TOPSIS foram cruciais para a estabilidade do aprendizado.

Legenda: WSM: *Weighted Sum Model* (Soma Ponderada); Ternária: Decisão direta entre Local, VEC ou V2V; SWQ: *Service Well-being Quality* (Ponderação entre taxa de sucesso e folga temporal).

Política	Categoria	% Sucesso	SWQ	JCT (s)	% Local
SAC-FTOPSIS *	DRL+TOPSIS	45,21	0,1484	6,547	74,1
PPO-TOPSIS *	DRL+TOPSIS	42,66	0,1426	5,895	98,7
TD3-TOPSIS *	DRL+TOPSIS	43,91	0,1388	3,703	76,5
A2C-TOPSIS *	DRL+TOPSIS	42,32	0,1418	6,045	100,0
Greedy-Unfair (Oráculo)	Heurística	41,29	0,1262	5,613	67,3
Gini	Heurística	35,24	0,1057	3,456	61,7
Random	Heurística	30,02	0,0950	17,853	40,7
Greedy-Fair	Heurística	20,61	0,0528	40,754	27,9
VEC (Incondicional)	Heurística	1,86	0,0030	144,191	1,2

- **Desempenho:** Algoritmos híbridos superaram as heurísticas clássicas e o oráculo guloso.
 - **Liderança:** O **SAC-FTOPSIS** mantém a maior taxa de sucesso geral (45,21 %).
- **Observação:** A estratégia local-dominante (PPO/A2C) minimiza latência, mas sacrifica oportunidades de offloading que o SAC aproveita.

* utiliza ranqueamento multicritério TOPSIS para pré-seleção de alvos de descarregamento.

- **Arquitetura SAC-FTOPSIS:** Integração eficaz entre ranqueamento multicritério (TOPSIS) e Aprendizado por Reforço (SAC).
 - **Escalabilidade:** O estado compacto 6D resolve o problema de número variável de veículos candidatos, garantindo uma interface invariante.
 - **Contribuições Técnicas:**
 - Engenharia de recompensa *deadline-aware* com foco em prazos rigorosos.
 - Redução de 8,6x no JCT médio em comparação ao SAC-Base.
 - Superação da heurística oráculo (*Greedy-Unfair*) em cenários reais.
 - **Métrica SWQ:** Nova métrica que pondera sucesso e folga temporal, provando-se superior à taxa de sucesso simples para avaliação de QoS.
- **Resumo:** A proposta demonstrou ser uma solução leve e adaptativa, capaz de operar em ambientes veiculares dinâmicos sem necessidade de retreinamento.

Evolução do Algoritmo

- **Integração do Fuzzy-TOPSIS:** Substituição do módulo clássico para incorporar incertezas e imprecisões nas medições da rede via Números Fuzzy Triangulares (TFNs).
- **Protocolo Estendido:** Expansão do protocolo de treinamento do agente DRL para múltiplos cenários e diferentes regimes dinâmicos de carga.

Validação e Simulação Realista

- **Simulação ns-3/SUMO:** Avaliação em ambiente de rede de eventos discretos completo, superando a simplificação atual de "canal perfeito".

Atividade / Ano	2026		2027		2028
	S1	S2	S1	S2	Q1
1. Exame de Qualificação	X				
2. Integração com Simulador (ns-3/SUMO)	X	X			
3. Refinamento de Algoritmos	X	X	X		
4. Avaliação de Desempenho		X	X		
5. Análise dos Resultados			X	X	
6. Escrita da Tese Final				X	X
7. Defesa Final					X

Legenda: S1: 1º semestre; S2: 2º semestre; Q1: 1º trimestre de 2028.

-  A. S. d. S. Vieira, A. B. de Souza, and J. C. Júnior, “Foff: An energy-efficient task offloading in vec-enabled vehicular networks using fuzzy topsis,” *Cluster Computing*, vol. 28, no. 13, p. 822, 2025.
-  J. Xue, L. Wang, Q. Yu, and P. Mao, “Multi-agent deep reinforcement learning-based partial offloading and resource allocation in vehicular edge computing networks,” *Computer Communications*, vol. 234, p. 108081, 2025.
-  S. Miriyala and V. R. Chirra, “Deep learning approaches for computation offloading in edge computing: A critical review,” *Telecommunication Systems*, vol. 89, p. 42, 2026.
-  V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu, “Asynchronous methods for deep reinforcement learning,” in *International conference on machine learning*, pp. 1928–1937, PMLR, 2016.

DOUTORADO EM CIÊNCIA DA COMPUTAÇÃO

SAC-FTOPSIS: Um Modelo de Decisão para o Descarregamento de Tarefas em Redes Veiculares

Antônio Sérgio de Sousa Vieira

sergio.vieira@ifce.edu.br

sergio.vieira@aluno.uece.br

Orientador: Prof. Dr. Joaquim Celestino Júnior (UECE)
Coorientador: Prof. Dr. Alisson Barbosa de Souza (UFC)

29 de maio de 2026