

DOUTORADO EM CIÊNCIA DA COMPUTAÇÃO

SAC-FTOPSIS: Um Modelo de Decisão para o Descarregamento de Tarefas em Redes Veiculares

Antônio Sérgio de Sousa Vieira

sergio.vieira@ifce.edu.br

sergio.vieira@aluno.uece.br


Orientador: Prof. Dr. Joaquim Celestino Júnior (UECE)
Coorientador: Prof. Dr. Alisson Barbosa de Souza (UFC)

29 de maio de 2026

1. Introdução e Motivação
2. Proposta
3. Metodologia e Proposta
4. Resultados e Análise
5. Conclusões e Cronograma
6. Referências

Sistemas Inteligentes de Transporte (ITS)

- **Objetivo:** Uso inteligente e coordenado da infraestrutura de rede.
- **Benefícios:** Trânsito mais seguro, usuários bem informados e economia de tempo, dinheiro e combustível.



Demandas e Perfis de Aplicação

- **Exemplos:** Direção autônoma, Realidade Aumentada (AR) e visão computacional.
- **Perfil Crítico:** Tarefas com **poucos bytes** de entrada, mas com **altíssima complexidade** de cálculo, exigindo muitos ciclos de CPU e alto gasto energético.



O Gargalo da Computação Local

- **Restrições:** As Unidades de Bordo (OBUs) possuem restrições físicas (bateria, dissipação térmica e CPU).
- **Consequência:** A computação puramente local não consegue atender aos requisitos de tempo, gerando falhas.



A viabilização do ITS depende também da superação das limitações computacionais locais.

Heterogeneidade e Cooperação


- **Capacidades:** As OBUs possuem hardware e níveis de bateria distintos.
- **Compartilhamento:** Veículos vizinhos podem ceder recursos ociosos.

A Estratégia de Offloading

Essencial para superar gargalos locais de processamento em tarefas complexas e sensíveis ao atraso.

O Desafio da Não-estacionariedade

Decisão: Como e onde descarregar em topologias altamente dinâmicas e imprevisíveis (cargas e recursos variáveis)?



O descarregamento de tarefas é uma necessidade para viabilizar aplicações de ITS em tempo real.

TAREFA


D	Tamanho	$\sim 1.5 \text{ kB}$
C	Complexidade	10^8 CPU
τ	Prazo	$\leq 100 \text{ ms}$

Total (Full)

- Envio integral de uma única tarefa indivisível para o servidor.


Parcial

- Divisão da tarefa em múltiplas subtarefas ou lotes.



Limitações das Abordagens Tradicionais


- **Convergência:** Iterações excessivas (GA, PSO) podem violar prazos.
- **Baixa Adaptabilidade:** Cenários estáticos falham sob alta mobilidade, canal variante e não-estacionariedade.
- **Ótimos Locais:** Heurísticas gulosas (*Greedy*) falham na otimização global.
- **Custo Elevado:** Busca intensiva pode sobrecarregar os recursos da borda e/ou veículos.
- **Escalabilidade:** Sofrem com **explosão combinatória** com o aumento de veículos.



Em redes veiculares, uma decisão "ótima" que chega atrasada é, na prática, uma decisão inútil.

Características e Limitações do DRL em Redes Veiculares

- **Model-Free:** Aprende por tentativa e erro diretamente com o ambiente, dispensando modelagem matemática exata.
- **Inferência Rápida:** Decisões de descarregamento em milissegundos.
- **Não-estacionariedade:** Adapta-se a mudanças, mas pode exigir retreinamento.
- **Ótimos Locais:** Risco de convergência prematura para decisões subótimas.
- **Baixa Eficiência Amostral:** Podem exigir grandes volumes de dados para treino.



O DRL desloca o peso computacional para a fase de treinamento (offline), permitindo que a OBU tome decisões complexas de forma quase instantânea.

Como tomar decisões de descarregamento de tarefas, utilizando DRL, em redes VEC/V2X, com número variável de candidatos ao processamento, não-estacionariedade, de forma confiável e adaptativa, cumprindo restrições de prazo e minimizando latência e consumo energético, sem necessidade de retreinamento diante de variações na densidade veicular?

Características da Rede Veicular

Ref.	Tecnologia		Modo			Servidor			Simulador			Mob.	Obs. Parcial	Modelagem			Car. Trabalho Dinâmica
	5G	6G	V2I	V2V	I2I	MEC	VEC	Nuvem	Pers.	NS3	Outro	SUMO		Ruído	Ganho	Camadas	
[1]	✓	-	✓	-	-	-	✓	-	✓	-	-	-	-	✓	✓	-	-
[2]	-	-	✓	-	-	✓	-	✓	✓	-	-	-	-	-	-	-	-
[3]	-	-	✓	-	-	✓	-	-	✓	-	-	-	-	-	-	-	✓
[4]	✓	-	✓	-	-	✓	-	-	✓	-	-	-	-	-	-	-	-
[5]	-	-	✓	-	-	-	✓	-	✓	-	-	-	-	-	-	-	-
[6]	-	-	✓	✓	-	✓	-	-	✓	-	-	-	-	-	-	-	-
[7]	-	-	✓	-	-	-	✓	-	✓	-	-	-	-	✓	✓	-	-
[8]	-	-	✓	✓	-	-	✓	-	✓	-	-	-	-	✓	✓	-	-
TOLB [9]	-	-	✓	-	✓	✓	-	-	✓	-	-	-	-	✓	✓	-	-
SAC-FTOPSIS	✓	-	✓	✓	-	-	✓	-	-	✓	-	✓	✓	✓	✓	✓	✓

Parâmetros de Modelagem

Ref.	Alg. DRL	Desc.			Métricas			Estado
		Modo		Prazo	Energia	Latência	Outra	Invariante
		Total	Parcial					
[1]	DDQN	✓	-	✓	✓	✓	-	-
[2]	SAC	✓	-	✓	✓	✓	-	-
[3]	DQN	-	✓	✓	✓	✓	✓	-
[4]	SAC	-	-	-	-	-	-	-
[5]	DQN	✓	-	-	✓	✓	-	-
[6]	DDPG	✓	-	✓	✓	✓	-	-
[7]	PPO	✓	-	✓	-	-	-	-
[8]	MADDPG	-	✓	✓	✓	✓	-	-
TOLB [9]	TD3	-	✓	✓	✓	✓	-	-
Proposta	SAC	✓	-	✓	✓	✓	-	✓

Parâmetros de Modelagem (Cont.)

Ref.	Recompensa				Comparação			Ação		Model-Free	Off-Policy	Rep. Buf.
	Soma Pond.	GAP	EO	Outra	Heur.	DRL	Meta	Bin.	N-Ár.			
[1]	✓	-	-	-	✓	✓	-	-	✓	✓	✓	✓
[2]	✓	-	-	-	-	✓	-	-	✓	✓	✓	✓
[3]	-	-	✓	-	-	✓	-	-	✓	✓	✓	✓
[4]	-	-	-	-	✓	✓	-	-	✓	✓	✓	✓
[5]	✓	-	-	-	✓	✓	✓	-	✓	✓	✓	✓
[6]	-	-	-	-	-	✓	-	-	✓	✓	✓	✓
[7]	-	-	-	✓	✓	✓	✓	-	✓	✓	-	-
[8]	-	-	-	✓	✓	-	-	-	✓	✓	✓	✓
TOLB [9]	✓	-	✓	-	✓	✓	-	-	✓	✓	✓	✓
Proposta	-	✓	✓	-	✓	✓	-	✓	-	✓	✓	✓

Proposta

Processo de Decisão de Markov Parcialmente Observável (POMDP)

O problema é formulado rigorosamente como um **POMDP**, definido pela sétupla $(\mathcal{S}, \mathcal{A}, \Omega, \mathcal{P}, \mathcal{O}, \mathcal{R}, \gamma)$:

- $\mathcal{S}$ (**Estados**): Conjunto de estados reais e inobserváveis do ambiente.
- $\mathcal{A}$ (**Ações**): Conjunto de ações possíveis disponíveis para o agente.
- Ω (**Observações**): Conjunto de observações possíveis que o agente pode receber.
- $\mathcal{P}$ (**Transição**): $\mathcal{P}(s_{t+1} | s_t, a_t)$. Dinâmica de transição de estados do ambiente.
- $\mathcal{O}$ (**Observação**): $\mathcal{O}(o_t | s_t, a_{t-1})$. Probabilidade de receber a observação o_t no estado s_t .
- $\mathcal{R}$ (**Recompensa**): $\mathcal{R}(s_t, a_t)$. Retorno imediato recebido após executar uma ação.
- γ (**Desconto**): $\gamma \in [0, 1)$. Pondera a importância das recompensas futuras.

A formulação como POMDP justifica-se em cenários onde o agente não possui acesso total ou perfeito ao estado global do ambiente, tomando decisões com base em informações parciais ou com incerteza.

O objetivo do agente é **maximizar a taxa de tarefas concluídas dentro do prazo**, minimizando latência e energia.

$$\max_{\pi} J(\pi) = \mathbb{E}_{\pi} \left[\underbrace{w_s \cdot \mathbb{1}(\widehat{\text{JCT}}_t \leq D_t)}_{\text{taxa de sucesso}} - w_c \cdot \underbrace{\frac{1}{2} \left(\frac{\widehat{\text{JCT}}_t}{\text{JCT}_t^{\max}} + \frac{E_t}{E_t^{\max}} \right)}_{\text{custo normalizado} \in [0,1]} \right] \quad (1)$$

$$\text{JCT}_t^{\max} = \max(\widehat{\text{JCT}}_t^{\ell}, \widehat{\text{JCT}}_t^{\text{vec}} \cdot \mathbb{1}_{\text{viável}}, \widehat{\text{JCT}}_t^{\text{v2v}} \cdot \mathbb{1}_{\text{viável}}) \quad (2)$$

$$E_t^{\max} = \max(E_t^{\ell}, E_t^{\text{vec}} \cdot \mathbb{1}_{\text{viável}}, E_t^{\text{v2v}} \cdot \mathbb{1}_{\text{viável}}) \quad (3)$$

Tabela de Vizinhança

Nó 1 (Tipo: Veículo, Freq: 1.0 GHz, Dist: 50m, Fila: 3)

Nó 2 (Tipo: Edge, Freq: 4.0 GHz, Dist: 10m, Fila: 1)

⋮

Nó n (Tipo, Freq, Dist, Fila)

Dinâmica da Tabela de Vizinhança:

- Montada periodicamente via recepção de características dos dispositivos vizinhos.
- Cada nó possui um **TTL** (*Time-to-Live*).
- Sem *refresh* (ex: Nó 1) dentro do limite, o dispositivo é removido.


Funcionamento do Ranqueamento:

- Realizado em função da **tarefa** a ser processada (requisitos de CPU, latência, etc.).
- Baseia-se nas **características (multicritério)** dos nós candidatos da vizinhança.

Ranqueamento - TOPSIS/Fuzzy-TOPSIS

Rank 1

$$S_t = \left[\Delta_{obj} \quad \frac{\widehat{JCT}^\ell}{D} \quad \frac{\widehat{JCT}^{r1}}{D} \quad \frac{|Q^{r1}|}{Q_{\max}} \quad \frac{|Q^\ell|}{Q_{\max}} \quad \frac{C}{C_{\max}} \right]$$




Problema

- A alta mobilidade e atenuações do canal causam oscilações nas estimativas de estado (latência, distância, filas etc).
- Avaliar candidatos usando métricas brutas e instáveis pode provocar inversões na ordem de preferência dos nós candidatos, dificultando o aprendizado do agente.


Solução: Atenuação de Ruído

- Valores numéricos ruidosos são mapeados em Números Fuzzy Triangulares (ex: "Baixo", "Médio") [10], absorvendo pequenas flutuações e incertezas do ambiente, deixando o ranqueamento estável.




$$r_t = \begin{cases} 1,0 - \frac{1}{4} \left(\frac{JCT_t}{D_t} + \frac{E_t}{E_t^{\max}} \right), & \text{se } JCT_t \leq D_t \text{ (Sucesso)} \\ -1,0 - \min \left(1,0, \frac{JCT_t - D_t}{D_t} \right), & \text{se } JCT_t > D_t \text{ (Falha)} \end{cases}$$

$$E_t^{\max} = \max(E_t^{\ell}, E_t^{\text{vec}} \cdot \mathbb{1}_{\text{viável}}, E_t^{\text{v2v}} \cdot \mathbb{1}_{\text{viável}}) \quad (4)$$




Treinamento do Modelo (Offline)



Resultados Preliminares

Perfil da Aplicação

- **Natureza:** Tarefas indivisíveis com **alta complexidade** computacional.
- **Carga:** Poucos bytes, mas cálculo pesado (CPU intensiva).
- **Prazos:** Curtos ($\leq 100\text{ms}$). Transmissão e processamento rápidos.
- **Exemplo:** Controle de veículo autônomo.
- **Exemplo:** 658 Cenários diferentes.



SAC-Base 4,5 %

Referência sem otimizações.
Estado (11D bruto):
 $C_t, D_t, d_{VEC}, f_{dyfs}, Q_{VEC}, T_{cpu}$
 $f_{loc}, Q_{loc}, f_{V2V}, Q_{V2V}, d_{V2V}$
Ação: Ternária {Loc, VEC, V2V}
Recompensa (WSM):
 $r = 2(1 - \bar{x}_a) - 1$
critérios: JCT, Energia, Fila
94,9 % V2V $\Rightarrow$ colapso.

+24,2 pp

SAC-S1 28,7 %

Avalia: compressão do estado.
Estado: $\oplus$ 6D normalizado
 $C/c_{max}, J\hat{C}T_{loc}/D, d_{VEC}/d_{max}$
 $Q_{VEC}/Q_{max}, Q_{loc}/Q_{max}, f_{loc}/f_{VEC}$
(sem info V2V no estado)
Ação: = Base (Ternária)
Recompensa: = Base (WSM)
Maior ganho isolado: +24pp.

+4,3 pp

SAC-T1 33,0 %

Avalia: TOPSIS como feature.
Estado: $\oplus$ 6D via TOPSIS
 $\Delta_{obj}, JCT_{r_1}/D, d_{VEC}/d_{max}$
 $Q_{VEC}/Q_{max}, Q_{loc}/Q_{max}, f_{loc}/f_{VEC}$
Ação: = SAC (Ternária)
Recompensa: $\oplus$ DL-aware
Feature TOPSIS +4pp.
Decisor TOPSIS +12pp.

+34,6 pp

SAC-A1 39,1 %

Avalia: efeito da ação binária.
Estado: = Base (11D bruto)
Ação: $\oplus$ Binária {Loc, Off}
destino: VEC > V2V (estático)
Recompensa: = Base (WSM)
Reduz espaço +34pp, mas destino sem critério dinâmico.

+33,8 pp

SAC-R1 38,3 %

Avalia: sinal de recompensa.
Estado: = Base (11D bruto)
Ação: = Base (Ternária)
Recompensa: $\oplus$ DL-aware
Sucesso: [0,5; 1,0] / Falha: [-2; -1]
(proporcional ao excesso)
Poderosa isolada; marginal com estado rico (+4pp).

+12,2 pp

SAC-TOPSIS 45,2 %

Proposta intermediária completa.
Estado: = T1 (6D TOPSIS)
Ação: $\oplus$ Binária {Loc, rank₁}
TOPSIS escolhe VEC ou V2V (elimina ambiguidade)
Recompensa: = T1 (DL-aware)
SWQ 0,1484; JCT 8,6x < Base.

Política	Categoria	% Sucesso	SWQ	JCT (s)	% Local
SAC-TOPSIS *	DRL+TOPSIS	45,21	0,1484	6,547	74,1
PPO-TOPSIS *	DRL+TOPSIS	42,66	0,1426	5,895	98,7
TD3-TOPSIS *	DRL+TOPSIS	43,91	0,1388	3,703	76,5
A2C-TOPSIS *	DRL+TOPSIS	42,32	0,1418	6,045	100,0
Greedy-Unfair (Oráculo)	Heurística	41,29	0,1262	5,613	67,3
Gini	Heurística	35,24	0,1057	3,456	61,7
Random	Heurística	30,02	0,0950	17,853	40,7
Greedy-Fair	Heurística	20,61	0,0528	40,754	27,9
Apenas VEC	Heurística	1,86	0,0030	144,191	1,2

- **Desempenho:** Algoritmos híbridos superaram as heurísticas clássicas e o oráculo guloso.
 - **Liderança:** O **SAC-TOPSIS** mantém a maior taxa de sucesso geral (45,21 %).
- **Observação:** A estratégia local-dominante (PPO/A2C) minimiza latência, mas sacrifica oportunidades de offloading que o SAC aproveita.

* utiliza ranqueamento multicritério TOPSIS para pré-seleção de alvos de descarregamento.

- **Arquitetura SAC-TOPSIS:** Integração eficaz entre ranqueamento multicritério (TOPSIS) e Aprendizado por Reforço (SAC).
 - **Escalabilidade:** O estado compacto 6D resolve o problema de número variável de veículos candidatos, garantindo uma interface invariante.
 - **Contribuições Técnicas:**
 - Engenharia de recompensa *deadline-aware* com foco em prazos rigorosos.
 - Redução de 8,6x no JCT médio em comparação ao SAC-Base.
 - Superação da heurística oráculo (*Greedy-Unfair*) em cenários reais.
 - **Métrica SWQ:** Nova métrica que pondera sucesso e folga temporal, provando-se superior à taxa de sucesso simples para avaliação de QoS.
- **Resumo:** A proposta demonstrou ser uma solução leve e adaptativa, capaz de operar em ambientes veiculares dinâmicos sem necessidade de retreinamento.

Evolução do Algoritmo

- **Integração do Fuzzy-TOPSIS:** Substituição do módulo clássico para incorporar incertezas e imprecisões nas medições da rede via Números Fuzzy Triangulares (TFNs).
- **Protocolo Estendido:** Expansão do protocolo de treinamento do agente DRL para múltiplos cenários e diferentes regimes dinâmicos de carga.

Validação e Simulação Realista

- **Simulação ns-3/SUMO:** Avaliação em ambiente de rede de eventos discretos completo, superando a simplificação atual de "canal perfeito".

Atividade / Ano	2026		2027		2028
	S1	S2	S1	S2	Q1
1. Exame de Qualificação	X				
2. Integração com Simulador (ns-3/SUMO)	X	X			
3. Refinamento de Algoritmos	X	X	X		
4. Avaliação de Desempenho		X	X		
5. Análise dos Resultados			X	X	
6. Escrita da Tese Final				X	X
7. Defesa Final					X

Legenda: S1: 1º semestre; S2: 2º semestre; Q1: 1º trimestre de 2028.

-  K. Moghaddasi, S. Rajabi, F. Soleimani Gharehchopogh, and M. Hosseinzadeh, “An energy-efficient data offloading strategy for 5g-enabled vehicular edge computing networks using double deep q-network,” *Wireless Personal Communications*, vol. 133, pp. 2019–2064, 12 2023.
-  S. L. Sidwini, S. Rout, H. K. Patnaik, B. B. Dash, U. C. De, and S. S. Patra, “Task offloading in edge computing: Energy optimization through sac based reinforcement learning,” 2024. Preprint / Anais de Conferência.
-  X. Li, Y. Pu, C. Yan, W. Duan, and X. Zhang, “Computation offloading and association in mec-assisted v2x network for delay minimization and collision avoidance via deep q-network,” *Discover Computing*, vol. 28, no. 302, 2025.

-  Y. Meghamala, P. J. Paul, and M. A. Kumar, “A multi-agent deep reinforcement learning framework for mec resource allocation in 5g networks,” *Electrical and Electronics Research (IJEER)*, vol. 13, no. 4, pp. 909–919, 2025.
-  L. Zhao, X. Dong, A. Hawbani, Y. Bi, Q. He, and Z. Liu, “Optimizing task offloading in vec: A pdqkm scheme combining deep reinforcement learning and kuhn-munkres matching,” *IEEE Transactions on Intelligent Transportation Systems*, 2025.
-  A. A. S. Mohammad, S. I. S. Al-Hawary, A. Hindieh, A. Vasudevan, H. M. Al-Shorman, A. S. Al-Adwan, M. T. Alshurideh, and I. Ali, “Intelligent data-driven task offloading framework for internet of vehicles using edge computing and reinforcement learning,” *Data and Metadata*, vol. 4, p. 521, 2025.

-  Y. Xie *et al.*, “Efficient task offloading in double roadside ris-assisted vehicular edge computing networks using deep reinforcement learning,” *IEEE Transactions on Intelligent Transportation Systems*, Aug 2025.
-  H. Wu, A. Gu, and Y. Liang, “Federated reinforcement learning-empowered task offloading for large models in vehicular edge computing,” *IEEE Transactions on Vehicular Technology*, vol. 74, no. 2, pp. 1979–1991, 2025.
-  Z. Wu, Z. Jia, X. Pang, and S. Zhao, “Deep reinforcement learning-based task offloading and load balancing for vehicular edge computing,” *Electronics*, vol. 13, p. 1511, 2024.
-  A. S. d. S. Vieira, A. B. de Souza, and J. C. Júnior, “Foff: An energy-efficient task offloading in vec-enabled vehicular networks using fuzzy topsis,” *Cluster Computing*, vol. 28, no. 13, p. 822, 2025.

DOUTORADO EM CIÊNCIA DA COMPUTAÇÃO

SAC-FTOPSIS: Um Modelo de Decisão para o Descarregamento de Tarefas em Redes Veiculares

Antônio Sérgio de Sousa Vieira

sergio.vieira@ifce.edu.br

sergio.vieira@aluno.uece.br

Orientador: Prof. Dr. Joaquim Celestino Júnior (UECE)
Coorientador: Prof. Dr. Alisson Barbosa de Souza (UFC)

29 de maio de 2026