UNIVERSIDADE ESTADUAL DO CEARÁ
CENTRO DE CIÊNCIAS E TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO
DOUTORADO EM CIÊNCIA DA COMPUTAÇÃO

ANTÔNIO SÉRGIO DE SOUSA VIEIRA

MODELO DE DECISÃO BASEADO EM LÓGICA FUZZY E APRENDIZADO POR REFORÇO PROFUNDO PARA O OFFLOADING DE TAREFAS EM REDES VEICULARES 5G

FORTALEZA – CEARÁ
2026

ANTÔNIO SÉRGIO DE SOUSA VIEIRA

MODELO DE DECISÃO BASEADO EM LÓGICA FUZZY E APRENDIZADO POR REFORÇO PROFUNDO PARA O OFFLOADING DE TAREFAS EM REDES VEICULARES 5G

Proposta de qualificação apresentada ao Curso de Doutorado em Ciência da Computação do Programa de Pós-Graduação em Ciência da Computação do Centro de Ciências e Tecnologia da Universidade Estadual do Ceará, como requisito parcial para a defesa de tese.
Orientador: Dr. Joaquim Celestino Júnior

FORTALEZA – CEARÁ

2026

ANTÔNIO SÉRGIO DE SOUSA VIEIRA

MODELO DE DECISÃO BASEADO EM LÓGICA FUZZY E APRENDIZADO POR REFORÇO PROFUNDO PARA O OFFLOADING DE TAREFAS EM REDES VEICULARES 5G

Proposta de qualificação apresentada ao Curso de Doutorado em Ciência da Computação do Programa de Pós-Graduação em Ciência da Computação do Centro de Ciências e Tecnologia da Universidade Estadual do Ceará, como requisito parcial para a defesa de tese.

Aprovada em:

BANCA EXAMINADORA

Dr. Joaquim Celestino Júnior (Orientador)
Universidade Estadual do Ceará – UECE

Membro da Banca Dois
Universidade do Membro da Banca Dois - SIGLA

Membro da Banca Três
Universidade do Membro da Banca Três - SIGLA

Membro da Banca Quatro
Universidade do Membro da Banca Quatro - SIGLA

Membro da Banca Cinco
Universidade do Membro da Banca Cinco - SIGLA

Membro da Banca Seis
Universidade do Membro da Banca Seis - SIGLA

RESUMO

O crescimento exponencial de dispositivos conectados e a emergência das redes veiculares 5G (V2X) têm impulsionado a necessidade de soluções eficientes de processamento distribuído, especialmente em cenários de *vehicular edge computing* (VEC). O desafio central reside em como decidir, de forma dinâmica e adaptativa, quando e onde descarregar tarefas computacionais. Este trabalho propõe um modelo híbrido que integra Lógica Fuzzy e Aprendizado por Reforço (Reinforcement Learning – RL) para otimizar o processo de descarregamento de tarefas em ambientes veiculares 5G. A Lógica Fuzzy é utilizada para modelar e quantificar as incertezas inerentes ao ambiente veicular (como qualidade do link, mobilidade e carga dos servidores de borda), transformando-as em indicadores de estado robustos. Esses indicadores são então utilizados como entrada para um agente de DRL, que aprende políticas adaptativas de alocação de tarefas visando maximizar uma função de recompensa multiobjetivo, focada em minimizar a latência fim-a-fim e o consumo energético. Os resultados esperados incluem um aprendizado mais estável e uma política de descarregamento mais eficiente em cenários densos e altamente móveis.

Palavras-chave: descarregamento de tarefas; reinforcement learning; fuzzy topsis; 5G; Rede Veicular.

ABSTRACT

In this on the radio waves: popular culture, peasants and the Basic Education Movement we analyze the participation of peasants of the Brazilian northeastern region in the Basic Education Movement. The focus of this thesis is to demonstrate how the labors involved with broadcast schools have elaborated actions for maintaining and spreading the schools in their communities, in order to achieve the necessary means to improve their way of life. Peasants of the Basic Education Movement have been coadjuvant of the modernizing catholic proposition of the early 1960s, by means of quite peculiar political and cultural representations. Some of these representations were: a meaning for the school, a role for the union and for the political participation, precepts of the land use rights and labor rights, and the multiple meanings of the radio as a mass communication, information and leisure medium. This study intends to stress that the actions – and the political enrollment – of the northeastern peasant could not ever be separated from the modernizing process. The connection can be observed in different social movements of the period, such as the Basic Education Movement, rural unions, the Catholic Agrarian Youth and the MCP. In this sense, we consider that, if the Brazilian modernization was a guideline for the institutions, political organisms and parties for the social movement, such a modernization was a guideline of demands based on elements of material life. Those elements included, by that time, the agrarian reform, the educational issue and labor urgencies.

Keywords: adult education; community schools; peasants; popular culture.

LISTA DE ILUSTRAÇÕES

Figura 1 – Formas de descarregamento de tarefas em VEC: total (*full*), parcial (*partial*) e adaptativo (*adaptive*), com seus trade-offs de confiabilidade e complexidade. 22

Figura 2 – Principais problemas inerentes ao descarregamento de tarefas veicular: mobilidade e instabilidade do enlace, heterogeneidade de recursos e filas, custos energéticos, incerteza de medições, dependência de tecnologias/protocolos e complexidade *NP-hard* sob restrições de latência e confiabilidade. 24

Figura 3 – Modelo de sistema básico 3GPP evidenciando os dois grandes blocos operacionais do 5G. 29

Figura 4 – Arquitetura Simplificada da Rede 5G (Plano de Controle e Usuário). . 30

Figura 5 – Conceito de Fatiamento de Rede (Network Slicing) baseado em NFV/SDN evidenciando o isolamento e parametrização por serviço. 31

Figura 6 – Integração do Computação de Borda de Múltiplos Acessos (*Multi-access Edge Computing*) (MEC) à rede Quinta Geração de Redes Móveis (*Fifth Generation*) (5G) distribuindo a função Função de Plano de Usuário (*User Plane Function*) (UPF) localmente visando reduzir a latência de tráfego sensível. 32

Figura 7 – Divisão funcional arquitetural da estação base Nó B de Próxima Geração (*Next-Generation Node B*) (gNB) nas unidades Unidade Central (*Central Unit*) (CU) e Unidade Distribuída (*Distributed Unit*) (DU), mostrando a alocação dos protocolos de rádio. 33

Figura 8 – Estrutura de implantação Não-Autônoma (Não-Autônomo (*Non-Standalone*) (NSA)) baseada no núcleo legado Núcleo de Pacotes Evoluído (*Evolved Packet Core*) (EPC), separando a controladora rádio *4G Long Term Evolution* (4G LTE) do nó secundário Nó B de NR para Acesso de Rádio Terrestre Universal Evoluído (*Evolved Universal Terrestrial Radio Access-New Radio Node B*) (en-gNB) (dividido em CU e DU). 34

Figura 9 – Estrutura de implantação Autônoma (Autônomo (*Standalone*) (SA)) ou Opção 2. O núcleo Núcleo 5G (*5G Core*) (5GC) conecta-se diretamente à estação base gNB via interface Interface de Próxima Geração (*Next Generation Interface*) (NG). 34

Figura 10 – Divisão conceitual do espectro de radiofrequência 5G Novo Rádio (*New Radio*) (NR) nas faixas Faixa de Frequência 1 (*Frequency Range 1*) (FR1) (Sub-6 GHz) e Faixa de Frequência 2 (*Frequency Range 2*) (FR2) (mmWave). 35

Figura 11 – Comparativo ilustrativo entre a arquitetura Quarta Geração de Redes Móveis (*Fourth Generation*) (4G) tradicional e o 5G *Massive* Múltiplas Entradas, Múltiplas Saídas (*Multiple-Input Multiple-Output*) (MIMO). À esquerda, nota-se a limitação dos painéis com poucos elementos e o desperdício de potência. À direita, aproveitando o diminuto comprimento de onda no FR2, o adensamento massivo de antenas gera uma altíssima resolução espacial, permitindo a conformação de feixes (*Beamforming*) eficientes e a multiplexação MIMO de Múltiplos Usuários (*Multi-User Multiple-Input Multiple-Output*) (MU-MIMO). 36

Figura 12 – Representação do Acesso Múltiplo por Divisão de Frequências Ortogonais (*Orthogonal Frequency-Division Multiple Access*) (OFDMA) no 5G: à esquerda, a estação base (gNB) distribui feixes dedicados a cada usuário; à direita, a grade bidimensional de tempo e frequência exibe como os Blocos de Recursos (Bloco de Recurso (*Resource Block*) (RB)) são alocados simultaneamente a diferentes Equipamento de Usuário (*User Equipment*) (UE). 37

Figura 13 – Numerologia escalável do 5G NR: a relação inversamente proporcional entre o espaçamento de subportadoras ($\Delta f = 15 \times 2^{\mu}$ kHz) e a duração útil do símbolo Multiplexação por Divisão de Frequências Ortogonais (*Orthogonal Frequency-Division Multiplexing*) (OFDM) ($T_u = 1/\Delta f$). Numerologias menores favorecem cobertura ampla, enquanto maiores reduzem latência. 38

Figura 14 – Efeito do multipercurso e da Interferência Inter-Simbólica (*Intersymbol Interference*) (ISI) em comunicações V2X. (a) Cenário urbano: o sinal da gNB chega ao veículo receptor pelo caminho direto (LOS, instante t_1) e por dois percursos refletidos (no prédio em t_2 e no solo em t_3), gerando um espalhamento de atraso $\tau_{DS} = t_3 - t_1$. (b) Domínio do tempo: o eco atrasado do Símbolo n invade a janela do Símbolo $n+1$, causando a zona hachurada de ISI. 39

Figura 15 – Mecanismo do Prefixo Cíclico (Prefixo Cíclico (*Cyclic Prefix*) (CP)) no 5G NR. Em (a), a porção final da parte útil do símbolo é copiada para seu início, parte (b), buscando proteger o sinal de interferências. 39

Figura 16 – Diagramas de constelação dos esquemas de modulação Modulação de Amplitude em Quadratura (*Quadrature Amplitude Modulation*) (QAM) utilizados no 5G NR. À medida que a ordem da modulação aumenta de (a) para (d), cada símbolo transporta mais bits, elevando a vazão, porém a maior densidade de pontos exige uma Relação Sinal-Interferência-e-Ruído (*Signal-to-Interference-plus-Noise Ratio*) (SINR) proporcionalmente superior para manter a taxa de erro aceitável. 40

Figura 17 – Arquitetura das comunicações 5G C-V2X: coexistência da interface celular Uu (V2I/V2N) com a interface direta PC5 *Sidelink* (V2V/V2P), integrando o núcleo 5GC, o servidor MEC de borda e os elementos veiculares e pedestres. 42

Figura 18 – Estrutura temporal básica da camada física em um *slot* do 5G NR *Sidelink*, ilustrando a multiplexação dos canais físicos PSCCH, PSSCH e PSFCH (COX, 2025; GARCIA; AL., 2021). 42

Figura 19 – Dinâmica sequencial de operação dos canais físicos PSCCH, PSSCH e PSFCH na interface PC5 do 5G NR *Sidelink*. A comunicação ocorre em três fases: anúncio de controle, transmissão de dados e confirmação de recepção. Em caso de falha (NACK), o ciclo de dados é repetido via retransmissão HARQ. 43

Figura 20 – Abstração do Ecossistema IoV: V2V, V2I, V2N e V2P em Cruzamento . 45

Figura 21 – Arquitetura de Protocolos DSRC / WAVE (IEEE 1609 / 802.11p) 46

Figura 22 – Arquitetura hierárquica em três camadas para computação em borda e nuvem. 48

Figura 23 – Fluxograma do processo decisório e ciclo de vida do descarregamento de tarefas. 49
Figura 24 – Ciclo básico de interação Agente-Ambiente no Aprendizado por Reforço (*Reinforcement Learning*) (RL). A cada passo, o agente observa o estado atual, escolhe uma ação, e o ambiente responde com uma recompensa e um novo estado. 51
Figura 25 – Sequência de interação em um Processo de Decisão de Markov (*Markov Decision Process*) (MDP). 52
Figura 26 – Dinâmica Ator-Crítico. 55
Figura 27 – Taxonomia adaptada para classificação dos trabalhos relacionados em descarregamento computacional veicular, com ênfase na modelagem de Aprendizado por Reforço Profundo (DRL) e ambiente de simulação. . . 57

LISTA DE TABELAS

Tabela 2 – Comparativo técnico da evolução V2X: do DSRC ao 6G 47
Tabela 3 – Resumo dos aspectos de Padrão de Comunicação, Servidor e Condições de Ambiente dos trabalhos relacionados 61
Tabela 4 – Classificação dos algoritmos clássicos de DRL quanto à adequação ao espaço de ação 65
Tabela 5 – Análise comparativa dos trabalhos relacionados por Função Objetivo, Estado, Recompensa e Ambiente Simulado 67

LISTA DE ALGORITMOS

LISTA DE CÓDIGOS-FONTES

LISTA DE ABREVIATURAS E SIGLAS

3GPP	*3rd Generation Partnership Project*
4G	Quarta Geração de Redes Móveis (*Fourth Generation*)
4G LTE	*4G Long Term Evolution*
5G	Quinta Geração de Redes Móveis (*Fifth Generation*)
5GC	Núcleo 5G (*5G Core*)
6G	Sexta Geração de Redes Móveis (*Sixth Generation*)
ADS	Sistemas de Condução Automatizada (*Automated Driving Systems*)
AMF	Função de Gerenciamento de Acesso e Mobilidade (*Access and Mobility Management Function*)
B5G	Além do 5G (*Beyond 5G*)
BER	Taxa de Erro de Bit (*Bit Error Rate*)
BS	Estação Base (*Base Station*)
C-MEC	Computação de Borda de Múltiplos Acessos Assistida por Nuvem (*Cloud-assisted Multi-access Edge Computing*)
C-V2X	*Cellular Vehicle-to-Everything*
CP	Prefixo Cíclico (*Cyclic Prefix*)
CTSRAO	Otimização de Alocação de Recursos e Divisão de Tarefas Nuvem-Terminal (*Cloud-Terminal Task Splitting and Resource Allocation Optimization*)
CU	Unidade Central (*Central Unit*)
CUPS	Separação do Plano de Controle e de Usuário (*Control and User Plane Separation*)
D2D	Dispositivo para Dispositivo (*Device-to-Device*)
D3QN	Rede Q Profunda Dupla com Dueling (*Dueling Double Deep Q-Network*)
DDPG	Gradiente de Política Determinístico Profundo (*Deep Deterministic Policy Gradient*)
DDQN	Redes Q-Deep Duplas (*Double Deep Q-Network*)
DN	Rede de Dados (*Data Network*)
DQN	Redes Q-Deep (*Deep Q-Network*)
DRL	Aprendizado por Reforço Profundo (*Deep Reinforcement Learning*)
DSRC	*Dedicated Short-Range Communications*

DSRC/IEEE	*Dedicated Short-Range Communications/Institute of Electrical and Electronics Engineers*
DT	Gêmeo Digital (*Digital Twin*)
DU	Unidade Distribuída (*Distributed Unit*)
eMBB	Banda Larga Móvel Melhorada (*enhanced Mobile Broadband*)
EN-DC	Conectividade Dupla E-UTRA-NR (*E-UTRA-NR Dual Connectivity*)
en-gNB	Nó B de NR para Acesso de Rádio Terrestre Universal Evoluído (*Evolved Universal Terrestrial Radio Access-New Radio Node B*)
eNodeB	Nó B Evoluído (*Evolved Node B*)
EPC	Núcleo de Pacotes Evoluído (*Evolved Packet Core*)
FL	Aprendizado Federado (*Federated Learning*)
FR1	Faixa de Frequência 1 (*Frequency Range 1*)
FR2	Faixa de Frequência 2 (*Frequency Range 2*)
GAN	Redes Adversárias Generativas (*Generative Adversarial Networks*)
gNB	Nó B de Próxima Geração (*Next-Generation Node B*)
GNN	Redes Neurais em Grafos (*Graph Neural Networks*)
HARQ	Solicitação de Repetição Automática Híbrida (*Hybrid Automatic Repeat Request*)
IA	Inteligência Artificial (*Artificial Intelligence*)
IoT	Internet das Coisas (*Internet of Things*)
IoV	Internet dos Veículos (*Internet of Vehicles*)
ISI	Interferência Inter-Simbólica (*Intersymbol Interference*)
ITS	Sistemas de Transporte Inteligentes (*Intelligent Transport Systems*)
ITU	União Internacional de Telecomunicações (*International Telecommunication Union*)
L-MADDPG	MADDPG com Otimização de Lyapunov (*Lyapunov-based Multi-Agent Deep Deterministic Policy Gradient*)
LLM	Grande Modelo de Linguagem (*Large Language Model*)
LTE	Evolução de Longo Prazo (*Long Term Evolution*)
LTE-Uu	Interface de Rádio LTE (*LTE Radio Interface*)
MAC	Controle de Acesso ao Meio (*Medium Access Control*)
MADDPG	Ator-Crítico Determinístico Profundo Multiagente (*Multi-Agent Deep Deterministic Policy Gradient*)
MARL	Aprendizado por Reforço Multiagente (*Multi-Agent Reinforcement Learning*)

MATD3	Multiagente Twin Delayed DDPG (*Multi-Agent Twin Delayed Deep Deterministic Policy Gradient*)
MCS	Esquema de Modulação e Codificação (*Modulation and Coding Scheme*)
MDP	Processo de Decisão de Markov (*Markov Decision Process*)
MEC	Computação de Borda de Múltiplos Acessos (*Multi-access Edge Computing*)
MIMO	Múltiplas Entradas, Múltiplas Saídas (*Multiple-Input Multiple-Output*)
ML	Aprendizado de Máquina (*Machine Learning*)
mMTC	Comunicações Massivas do Tipo Máquina (*Massive Machine Type Communications*)
mmWave	Ondas Milimétricas (*Millimeter Wave*)
MN	Nó Mestre (*Master Node*)
MU-MIMO	MIMO de Múltiplos Usuários (*Multi-User Multiple-Input Multiple-Output*)
NAS	Estrato de Não-Acesso (*Non-Access Stratum*)
NFV	Virtualização das Funções de Rede (*Network Functions Virtualization*)
NG	Interface de Próxima Geração (*Next Generation Interface*)
NG-RAN	Rede de Acesso por Rádio de Próxima Geração (*Next Generation Radio Access Network*)
NR	Novo Rádio (*New Radio*)
NR-Uu	Interface de Rádio NR (*NR Radio Interface*)
NS	Fatiamento de Rede (*Network Slicing*)
NSA	Não-Autônomo (*Non-Standalone*)
OBU	Unidade de Bordo (*On-Board Unit*)
OFDM	Multiplexação por Divisão de Frequências Ortogonais (*Orthogonal Frequency-Division Multiplexing*)
OFDMA	Acesso Múltiplo por Divisão de Frequências Ortogonais (*Orthogonal Frequency-Division Multiple Access*)
P-DQN	Rede Q Profunda Parametrizada (*Parametrized Deep Q-Network*)
PC5	Interface de Comunicação Direta PC5
PDCP	Protocolo de Convergência de Protocolo de Dados (*Packet Data Convergence Protocol*)
PDQKM	DQN Preditivo e Emparelhamento de Kuhn-Munkres (*Predictive DQN and Kuhn-Munkres scheme*)
PHY	Camada Física (*Physical Layer*)

POMDP	Processo de Decisão de Markov Parcialmente Observável (*Partially Observable Markov Decision Process*)
PPO	Otimização de Política Proximal (*Proximal Policy Optimization*)
PRB	Bloco de Recurso Físico (*Physical Resource Block*)
PSFCH	Canal Físico de Feedback do Sidelink (*Physical Sidelink Feedback Channel*)
PSO	Otimização por Enxame de Partículas (*Particle Swarm Optimization*)
QAM	Modulação de Amplitude em Quadratura (*Quadrature Amplitude Modulation*)
QDPG	Gradiente de Política com Q-Learning e DDPG (*Q-learning and Deep Deterministic Policy Gradient*)
QoS	Qualidade de Serviço (*Quality of Service*)
RB	Bloco de Recurso (*Resource Block*)
RBS	Estação Rádio Base (*Radio Base Station*)
RIS	Superfície Inteligente Reconfigurável (*Reconfigurable Intelligent Surface*)
RL	Aprendizado por Reforço (*Reinforcement Learning*)
RLC	Controle de Enlace de Rádio (*Radio Link Control*)
RLHF	Aprendizado por Reforço a partir de Feedback Humano (*Reinforcement Learning from Human Feedback*)
RRC	Controle de Recursos de Rádio (*Radio Resource Control*)
RSU	Unidade de Borda de Estrada (*Road Side Unit*)
S1-C	Interface do Plano de Controle S1 (*S1 Control Plane Interface*)
S1-U	Interface do Plano de Usuário S1 (*S1 User Plane Interface*)
SA	Autônomo (*Standalone*)
SAC	Ator-Crítico Suave (*Soft Actor-Critic*)
SBA	Arquitetura Baseada em Serviços (*Service Based Architecture*)
SCS	Espaçamento de Subportadoras (*Subcarrier Spacing*)
SDAP	Protocolo de Adaptação de Dados de Serviço (*Service Data Adaptation Protocol*)
SDN	Redes Definidas por Software (*Software-Defined Networking*)
SIDDPG	DDPG com Iteração de Estados Internos Sequenciais (*Sequential Internal-state Deep Deterministic Policy Gradient*)
SINR	Relação Sinal-Interferência-e-Ruído (*Signal-to-Interference-plus-Noise Ratio*)
SMF	Função de Gerenciamento de Sessão (*Session Management Function*)
SN	Nó Secundário (*Secondary Node*)
SOE	Eficiência Operacional do Sistema (*System Operation Efficiency*)

TD2PG	*Task Descriptor Policy Gradient*
TL	Aprendizado por Transferência (*Transfer Learning*)
UE	Equipamento de Usuário (*User Equipment*)
UPF	Função de Plano de Usuário (*User Plane Function*)
URLLC	Comunicações Ultraconfiáveis de Baixa Latência (*Ultra-Reliable Low-Latency Communications*)
Uu	Interface de Rádio Celular Uu
V2I	Veículo-para-Infraestrutura (*Vehicle-to-Infrastructure*)
V2N	Veículo-para-Rede (*Vehicle-to-Network*)
V2P	Veículo-para-Pedestre (*Vehicle-to-Pedestrian*)
V2V	Veículo-para-Veículo (*Vehicle-to-Vehicle*)
V2X	Veículo-para-Tudo (*Vehicle-to-Everything*)
VEC	Computação de Borda Veicular (*Vehicular Edge Computing*)
X2	Interface X2 (*X2 Interface*)

SUMÁRIO

1 INTRODUÇÃO 19
1.1 Contextualização 19
1.2 Motivação 21
1.3 Definição do Problema 21
1.4 Questões de Pesquisa 23
1.5 Hipóteses 24
1.6 Objetivos 25
1.6.1 Objetivo Geral 25
1.6.2 Objetivos Específicos 25
1.7 Contribuições Esperadas 26
1.8 Publicação 27
1.9 Organização do Trabalho 27
2 FUNDAMENTAÇÃO TEÓRICA 28
2.1 Arquitetura e Modelagem 5G V2I e C-V2X 28
2.2 A Internet de Veículos (IoV) e as Redes Veiculares 43
2.3 Descarregamento de Tarefas 47
2.4 Aprendizado por Reforço 50
2.4.1 Policy Gradients e REINFORCE 55
2.4.2 Actor-Critic, PPO, TRPO e SAC 55
2.4.3 Avanços e Extensões 56
2.5 Contexto 56
2.6 Considerações Finais 56
3 REVISÃO DE LITERATURA 57
3.1 Padrão de Comunicação 57
3.1.1 Tecnologia 58
3.1.2 Servidor 59
3.2 Problema 62
3.2.1 Estratégia 62
3.3 Considerações Finais 69
REFERÊNCIAS 70
GLOSSÁRIO 77

APÊNDICE A – LOREM IPSUM 78
APÊNDICE B – MODELO DE CAPA 79
APÊNDICE C – TERMO DE FIEL DEPOSITÁRIO 80
ANEXO A – EXEMPLO DE ANEXO 81
ANEXO B – DINÂMICA DAS CLASSES SOCIAIS 82
ÍNDICE 83

1 INTRODUÇÃO

Este capítulo apresenta uma visão geral do trabalho, descrevendo o contexto e os desafios que o motivaram (Seção 1.1 e Seção 1.2). A partir disso, formaliza-se o problema de pesquisa (Seção 1.3), as questões norteadoras (Seção 1.4) e as hipóteses elencadas (Seção 1.5). Por fim, são traçados os objetivos (Seção 1.6), as contribuições esperadas (Seção 1.7), as publicações decorrentes da pesquisa (Seção 1.8) e a forma como o documento está estruturado (Seção 1.9).

1.1 Contextualização

A convergência entre tecnologias de comunicação, eletrificação veicular e condução autônoma tem moldado um novo paradigma para o setor de transportes. O conceito de Internet de Veículos (IoV) transforma veículos em sistemas computacionais sofisticados, capazes de viabilizar diversas aplicações de Sistemas de Transporte Inteligentes (ITS) (RANI; SHARMA, 2023).

Veículos modernos são equipados com múltiplos sensores, unidades de processamento e interfaces de comunicação, permitindo a coleta e o processamento de grandes volumes de dados. Contudo, a complexidade das aplicações e a quantidade crescente de dados a serem processados podem exceder a capacidade computacional das unidades de bordo (*On-Board Unit* - OBU) instaladas.

Uma solução imediata seria aumentar a capacidade computacional dessas OBUs, possibilitando maior processamento local. No entanto, o atual período de transição tecnológica resulta em cenários heterogêneos, no qual coexistem OBUs com diferentes capacidades computacionais (LUO *et al.*, 2024) e distintas tecnologias de comunicação (ZHENG *et al.*, 2015). Essa diversidade representa um desafio fundamental para a implementação de aplicações veiculares em larga escala, especialmente no contexto das cidades inteligentes (*Smart Cities*) (LUO *et al.*, 2024).

Nesse ambiente fortemente dinâmico e caótico, muitas aplicações, em particular aquelas voltadas à condução autônoma, impõem requisitos rigorosos de latência (HE *et al.*, 2025). A execução integral do processamento nos dispositivos terminais (*User Equipments* – UEs) frequentemente inviabiliza o atendimento a tais requisitos, devido às limitações físicas de energia e capacidade computacional dos chips embarcados (LUO *et al.*, 2024).

Para superar essas restrições, destaca-se a Computação Veicular de Borda (*Vehicular*

Edge Computing – VEC), um paradigma onde servidores computacionalmente robustos são posicionados próximos aos veículos, reduzindo de forma significativa a latência de processamento (LIU *et al.*, 2021). Tecnologias relacionadas, como a Computação em Nuvem Veicular (*Vehicular Cloud Computing* – VCC) (WHAIDUZZAMAN *et al.*, 2014) e a Computação em Névoa Veicular (*Vehicular Fog Computing* – VFC) (KESHARI; SINGH; MAURYA, 2022), ampliam o escopo do processamento distribuído, oferecendo suporte adicional em diferentes níveis de proximidade e escalabilidade.

O descarregamento de tarefas surge como o mecanismo central para operacionalizar a comunicação e o processamento colaborativo entre veículos e essas arquiteturas distribuídas. Essa técnica consiste em migrar tarefas computacionais para nós mais capazes, como servidores de borda ou outros veículos com maior poder de processamento (WANG *et al.*, 2022). Dessa forma, veículos com recursos limitados conseguem executar aplicações complexas, aproveitando melhor a infraestrutura distribuída disponível na rede.

O principal desafio, entretanto, está em decidir quando e para onde descarregar as tarefas, considerando múltiplos fatores conflitantes, como tempo limite de processamento, custo energético, balanceamento de carga e qualidade do enlace de comunicação. Abordagens determinísticas, baseadas exclusivamente em heurísticas, apresentam desempenho limitado diante da alta variabilidade espacial e temporal do ambiente veicular (AHMED *et al.*, 2022). Mobilidade intensa, flutuações do canal e mudanças abruptas na carga computacional tornam as decisões estáticas rapidamente obsoletas, comprometendo a eficiência do sistema.

Essa limitação tem impulsionado a busca por soluções adaptativas e mais robustas, baseadas em aprendizado de máquina e sistemas inteligentes (MAO *et al.*, 2017; ZHANG *et al.*, 2018; ZHOU *et al.*, 2019; HUANG *et al.*, 2020; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024). Diante desse cenário, este trabalho propõe um modelo híbrido para o descarregamento de tarefas que integra técnicas de aprendizado de máquina (ML) e lógica fuzzy. Essa abordagem combina a capacidade do ML de capturar padrões dinâmicos e realizar decisões adaptativas com a habilidade da lógica fuzzy de lidar com incertezas e valores imprecisos do ambiente veicular, oferecendo um mecanismo mais flexível e eficaz para tomada de decisão em tempo real.

1.2 Motivação

1.3 Definição do Problema

Diante das limitações de processamento local e da elevada variabilidade do ambiente veicular, o problema central investigado neste trabalho pode ser formulado da seguinte maneira:

> **Como realizar o descarregamento de tarefas em sistemas de Computação Veicular de Borda (VEC) ou em outros dispositivos veiculares de modo confiável e adaptativo, garantindo redução no tempo de execução, diminuição do consumo energético e adequado balanceamento de carga entre os nós disponíveis?**

Estudos recentes reforçam que a alta mobilidade, a intermitência dos enlaces e a heterogeneidade de recursos tornam esse desafio ainda mais complexo (LIU *et al.*, 2021; MAO *et al.*, 2017; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024).

Para delimitar o escopo da solução proposta, é importante destacar que o problema de descarregamento de tarefas, em sua essência, configura-se como um problema de otimização *NP-hard* (MAO *et al.*, 2017; WANG *et al.*, 2017). Isso implica que soluções exatas em tempo polinomial são inviáveis para cenários dinâmicos como o veicular, o que direciona a busca por métodos de baixa complexidade computacional e boa capacidade de adaptação.

Outro aspecto importante refere-se a maneira na qual o descarregamento é realizado, podendo ser classificado em três categorias principais: descarregamento total (*full offloading*), descarregamento parcial (*partial offloading*) e descarregamento adaptativo (*adaptive offloading*) (WANG *et al.*, 2022) como pode ser observado na Figura 1. Cada abordagem apresenta vantagens e desvantagens específicas, influenciando diretamente a formulação do problema e as estratégias de solução adotadas.

Nesse contexto, a literatura apresenta diversas abordagens para modelar e melhorar a tomada de decisão de descarregamento de tarefas, por exemplo: programação linear e inteira para cenários de Computação de de Borda Multiacesso (*Multi-access Edge Computing* - MEC) (KHAN *et al.*, 2020), meta-heurísticas como algoritmos genéticos (LI; ZHU, 2020), PSO (YOU; TANG, 2021) e colônia de formigas (KISHOR; CHAKARBARTY, 2022) para problemas de grande escala, além de abordagens baseadas em aprendizado de máquina e aprendizado por reforço profundo, adequadas para ambientes altamente variáveis e parcialmente observáveis (HUANG *et al.*, 2020; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024).

Figura 1 – Formas de descarregamento de tarefas em VEC: total (*full*), parcial (*partial*) e adaptativo (*adaptive*), com seus trade-offs de confiabilidade e complexidade.

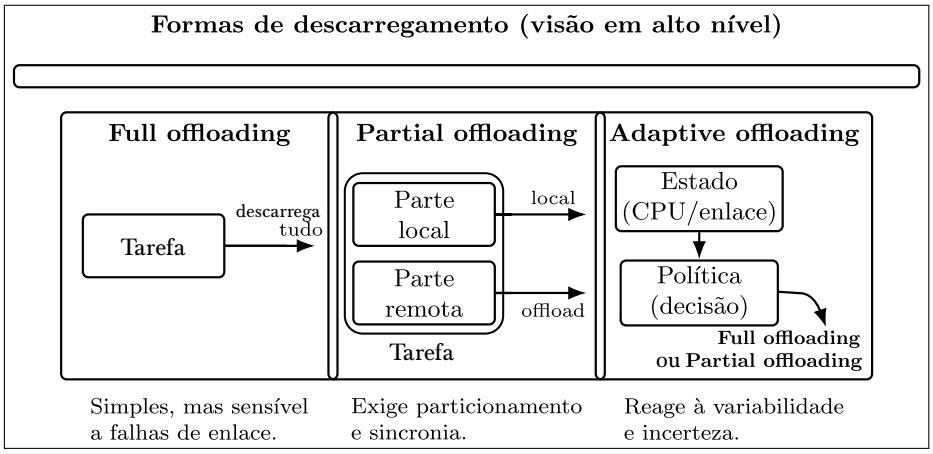

Fonte**:** Elaborado pelo autor

Outra consideração fundamental diz respeito à modelagem do ambiente veicular. Cada solução proposta na literatura assume combinações específicas de tecnologias de comunicação, capacidades computacionais e modelos de consumo energético, o que impacta diretamente a forma como o problema é otimizado (LIU *et al.*, 2021). Além disso, deve-se definir se o descarregamento será realizado apenas para servidores de borda, para veículos vizinhos (descarregamento colaborativo) ou para ambos, como no paradigma de *Vehicular Fog Computing* (*VFC*) (KESHARI; SINGH; MAURYA, 2022). Essa escolha é influenciada pela disponibilidade de recursos, pelo perfil da aplicação e pela estabilidade dos enlaces, variando conforme o cenário de estudo.

A mobilidade veicular constitui outro elemento crítico. Diferentes cenários, como os urbanos, suburbanos e rodoviários, apresentam padrões distintos de flutuação do canal, densidade de veículos e comportamento do tráfego. Em áreas urbanas, fatores como congestionamentos, presença de pedestres, ônibus e motocicletas podem alterar significativamente a dinâmica da conectividade e, consequentemente, as estratégias de descarregamento (HE *et al.*, 2025; LUO *et al.*, 2024). Tais aspectos precisam ser considerados para que a tomada de decisão seja realista e eficaz.

A viabilização do processo de decisão depende de mecanismos eficientes de comunicação e descoberta de recursos. Neste trabalho, assume-se comunicação via 5G NR (*Fifth-Generation Wireless Technology NewRadio*) entre os veículos e os servidores de borda, e comunicação V2X (*Vehicle-to-Everything*) entre os veículos, alinhado às diretrizes das arquiteturas 3GPP Release 16/17 (3GPP, 2022). Além disso, protocolos de descoberta e anúncios

de recursos são necessários para que os veículos obtenham informações sobre capacidade de CPU, características relacionadas ao estado energético e qualidade do enlace dos dispositivos vizinhos (ZHOU *et al.*, 2019; LIU *et al.*, 2021).

Outro ponto essencial refere-se ao perfil das aplicações beneficiadas pelo descarregamento. A popularização de hardware embarcado mais poderoso em OBUs permite o processamento local de aplicações leves; contudo, aplicações com baixa carga de dados, mas com alta demanda computacional, como visão computacional, detecção de objetos, fusão sensorial, criptografia e algoritmos de navegação autônoma, são candidatas naturais ao descarregamento (SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024). Para evitar latências excessivas, é necessário equilibrar o custo de transmissão com o ganho de processamento externo, preservando as restrições temporais impostas pela aplicação.

Somente após a coleta e integração dessas informações é possível realizar a tomada de decisão sobre o descarregamento. Essa decisão deve considerar a incerteza inerente às medições, a rápida variação do ambiente e a necessidade de minimizar falhas. Assim, soluções adaptativas baseadas em aprendizado de máquina, reforço profundo ou lógica fuzzy têm sido exploradas como alternativas promissoras para lidar com a incerteza, o dinamismo e a complexidade dos cenários veiculares (HUANG *et al.*, 2020; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024).

De forma geral pode-se resumir os problemas enfrentados através da Figura 2 onde uma decisão de descarregamento de tarefa deve considerar o cenário observado, as tecnologias de comunicação empregadas, as aplicações utilizadas, a incerteza do ambiente, o custo e o objetivo buscado.

1.4 Questões de Pesquisa

Este trabalho busca responder às seguintes questões de pesquisa, formuladas a partir das limitações inerentes ao ambiente veicular, da complexidade do problema de descarregamento de tarefas e da necessidade de garantir confiabilidade, eficiência energética e baixa latência em sistemas VEC/V2X:

QP1. Como realizar o descarregamento de tarefas em ambientes VEC/V2X de maneira confiável e adaptativa, considerando a alta variabilidade da mobilidade veicular, do canal de comunicação e da carga computacional?

QP2. De que forma modelos híbridos, combinando aprendizado de máquina e lógica fuzzy, podem melhorar a tomada de decisão de descarregamento de

Figura 2 – Principais problemas inerentes ao descarregamento de tarefas veicular: mobilidade e instabilidade do enlace, heterogeneidade de recursos e filas, custos energéticos, incerteza de medições, dependência de tecnologias/protocolos e complexidade *NP-hard* sob restrições de latência e confiabilidade.

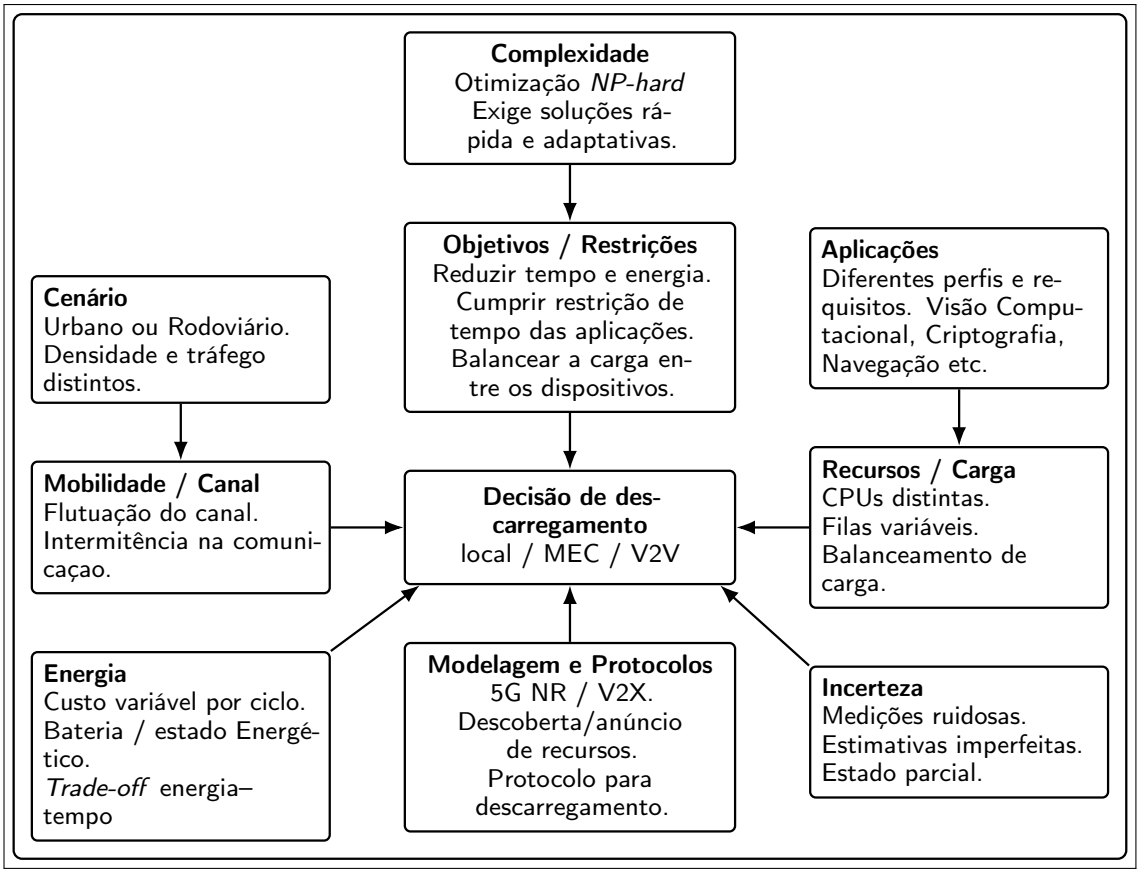

Fonte**:** Elaborado pelo autor

tarefas em cenários veiculares dinâmicos, mitigando incertezas na coleta de informação e na predição do estado futuro da rede?

QP3. Quais são os impactos do uso conjunto de comunicação 5G NR e V2X no desempenho do descarregamento de tarefas, especialmente na redução da latência, no consumo energético e na taxa de falhas de descarregamento?

QP4. Como diferentes perfis de aplicação veicular, especialmente aquelas com baixa carga de dados e alta demanda computacional, influenciam a decisão de quando, para onde e quanto descarregar, considerando limites de latência, balanceamento de carga e consumo energético?

1.5 Hipóteses

A partir das questões acima e da fundamentação teórica apresentada, formulam-se as seguintes hipóteses de pesquisa:

H1. A integração de aprendizado de máquina com lógica fuzzy é capaz de produzir um modelo de decisão adaptativo que supera métodos puramente determinísticos ou heurísticos em cenários VEC/V2X altamente dinâmicos.

H2. O uso de modelos híbridos reduz o impacto das incertezas inerentes à mobilidade veicular, permitindo estimar de forma mais robusta o melhor destino para o descarregamento de tarefas.

H3. A utilização conjunta de 5G NR e V2X proporciona atendimento as requisitos das aplicações mais estáveis e de menor latência, aumentando a confiabilidade do descarregamento e reduzindo a probabilidade de falhas decorrentes de desconexões súbitas.

H4. Aplicações com baixa carga de dados e alta demanda computacional apresentam o maior ganho com o descarregamento, desde que o modelo consiga estimar adequadamente o custo energético e o impacto na latência de processamento.

1.6 Objetivos

1.6.1 Objetivo Geral

Desenvolver e avaliar um modelo híbrido de decisão, baseado na integração da lógica fuzzy com o aprendizado por reforço, para otimizar o descarregamento de tarefas multiobjetivo em redes veiculares 5G NR (VEC/V2X).

1.6.2 Objetivos Específicos

OE1. Realizar uma revisão sistemática de algoritmos de descarregamento de tarefas em cenários VEC, focando em abordagens de DRL e Lógica Fuzzy.

OE2. Modelar as incertezas do ambiente veicular (ex: qualidade do link, carga do servidor, mobilidade) usando Lógica Fuzzy, projetando funções de pertinência e regras de inferência para gerar indicadores de estado robustos.

OE3. Desenvolver um agente Híbrido Fuzzy-RL que utilize os indicadores fuzzy gerados como parte de seu vetor de estado, e que aprenda uma política de descarregamento para otimizar uma função de recompensa que equilibre latência, balanceamento de carga, taxa de sucesso no descarregamento e

consumo energético.

OE4. Validar a arquitetura híbrida proposta em ambiente de simulação (NS-3), comparando seu desempenho (latência fim-a-fim, consumo de energia e taxa de sucesso no descarregamento) com algoritmos de DRL puros (não-fuzzy) e heurísticas tradicionais.

1.7 Contribuições Esperadas

Espera-se que este trabalho produza contribuições relevantes tanto do ponto de vista científico quanto do ponto de vista prático, sobretudo no contexto de sistemas veiculares inteligentes e computação de borda. As principais contribuições previstas são:

CE1. Proposição de um modelo híbrido para descarregamento de tarefas em ambientes veiculares, integrando técnicas de aprendizado de máquina com lógica fuzzy. O modelo pretende oferecer uma tomada de decisão mais robusta e adaptativa do que abordagens puramente determinísticas ou exclusivamente baseadas em ML, sobretudo em cenários com forte incerteza e alta mobilidade.

CE2. Modelagem detalhada do ambiente de comunicação e processamento veicular, incluindo enlaces 5G NR (com alinhamento às diretrizes do 3GPP Release 17), comunicação V2X sidelink, parâmetros de mobilidade e heterogeneidade computacional entre veículos e servidores de borda. Essa modelagem fornece uma plataforma de simulação realista para decisões de descarregamento.

CE3. Desenvolvimento de um módulo fuzzy para tratamento de incertezas e valores imprecisos, voltado para critérios críticos como latência, energia, estabilidade do canal e carga computacional. O módulo fuzzy será integrado ao sistema de decisão, auxiliando na suavização das transições e na prevenção de falhas abruptas.

CE4. Construção e avaliação de um mecanismo de aprendizado por reforço capaz de identificar padrões dinâmicos e otimizar a ação de descarregamento em tempo real.

CE5. Implementação do modelo completo em ambiente ns-3 (versão 3.42), utilizando o 5G-LENA e o suporte ao V2X, permitindo avaliar de forma rigorosa

métricas como latência, taxa de sucesso, consumo energético, throughput e eficiência do uso do canal.

CE6. Comparação sistemática com métodos de referência da literatura, incluindo heurísticas tradicionais, algoritmos matemáticos e abordagens baseadas exclusivamente em heurísticas, destacando os ganhos obtidos pela integração híbrida ML–Fuzzy.

CE7. Produção de um conjunto de diretrizes práticas para pesquisadores e engenheiros interessados em projetar sistemas de descarregamento de tarefas veicular, evidenciando cenários onde o modelo híbrido apresenta maior vantagem.

1.8 Publicação

Como parte do desenvolvimento deste trabalho, foi submetido e aceito um artigo no periódico internacional *Journal of Cloud Computing* (Springer), classificado como Q1 nas bases *Scopus/SJR* e posicionado no percentil superior da área de *Computer Networks and Communications*. O artigo, intitulado "*FOFF: descarregamento de tarefas eficiente energeticamente em redes veiculares baseadas em VEC usando fuzzy TOPSIS*" (VIEIRA; SOUZA; JÚNIOR, 2025), apresenta uma versão preliminar do modelo híbrido de descarregamento de tarefas proposto nesta dissertação, incluindo a arquitetura conceitual e os primeiros resultados derivados de experimentos em simulação. A publicação serviu tanto como validação da relevância científica da abordagem quanto como etapa intermediária para o refinamento metodológico, a ampliação dos cenários simulados e o aprofundamento das análises apresentadas nos capítulos seguintes.

1.9 Organização do Trabalho

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos teóricos que sustentam esta pesquisa, organizados para construir uma base sólida sobre a qual a proposta é desenvolvida. A Seção 2.1 detalha a arquitetura e a modelagem das comunicações 5G, com ênfase nas interfaces Veículo-para-Infraestrutura (*Vehicle-to-Infrastructure*) (V2I) e *Sidelink* (Veículo-para-Veículo (*Vehicle-to-Vehicle*) (V2V)). A Seção **??** aprofunda-se na avaliação analítica de desempenho e no cálculo de restrições matemáticas de latência. Em seguida, a Seção 2.2 apresenta as Redes Veiculares sob o prisma da Inteligência e do ecossistema de Internet dos Veículos (Internet dos Veículos (*Internet of Vehicles*) (IoV)).

2.1 Arquitetura e Modelagem 5G V2I e C-V2X

Nesta seção, analisam-se as arquiteturas 5G NR e 5G NR Veículo-para-Tudo (*Vehicle-to-Everything*) (V2X), fundamentadas nas especificações do Release 16 do *3rd Generation Partnership Project* (3GPP) (STUDY..., 2020).

A quinta geração de comunicações móveis celulares, o 5G, representou um avanço tecnológico disruptivo. Ele foi projetado para revolucionar não apenas o setor de telecomunicações, mas também a sociedade como um todo (STALLINGS, 2021). Essa geração teve por objetivo entregar altas taxas de dados, maior confiabilidade, cobertura aprimorada e latências bem menores em comparação com as tecnologias antecessoras, como a Evolução de Longo Prazo (*Long Term Evolution*) (LTE) (STALLINGS, 2021; 5G..., 2020).

As especificações técnicas e diretrizes de avaliação do 5G foram fundamentadas pelo padrão internacional IMT-2020, enquanto que a União Internacional de Telecomunicações (*International Telecommunication Union*) (ITU) ficou encarregada de sua avaliação e monitoramento (ASPLUND *et al.*, 2025; COX, 2025; ITU-R, 2015; ITU-R, 2017; ITU-R, 2021).

Para satisfazer os requisitos estipulados no IMT-2020, o 3GPP definiu toda a arquitetura lógica e física do 5G em sucessivos lançamentos, denominados de "Releases" (STALLINGS, 2021; ASPLUND *et al.*, 2025; COX, 2025; ITU-R, 2015; ITU-R, 2017; ITU-R, 2021).

Ele foi idealizado para funcionar em três grandes cenários de uso, vitais para a implantação das futuras infraestruturas digitais das cidades e da indústria (IOANNOU *et al.*, 2025). Estas características são fundamentais para viabilizar os Sistemas de Transporte Inteligentes (*Intelligent Transport Systems*) (ITS), que exigem comunicações capazes de suportar casos de

uso avançados, como o *platooning* [1] e a direção autônoma de Nível 4 e 5, estágios onde o Sistemas de Condução Automatizada (*Automated Driving Systems*) (ADS) detém o controle total e permanente da tarefa dinâmica de direção (SAE International, 2021).

O primeiro cenário, conhecido como Banda Larga Móvel Melhorada (*enhanced Mobile Broadband*) (eMBB), busca atender a demanda por serviços que exigem altas taxas de transferência de dados, como realidade aumentada e streaming de vídeo em alta definição. Para isso, o 5G foi projetado para suportar picos de taxas de transferência de até 20 Gbps no *downlink* e 10 Gbps no *uplink* (STALLINGS, 2021; ASPLUND *et al.*, 2025; COX, 2025; ITU-R, 2015; ITU-R, 2017; ITU-R, 2021).

O segundo cenário é o de Comunicações Massivas do Tipo Máquina (*Massive Machine Type Communications*) (mMTC), que foi formulado para interconectar eficientemente o ecossistema da Internet das Coisas (*Internet of Things*) (IoT), suportando um grande número de dispositivos interligados que requerem economia rigorosa de energia e baixo custo operacional (MORAIS, 2025; RAGHAVAN *et al.*, 2025).

O terceiro cenário é o de Comunicações Ultraconfiáveis de Baixa Latência (*Ultra-Reliable Low-Latency Communications*) (URLLC), sendo este essecial para aplicações que demanda atrasos a frações de milissegundos e taxas de erro na casa de 10^{-5}, como controle robótico, ITS ou qualquer aplicação que demande alta confiabilidade e baixa latência (RAGHAVAN *et al.*, 2025; SHEIKH; BHAT; MASOODI, 2026).

Para suportar tais exigências, a arquitetura do 5G foi subdividida em dois grandes blocos: (i) a Rede de Acesso por Rádio de Próxima Geração (*Next Generation Radio Access Network*) (NG-RAN) e (ii) o 5GC (STALLINGS, 2021) (Figura 3).

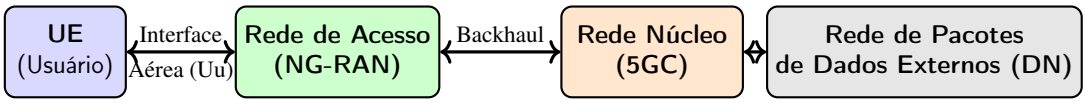

Figura 3 – Modelo de sistema básico 3GPP evidenciando os dois grandes blocos operacionais do 5G.

Fonte**:** Baseado no modelo de sistema 3GPP (FOWDUR *et al.*, 2025).

O 5GC implementa o modelo de Arquitetura Baseada em Serviços (*Service Based Architecture*) (SBA), onde diversas funções de rede comunicam-se através de requisições de serviço em interfaces bem padronizadas (STALLINGS, 2021). A Figura 4 ilustra alguns serviços

[1] Refere-se à aplicação de ITS que vincula eletronicamente dois ou mais veículos para que trafeguem de forma coordenada, mantendo uma distância mínima e constante entre si.

que se integram entre si e com os outros elementos do 5G além da divisão entre Separação do Plano de Controle e de Usuário (*Control and User Plane Separation*) (CUPS).

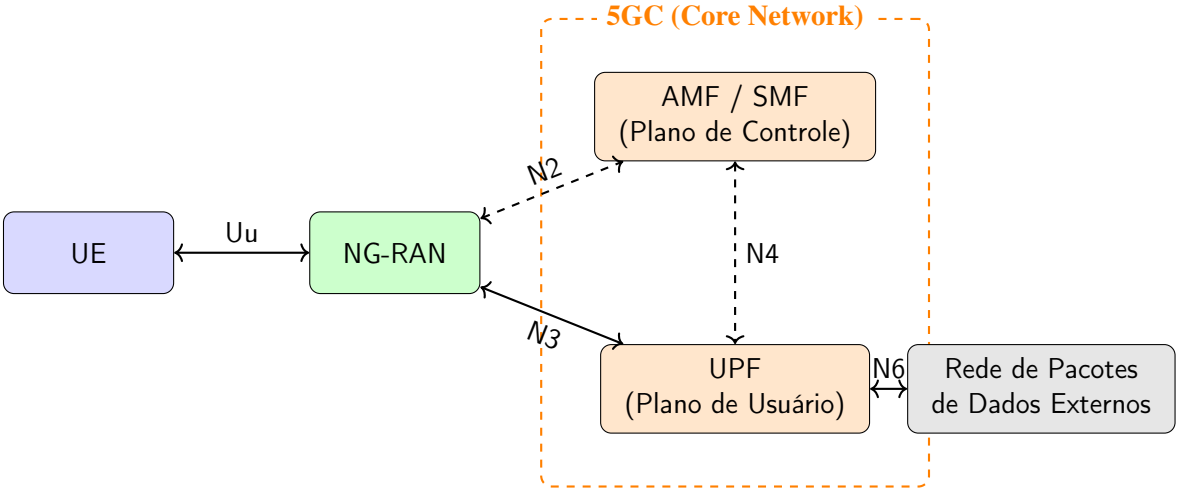

Figura 4 – Arquitetura Simplificada da Rede 5G (Plano de Controle e Usuário).

Fonte**:** Elaborado pelo autor.

Na Figura 4, o componente Função de Gerenciamento de Acesso e Mobilidade (*Access and Mobility Management Function*) (AMF) é o responsável por gerenciar o acesso do usuário à rede, sua mobilidade contínua (rastreamento de localização e transição entre antenas) e o estado de suas conexões através do protocolo Estrato de Não-Acesso (*Non-Access Stratum*) (NAS). Já o Função de Gerenciamento de Sessão (*Session Management Function*) (SMF) é responsável por estabelecer e gerenciar o tráfego de dados do usuário, isto inclui a conexão do usuário com a rede, a alocação de endereços IP, o fornecimento de regras de como os pacotes de dados devem ser roteados, inspecionados ou bloqueados, além do monitoramento do tráfego e geração de relatórios de uso de dados (FOWDUR *et al.*, 2025).

Nas especificações do 3GPP foram definidas nomenclaturas, ou pontos de referência, que identificam as interfaces lógicas de comunicação entre os elementos da arquitetura 5G. Elas são identificadas pela união da letra "N"seguido de um número (STALLINGS, 2021; FOWDUR *et al.*, 2025). A seguir, são apresentadas as principais interfaces lógicas e suas definições:

- **N1:** Conexão lógica fim a fim. É a interface de sinalização entre o UE e a AMF.
- **N2:** Interface exclusiva de sinalização do Plano de Controle que interliga a estação rádio base (NG-RAN) à AMF do núcleo.
- **N3:** Interface responsável por transportar o tráfego de dados entre a rede de acesso (NG-RAN) e a UPF.
- **N4:** Interface de comunicação que viabiliza a separação dos planos de controle e usuário

(CUPS); é através dela que a SMF envia as regras de roteamento, processamento e liberação de pacotes para a UPF.

- **N6:** Interface que conecta a UPF diretamente às Rede de Dados (*Data Network*) (DN) externas, como a Internet pública ou intranets de clientes.

A arquitetura do 5GC, por conta de sua modularidade, viabiliza o conceito de Fatiamento de Rede (*Network Slicing*) (NS). Tal conceito possibilita a criação de redes virtuais independentes, isoladas e que operam em paralelo sobre uma infraestrutura física compartilhada (STALLINGS, 2021). Graças à abstração de hardware permitida pelas tecnologias de Redes Definidas por Software (*Software-Defined Networking*) (SDN) e Virtualização das Funções de Rede (*Network Functions Virtualization*) (NFV), cada rede virtual individual (*slice*) adquire um conjunto dedicado de recursos físicos e funções de rede (STALLINGS, 2021). Dessa forma, cada *slice* (Figura 5) pode ser parametrizado em termos de latência, largura de banda, mobilidade e segurança, oferecendo atributos específicos e blindando o desempenho de um cenário de uso contra congestionamentos em serviços paralelos, viabilizando o diversificado ecossistema digital do 5G (STALLINGS, 2021).

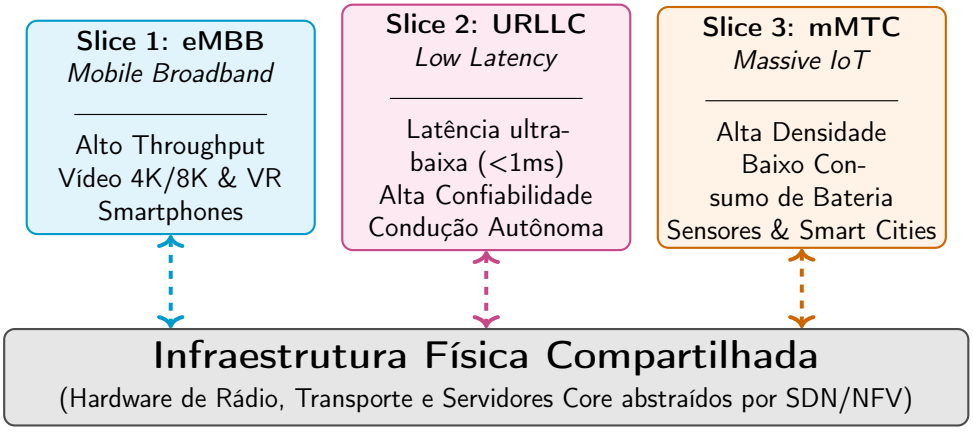

Figura 5 – Conceito de Fatiamento de Rede (Network Slicing) baseado em NFV/SDN evidenciando o isolamento e parametrização por serviço.

Fonte**:** Elaborado pelo autor.

Enquanto a tecnologia NFV abstrai as capacidades de computação, armazenamento e funções de rede via software, dispensando hardwares físicos proprietários, a SDN isola o plano de dados do plano de controle nos dispositivos de rede, consolidando as rotas a partir de um controlador centralizado e programável (STALLINGS, 2021).

Para garantir baixas latências, foi necessário distribuir as funções de processamento e armazenamento da nuvem para dispositivos mais próximos do cliente do serviço. Na prática, isto

significou que as aplicações não precisariam mais enviar seus dados para *datacenters* distantes, sendo penalizadas com latências elevadas. Essa solução foi materializada com a integração do MEC à rede móvel 5G, onde a UPF é distribuída localmente para rotear os dados diretamente aos servidores periféricos, possibilitando a resposta em tempo real. A Figura 6 ilustra a arquitetura do 5GC com a integração do MEC.

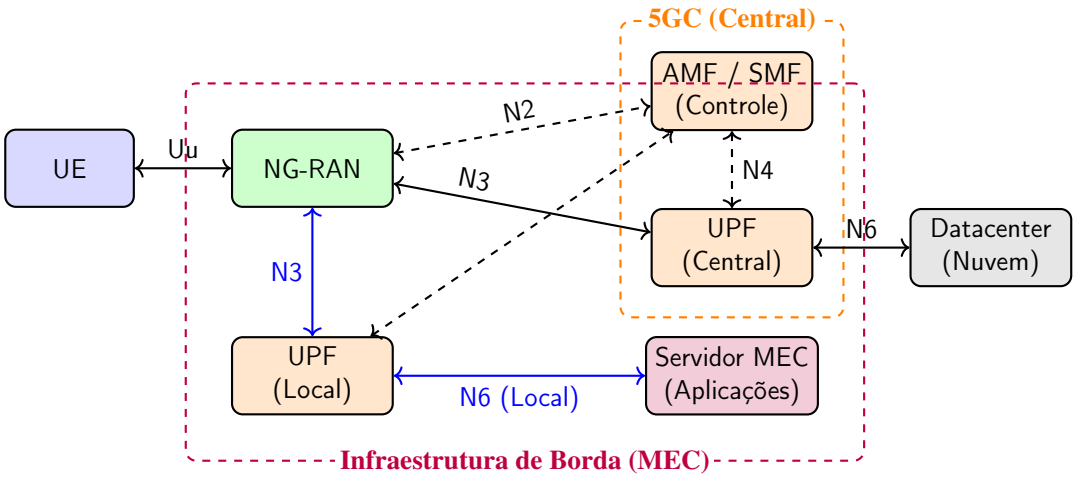

Figura 6 – Integração do MEC à rede 5G distribuindo a função UPF localmente visando reduzir a latência de tráfego sensível.

Fonte: Elaborado pelo autor.

Na rede de acesso 5G, a gNB atua como a Estação Rádio Base (*Radio Base Station*) (RBS) responsável por fornecer a interface aérea, gerenciando a transmissão e a recepção de dados entre o UE e a rede núcleo (FOWDUR *et al.*, 2025; COX, 2025). Quanto à sua infraestrutura, a gNB evoluiu em relação ao Nó B Evoluído (*Evolved Node B*) (eNodeB) (rede de acesso do 4G LTE) adotando uma arquitetura modular. Essa nova estrutura separa suas funções base em duas unidades (divisão funcional): a CU e as DUs.

A CU é responsável pelo processamento de serviços em tempo não real e hospeda os protocolos de maior nível da pilha de rádio, como o Controle de Recursos de Rádio (*Radio Resource Control*) (RRC) (para controle de mobilidade e conexões), o Protocolo de Convergência de Protocolo de Dados (*Packet Data Convergence Protocol*) (PDCP) e o Protocolo de Adaptação de Dados de Serviço (*Service Data Adaptation Protocol*) (SDAP) (responsáveis pela criptografia e mapeamento de Qualidade de Serviço (*Quality of Service*) (QoS)). Por outro lado, as DUs são alocadas localmente, mais próximas às antenas, para executar serviços estritamente de tempo real. Elas hospedam os protocolos de camadas inferiores, como o Controle de Enlace de Rádio (*Radio Link Control*) (RLC), Controle de Acesso ao Meio (*Medium Access Control*) (MAC) e a camada Física (Camada Física (*Physical Layer*) (PHY)), lidando diretamente com o agendamento de

recursos de rádio em milissegundos, correção rápida de erros e o processamento digital dos sinais. A Figura 7 ilustra essa divisão funcional da gNB.

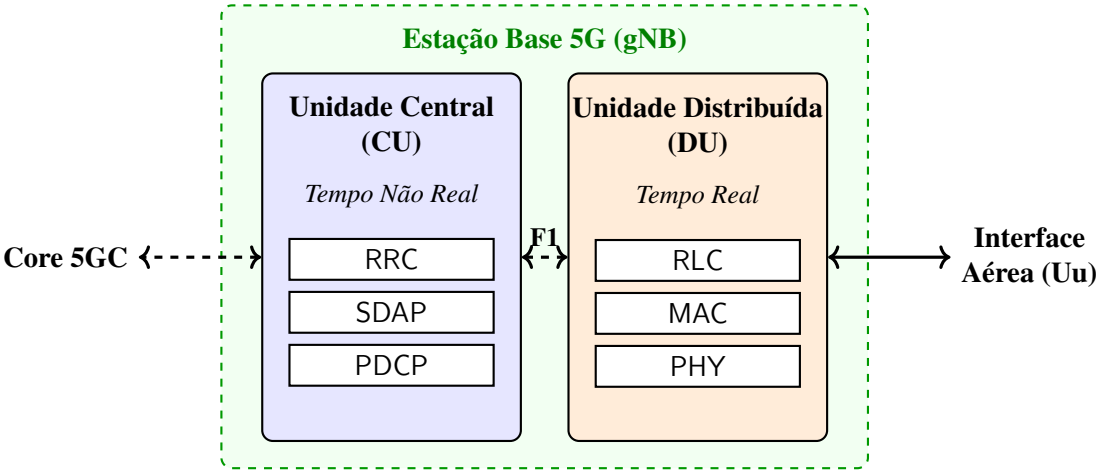

Figura 7 – Divisão funcional arquitetural da estação base gNB nas unidades CU e DU, mostrando a alocação dos protocolos de rádio.

Fonte: Elaborado pelo autor.

Estas mudanças na arquitetura da rede forçaram as operadoras a elaborar um plano estratégico para migrar do 4G LTE para o 5G, formalmente designado como Opção 3. Inicialmente, a ideia foi aproveitar a infraestrutura existente do 4G LTE como base, adotando o modelo de implantação NSA. O modelo NSA mantém o uso do núcleo de pacotes do 4G LTE, conhecido como EPC, e fornece Conectividade Dupla E-UTRA-NR (*E-UTRA-NR Dual Connectivity*) (EN-DC) ao usuário. Nesse arranjo, a estação base LTE (eNodeB) atua como nó mestre, utilizando o UPF do EPC para gerenciar a sinalização (como autenticação, mobilidade e estabelecimento da conexão). Simultaneamente, a estação 5G (en-gNB) atua como nó secundário dedicado ao Plano de Usuário, fornecendo a interface de rádio de alta capacidade para reforçar o fluxo de dados brutos da internet (Figura 8). A Figura 8 ilustra essa migração.

Ainda na Figura 8, as interfaces lógicas S1 (Interface do Plano de Controle S1 (*S1 Control Plane Interface*) (S1-C) e Interface do Plano de Usuário S1 (*S1 User Plane Interface*) (S1-U)) ligam a rede de acesso ao núcleo EPC. A S1-C transporta o tráfego do plano de controle (sinalização), enquanto a S1-U transporta pacotes de dados do usuário. Já a interface Interface X2 (*X2 Interface*) (X2) conecta diretamente o eNodeB e o en-gNB, permitindo que o Nó Mestre (*Master Node*) (MN) coordene o Nó Secundário (*Secondary Node*) (SN), gerencie a mobilidade e divida o fluxo de dados do usuário entre as duas torres. As interfaces Interface de Rádio LTE (*LTE Radio Interface*) (LTE-Uu) e Interface de Rádio NR (*NR Radio Interface*) (NR-Uu) são as interfaces aéreas de conexão de rádio que conectam o UE às torres 4G e 5G, respectivamente.

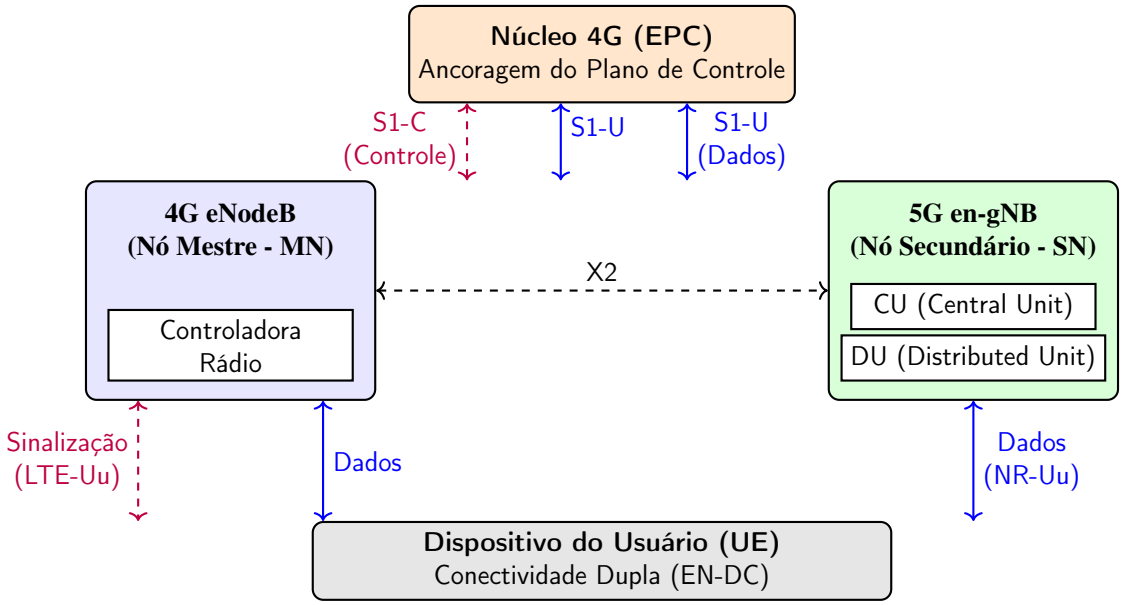

Figura 8 – Estrutura de implantação Não-Autônoma (NSA) baseada no núcleo legado EPC, separando a controladora rádio 4G LTE do nó secundário en-gNB (dividido em CU e DU).

Fonte: Elaborado pelo autor.

O segundo passo em direção ao uso pleno do 5G é a migração para o modelo SA, cenário formalmente designado como Opção 2. Nessa arquitetura, a estação base gNB conecta-se diretamente ao núcleo 5GC através da interface lógica NG, concretizando suas funcionalidades sem qualquer dependência da infraestrutura legada do 4G LTE (Figura 9).

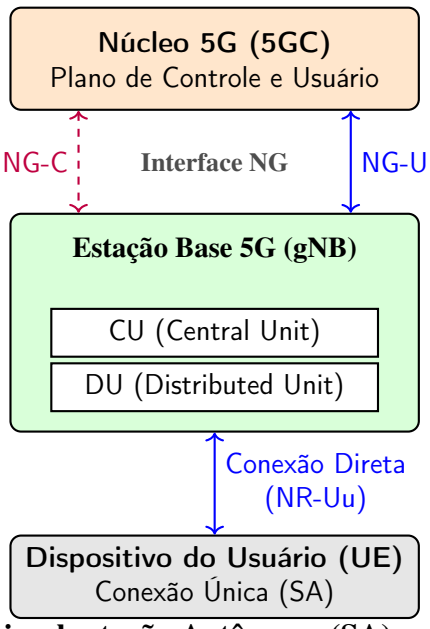

Figura 9 – Estrutura de implantação Autônoma (SA) ou Opção 2. O núcleo 5GC conecta-se diretamente à estação base gNB via interface NG.

Fonte: Elaborado pelo autor.

No modelo SA, as conexões sem fio com o usuário final operam através de uma

interface aérea, conhecida como 5G NR. Nela, o espectro de radiofrequência suporta maiores larguras de banda. Para tanto, as operações foram divididas em duas faixas de frequência: (i) a FR1 e (ii) a FR2.

O intervalo de radiofrequência FR1 abrange o espectro da faixa sub-6 GHz, partindo de 410 MHz até 7.125 GHz, o que possibilita um balanço entre penetração em ambientes internos e uma boa capacidade de cobertura. Em relação a largura de banda, o FR1 suporta até 100 MHz. Já o intervalo de radiofrequência FR2, cujas frequências são conhecidas como Ondas Milimétricas (*Millimeter Wave*) (mmWave), estendem-se de 24.25 GHz a 71 GHz e suporta até 400 MHz de largura de banda. A Figura 10 sintetiza conceitualmente essa divisão de frequências no espectro da interface NR.

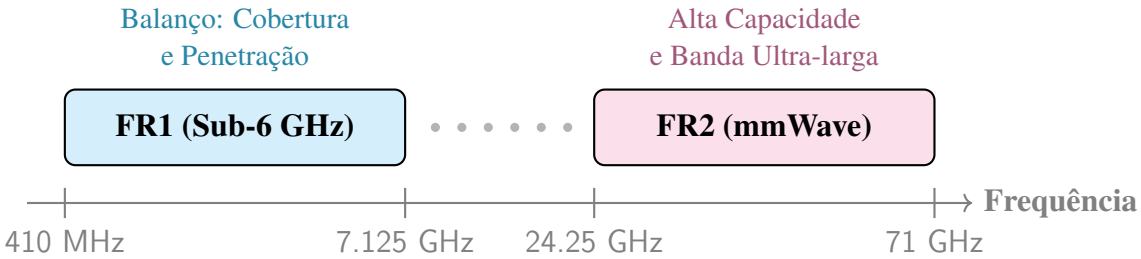

Figura 10 – Divisão conceitual do espectro de radiofrequência 5G NR nas faixas FR1 (Sub-6 GHz) e FR2 (mmWave).

Fonte: Elaborado pelo autor.

No 4G tradicional, eram utilizadas antenas MIMO com até 8 elementos, mas tal configuração revelou-se inadequada para as operações em faixas de frequência milimétricas. Portanto, no 5G, aproveitando-se do diminuto comprimento de onda dessas frequências, foi possível aumentar o número de elementos de antena consideravelmente, integrando dezenas ou centenas de elementos (como 64, 128 ou 256) em um único painel. Essa configuração é conhecida como *Massive* MIMO. Ela é altamente densa e atua em conjunto para gerar ganhos consideráveis, compensando a atenuação natural do sinal nas faixas do FR2.

A eficácia do *Massive* MIMO depende de uma técnica de filtragem espacial dos sinais conhecida como conformação de feixes (*Beamforming*). As antenas, em vez de irradiar a energia do rádio em todas as direções, direcionam o sinal de forma precisa para o dispositivo do usuário. Isso evita que o sinal cause interferência a usuários próximos e mitiga o desperdício de potência em rotas desnecessárias, o que eleva a eficiência energética do sistema e entrega conexões mais eficientes ao usuário pontual e em movimento. Além disso, a altíssima resolução espacial do *Massive* MIMO confere ao sistema a capacidade de mapear a assinatura espacial do canal, distinguindo e separando diferentes ângulos de propagação com extrema precisão. É essa

característica que permite realizar a multiplexação espacial para atender a múltiplos usuários simultaneamente sobre o mesmo recurso de tempo e frequência (MU-MIMO).

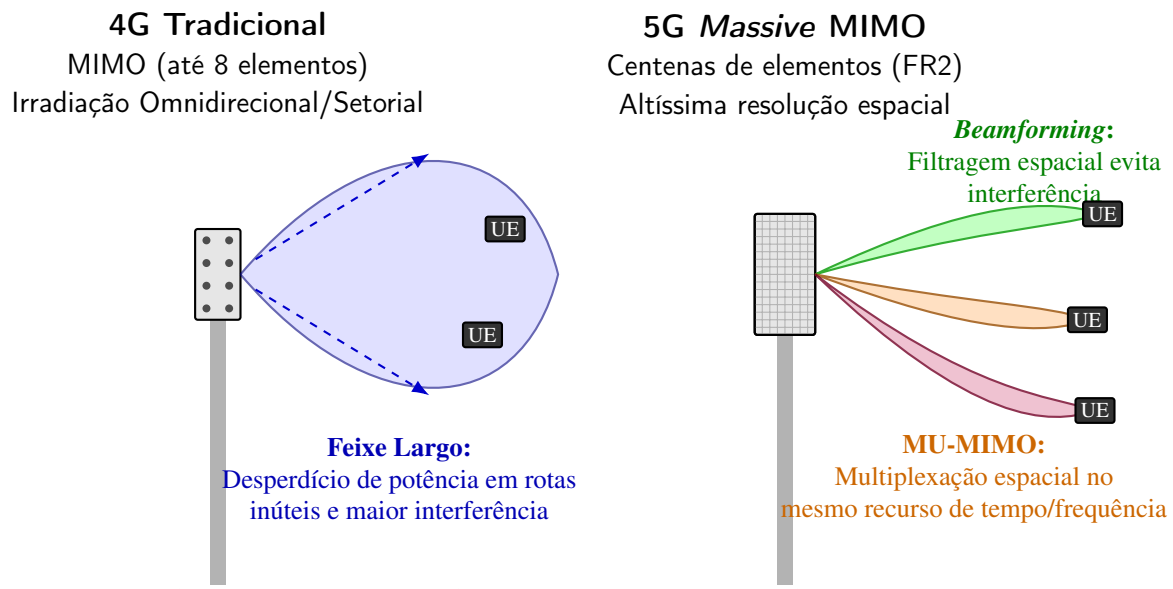

Figura 11 – Comparativo ilustrativo entre a arquitetura 4G tradicional e o 5G *Massive* MIMO. À esquerda, nota-se a limitação dos painéis com poucos elementos e o desperdício de potência. À direita, aproveitando o diminuto comprimento de onda no FR2, o adensamento massivo de antenas gera uma altíssima resolução espacial, permitindo a conformação de feixes (*Beamforming*) eficientes e a multiplexação MU-MIMO.

Os sinais e dados enviados ao UE a partir da RBS utilizam o esquema de acesso múltiplo OFDMA. O OFDMA divide a largura de banda total em múltiplas subportadoras ortogonais, eliminando a interferência entre elas. Os recursos são gerenciados pela estação base como uma matriz bidimensional de tempo e frequência e agrupados em RB, em que cada bloco contém 12 subportadoras. Dessa forma, a rede entrega diferentes fatias do espectro a diferentes usuários de forma simultânea, o que aumenta a eficiência espectral da transmissão e a qualidade da experiência do usuário. A Figura 12 ilustra o funcionamento do OFDMA onde são alocados RB para quatro UE diferentes.

Diferente do LTE, que limitava o Espaçamento de Subportadoras (*Subcarrier Spacing*) (SCS) ao valor fixo de 15 kHz, o 5G NR utiliza um mecanismo capaz de flexibilizar o espaçamento de subportadoras (STALLINGS, 2021). Através da numerologia escalável $\mu \in \{0,1,2,3,4,5,6\}$, é possível obter diferentes valores de SCS (Equação 2.1), viabilizando a adaptação da rede a diferentes faixas de frequência e cenários de uso (ASPLUND *et al.*, 2025; COX, 2025).

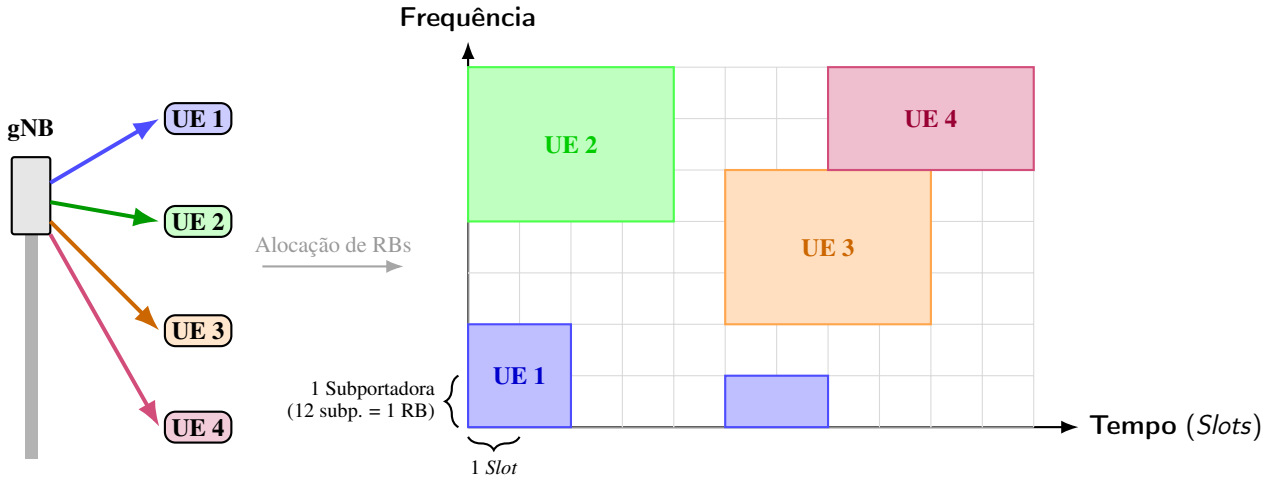

Figura 12 – Representação do OFDMA no 5G: à esquerda, a estação base (gNB) distribui feixes dedicados a cada usuário; à direita, a grade bidimensional de tempo e frequência exibe como os Blocos de Recursos (RB) são alocados simultaneamente a diferentes UE.

Fonte: Elaborado pelo autor.

$$\Delta f = 15 \times 2^{\mu} \text{ kHz} \tag{2.1}$$

Por conta da relação inversamente proporcional entre tempo e frequência, $T_u = \frac{1}{\Delta f}$, o aumento do parâmetro μ alarga a banda ocupada pela subportadora, reduzindo exponencialmente a duração útil do símbolo OFDM (COX, 2025). A Figura 13 ilustra essa dinâmica: à medida que μ é incrementado em uma unidade, o espaçamento entre as subportadoras duplica e, consequentemente, a duração temporal do símbolo OFDM cai pela metade (STALLINGS, 2021).

Outro aspecto importante da numerologia escalável do 5G NR é a flexibilidade da duração do *slot*. Ela permite que a rede adapte dinamicamente a transmissão aos cenários de uso. Ao utilizar espaçamentos maiores de subportadoras (símbolos mais curtos), reduz-se a latência na rede e mitigam-se distorções de sinal em altas frequências, como o ruído de fase e o espalhamento Doppler em veículos de alta velocidade (GARCIA; AL., 2021). Em contrapartida, o uso de espaçamentos menores preserva símbolos mais longos, aumentando a tolerância da rede em células de grande cobertura (STALLINGS, 2021).

Para mitigar a ISI, a porção final do símbolo OFDM é copiada e inserida em seu próprio início. Essa técnica é conhecida por CP. Se a duração do CP (T_{CP}) for maior que o Espalhamento de Atraso (τ_{DS}) do canal, os ecos do multipercurso são totalmente absorvidos, permitindo que o receptor processe o sinal sem interferências. Fisicamente, a duração total de

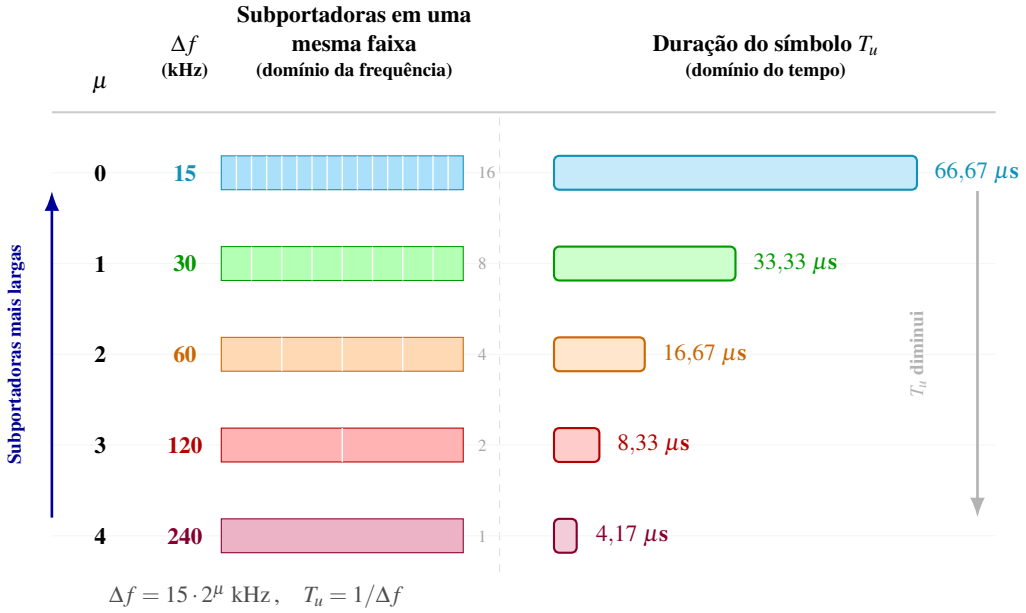

Figura 13 – Numerologia escalável do 5G NR: a relação inversamente proporcional entre o espaçamento de subportadoras ($\Delta f = 15 \times 2^{\mu}$ kHz) e a duração útil do símbolo OFDM ($T_u = 1/\Delta f$). Numerologias menores favorecem cobertura ampla, enquanto maiores reduzem latência.

Fonte**:** Elaborado pelo autor com base em (COX, 2025; STALLINGS, 2021).

um símbolo na interface aérea é dada por $T_s = \frac{1}{\Delta f} + T_{CP}$, como ilustrado na Figura 15.

Na camada física do 5G, a informação digital é mapeada em ondas eletromagnéticas utilizando esquemas de QAM. Para o dimensionamento dinâmico da transmissão, o 3GPP especifica tabelas de Esquema de Modulação e Codificação (*Modulation and Coding Scheme*) (MCS) que associam um índice a um esquema de modulação específico (como QPSK, 16-QAM, 64-QAM e 256-QAM) e à sua respectiva taxa de codificação (*code rate*). Cada esquema empacota uma quantidade crescente de bits em um único símbolo transmitido — variando de 2 bits no QPSK a 8 bits no 256-QAM —, o que contribui diretamente para a elevação da vazão de dados e da eficiência espectral da rede.

No entanto, à medida que a ordem de modulação aumenta e um único símbolo empacota mais bits, os pontos no diagrama de constelação tornam-se mais densos e próximos uns dos outros (Figura 16). Isso torna o sinal altamente vulnerável, exigindo uma SINR excepcional para evitar que distorções no canal causem a leitura errônea de um símbolo, o que elevaria severamente a Taxa de Erro de Bit (*Bit Error Rate*) (BER).

Para contornar esse problema de degradação, a rede utiliza o mecanismo de Adaptação de Enlace (*Link Adaptation*). O sistema avalia continuamente a qualidade do canal e, sob

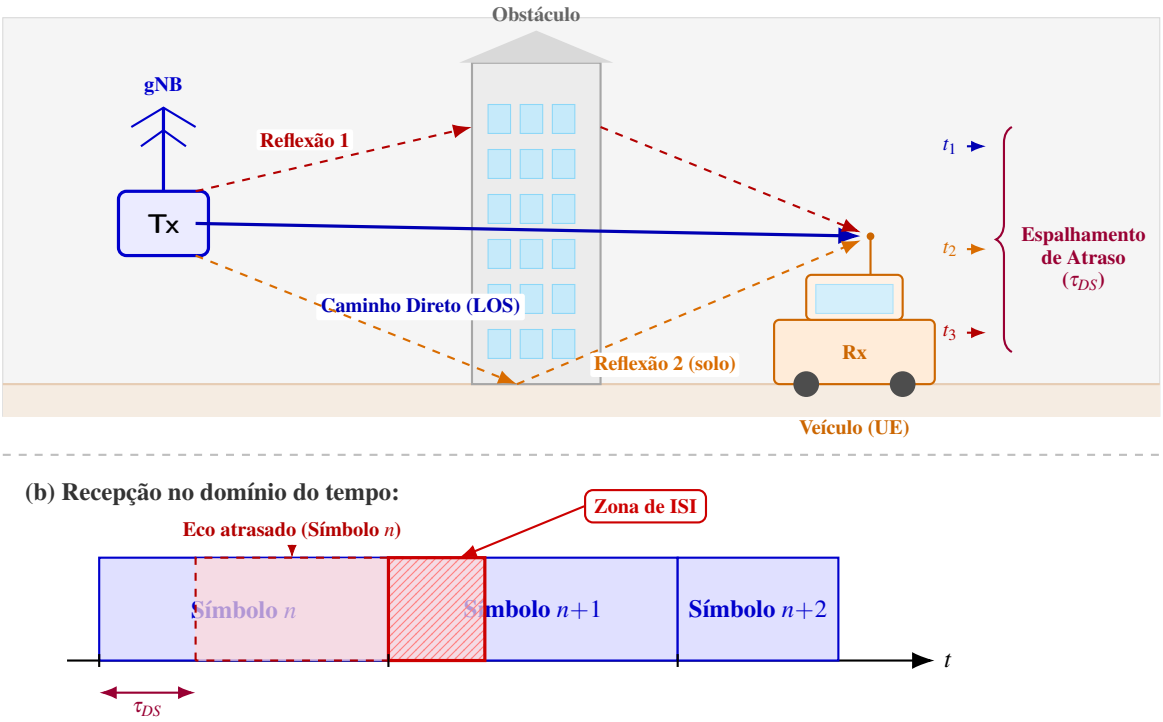

Figura 14 – Efeito do multipercurso e da ISI em comunicações V2X. (a) Cenário urbano: o sinal da gNB chega ao veículo receptor pelo caminho direto (LOS, instante t_1) e por dois percursos refletidos (no prédio em t_2 e no solo em t_3), gerando um espalhamento de atraso $\tau_{DS} = t_3 - t_1$. (b) Domínio do tempo: o eco atrasado do Símbolo n invade a janela do Símbolo $n+1$, causando a zona hachurada de ISI.

Fonte: Elaborado pelo autor com base em (STALLINGS, 2021).

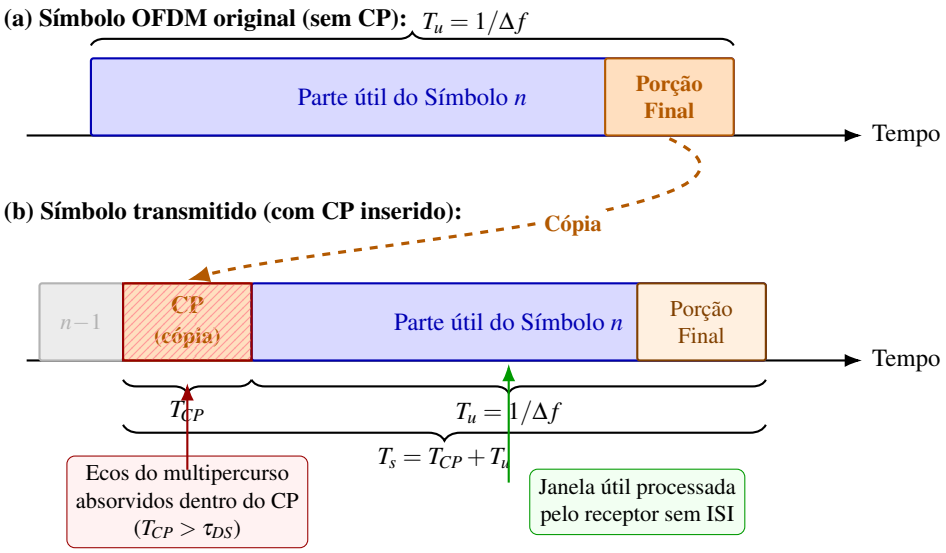

Figura 15 – Mecanismo do Prefixo Cíclico (CP) no 5G NR. Em (a), a porção final da parte útil do símbolo é copiada para seu início, parte (b), buscando proteger o sinal de interferências.

Fonte: Elaborado pelo autor com base em (STALLINGS, 2021; COX, 2025).

condições adversas (como na borda da célula), obriga o transmissor a regredir dinamicamente para esquemas de modulação mais simples e com maior espaçamento entre os pontos, como o QPSK. Apesar de o QPSK transportar apenas 2 bits por símbolo – reduzindo a vazão de dados –, ele é extremamente resiliente contra ruídos e interferências, assegurando a confiabilidade da entrega dos pacotes.

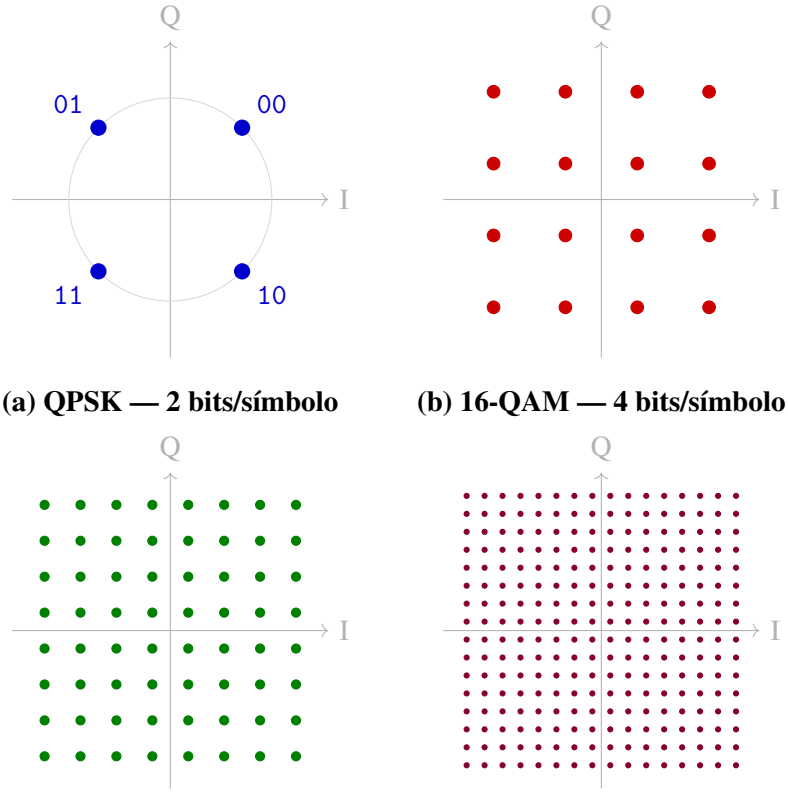

(a) QPSK — 2 bits/símbolo **(b) 16-QAM — 4 bits/símbolo**

(c) 64-QAM — 6 bits/símbolo **(d) 256-QAM — 8 bits/símbolo**

Figura 16 – Diagramas de constelação dos esquemas de modulação QAM utilizados no 5G NR. À medida que a ordem da modulação aumenta de (a) para (d), cada símbolo transporta mais bits, elevando a vazão, porém a maior densidade de pontos exige uma SINR proporcionalmente superior para manter a taxa de erro aceitável.

Fonte**:** Elaborado pelo autor com base em (COX, 2025).

O próximo passo natural, depois dessa evolução na arquitetura da comunicação móvel, foi o aprimoramento da comunicação direta entre os UE. No que tange à comunicação veicular, a tecnologia de quinta geração trouxe avanços significativos, consolidando o paradigma **C-V2X (*Cellular Vehicle-to-Everything*)** (GARCIA; AL., 2021). Ao herdar a robustez do 5G NR, o *Cellular Vehicle-to-Everything* (C-V2X) supera as limitações de tecnologias baseadas em redes

ad-hoc (como o *Dedicated Short-Range Communications/Institute of Electrical and Electronics Engineers* (DSRC/IEEE) 802.11p), garantindo a latência e a confiabilidade necessárias para aplicações críticas de segurança e condução autônoma.

O C-V2X opera fundamentalmente sobre duas interfaces: (i) a **Uu**, conectando o veículo à infraestrutura da rede celular (V2I/Veículo-para-Rede (*Vehicle-to-Network*) (V2N)), e (ii) a **PC5 (*Sidelink*)**, que estabelece um enlace direto veículo-veículo (V2V) e veículo-pedestre (Veículo-para-Pedestre (*Vehicle-to-Pedestrian*) (V2P)) sem que os dados precisem transitar pelas antenas ou pelo núcleo da rede 5GC. No *Release* 16 do 3GPP, o *Sidelink* do 5G NR foi aprimorado para suportar não apenas transmissões abertas (*broadcast*), mas também comunicações *unicast* e *groupcast*, garantindo maior controle de QoS em manobras cooperativas, como a formação de pelotões (*platooning*).

O gerenciamento do acesso ao meio e a reserva de recursos de rádio no Interface de Comunicação Direta PC5 (PC5) *Sidelink* operam sob dois modos distintos. No **Modo 1**, a alocação de recursos é centralizada. A estação base (gNB) agenda os recursos para os veículos através da interface celular (Interface de Rádio Celular Uu (Uu)), garantindo uma baixa ocorrência de colisões, mas exigindo que os veículos estejam sob cobertura celular ininterrupta. No **Modo 2**, os próprios veículos gerenciam os recursos de rádio de forma autônoma através de sensoriamento prévio do canal (*Channel Sensing*). A Figura 17 apresenta essas conexões.

Para viabilizar essa comunicação direta, a camada física da PC5 organiza a troca de dados em três canais físicos complementares que operam sequencialmente dentro de um mesmo *slot* de transmissão: o **PSCCH** (*Physical Sidelink Control Channel*), o **PSSCH** (*Physical Sidelink Shared Channel*), que transporta efetivamente a carga útil de dados e o **PSFCH** (*Physical Sidelink Feedback Channel*). A Figura 18 ilustra a coexistência e a multiplexação temporal desses canais dentro de um *slot* do 5G NR *Sidelink*.

O canal de controle (**PSCCH**) anuncia publicamente a reserva de recursos de tempo e frequência (Bloco de Recurso Físico (*Physical Resource Block*) (PRB)), permitindo aos veículos vizinhos realizarem o sensoriamento do meio para evitar colisões de dados e encontrar blocos de rádio livres para transmissão. Em seguida, o canal compartilhado (**PSSCH**) transmite a carga útil da aplicação e as instruções para o destinatário processar e responder às requisições. Essas instruções incluem o identificador do emissor, um indicador que avisa ao receptor se o pacote contém novos dados ou é uma retransmissão, o tipo de comunicação (*broadcast*, *unicast* ou *groupcast*), dados geográficos e uma requisição ao receptor sobre as condições físicas do enlace de dados. Por último, o canal de *feedback* (**PSFCH**) opera confirmando ou não, quase que

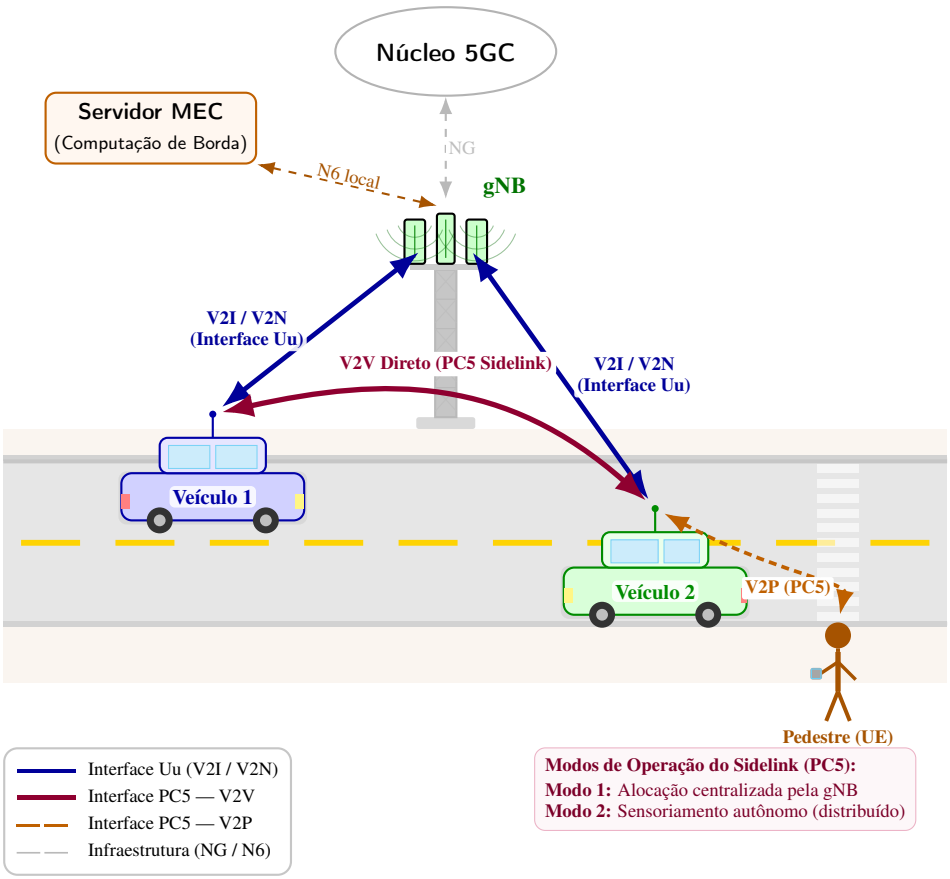

Figura 17 – Arquitetura das comunicações 5G C-V2X: coexistência da interface celular Uu (V2I/V2N) com a interface direta PC5 *Sidelink* (V2V/V2P), integrando o núcleo 5GC, o servidor MEC de borda e os elementos veiculares e pedestres.

Fonte**:** Elaborado pelo autor com base em (GARCIA; AL., 2021; COX, 2025).

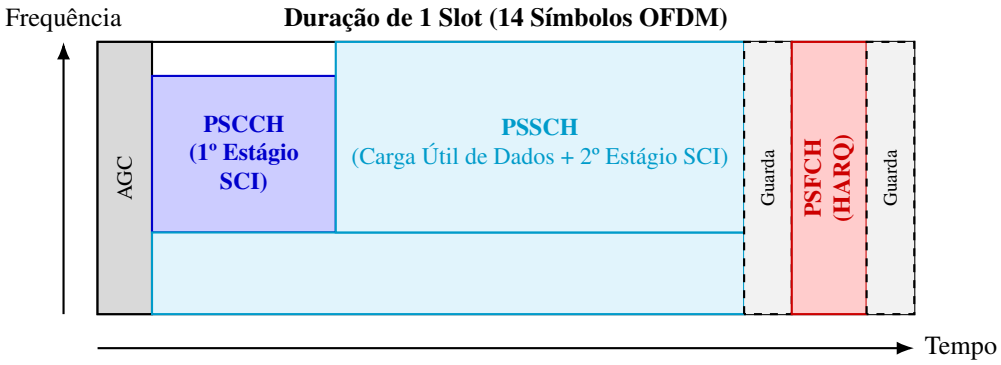

Figura 18 – Estrutura temporal básica da camada física em um *slot* do 5G NR *Sidelink*, ilustrando a multiplexação dos canais físicos PSCCH, PSSCH e PSFCH (COX, 2025; GARCIA; AL., 2021).

instantaneamente, o sucesso ou a falha da recepção daquele pacote (ACK/NACK). A Figura 19 ilustra essa dinâmica sequencial entre dois veículos.

Figura 19 – Dinâmica sequencial de operação dos canais físicos PSCCH, PSSCH e PSFCH na interface PC5 do 5G NR *Sidelink*. A comunicação ocorre em três fases: anúncio de controle, transmissão de dados e confirmação de recepção. Em caso de falha (NACK), o ciclo de dados é repetido via retransmissão HARQ.

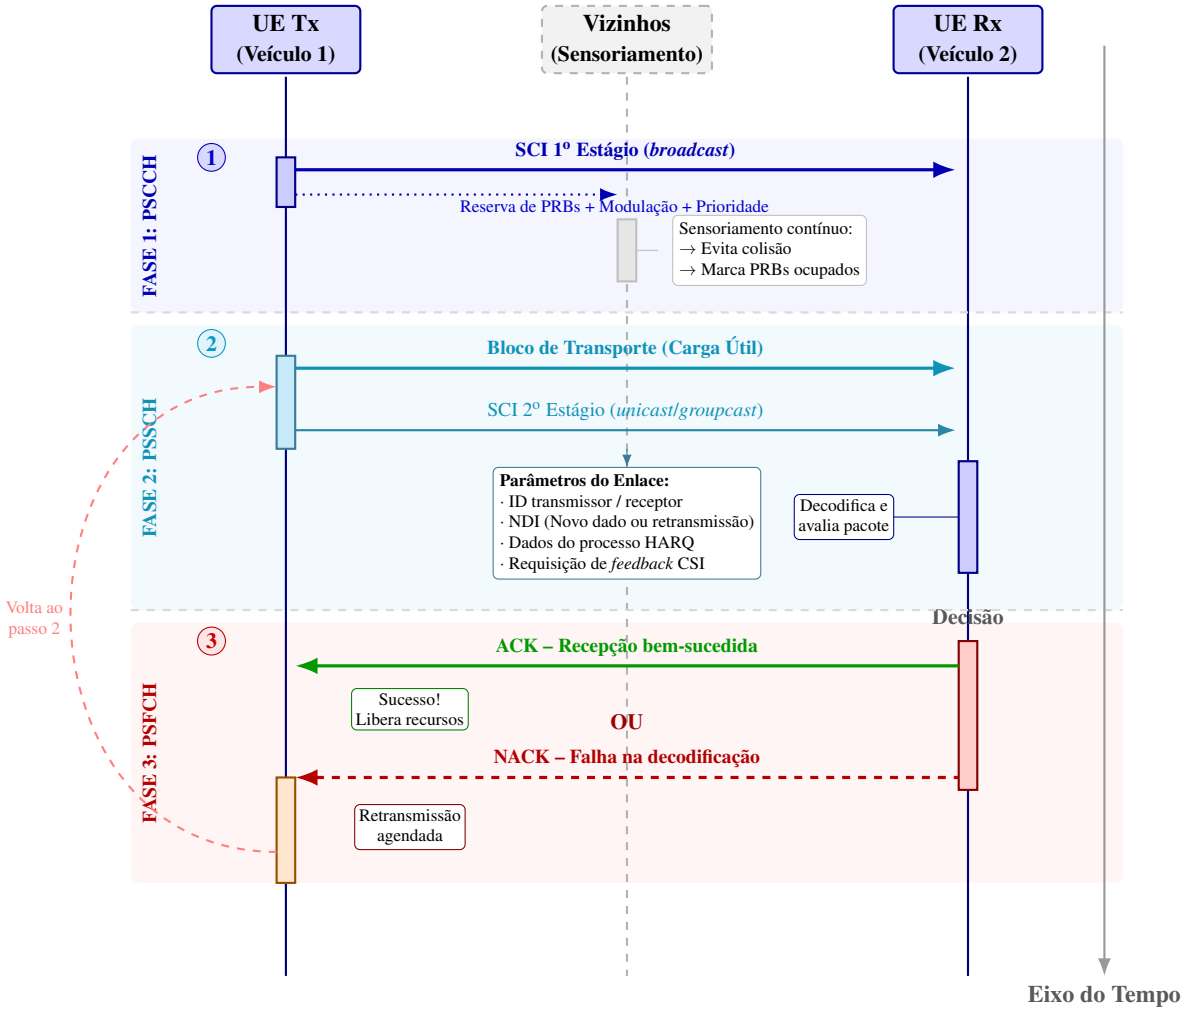

Fonte: Elaborado pelo autor com base em (GARCIA; AL., 2021; COX, 2025).

2.2 A Internet de Veículos (IoV) e as Redes Veiculares

A evolução das Redes de Comunicação Veicular nas últimas décadas é marcada por uma transição clara entre paradigmas tecnológicos. Inicialmente, o foco concentrava-se nas Redes Ad Hoc Veiculares (VANETs, *Vehicular Ad hoc NETworks*), priorizando a conectividade direta entre os veículos. Com o amadurecimento da Internet das Coisas (IoT, *Internet of Things*),

iniciou-se um processo de convergência que resultou no atual ecossistema da Internet dos Veículos (IoV, *Internet of Vehicles*) (PARRA *et al.*, 2025; ABD-ELNABY *et al.*, 2024). Enquanto o estágio inicial das VANETs visava a comunicação básica, a IoV contemporânea integra sensores embarcados, Inteligência Artificial (IA) e Redes Definidas por Software (SDN) para viabilizar Sistemas de Transporte Inteligentes (ITS) verdadeiramente autônomos e conectados.

As VANETs emergiram como uma evolução das redes móveis ad hoc (MANETs, *Mobile Ad hoc NETworks*). No entanto, seu grande diferencial é a alta mobilidade dos nós, o que impõe desafios rigorosos em termos de conectividade e latência. Diferente das MANETs, os enlaces nas redes veiculares surgem e desaparecem rapidamente. Para aplicações de segurança crítica, como alertas de colisão, atrasos na comunicação são intoleráveis. Consequentemente, novas tecnologias de comunicação foram desenvolvidas para atender às exigências das VANETs e da futura IoV, destacando-se o DSRC (*Dedicated Short-Range Communications*) e o C-V2X (*Cellular Vehicle-to-Everything*).

À medida que as redes veiculares evoluíam, os sistemas de IoT se expandiam pelas infraestruturas urbanas. Cada vez mais, dispositivos com sensores foram instalados em semáforos, estações meteorológicas, equipamentos públicos e até mesmo sendo carregados por pedestres (ABD-ELNABY *et al.*, 2024). A IoV surge da consolidação deste cenário, sendo definida como uma rede heterogênea de grande escala que possibilita a comunicação entre veículos, infraestrutura, pedestres e a nuvem (ANSARI, 2020). O compartilhamento destas informações amplia a observação do ambiente (NAIK *et al.*, 2019), otimiza a orquestração do tráfego (SáNCHEZ *et al.*, 2025) e aprimora os sistemas de segurança (ABD-ELNABY *et al.*, 2024).

O ecossistema IoV, referenciado como *Vehicle-to-Everything* (V2X), é estruturado por quatro interfaces de comunicação que determinam a topologia e o alcance da troca de dados. A interface **Vehicle-to-Vehicle (V2V)** viabiliza a comunicação direta entre veículos, configurando-se como um requisito crítico para sistemas de segurança ativa e alertas de colisão iminente. A comunicação **Vehicle-to-Infrastructure (V2I)** conecta o veículo aos equipamentos da infraestrutura viária (RSUs, *Road Side Units*), provendo tanto dados locais de tráfego quanto o acesso a recursos de computação robustos com baixa latência. Para cenários que demandam coordenação global ou acesso a um poder de armazenamento e processamento massivo, a interface **Vehicle-to-Network (V2N)** estabelece o enlace celular com a rede núcleo da operadora, encaminhando o tráfego para a nuvem em detrimento do aumento da latência. Por fim, a interface **Vehicle-to-Pedestrian (V2P)** integra pedestres à rede por meio de dispositivos móveis,

Figura 20 – Abstração do Ecossistema IoV: V2V, V2I, V2N e V2P em Cruzamento

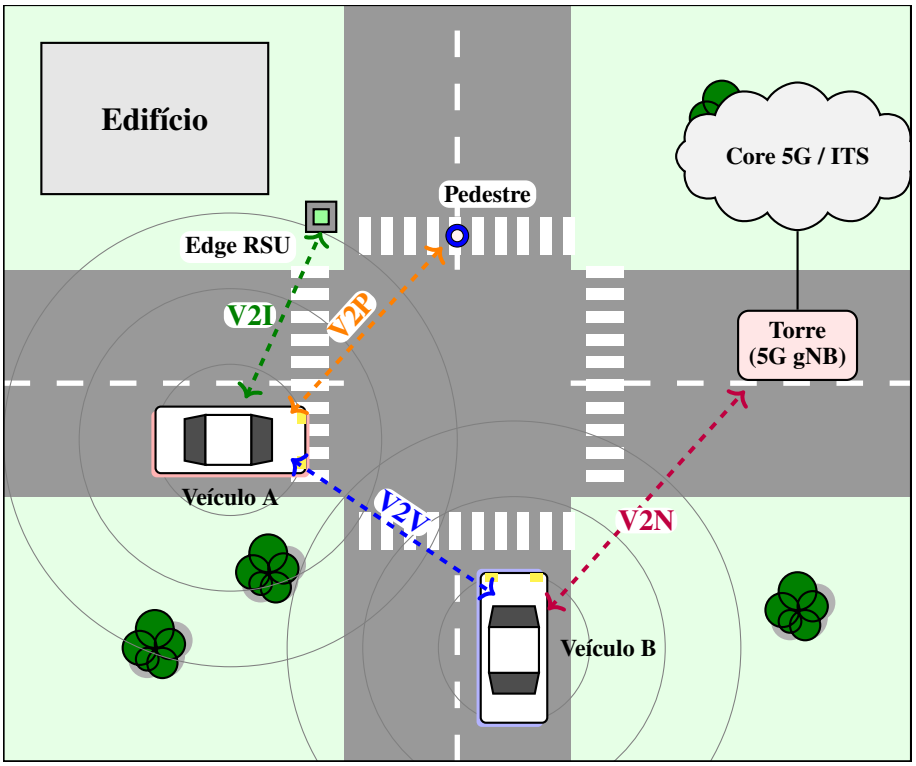

Fonte: Elaborado pelo autor

ampliando a consciência situacional do sistema de transporte.

Neste cenário, a viabilização da IoV é intrinsecamente dependente da maturidade de tecnologias de rádio robustas. Historicamente, o marco inicial no desenvolvimento de sistemas de comunicação de baixa latência ocorreu no final da década de 1990, com a alocação de 75MHz do espectro na banda 5.9GHz para sistemas de transporte inteligente (ZHENG *et al.*, 2015). A motivação na época, residia na incapacidade das redes celulares em atender aos requisitos de segurança viária (latências proibitivas e instabilidade de conexão), somada às limitações de interferência das bandas não licenciadas *Industrial, Scientific, and Medical* (ISM). Sob uma perspectiva técnica, o DSRC consolidou-se não como um protocolo isolado, mas como um arcabouço regulatório e tecnológico que, ao integrar a camada física IEEE 802.11p à arquitetura *Wireless Access in Vehicular Environments* (WAVE) — responsável por definir como as mensagens de segurança são estruturadas, criptografadas e um conjunto de padrões de interface de comunicação V2V e V2I — definiu os parâmetros fundamentais para aplicações de segurança ativa e sistemas de tarifação eletrônica (Figura 21).

A partir do legado do DSRC, a evolução tecnológica da comunicação veicular ramificou-se em dois eixos técnicos distintos. O primeiro, o padrão **IEEE 802.11bd** (*Next Generation V2X* - NGV), surge como uma melhoria incremental do IEEE 802.11p. Conforme

Figura 21 – Arquitetura de Protocolos DSRC / WAVE (IEEE 1609 / 802.11p)

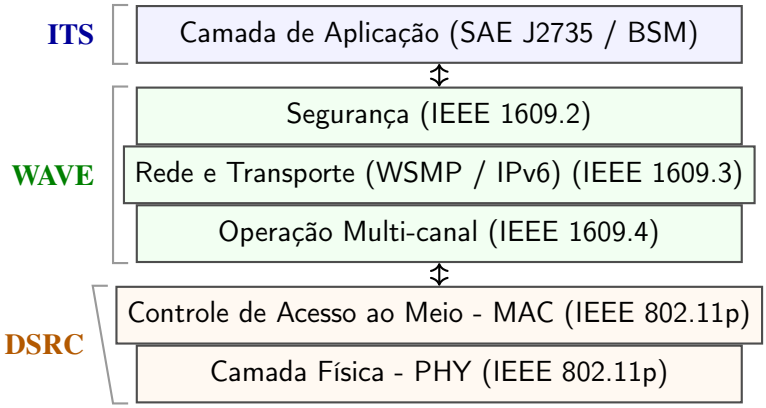

Fonte: Adaptado de (ZHENG *et al.*, 2015)

(NAIK; CHOUDHURY; PARK, 2019), a demanda por maior vazão de dados (*throughput*) e a necessidade de robustez contra o desvanecimento rápido em cenários de alta mobilidade foram os principais motivadores desta evolução, integrando técnicas para suporte a velocidades de até 250 km/h.

O segundo eixo representa uma mudança de paradigma com o surgimento do **C-V2X** (*Cellular V2X*) e sua posterior transição para o **5G NR-V2X** e o horizonte do **6G** (RODRíGUEZ-PIñEIRO *et al.*, 2025). As limitações do DSRC em termos de escalabilidade e custo de implantação impulsionaram o desenvolvimento do C-V2X pelo 3GPP (CHEN; AL., 2017). Sob uma perspectiva regulatória atual, a disputa tecnológica foi amplamente resolvida em mercados-chave; nos Estados Unidos, a FCC estabeleceu o C-V2X como padrão obrigatório para segurança ITS com descontinuação oficial do DSRC em dezembro de 2026 (Federal Communications Commission (FCC), 2024), enquanto no Brasil a ANATEL, através da Resolução nº 772/2025 (Agência Nacional de Telecomunicações (Anatel), 2025b), harmonizou os requisitos técnicos nacionais com os padrões globais celular e radar automotivo (Agência Nacional de Telecomunicações (Anatel), 2025a). A Tabela 2 sintetiza a evolução e as divergências técnicas entre essas abordagens.

As redes veiculares evoluíram com a integração à IoV, transitando da incerteza tecnológica para uma realidade onde a superioridade do C-V2X é um fato regulatório consolidado (ANSARI, 2020). Embora o DSRC possua validação extensiva em segurança básica, a indústria convergiu para o ecossistema celular em função de sua projeção escalonável em direção ao 5G NR em frequências milimétricas (mmWave, FR2) e aos futuros padrões 6G operando em faixas Terahertz (THz) (NAIK *et al.*, 2019). Entretanto, o transplante das arquiteturas de rádio para bandas de frequência tão elevadas introduz barreiras operacionais agressivas, como deficiências

Tabela 2 – Comparativo técnico da evolução V2X: do DSRC ao 6G

Atributo	DSRC (11p)	NGV (11bd)	C-V2X (5G NR)	6G-V2X (Exp.)
Acesso MAC	CSMA/CA	CSMA/CA+	CP-OFDM	Holístico/Cognit.
Código Canal	BCC	LDPC	LDPC	Polar / AI-based
Latência	100 ms	< 50 ms	3 - 10 ms	< 1 ms
Taxa Dados	6 - 27 Mbps	Até 90 Mbps	Mbps a Gbps	> 1 Tbps
Transmissão	Broadcast	Broadcast	Uni/Groupcast	Semântica / ISAC
Conectividade	Ad-hoc	Ad-hoc	Nativa Sidelink	Integrada (Sat.)
Robustez Doppler	Moderada	Alta	Muito Alta	Extrema
Sincronização	Não exigida	Não exigida	Exigida (GNSS)	Pevasiva (AI)

Fonte**:** Elaborado pelo autor com base em (NAIK *et al.*, 2019; ABD-ELNABY *et al.*, 2024; SáNCHEZ *et al.*, 2025)

Nota**:** BC: *Broadcast*; CP-OFDM: *Cyclic Prefix Orthogonal Frequency Division Multiplexing*; GNSS: *Global Navigation Satellite System*; ISAC: *Integrated Sensing and Communication*; LDPC: *Low-Density Parity-Check*; NGV: *Next Generation V2X*.

estruturais de difração, elevada taxa de absorção atmosférica e severas falhas (*outage*) originadas pelo bloqueio dinâmico gerado pelo próprio tráfego (veículos de grande porte e pedestres), demandando arranjos de antenas estritamente direcionais e complexas matrizes estocásticas e de teoria de filas para modelar matematicamente sua real confiabilidade (MOLTCHANOV *et al.*, 2022). Consequentemente, a pesquisa atual concentra-se em preencher os hiatos dos mecanismos de serviço (*service-level performance*) propondo sub-rogação de tráfego, reservas de banda vitais, sistemas híbridos de predição e gestão inteligente de espectro — como Redes de Atenção para Grafos (GAT) e Aprendizado por Reforço Multiagente (MARL) — com a finalidade de otimizar a coexistência multitecnologia e manter a operação em tempo real irrestrita (TURCANU; AL., 2016).

2.3 Descarregamento de Tarefas

Arquitetura e Funcionamento do Descarregamento de Tarefas

O **descarregamento de tarefas** (ou descarregamento de tarefas computacionais) é uma estratégia que visa transferir a responsabilidade de computar tarefas complexas de dispositivos com recursos limitados para nós de processamento remoto mais poderosos. O objetivo é contornar as restrições locais de bateria, armazenamento e processamento, com o intuito de reduzir o consumo de energia, minimizar a latência e melhorar o desempenho e a qualidade do serviço (QoS) para o usuário.

Em termos de infraestrutura, geralmente o descarregamento de tarefas é implemen-

tado em uma hierarquia de três camadas (A. . . , 2022; THE. . . , 2023). A primeira é composta pelos dispositivos dos usuários (como *smartphones* e sensores IoT) que demandam a execução de tarefas (MOBILE. . . , 2024). A segunda é composta por dispositivos próximos ao usuário que atuam como extensão da nuvem tradicional, fornecendo serviços de computação com tempos de resposta ultrarrápidos (baixa latência) e aliviando o tráfego nos links de comunicação de longa distância (ZHANG *et al.*, 2023a). A terceira é composta por servidores de nuvem tradicionais que dispõem de recursos computacionais e de armazenamento virtualmente ilimitados (REFERENCE. . . , 2022).

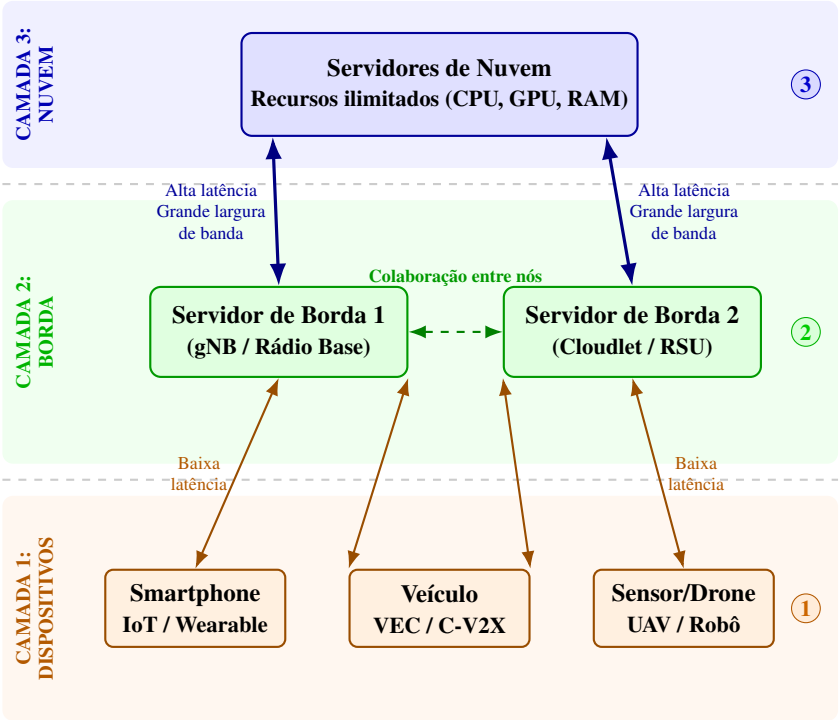

Figura 22 – Arquitetura hierárquica em três camadas para computação em borda e nuvem.

Vale ressaltar que a estratégia de descarregamento pode atuar com **descarregamento total (*full offloading*)** — onde a execução integral de tarefas não fracionáveis é feita no servidor remoto — ou com **descarregamento parcial (*partial offloading*)**, onde algoritmos dividem as sub-tarefas da aplicação para que ocorram computações paralelas tanto localmente quanto nos nós de borda simultaneamente (BOUKERCHE; SOTO, 2020; ZHANG; YI; MA, 2024; ZHANG *et al.*, 2023b; MACH; BECVAR, 2017).

O processo de funcionamento do descarregamento de tarefas ocorre em uma sequência de etapas, iniciando-se com a geração da tarefa (ZHANG; YI; MA, 2024). Quando a estratégia de descarregamento parcial é adotada, as aplicações são particionadas e dividem a tarefa em duas categorias: componentes não descarregáveis, que obrigatoriamente devem

ser executados localmente (como interfaces de usuário ou acesso a sensores), e componentes computacionalmente intensivos, que podem ser descarregados para execução em servidores remotos (MACH; BECVAR, 2017; ZHANG *et al.*, 2023b). Em seguida, realiza-se a fase de decisão, frequentemente apontada como a mais complexa, onde um algoritmo avalia, segundo sua política de funcionamento, se é vantajoso descarregar a tarefa para processamento remoto ou mantê-la local. Caso a decisão seja pelo processamento remoto, o dispositivo negocia a execução da tarefa através de protocolos de comunicação. Após a confirmação da alocação de recursos, o dispositivo transmite os dados (e o código, se necessário) para o servidor escolhido e aguarda o processamento. Por fim, os resultados são retornados e incorporados à aplicação original de forma transparente para o usuário (BOUKERCHE; SOTO, 2020).

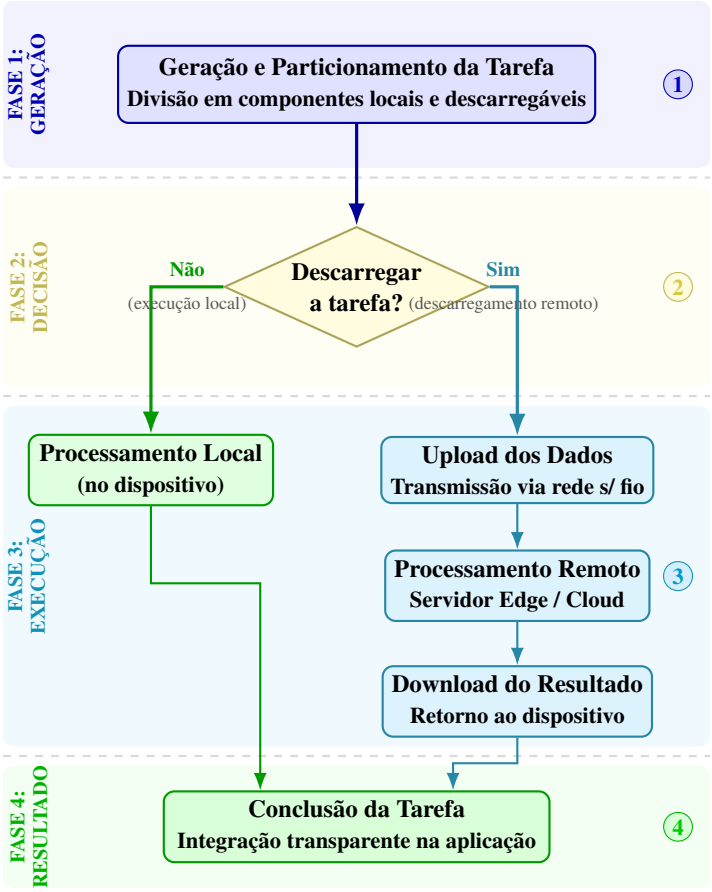

Figura 23 – Fluxograma do processo decisório e ciclo de vida do descarregamento de tarefas.

Vale ainda ressaltar que, durante o processo de geração e modelagem das tarefas, a aplicação pode especificar parâmetros essenciais como a complexidade computacional exigida (frequentemente medida em ciclos de CPU) e o prazo máximo tolerável (*deadline* ou restrição de latência) (LIN *et al.*, 202x; WANG *et al.*, 2024). Esse limite temporal é estipulado para

garantir que todo o ciclo de descarregamento remoto — o qual engloba a transmissão de dados, a espera em filas de recursos (*queuing delay*), o processamento e o retorno dos resultados — seja concluído sem causar degradação na qualidade do serviço ofertado ao usuário (ZHANG *et al.*, 2023b).

2.4 Aprendizado por Reforço

Fundamentos

O RL é um paradigma de Aprendizado de Máquina (*Machine Learning*) (ML) onde o treinamento dos modelos se dá com a interação direta com o ambiente através de ações e a observação da recompensa ou penalização por tal ato (SUTTON; BARTO, 2018). Nela, o agente (aquele que procura aprender as relações intrínsecas do problema que se busca resolver) não tem acesso a nenhum supervisor que indique qual a melhor ação a ser tomada, e nem mesmo a um conjunto de dados de partida rotulados para que ele possa analisar e buscar reconhecer padrões (HU, 2024; SUTTON; BARTO, 2018).

De maneira geral, o aprendizado em problemas de RL ocorre por meio de um ciclo de interação contínua entre o agente e o ambiente, dinâmica que pode ser observada na Figura 24 (HU, 2024; SUTTON; BARTO, 2018). Embora esse mecanismo iterativo de tentativa e erro seja conceitualmente simples, ele serve de base para o desenvolvimento de modelos de Inteligência Artificial (*Artificial Intelligence*) (IA) capazes de resolver problemas complexos de tomada de decisão em áreas desafiadoras, como robótica, condução autônoma e jogos de alto desempenho (HU, 2024). Além disso, essa mesma interação tem sido fundamental para auxiliar no treinamento e alinhamento de Grande Modelo de Linguagem (*Large Language Model*)s (LLMs), empregando algoritmos de otimização de políticas aliados ao Aprendizado por Reforço a partir de Feedback Humano (*Reinforcement Learning from Human Feedback*) (RLHF) para refinar e instruir sistemas avançados, a exemplo do InstructGPT e do ChatGPT (OUYANG *et al.*, 2022; HU, 2024).

Processos de Decisão de Markov (MDP) e seus Componentes

Um MDP é uma estrutura matemática utilizada para modelar problemas de tomada de decisão sequencial sob incerteza. Um problema modelado sob o paradigma MDP é frequentemente representado pela tupla (S, A, P, R, γ). Nela, S representa o espaço de estados,

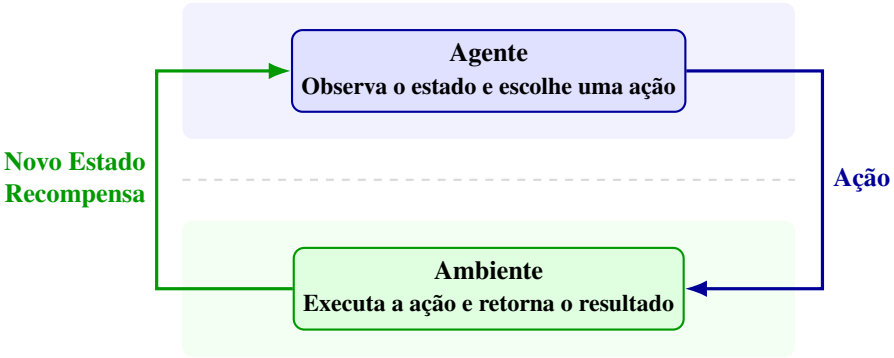

Figura 24 – Ciclo básico de interação Agente-Ambiente no RL. A cada passo, o agente observa o estado atual, escolhe uma ação, e o ambiente responde com uma recompensa e um novo estado.

Fonte**:** Elaborado pelo autor com base em (HU, 2024; SUTTON; BARTO, 2018).

contendo todas as configurações possíveis do ambiente, e A denota o espaço de ações disponíveis para o agente (HU, 2024). A função de transição, $P(s'|s,a)$, define a probabilidade de o ambiente transitar para um estado sucessor s' dado que a ação a foi tomada no estado atual s. Por sua vez, a Função de Recompensa (R) especifica a retribuição numérica imediata (que pode ser positiva ou negativa) indicando o ganho ou custo da transição (SUTTON; BARTO, 2018; HU, 2024). A recompensa esperada para um par estado-ação é formalmente expressa por $R(s,a) = \mathbb{E}[R_t|S_t = s, A_t = a]$ (HU, 2024).

O parâmetro $\gamma \in [0,1]$ atua como um fator de desconto, controlando o peso que o agente dará às recompensas futuras em comparação às imediatas (SUTTON; BARTO, 2018). Além disso, o agente pode seguir uma estratégia para mapear estados e tomar suas ações, mecanismo este conhecido como política (π) (HU, 2024). A dinâmica desse sistema atende rigorosamente à Propriedade de Markov, a qual postula que o futuro independe do passado dado o estado e a ação presentes (SUTTON; BARTO, 2018). Por fim, em cenários onde o agente não observa o estado real, mas recebe apenas uma observação corrompida ou baseada em probabilidades, o modelo é generalizado para os Processo de Decisão de Markov Parcialmente Observável (*Partially Observable Markov Decision Process*)s (POMDPs) (SUTTON; BARTO, 2018; HU, 2024).

Retorno Esperado, Fator de Desconto e Horizontes

O MDP é capaz de modelar problemas que possuem um final natural bem definido, conhecidos na literatura como tarefas episódicas (Horizonte Finito), como uma partida de xadrez, ou problemas em que o agente continua interagindo com o ambiente perpetuamente, chamados de tarefas contínuas (Horizonte Infinito) (SUTTON; BARTO, 2018; HU, 2024). Em tarefas

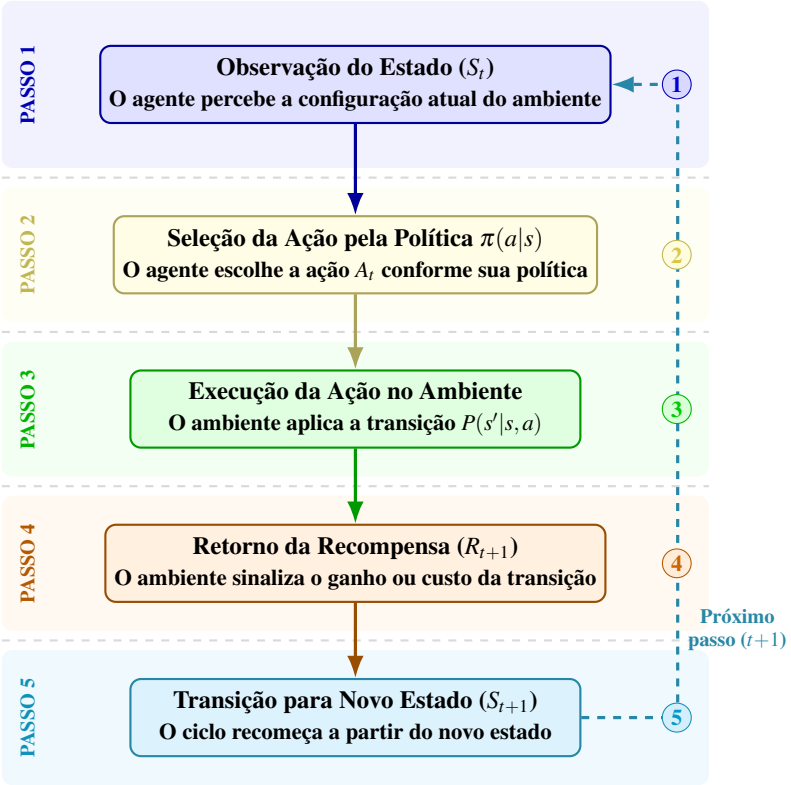

Figura 25 – Sequência de interação em um MDP.

Fonte**:** Elaborado pelo autor com base em (SUTTON; BARTO, 2018).

episódicas, que finalizam em um passo de tempo terminal T, o agente busca maximizar o retorno cumulativo simples, dado pela soma $G_t = R_{t+1} + R_{t+2} + \cdots + R_T$ (SUTTON; BARTO, 2018).

No entanto, para tarefas contínuas (Horizonte Infinito), a simples soma das recompensas ao longo do tempo poderia divergir e tender ao infinito (HU, 2024; SUTTON; BARTO, 2018). Para solucionar esse problema, aplica-se o Fator de Desconto $\gamma \in [0,1)$ (SUTTON; BARTO, 2018; ZHAO, 2024). O Retorno Descontado G_t, iniciado no passo t, é calculado como a soma infinita das recompensas futuras, onde cada recompensa é penalizada exponencialmente pelo quão distante no futuro ela for recebida (SUTTON; BARTO, 2018):

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{2.2}$$

Para garantir matematicamente que o valor desse retorno descontado seja finito, utiliza-se a convergência das séries geométricas (SUTTON; BARTO, 2018; ZHAO, 2024). Caso a recompensa máxima possível do ambiente seja um valor constante R não nulo (por exemplo, se o agente receber $+1$ a cada passo), a soma infinita converge limitando o retorno a $G_t = \sum_{k=0}^{\infty} \gamma^k R = \frac{R}{1-\gamma}$ (SUTTON; BARTO, 2018; ZHAO, 2024).

Além disso, uma propriedade algébrica fundamental do retorno em RL é que a

Equação 2.2 pode ser reescrita de forma exata como uma relação recursiva (HU, 2024; SUTTON; BARTO, 2018). Ela separa a recompensa imediatamente recebida do retorno descontado do próximo passo de tempo (SUTTON; BARTO, 2018; HU, 2024).

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = R_{t+1} + \gamma G_{t+1} \tag{2.3}$$

Esta decomposição recursiva forma a base matemática que torna possíveis as Equações de Bellman e a atualização iterativa das estimativas das funções de valor nos algoritmos de aprendizado (HU, 2024; SUTTON; BARTO, 2018). Em última análise, o objetivo central do agente é maximizar o retorno esperado $\mathbb{E}[G_t]$, ponderando tanto a dinâmica estocástica do ambiente quanto as ações definidas pela sua política, que pode ser determinística ($a = \pi(s)$) ou estocástica ($\pi(a|s) = P(A_t = a|S_t = s)$) (SUTTON; BARTO, 2018; HU, 2024).

Funções de Valor e Equações de Bellman

Em problemas de RL, o agente avalia o quão bom é o seu comportamento ao seguir uma determinada política por meio da estimativa do retorno esperado a longo prazo (SUTTON; BARTO, 2018). Para quantificar formalmente esse desempenho, a literatura estabelece duas abordagens principais: estimar o valor de estar no estado atual (s), ou estimar o valor de selecionar uma ação específica (a) a partir desse estado (s) (HU, 2024; SUTTON; BARTO, 2018). A primeira estimativa é calculada utilizando a Função de Valor de Estado (V^π), enquanto a segunda é obtida por meio da Função de Valor de Ação (Q^π) (HU, 2024; SUTTON; BARTO, 2018). Ambas as funções fundamentam-se em uma propriedade de consistência recursiva, expressas matematicamente pelas Equações de Expectativa de Bellman (SUTTON; BARTO, 2018):

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) \left[r + \gamma V^\pi(s') \right] \tag{2.4}$$

$$Q^\pi(s,a) = \sum_{s',r} p(s',r|s,a) \left[r + \gamma \sum_{a'} \pi(a'|s') Q^\pi(s',a') \right] \tag{2.5}$$

Também é possível definir a Função de Vantagem (*Advantage*), que mede quão melhor é uma ação isolada comparada à média das demais ações daquele estado (WANG *et al.*, 2016):

$$A^\pi(s,a) = Q^\pi(s,a) - V^\pi(s) \tag{2.6}$$

Métodos de Aprendizado e Diferença Temporal

De forma geral, durante o ciclo de interação, o agente enfrenta o **Dilema Exploração-Explotação** (*Exploration-Exploitation Dilemma*), precisando decidir continuamente entre explorar o ambiente para descobrir novas ações e estados, e explotar o conhecimento já adquirido para maximizar sua recompensa cumulativa (SUTTON; BARTO, 2018; HU, 2024). O balanceamento adequado entre essas duas estratégias é fundamental para evitar a convergência prematura para comportamentos subótimos e garantir a descoberta das melhores decisões (HU, 2024).

Quanto ao conhecimento prévio sobre as dinâmicas do ambiente (as regras de transição e recompensa), a literatura divide os métodos em duas categorias principais (SUTTON; BARTO, 2018; MOERLAND *et al.*, 2023). Em abordagens *Model-Based* (Baseadas em Modelo), o agente possui ou aprende um modelo matemático do ambiente, permitindo o uso de técnicas de planejamento como a Programação Dinâmica para simular trajetórias e antecipar ações (SUTTON; BARTO, 2018; HU, 2024). Por outro lado, nas abordagens *Model-Free* (Livres de Modelo), o agente não constrói um modelo das regras do jogo, mas aprende as funções de valor ou as políticas diretamente a partir da experiência obtida por tentativa e erro no ambiente (HU, 2024; SUTTON; BARTO, 2018).

Para resolver problemas *Model-Free*, destacam-se duas estratégias: os *Métodos de Monte Carlo*, que atualizam as estimativas de valor apenas ao final de um episódio, utilizando o retorno total e real acumulado (SUTTON; BARTO, 2018; HU, 2024) e através da *Aprendizagem por Diferença Temporal (TD Learning)*, que atualiza suas estimativas a cada passo, utilizando o retrocesso (*bootstrapping*) embasado na estimativa de valor do próximo estado e na recompensa imediata (SUTTON; BARTO, 2018).

Aprendizagem por Reforço Profundo (DRL)

A era profunda começa integrando Redes Neurais à função Q. A clássica **Rede Q Profunda (DQN)** (MNIH *et al.*, 2015) minimiza o Erro TD usando um Replay Buffer e Redes Alvo (θ^-) estáticas:

$$L(\theta) = \mathbb{E}_{(s,a,r,s')\sim D}\left[\left(r + \gamma \max_{a'} Q(s',a';\theta^-) - Q(s,a;\theta)\right)^2\right] \tag{2.7}$$

Evoluções incluem a **Repetição de Experiência Priorizada (PER)**, que amostra transições com base na magnitude do erro TD em vez de uniforme (SCHAUL *et al.*, 2016), a já

citada **Double DQN**, e a **Dueling DQN** que ramifica a rede neural final estimando separadamente valor (V) e vantagem (A) (WANG *et al.*, 2016).

2.4.1 Policy Gradients e REINFORCE

Nos **Gradientes de Política**, não calculamos o valor para extrair política; otimizamos diretamente uma política parametrizada π_θ. O **Teorema do Gradiente de Política** embasa essas atualizações estocásticas. Utiliza-se o **Truque da Razão de Verossimilhança** $\nabla_\theta P = P \nabla_\theta \log P$ para derivar a expectativa (SUTTON; BARTO, 2018):

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} \left[\nabla_\theta \log \pi_\theta(A_t|S_t) Q^\pi(S_t, A_t) \right] \tag{2.8}$$

A versão de Monte Carlo é o famoso **Algoritmo REINFORCE**, trocando Q^π pelo retorno do episódio amostrado G_t (WILLIAMS, 1992).

2.4.2 Actor-Critic, PPO, TRPO e SAC

Para diminuir a alta variância dos gradientes, introduzem-se as **Arquiteturas Ator-Crítico** (SUTTON; BARTO, 2018): o Ator ajusta as probabilidades $\pi(a|s)$, enquanto o Crítico estima o valor $V(s)$ que atua como baseline para um Erro TD redutor de ruído de gradiente. Tais arquiteturas permitiram resolver **Espaços de Ação Contínuos**.

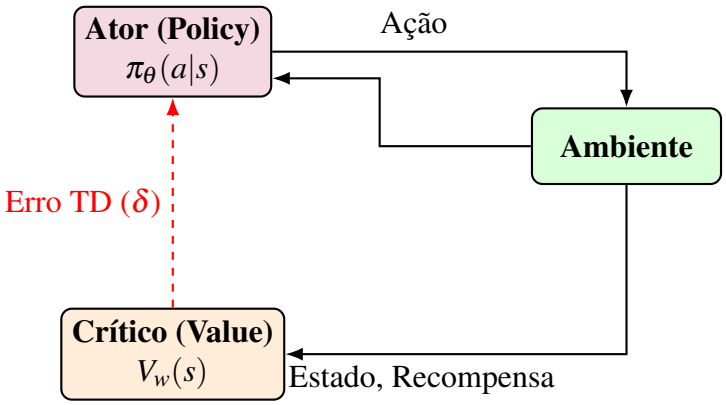

Figura 26 – Dinâmica Ator-Crítico.

Fonte**:** Elaborado pelo autor com base em (SUTTON; BARTO, 2018).

Para mitigar o colapso por passos muito largos nas atualizações de gradiente contínuo:

- **TRPO:** Impõe uma restrição (Trust Region) usando Divergência KL para travar passos agressivos (SCHULMAN *et al.*, 2015).

- **PPO:** Muito mais simples que TRPO, ele "corta"(clip) a função objetivo de modo a desincentivar uma política nova de se afastar demais da antiga (SCHULMAN *et al.*, 2017):

$$L^{CLIP}(\theta) = \mathbb{E}\left[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t)\right] \tag{2.9}$$

  onde $r_t(\theta) = \frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}$.
- **DDPG:** Ator-Crítico para espaços determinísticos contínuos usando técnicas de replay do DQN (SUTTON; BARTO, 2018).
- **SAC:** Abordagem focada em regularização de entropia; o agente tenta escalar recompensas ao máximo mas preservando a máxima entropia (agindo aleatoriamente onde possível) (HAARNOJA *et al.*, 2018).

2.4.3 Avanços e Extensões

Dentre outras áreas sofisticadas constam o **Aprendizado por Reforço Multi-Agente (MARL)**, onde agentes interagem no mesmo ambiente. O **Independent Q-Learning** treina agentes individuais tratando os outros como parte estacionária do ambiente, o que na prática gera um POMDP instável. O **Curriculum Learning** ataca a **Lida com Recompensas Esparsas** submetendo o agente a tarefas crescentemente difíceis. **Aprendizado por Reforço Inverso (IRL)** decodifica a função de recompensa baseando-se num especialista humano, enquanto o **Aprendizado por Reforço Offline** procura aprender comportamentos unicamente consumindo um dataset preexistente gigante, sem tocar ou explorar ativamente o simulador ao vivo.

2.5 Contexto

2.6 Considerações Finais

3 REVISÃO DE LITERATURA

Este capítulo tem como objetivo apresentar uma revisão bibliográfica aprofundada dos trabalhos recentes e relevantes para o desenvolvimento desta proposta. Os critérios de seleção englobaram pesquisas focadas na interseção entre comunicação veicular emergente e soluções de aprendizado de máquina adaptativo voltadas para o descarregamento de tarefas dinâmico.

Para classificar e relacionar o estado da arte das soluções de descarregamento de tarefas em ambientes de Computação de Borda Veicular (*Vehicular Edge Computing*) (VEC) e MEC, adotou-se uma versão adaptada da taxonomia proposta em (SOUZA *et al.*, 2020), sendo ela dividida em duas vertentes estruturais: **Padrão de Comunicação**, que avalia as tecnologias de rede e os servidores utilizados; e **Problema**, que analisa as estratégias com ênfase em modelos Aprendizado por Reforço Profundo (*Deep Reinforcement Learning*) (DRL). Dessa maneira, os artigos relacionados foram classificados conforme a Figura 27.

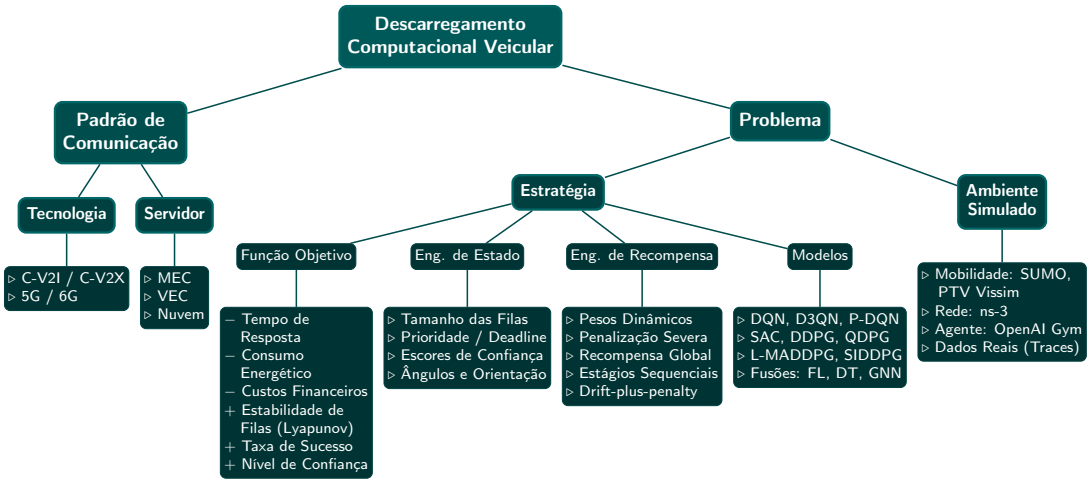

Figura 27 – Taxonomia adaptada para classificação dos trabalhos relacionados em descarregamento computacional veicular, com ênfase na modelagem de Aprendizado por Reforço Profundo (DRL) e ambiente de simulação.

Fonte**:** Adaptado de Souza *et al.* (2020).

3.1 Padrão de Comunicação

No descarregamento de tarefas, o cenário de comunicação celular vem ganhando bastante destaque. Neste quesito, suas tecnologias vêm evoluindo rapidamente e ditam a maioria das pesquisas aqui apresentadas. A seguir são apresentados alguns trabalhos que utilizam tecnologias 5G e além (Além do 5G (*Beyond 5G*) (B5G)/Sexta Geração de Redes Móveis (*Sixth*

Generation) (6G)) para atender às exigentes demandas relacionadas a aplicações veiculares.

3.1.1 Tecnologia

A evolução das tecnologias de comunicação veicular destaca a transição de padrões tradicionais, como o *Dedicated Short-Range Communications* (DSRC) e o IEEE 802.11bd, para a comunicação celular aliada à IA. Essa mudança visa, sobretudo, possibilitar baixas latências e alta vazão de dados em cenários de alta mobilidade, contribuindo para resolver o problema de descarregamento de tarefas. Nesse contexto, diversos trabalhos, como os de (MOGHADDASI *et al.*, 2023; SIDWINI *et al.*, 2024; LI *et al.*, 2025; MEGHAMALA; PAUL; KUMAR, 2025), utilizam interfaces C-V2X e arquiteturas de borda para o compartilhamento de informações em aplicações veiculares avançadas.

O estudo de (MOGHADDASI *et al.*, 2023) propõe um algoritmo de DRL, especificamente o Redes Q-Deep Duplas (*Double Deep Q-Network*) (DDQN), em redes 5G para solucionar o problema de descarregamento de tarefas utilizando a comunicação V2I para alcançar eficiência energética e a diminuição da latência. O trabalho de (SIDWINI *et al.*, 2024) explora o uso de algoritmos avançados de DRL, como o Ator-Crítico Suave (*Soft Actor-Critic*) (SAC), para otimizar o descarregamento dinâmico entre dispositivos locais, servidores de borda e a nuvem, equilibrando o consumo de energia e o atraso na execução. Em um cenário direcionado aos sistemas 6G, (LI *et al.*, 2025) introduz um esquema inteligente baseado em Redes Q-Deep (*Deep Q-Network*) (DQN) em redes V2X assistidas por MEC para otimizar conjuntamente a associação aos servidores, a taxa de descarregamento de tarefas e a aceleração dos veículos. Essa abordagem visa minimizar o atraso do sistema e evitar colisões de trânsito, utilizando uma função de recompensa segmentada que respeita restrições de atraso, energia e segurança. Por fim, (MEGHAMALA; PAUL; KUMAR, 2025) propõe um framework de Aprendizado por Reforço Multiagente (*Multi-Agent Reinforcement Learning*) (MARL) para redes 5G que combina o algoritmo SAC com arquiteturas hierárquicas (Multiagente Twin Delayed DDPG (*Multi-Agent Twin Delayed Deep Deterministic Policy Gradient*) (MATD3) e *Task Descriptor Policy Gradient* (TD2PG)). Essa solução visa a alocação dinâmica de subcanais, potência de transmissão e recursos computacionais em servidores MEC, levando em consideração a mobilidade dos usuários e o isolamento das fatias de rede (*network slicing*).

3.1.2 Servidor

Quando há necessidade de transferência de responsabilidade de processamento de tarefas, existem três opções viáveis: processar as tarefas em (i) um dispositivo de infraestrutura de borda, (ii) recursos ociosos das unidades processadoras dos veículos vizinhos, ou (iii) uma robusta infraestrutura de nuvem, que apresenta maior capacidade, mas latência consideravelmente superior. A seguir, é descrito como as principais opções locais foram modeladas.

MEC

Servidores MEC contribuem significativamente para atender exigências de URLLC em 5G NR. Eles ficam localizados na borda da rede e podem ser constituídos de equipamentos robustos, capazes de auxiliar no processamento pesado de tarefas delegadas por outros dispositivos com recursos limitados.

Nesse contexto, esses servidores frequentemente estão conectados a Unidade de Borda de Estrada (*Road Side Unit*) (RSU) e estações base para oferecer suporte computacional de baixa latência aos veículos. Aproveitando essa infraestrutura de borda, o estudo de (ZHAO *et al.*, 2025) propõe o esquema DQN Preditivo e Emparelhamento de Kuhn-Munkres (*Predictive DQN and Kuhn-Munkres scheme*) (PDQKM) para otimizar o descarregamento de múltiplas tarefas, permitindo reduzir a latência total do sistema. Por outro lado, o trabalho de (WU *et al.*, 2025) utiliza Redes Adversárias Generativas (*Generative Adversarial Networks*) (GAN) para expandir amostras de tarefas evitando o desequilíbrio de dados, criando um modelo de Aprendizado Federado (*Federated Learning*) (FL) para realizar o descarregamento de tarefas de forma energeticamente eficiente em servidores MEC. O estudo de (MOHAMMAD *et al.*, 2025) apresenta o framework EMEC-IoVTOF, que integra DRL com a técnica de Otimização por Enxame de Partículas (*Particle Swarm Optimization*) (PSO) para otimizar a alocação de recursos em sistemas IoV. A solução calcula custos de descarregamento para evitar a convergência para ótimos locais, conseguindo reduções significativas de latência e consumo de energia, além de contornar restrições de largura de banda em cenários veiculares dinâmicos. Por sua vez, o estudo de (LIU *et al.*, 2024) utiliza o método de aproximação de Bernstein para converter restrições probabilísticas de interferência em formato tratável, minimizando uma função de utilidade que equilibra atrasos na transmissão e na computação para o Computação de Borda de Múltiplos Acessos Assistida por Nuvem (*Cloud-assisted Multi-access Edge Computing*) (C-MEC).

VEC

VEC distribui poder computacional formando micro-nuvens entre os próprios veículos na estrada, empregando recursos ociosos de suas unidades embarcadas (Unidade de Bordo (*On-Board Unit*) (OBU)) para auxiliar vizinhos próximos através de canais de comunicação direta, frequentemente desassociados de infraestruturas estáticas da pista. O estudo de (XIE *et al.*, 2025) propõe utilizar Superfície Inteligente Reconfigurável (*Reconfigurable Intelligent Surface*) (RIS) juntamente com VEC para reduzir custos de implantação, ao mesmo tempo que busca maximizar Eficiência Operacional do Sistema (*System Operation Efficiency*) (SOE) via algoritmo Otimização de Política Proximal (*Proximal Policy Optimization*) (PPO), otimizando conjuntamente decisões de descarregamento, alocação de recursos computacionais e vetores de mudança de fase. Por sua vez, (WU; GU; LIANG, 2025) utiliza FL e Ator-Crítico Determinístico Profundo Multiagente (*Multi-Agent Deep Deterministic Policy Gradient*) (MADDPG), empregando mecanismos de incentivo baseados em reputação para determinar a proporção ideal de recursos cedidos por veículos vizinhos, visando minimizar latência e consumo de energia e garantindo alta taxa de conclusão em tarefas computacionalmente intensivas. O trabalho de (LONG *et al.*, 2025) desenvolve o algoritmo Otimização de Alocação de Recursos e Divisão de Tarefas Nuvem-Terminal (*Cloud-Terminal Task Splitting and Resource Allocation Optimization*) (CTS-RAO), que integra dispositivos finais, borda veicular e nuvem para realizar descarregamento parcial de tarefas, separando o problema em subproblemas convexos para otimizar de forma colaborativa o *task splitting* (taxa de divisão de tarefas) e a alocação de recursos computacionais, alcançando equilíbrio de desempenho global do sistema. Em (ABBAS; XU; ZHANG, 2024), propõe-se um algoritmo baseado em aprendizado descentralizado colaborativo, que orquestra a execução concorrente de tarefas fragmentadas pelos veículos presentes na área de cobertura, otimizando conjuntamente a alocação de canais sem fio com os recursos computacionais. Dessa forma, minimiza-se a latência total e o consumo de energia em ambientes veiculares dinâmicos.

Discussão

Analisando a Tabela 3, constata-se forte tendência de padronização de tecnologias celulares avançadas para comunicação veicular. Grande parte dos trabalhos recentes analisados concentra-se na utilização de conectividade V2I via redes 5G e 6G. Em relação à comunicação entre os nós, embora o padrão C-V2X englobe diferentes interfaces, diversos trabalhos referem-se estritamente à utilização das interfaces *sidelink* destas comunicações para troca direta de dados

Tabela 3 – Resumo dos aspectos de Padrão de Comunicação, Servidor e Condições de Ambiente dos trabalhos relacionados

Referência	Tecnologia		Servidor			Observabilidade Parcial	Canal Perfeito	Carga de Trabalho
	V2I	Sidelink (V2V)	MEC	VEC	Nuvem	(Incerteza de Estado)		(Diferentes regimes)
(MOGHADDASI *et al.*, 2023)	✓		✓				✓	✓
(SIDWINI *et al.*, 2024)	✓		✓		✓		✓	
(LI *et al.*, 2025)		✓	✓				✓	
(MEGHAMALA; PAUL; KUMAR, 2025)	✓		✓				✓	
(ZHAO *et al.*, 2025)	✓		✓				✓	
(WU *et al.*, 2025)	✓		✓				✓	
(MOHAMMAD *et al.*, 2025)		✓	✓				✓	
(LIU *et al.*, 2024)	✓		✓		✓			
(XIE *et al.*, 2025)	✓			✓			✓	
(WU; GU; LIANG, 2025)		✓		✓			✓	
(LONG *et al.*, 2025)	✓	✓		✓	✓		✓	
(ABBAS; XU; ZHANG, 2024)	✓			✓			✓	

(V2V). Já em relação à infraestrutura, a adoção de servidores MEC centralizados em unidades RSU ainda é predominante, mas observa-se tendência crescente de pesquisas que exploram VEC, tratando os próprios veículos como provedores de recursos. Trabalhos como os de (LIU *et al.*, 2024) e (LONG *et al.*, 2025) adotam arquiteturas colaborativas integrando MEC com nuvem e VEC com nuvem, respectivamente.

Outro aspecto identificado foi a ausência de tratamento para a observabilidade parcial, caracterizada na tabela pela coluna "Incerteza de Estado". Todos os trabalhos identificados na tabela modelam o ambiente assumindo conhecimento perfeito do cenário, como a disponibilidade de CPU dos servidores no exato momento da tomada de decisão. Dessa forma, agentes independentes podem decidir descarregar tarefas para um mesmo servidor simultaneamente com base em informações desatualizadas. Além disso, não há menção nos trabalhos sobre imperfeições do canal de comunicação. Portanto, assumir tais características cria políticas de decisão pouco robustas frente à dinâmica real.

Outra limitação identificada diz respeito à modelagem de cargas de trabalho. Com exceção do estudo de (MOGHADDASI *et al.*, 2023), os demais trabalhos avaliam seus algoritmos sob regimes de tráfego constantes ou com taxa de chegada fixa por episódio. Em cenários de tráfego reais, eventos imprevisíveis podem causar rajadas instantâneas (*bursts*) no envio de pacotes críticos, alterando a distribuição de chegada das tarefas. Modelos DRL treinados exclusivamente sem variação dinâmica de carga tendem a sofrer degradação de desempenho com tais mudanças de regime.

Nesse contexto, o modelo proposto neste trabalho visa endereçar essas lacunas ao modelar, desde a concepção do ambiente, tais dificuldades e estocasticidades inerentes a redes veiculares reais, conforme a adoção das tecnologias supramencionadas.

3.2 Problema

Com a infraestrutura de comunicação estabilizada, a escolha de abordagens apropriadas constitui um passo crítico para a garantia dos requisitos no ambiente veicular. A formulação de soluções para o descarregamento de tarefas dinâmico e em tempo real apresenta elevada complexidade. Para contornar essa dificuldade, diversos trabalhos na literatura optam por simplificar o escopo, desenvolvendo abordagens focadas em uma única métrica, como a minimização exclusiva da latência ou do consumo de energia (FENG *et al.*, 2017; HOU *et al.*, 2016; REN *et al.*, 2018; REN *et al.*, 2019; ZHANG *et al.*, 2019). No entanto, o estudo de (QIN *et al.*, 2020) enfatiza que otimizar um único objetivo isoladamente não reflete a realidade das redes, enquanto (ZHANG; YI; MA, 2024) reitera que a busca por um compromisso dinâmico entre tempo de resposta e consumo energético transforma a alocação em um problema incerto de otimização multiobjetivo NP-difícil. Diante dessa constatação, observa-se a necessidade do desenvolvimento de políticas que considerem múltiplos critérios simultaneamente, com o intuito de projetar propostas robustas e capazes de atender às demandas operacionais e funcionais de longo prazo.

A modelagem de um cenário realista precisa lidar fundamentalmente com incertezas espaciais da rede. A alta velocidade dos veículos altera significativamente a infraestrutura veicular, mascarando os estados reais e comprometendo a acurácia dos dados divulgados pelos nós de computação (LIU *et al.*, 2024). A somatória entre a imprevisibilidade de processos no interior da borda (ABBAS; XU; ZHANG, 2024) e o natural decréscimo de precisão proveniente do atraso por telemetria exige uma abordagem maleável. Decisões sustentadas integralmente por lógicas determinísticas tornam-se insatisfatórias, contribuindo que os modelos não atendam adequadamente os requisitos de qualidade no descarregamento de tarfas (KANDALI *et al.*, 2025; ZHAO *et al.*, 2025).

3.2.1 Estratégia

Para contornar grande parte dos vieses supracitados, a literatura contemporânea aponta uma considerável substituição do uso de heurísticas e meta-heurísticas por soluções mais sofisticados e adaptativos. A respeito desta transformação, destaca-se a utilização de DRL, por conta de sua capacidade de aprimorar sequências de ações de longo prazo extraídas através de intensas interações com ambiente simulado.

De fato, o escopo científico atual tem explorado ativamente o uso de diversas

estatégias integradas ao DRL. Uma delas é a integração com aprendizado FL, que permite o treinamento colaborativo de modelos DRL entre múltiplos agentes, preservando a privacidade dos dados locais (CHEN *et al.*, 2025). Outra frente mescla esquemas DRL com tecnologia Gêmeo Digital (*Digital Twin*) (DT), possibilitando que soluções sejam testadas e simuladas virtualmente antes da execução no ambiente físico (WEI *et al.*, 2024). Para lidar com o vasto espaço de estados e com cenários altamente variáveis, pesquisas recentes fundem arquiteturas DRL com redes Redes Neurais em Grafos (*Graph Neural Networks*) (GNN) para capturar de forma eficiente as relações e as dependências espaciais entre os nós veiculares (WANG *et al.*, 2024; TANG *et al.*, 2024). Adicionalmente, métodos Aprendizado por Transferência (*Transfer Learning*) (TL) têm sido utilizados para acelerar a adaptação de veículos recém-conectados em infraestruturas baseadas em SDN, onde a separação entre os planos de controle e de dados facilita a gerência global (BAKER *et al.*, 2024). Por fim, destaca-se a incorporação da teoria de otimização de Lyapunov acoplada a métodos DRL para garantir matematicamente a estabilidade contínua das filas de tarefas a longo prazo (KUMAR; ZHAO; FERNANDO, 2023).

Função Objetivo

Além do compromisso entre a minimização da latência de processamento e a redução do consumo de energia, a literatura recente incorpora a otimização de custos operacionais e financeiros da rede (MA *et al.*, 2025). A estabilidade das filas de tarefas (*queue stability*) a longo prazo também é um objetivo considerado, frequentemente abordado por meio da otimização de Lyapunov acoplada a técnicas de aprendizado (KUMAR; ZHAO; FERNANDO, 2023). Outros estudos buscam maximizar a taxa de sucesso das tarefas sob restrições de prioridade e da capacidade dos nós de computação (KUMARI *et al.*, 2025). Adicionalmente, o gerenciamento de confiança (*trust management*) dos nós de borda desponta como um objetivo crítico em infraestruturas SDN para evitar descarregamentos falhos ou maliciosos (BAKER *et al.*, 2024).

Engenharia de Estado e Recompensa

No MDP, a engenharia do espaço de estado não busca prever matematicamente as transições do sistema, uma vez que algoritmos DRL se destacam justamente por gerenciar o controle em ambientes estocásticos e dinâmicos sem conhecimento prévio dessas transições (FAN; CAI, 2024). Em vez disso, o estado é projetado para permitir que o agente avalie diretamente a dinâmica da rede com base nos resultados observados. Para isso, o espaço de estado deve

utilizar métricas além das básicas, incorporando variáveis que capturem a dinamicidade dos nós de computação (KUMAR; ZHAO; FERNANDO, 2023) ou até mesmo escores de confiança dos dispositivos candidatos (BAKER *et al.*, 2024). A literatura recente expande ainda mais essa abstração ao integrar as características das tarefas — englobando requisitos de recursos, níveis de prioridade e prazos máximos toleráveis (*deadlines*) (FAN; CAI, 2024; WEI *et al.*, 2024). Além disso, para refinar a percepção física, as pesquisas incluem o ângulo de desvio e a orientação direcional dos veículos em relação aos servidores. Essa consciência espacial de granularidade fina complementa o estado atual, otimizando a escolha do nó alvo de forma proativa (FARIMANI *et al.*, 2024).

A respeito da função de recompensa, é uma boa prática (SUTTON; BARTO, 2018) realizar o dimensionamento adequado (*scaling*) das métricas e a normalização dos dados para evitar que uma única variável domine o processo de convergência. Além disso, alguns trabalhos utilizam pesos dinâmicos em vez de estáticos, ajustando-os em tempo real de acordo com as condições momentâneas da rede e com o nível de urgência das tarefas (KUMARI *et al.*, 2025; FAN; CAI, 2024; SHI; CHEN; ZHU, 2023). Já a penalização para quando um agente escolhe uma ação ruim — como a violação do tempo máximo tolerável (*deadline*) ou quebras de comunicação por evasão de cobertura — é integrada à recompensa para guiar o agente a priorizar o cumprimento dos requisitos de latência e confiabilidade. Também se observa uma forte transição para mecanismos de recompensa globais, nos quais os agentes colaboram buscando a eficiência sistêmica da rede, mesmo que em detrimento do custo ótimo individual imediato (FARIMANI *et al.*, 2024). Em cenários de descarregamento parcial, a recompensa é formulada dividindo a ação em múltiplos estágios sequenciais, avaliando o impacto do particionamento da tarefa de forma independente da alocação de recursos (TIAN *et al.*, 2025). Por fim, a teoria de Lyapunov é frequentemente utilizada na recompensa por meio de funções *drift-plus-penalty*, garantindo matematicamente que o agente seja penalizado caso a redução excessiva do consumo energético coloque em risco a estabilidade das filas do sistema a longo prazo (KUMAR; ZHAO; FERNANDO, 2023).

Modelos

No que tange aos modelos, existem diversos trabalhos focados em otimizar a forma como o agente observa o estado e seleciona ações eficientemente. Variantes baseadas em valor, como redes DQN aprimoradas, realizam a seleção de servidores reconhecendo que nem todas

as tarefas computacionais geradas possuem a mesma importância ou urgência (KUMARI *et al.*, 2025). Para espaços de ação contínuos, arquiteturas Ator-Crítico dominam o cenário. O algoritmo SAC é empregado para evitar a convergência prematura para ótimos locais, utilizando a maximização da entropia estocástica para explorar melhor as opções de descarregamento e *caching* (BAO *et al.*, 2025). Para lidar com o problema de espaços de ação híbridos — nos quais decisões discretas de seleção de servidor são combinadas com a alocação contínua de recursos computacionais —, alguns trabalhos propõem métodos como o algoritmo Rede Q Profunda Parametrizada (*Parametrized Deep Q-Network*) (P-DQN) (MA *et al.*, 2025) ou mesmo fusões entre modelos, como o Gradiente de Política com Q-Learning e DDPG (*Q-learning and Deep Deterministic Policy Gradient*) (QDPG), que une as arquiteturas Gradiente de Política Determinístico Profundo (*Deep Deterministic Policy Gradient*) (DDPG) e Rede Q Profunda Dupla com Dueling (*Dueling Double Deep Q-Network*) (D3QN) aliadas a algoritmos de clusterização *K-Means* (WEI *et al.*, 2024). Em sistemas compostos por múltiplos agentes, o modelo MADDPG com Otimização de Lyapunov (*Lyapunov-based Multi-Agent Deep Deterministic Policy Gradient*) (L-MADDPG) utiliza a otimização de Lyapunov para garantir matematicamente a estabilidade do sistema a longo prazo (KUMAR; ZHAO; FERNANDO, 2023), enquanto abordagens como o modelo DDPG com Iteração de Estados Internos Sequenciais (*Sequential Internal-state Deep Deterministic Policy Gradient*) (SIDDPG) iteram múltiplos estados internamente para refinar o particionamento de sub-tarefas de forma sequencial (TIAN *et al.*, 2025). A Tabela 4 mapeia alguns algoritmos DRL ao tipo de espaço de ação adequado.

Tabela 4 – Classificação dos algoritmos clássicos de DRL quanto à adequação ao espaço de ação

Algoritmo DRL	**Espaço de Ação**	**Referência Base**
DQN (*Deep Q-Network*)	Discreto	(UDDIN; ZHANG; SAKR, 2025; FARIMANI *et al.*, 2024)
Double DQN	Discreto	(UDDIN; ZHANG; SAKR, 2025)
Dueling DQN	Discreto	(UDDIN; ZHANG; SAKR, 2025)
DDPG (*Deep Deterministic Policy Gradient*)	Contínuo	(UDDIN; ZHANG; SAKR, 2025; FARIMANI *et al.*, 2024)
TD3 (*Twin Delayed DDPG*)	Contínuo	(UDDIN; ZHANG; SAKR, 2025)
PPO (*Proximal Policy Optimization*)	Discreto e Contínuo	(UDDIN; ZHANG; SAKR, 2025)
TRPO (*Trust Region Policy Optimization*)	Discreto e Contínuo	(UDDIN; ZHANG; SAKR, 2025)
SAC (*Soft Actor-Critic*)	Contínuo	(UDDIN; ZHANG; SAKR, 2025; FARIMANI *et al.*, 2024)

Ambiente Simulado

O treinamento e a validação de algoritmos de aprendizado DRL voltados para redes veiculares exigem ambientes simulados capazes de replicar a natureza não estacionária e volátil

do mundo real. Diferente de aplicações computacionais estáticas, os modelos precisam interagir com um ecossistema que engloba tanto a física da movimentação quanto a complexidade das comunicações sem fio e da carga de processamento (UDDIN; ZHANG; SAKR, 2025).

Para modelar a mobilidade com precisão, simuladores de tráfego microscópico, como o *SUMO* (Simulation of Urban MObility) (LOPEZ *et al.*, 2018) e o *PTV Vissim* (PTV Group, 2020), são amplamente adotados na literatura (SOUZA *et al.*, 2021; KUMAR; ZHAO; FERNANDO, 2023). Ferramentas desse tipo permitem a criação de malhas rodoviárias e urbanas e simulam o comportamento dinâmico dos veículos por meio de modelos matemáticos, capturando variações de velocidade, aceleração e respostas a semáforos (LI *et al.*, 2025). Em paralelo, a dinâmica das comunicações — que inclui o desvanecimento do canal, perdas de propagação e bloqueios físicos (condições de visada *LoS/NLoS*) — é frequentemente emulada por simuladores de rede de eventos discretos, destacando-se o ns-3, o qual costuma ser integrado ao SUMO para formar plataformas de co-simulação (SOUZA *et al.*, 2021; UDDIN; ZHANG; SAKR, 2025).

Em relação ao treinamento do modelo de inteligência artificial, o ambiente de simulação é abstraído matematicamente para que o agente observe os estados e tome decisões. Para viabilizar esse treinamento, trabalhos recentes constroem ambientes customizados baseados em padrões como o *OpenAI Gym* (BROCKMAN *et al.*, 2016), que gerenciam o ciclo de observação do estado, execução da ação e recebimento da recompensa (UDDIN; ZHANG; SAKR, 2025) para treinar e otimizar os pesos das redes neurais (MOGHADDASI; RAJABI; GHAREHCHOPOGH, 2024; KUMAR; ZHAO; FERNANDO, 2023; WU *et al.*, 2025).

Por fim, para evitar que o treinamento ocorra de forma puramente teórica, a literatura atual enfatiza o uso de dados do mundo real (*real-world traces*) dentro do ambiente de simulação (FARIMANI *et al.*, 2024). Algumas abordagens incorporam trajetórias extraídas de frotas reais ou bases de dados de servidores comerciais — como o *Google Cluster Dataset* — para emular as flutuações estocásticas na geração de tarefas e a exigência de recursos de CPU, Memória e Largura de Banda (LONG *et al.*, 2025). Essa imersão de dados reais no ambiente simulado garante que as políticas de descarregamento aprendidas pelo agente DRL sejam aplicáveis e estáveis diante das dinâmicas de arquiteturas VEC no mundo físico.

Discussão

Tabela 5 – Análise comparativa dos trabalhos relacionados por Função Objetivo, Estado, Recompensa e Ambiente Simulado

Referência	Função Objetivo				Estado				Recompensa					Ambiente Simulado			
										Pesos		Penalização		Mobilidade		DES	
	Latência	**Energia**	**Utilidade**	**Financeiro**	**Tarefa**	**Recursos**	**Tendências**	**Escore**	**Escalonamento**	**Estáticos**	**Dinâmicos**	**Discreta**	**Contínua**	**SUMO**	**Vissim**	**Customizado**	**Simulador**
(BAKER *et al.*, 2024)	✓	✓	✓			✓		✓	✓	✓		✓				✓	
(WEI *et al.*, 2024)	✓	✓			✓	✓			✓	✓			✓			✓	
(CHEN *et al.*, 2025)	✓					✓	✓			✓		✓				✓	
(MA *et al.*, 2025)	✓	✓		✓		✓			✓	✓		✓				✓	
(KUMAR; ZHAO; FERNANDO, 2023)	✓	✓	✓			✓	✓		✓				✓	✓	✓	✓	
(KUMARI *et al.*, 2025)	✓	✓	✓		✓	✓			✓		✓	✓				✓	
(TIAN *et al.*, 2025)	✓	✓				✓			✓	✓		✓	✓			✓	
(BAO *et al.*, 2025)	✓	✓				✓			✓	✓			✓			✓	
(FAN; CAI, 2024)	✓	✓			✓	✓					✓	✓				✓	
(FARIMANI *et al.*, 2024)	✓	✓	✓				✓					✓				✓	
(SHI; CHEN; ZHU, 2023)	✓	✓									✓					✓	

Segundo (MIRIYALA; CHIRRA, 2025), apesar dos notáveis avanços proporcionados pela integração do DRL no descarregamento de tarefas, a literatura recente aponta limitações que dificultam que os modelos teóricos sejam utilizados no mundo real. Uma análise rigorosa conduzida por (MIRIYALA; CHIRRA, 2025) revela que a maioria das abordagens atuais sofre de simplificações excessivas na modelagem do ambiente. Frequentemente, os trabalhos utilizam representações de estado baseadas em vetores planos (*flat vectors*), o que ignora as complexas relações estruturais e topológicas entre os veículos e a infraestrutura. Essa lacuna evidencia a necessidade de incorporar arquiteturas diferentes, como as GNN para extrair representações topológicas antes da tomada de decisão. Além disso, os ambientes simulados costumam assumir canais de comunicação idealizados e conectividade persistente, negligenciando falhas físicas comuns nas redes veiculares, como quedas intermitentes de conexão (*dropouts*) (MIRIYALA; CHIRRA, 2025).

Outra lacuna está relacionada a carga computacional imposta pelos próprios modelos de aprendizado de máquina. Grande parte das pesquisas assume que os servidores de borda possuem recursos substanciais de hardware, deixando um vácuo no estudo onde dispositivos possuem severas restrições energéticas, de memória e de processamento (teto operacional de *FLOPS*). Para contornar esse obstáculo e viabilizar a implantação, (MIRIYALA; CHIRRA, 2025) destacam que pesquisas futuras devem focar no desenvolvimento de arquiteturas e representações mais leves, aplicando técnicas de compressão de modelos.

No que tange à adaptabilidade dos algoritmos, observa-se que as políticas DRL são tradicionalmente treinadas e permanecem imutáveis durante a implantação em produção. Contudo, em cenários veiculares não estacionários, onde o ambiente sofre alterações constantes devido a mudanças de distribuição das cargas (*distribution shifts*), tais políticas estáticas divergem e rapidamente se tornam obsoletas e ineficientes (MIRIYALA; CHIRRA, 2025). Identifica-se que há espaço na exploração de mecanismos de adaptação *online* de modo a evoluir a política computada pelo modelo.

Por fim, a transição destas propostas para sistemas reais esbarra na falta de avaliação comparativa confiável (*benchmarking*). A disparidade entre os estudos dificulta extrapolações e comparações parciais justas sobre as potenciais eficiências obtidas. (MIRIYALA; CHIRRA, 2025) criticam o fato de que a literatura tende a se atentar demasiadamente com as constatações de performance baseadas no treinamento ideal dos agentes.

3.3 Considerações Finais

Conforme discutido ao longo deste capítulo, as abordagens baseadas em DRL têm se solidificado como a direção mais promissora para o gerenciamento de recursos em arquiteturas de borda veicular. A integração com técnicas emergentes demonstra que há flexibilidade suficiente para abarcar os altos desafios impostos pelos cenários veiculares práticos. No entanto, as lacunas destacadas — como a predominância de simulações com observabilidade perfeita e cenários determinísticos — salientam a necessidade crítica de propostas que incorporem incerteza, variação de rajadas e carga de trabalho. Este alinhamento direciona o desenvolvimento da solução apresentada nos capítulos seguintes, projetada com vistas a preencher estas falhas e entregar maior robustez.

REFERÊNCIAS

3GPP. *Release 17 Overview*. [S.l.], 2022. Accessed: 2025-01-01.

5G and Beyond for Dummies. [S.l.]: John Wiley & Sons, 2020. Custom For Dummies.

A state-of-the-art review of offloading mechanisms in fog environments. *Multimedia Tools and Applications*, v. 81, p. 1997–2042, 2022.

ABBAS, Z.; XU, S.; ZHANG, X. An efficient partial task offloading and resource allocation scheme for vehicular edge computing in a dynamic environment. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, 2024.

ABD-ELNABY, M. *et al.* Comparative analysis of IEEE 802.11bd and 5G NR-V2X for intelligent transportation systems. **Vehicular Communications**, v. 45, p. 100678, 2024.

Agência Nacional de Telecomunicações (Anatel). **Ato nº 14158, de 1º de outubro de 2025: Requisitos Técnicos para Avaliação da Conformidade de Equipamentos de Radiocomunicação**. 2025. Disponível em: https://www.anatel.gov.br/legislacao/atos-de-certificacao-de-produtos/2025/1959-ato-14158.

Agência Nacional de Telecomunicações (Anatel). **Resolução nº 772, de 16 de janeiro de 2025: Plano de Atribuição, Destinação e Distribuição de Faixas de Frequências no Brasil**. 2025.

AHMED, M.; RAZA, S.; MIRZA, M. A.; AZIZ, A.; KHAN, M. A.; KHAN, W. U.; LI, J.; HAN, Z. A survey on vehicular task offloading: Classification, issues, and challenges. **Journal of King Saud University - Computer and Information Sciences**, v. 34, n. 7, p. 4135–4162, 2022. ISSN 1319-1578. Disponível em: https://www.sciencedirect.com/science/article/pii/S1319157822001653.

ANSARI, K. The 5.9 GHz spectrum for safety-related V2X: The battle between DSRC and C-V2X. **IEEE Access**, v. 8, p. 143161–143171, 2020.

ASPLUND, H.; ASTELY, D.; BUTOVITSCH, P. von; CHAPMAN, T.; FAXéR, S.; FRENNE, M.; GHASEMZADEH, F.; HAGSTRöM, M.; HOGAN, B.; JöNGREN, G.; KARLSSON, J.; KRONESTEDT, F.; LARSSON, E. **Massive MIMO in Practice: From 5G to 6G**. 2nd. ed. [S.l.]: Academic Press (Elsevier), 2025.

BAKER, T.; AGHBARI, Z. A.; KHEDR, A.; AHMED, N.; GIRIJA, S. Editors: Energy-aware dynamic task offloading using deep reinforcement and transfer learning for sdn-enabled edge cloud. **Internet of Things**, Elsevier, v. 25, p. 101118, 2024.

BAO, H.; WANG, Y.; LI, P.; NIE, L.; YU, G.; HUO, Y.; WU, L. Joint task offloading, resource allocation, and service caching in mobile edge computing via soft actor-critic learning. **IEEE Transactions on Vehicular Technology**, IEEE, 2025.

BOUKERCHE, A.; SOTO, V. Computation offloading and retrieval for vehicular edge computing: Algorithms, models and classification. **ACM Computing Surveys**, v. 53, n. 4, p. 1–35, 2020.

BROCKMAN, G.; CHEUNG, V.; PETTERSSON, L.; SCHNEIDER, J.; SCHULMAN, J.; TANG, J.; ZAREMBA, W. Openai gym. **arXiv preprint arXiv:1606.01540**, 2016.

CHEN, S.; AL. et. Vehicle-to-everything (v2x) services: Mode 4 communication in lte-v2x. **IEEE Access**, v. 5, p. 22461–22471, 2017.

CHEN, S.; LI, W.; SUN, J.; PACE, P.; HE, L.; FORTINO, G. An efficient collaborative task offloading approach based on multi-objective algorithm in mec-assisted vehicular networks. **IEEE Transactions on Vehicular Technology**, 2025.

COX, C. **An Introduction to 5G: The New Radio, 5G Network, 5G Advanced and Beyond**. 2nd. ed. [S.l.]: John Wiley & Sons Ltd, 2025.

FAN, Y.; CAI, X. A deep reinforcement approach for computation offloading in mec dynamic networks. **EURASIP Journal on Advances in Signal Processing**, Springer, v. 2024, n. 48, 2024.

FARIMANI, M. K. *et al.* Deadline-aware task offloading in vehicular networks using deep reinforcement learning. **Expert Systems With Applications**, Elsevier, v. 249, p. 123622, 2024.

Federal Communications Commission (FCC). **Use of the 5.850-5.925 GHz Band: Second Report and Order**. [S.l.], 2024. Adopted November 20, 2024. Establishing sunset for DSRC by December 2025.

FENG, J.; LIU, Z.; WU, C.; JI, Y. Ave: Autonomous vehicular edge computing framework with aco-based scheduling. **IEEE Transactions on Vehicular Technology**, IEEE, v. 66, n. 12, p. 10660–10675, 2017.

FOWDUR, T. P.; INDOONUNDON, M.; MILOVANOVIC, D. A.; BOJKOVIC, Z. S. **5G NR Modelling in MATLAB**. [S.l.]: CRC Press, 2025.

GARCIA, M. H. C.; AL. et. A tutorial on 5g nr v2x communications. **IEEE Communications Surveys & Tutorials**, v. 23, n. 3, p. 1972–2025, 2021.

HAARNOJA, T. *et al.* Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In: **ICML**. [S.l.: s.n.], 2018.

HE, C.; WANG, W.; JIANG, W.; HE, Z.; WANG, J.; XIE, X. Security for the internet of vehicles with integration of sensing, communication, computing, and intelligence: A comprehensive survey. **Sensors**, v. 25, n. 16, 2025. ISSN 1424-8220. Disponível em: https://www.mdpi.com/1424-8220/25/16/5119.

HOU, X.; LI, Y.; CHEN, M.; WU, D.; JIN, D.; CHEN, S. Vehicular fog computing: A viewpoint of vehicles as the infrastructures. **IEEE Transactions on Vehicular Technology**, IEEE, v. 65, n. 6, p. 3860–3873, 2016.

HU, M. **The Art of Reinforcement Learning: Fundamentals, Mathematics, and Implementations with Python**. [S.l.]: Apress, 2024.

HUANG, X.; YE, Q.; LI, J.; WU, Y. Deep reinforcement learning for offloading and resource allocation in vehicular edge computing. **IEEE Transactions on Vehicular Technology**, v. 69, n. 8, p. 8334–8345, 2020.

IOANNOU, I.; VASSILIOU, V.; NAGARADJANE, P.; CHRISTOPHOROU, C.; PITSILLIDES, A. **Distributed Artificial Intelligence for 5G-6G Communications**. [S.l.]: CRC Press, 2025.

ITU-R. **IMT Vision - Framework and overall objectives of the future development of IMT for 2020 and beyond**. Geneva, Switzerland, 2015.

ITU-R. **Minimum requirements related to technical performance for IMT-2020 radio interface(s)**. Geneva, Switzerland, 2017.

ITU-R. **Detailed specifications of the terrestrial radio interfaces of International Mobile Telecommunications-2020 (IMT-2020)**. Geneva, Switzerland, 2021.

KANDALI, K.; NOUH, S.; BENNIS, L.; BENNIS, H. A comprehensive survey on vanet–iot integration toward the internet of vehicles: Architectures, communications, and system challenges. **Data and Metadata**, v. 4, p. 521, 2025.

KESHARI, N.; SINGH, D.; MAURYA, A. K. A survey on vehicular fog computing: Current state-of-the-art and future directions. **Vehicular Communications**, v. 38, p. 100512, 2022. Disponível em: https://doi.org/10.1016/j.vehcom.2022.100512.

KHAN, P. W.; ABBAS, K.; SHAIBA, H.; MUTHANNA, A.; ABUARQOUB, A.; KHAYYAT, M. Energy efficient computation offloading mechanism in multi-server mobile edge computing—an integer linear optimization approach. **Electronics**, MDPI, v. 9, n. 6, p. 1010, 2020.

KISHOR, A.; CHAKARBARTY, C. Task offloading in fog computing for using smart ant colony optimization. **Wireless personal communications**, Springer, v. 127, n. 2, p. 1683–1704, 2022.

KUMAR, A. S.; ZHAO, L.; FERNANDO, X. Task offloading and resource allocation in vehicular networks: A lyapunov-based deep reinforcement learning approach. **IEEE Transactions on Vehicular Technology**, IEEE, v. 72, 2023.

KUMARI, S. *et al.* Task offloading in vehicular edge computing network using deep q-network. **International Journal of Intelligent Engineering and Systems**, v. 18, n. 9, p. 659–672, 2025.

LI, X.; PU, Y.; YAN, C.; DUAN, W.; ZHANG, X. Computation offloading and association in mec-assisted v2x network for delay minimization and collision avoidance via deep q-network. **Discover Computing**, Springer, v. 28, n. 302, 2025.

LI, Z.; ZHU, Q. Genetic algorithm-based optimization of offloading and resource allocation in mobile-edge computing. **Information**, MDPI, v. 11, n. 2, p. 83, 2020.

LIN, L. *et al.* A survey on computation offloading and current trends. **IEEE Access**, 202x.

LIU, L.; CHEN, C.; PEI, Q.; MAHARJAN, S.; ZHANG, Y. Vehicular edge computing and networking: A survey. **Mobile Networks and Applications**, v. 26, n. 3, p. 1145–1168, jun. 2021. ISSN 1572-8153. Disponível em: https://doi.org/10.1007/s11036-020-01624-1.

LIU, Z.; SU, J.; WEI, J.; CHEN, W.; CHAN, K. Y.; YUAN, Y.; GUAN, X. Joint robust power control and task scheduling for vehicular offloading in cloud-assisted mec networks. **IEEE Transactions on Network Science and Engineering**, 2024.

LONG, Y.; WANG, Z.; LAN, S.; ZHANG, R.; XU, K. Energy-latency tradeoff for task offloading and resource allocation in vehicular edge computing. **Computer Networks**, Elsevier, v. 258, p. 111026, 2025.

LOPEZ, P. A.; BEHRISCH, M.; BIEKER-WALZ, L.; ERDMANN, J.; FLÖTTERÖD, Y.-P.; HILBRICH, R.; LÜCKEN, L.; RUMMEL, J.; WAGNER, P.; WIESSNER, E. Microscopic traffic simulation using sumo. In: **The 21st IEEE International Conference on Intelligent Transportation Systems**. [S.l.]: IEEE, 2018. p. 2575–2582.

LUO, Q.; LUAN, T. H.; SHI, W.; FAN, P. Heterogeneous task oriented data scheduling in vehicular edge computing via deep reinforcement learning. **IEEE Transactions on Vehicular Technology**, v. 73, n. 12, p. 19582–19596, 2024.

MA, R.; ZHOU, J.; WANG, R.; CHEN, H.-H.; LIU, G. Computation offloading and resource allocation in vehicular mec: A parameterized deep reinforcement learning approach. **IEEE Transactions on Vehicular Technology**, IEEE, 2025.

MACH, P.; BECVAR, Z. Mobile edge computing: A survey on architecture and computation offloading. **IEEE Communications Surveys & Tutorials**, v. 19, n. 3, p. 1628–1656, 2017.

MAO, Y.; YOU, C.; ZHANG, J.; HUANG, K.; LETAIEF, K. B. A survey on mobile edge computing: The communication perspective. **IEEE Communications Surveys & Tutorials**, v. 19, n. 4, p. 2322–2358, 2017.

MEGHAMALA, Y.; PAUL, P. J.; KUMAR, M. A. A multi-agent deep reinforcement learning framework for mec resource allocation in 5g networks. **Electrical and Electronics Research (IJEER)**, v. 13, n. 4, p. 909–919, 2025.

MIRIYALA, S.; CHIRRA, V. R. Deep learning approaches for computation offloading in edge computing: A critical review. **Telecommunication Systems**, Springer, v. 89, p. 42, 2025.

MNIH, V. *et al.* Human-level control through deep reinforcement learning. **Nature**, v. 518, n. 7540, p. 529–533, 2015.

MOBILE Edge Computing Task Offloading. **Applied Sciences**, v. 15, 2024.

MOERLAND, T. M.; BROEKENS, J.; PLAAT, A.; JONKER, C. M. Model-based reinforcement learning: A survey. **Foundations and Trends® in Machine Learning**, Now Publishers, v. 16, n. 1, p. 1–118, 2023.

MOGHADDASI, K.; RAJABI, S.; GHAREHCHOPOGH, F. S. Multi-objective secure task offloading strategy for blockchain-enabled iov-mec systems: A double deep q-network approach. **IEEE Access**, 2024.

MOGHADDASI, K.; RAJABI, S.; GHAREHCHOPOGH, F. S.; HOSSEINZADEH, M. An energy-efficient data offloading strategy for 5g-enabled vehicular edge computing networks using double deep q-network. **Wireless Personal Communications**, v. 133, n. 3, p. 2019–2064, 12 2023. ISSN 1572-834X. Disponível em: https://doi.org/10.1007/s11277-024-10862-5.

MOHAMMAD, A. A. S.; AL-HAWARY, S. I. S.; HINDIEH, A.; VASUDEVAN, A.; AL-SHORMAN, H. M.; AL-ADWAN, A. S.; ALSHURIDEH, M. T.; ALI, I. Intelligent data-driven task offloading framework for internet of vehicles using edge computing and reinforcement learning. **Data and Metadata**, v. 4, p. 521, 2025.

MOLTCHANOV, D.; SOPIN, E.; BEGISHEV, V.; SAMUYLOV, A.; KOUCHERYAVY, Y.; SAMOUYLOV, K. A tutorial on mathematical modeling of 5g/6g millimeter wave and terahertz cellular systems. **IEEE Communications Surveys & Tutorials**, IEEE, v. 24, n. 2, p. 1072–1116, 2022.

MORAIS, D. H. **5G/5G-Advanced, Wi-Fi 6/7, and Bluetooth 5/6: A Primer on Smartphone Wireless Technologies**. 2nd. ed. [S.l.]: Springer Nature, 2025.

NAIK, G.; CHOUDHURY, B.; PARK, J.-M. J. IEEE 802.11bd & 5g nr v2x: Evolution of radio access technologies for v2x communications. **IEEE Access**, v. 7, p. 70113–70128, 2019.

NAIK, G. *et al.* Next generation vehicular communications: From DSRC to V2X. **IEEE Access**, v. 7, p. 142934–142947, 2019.

NIETO, G.; IGLESIA, I. de la; LOPEZ-NOVOA, U.; PERFECTO, C. Deep reinforcement learning techniques for dynamic task offloading in the 5g edge-cloud continuum. **Journal of Cloud Computing**, v. 13, n. 1, p. 94, 2024. ISSN 2192-113X. Disponível em: https://doi.org/10.1186/s13677-024-00658-0.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C. L.; MISHKIN, P.; ZHANG, C.; AGARWAL, S.; SLAMA, K.; RAY, A.; SCHULMAN, J.; HILTON, J.; KELTON, F.; MILLER, L.; SIMENS, M.; ASKELL, A.; WELINDER, P.; CHRISTIANO, P.; LEIKE, J.; LOWE, R. **Training language models to follow instructions with human feedback**. 2022.

PARRA, O. J. S. *et al.* The evolution of VANET: A review of emerging trends in artificial intelligence and software-defined networks. **IEEE Access**, IEEE, v. 13, p. 49195–49212, 2025.

PTV Group. **PTV Vissim - User Manual**. Karlsruhe, Germany: PTV Planung Transport Verkehr AG, 2020.

QIN, X. *et al.* A survey and taxonomy on task offloading for edge-cloud computing. **IEEE Access**, IEEE, v. 8, 2020.

RAGHAVAN, V.; LI, J.; SAMPATH, A.; KOYMEN, O. H.; LUO, T. (Ed.). **Millimeter Wave Communications in 5G and Towards 6G**. [S.l.]: CRC Press, 2025.

RANI, P.; SHARMA, R. Intelligent transportation system for internet of vehicles based vehicular networks for smart cities. **Computers and Electrical Engineering**, v. 105, p. 108543, 2023. ISSN 0045-7906. Disponível em: https://www.sciencedirect.com/science/article/pii/S0045790622007583.

REFERENCE architecture for the compute continuum. [S.l.], 2022.

REN, J.; YU, G.; CAI, Y.; HE, Y. Latency optimization for resource allocation in mobile-edge computation offloading. **IEEE Transactions on Wireless Communications**, IEEE, v. 17, n. 8, p. 5506–5519, 2018.

REN, J.; YU, G.; HE, Y.; LI, G. Y. Collaborative cloud and edge computing for latency minimization. **IEEE Transactions on Vehicular Technology**, IEEE, v. 68, n. 5, p. 5031–5044, 2019.

RODRíGUEZ-PIñEIRO, J. *et al.* 6g-enabled vehicle-to-everything communications: Current research trends and open challenges. **IEEE Open Journal of Vehicular Technology**, v. 6, p. 1–18, August 2025.

SAE International. **Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles**. Warrendale, PA, USA, 2021. Disponível em: https://www.sae.org/standards/content/j3016_202104/.

SCHAUL, T.; QUAN, J.; ANTONOGLOU, I.; SILVER, D. Prioritized experience replay. In: **ICLR**. [S.l.: s.n.], 2016.

SCHULMAN, J.; LEVINE, S.; ABBEEL, P.; JORDAN, M.; MORITZ, P. Trust region policy optimization. In: **ICML**. [S.l.: s.n.], 2015. p. 1889–1897.

SCHULMAN, J.; WOLSKI, F.; DHARIWAL, P.; RADFORD, A.; KLIMOV, O. Proximal policy optimization algorithms. **arXiv preprint arXiv:1707.06347**, 2017.

SHEIKH, J. A.; BHAT, Z. A.; MASOODI, I. S. (Ed.). **Radio Frequency, Communications and Signal Processing for 5G and Beyond 5G Networks**. [S.l.]: CRC Press, 2026.

SHI, W.; CHEN, L.; ZHU, X. Task offloading decision-making algorithm for vehicular edge computing: A deep-reinforcement-learning-based approach. **Sensors**, v. 23, n. 17, 2023. ISSN 1424-8220. Disponível em: https://www.mdpi.com/1424-8220/23/17/7595.

SIDWINI, S. L.; ROUT, S.; PATNAIK, H. K.; DASH, B. B.; DE, U. C.; PATRA, S. S. Task offloading in edge computing: Energy optimization through sac based reinforcement learning. In: . [S.l.: s.n.], 2024. Preprint / Anais de Conferência.

SOUZA, A. B. D.; REGO, P. A.; CARNEIRO, T.; RODRIGUES, J. D. C.; FILHO, P. P. R.; SOUZA, J. N. D.; CHAMOLA, V.; ALBUQUERQUE, V. H. C. D.; SIKDAR, B. Computation offloading for vehicular environments: A survey. **IEEE Access**, IEEE, v. 8, p. 198214–198243, 2020.

SOUZA, A. B. de; REGO, P. A. L.; CARNEIRO, T.; ROCHA, P. H. G.; SOUZA, J. N. de. A context-oriented framework for computation offloading in vehicular edge computing using wave and 5g networks. **Vehicular Communications**, Elsevier, v. 32, p. 100389, 2021.

STALLINGS, W. **5G Wireless: A Comprehensive Introduction**. [S.l.]: Pearson Education, 2021.

STUDY on channel model for frequencies from 0.5 to 100 GHz (3GPP TR 38.901 version 16.1.0 Release 16). [S.l.], 2020. Release 16.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning: An Introduction**. 2nd. ed. [S.l.]: The MIT Press, 2018.

SáNCHEZ, J. *et al.* The evolution of vehicular communications: From V2V to V2X and beyond. **IEEE Communications Surveys & Tutorials**, v. 27, n. 1, p. 100–145, 2025.

TANG, H.; DU, M.; WU, H.; JIAO, P. Link topology-adaptive offloading method on vehicular edge computing. **IEEE Transactions on Vehicular Technology**, IEEE, 2024.

THE Evolution from Cloud Computing to MEC. **Future Internet**, v. 15, p. 391, 2023.

TIAN, S.; ZHU, X.; FENG, B.; ZHENG, Z.; LIU, H.; LI, Z. Partial offloading strategy based on deep reinforcement learning in the internet of vehicles. **IEEE Transactions on Mobile Computing**, IEEE, 2025.

TURCANU, I.; AL. et. A hybrid dsrc-pmp communication architecture for vehicular networks. **IEEE Communications Letters**, v. 20, n. 7, p. 1389–1392, 2016.

UDDIN, A.; ZHANG, N.; SAKR, A. H. Intelligent offloading in vehicular edge computing: A comprehensive review of deep reinforcement learning approaches and architectures. **arXiv preprint arXiv:2502.06963v2**, 2025.

VIEIRA, A. S. de S.; SOUZA, A. B. de; JÚNIOR, J. C. Foff: an energy-efficient task offloading in vec-enabled vehicular networks using fuzzy topsis. **Cluster Computing**, Springer, v. 28, n. 13, p. 822, 2025.

WANG, D. *et al.* Iot task offloading in mec: A comprehensive review. **Heliyon**, v. 10, n. e29916, 2024.

WANG, F.; XU, J.; WANG, X.; CUI, S. Joint offloading and computing optimization in wireless powered mobile-edge computing systems. In: **IEEE International Conference on Communications (ICC)**. [S.l.: s.n.], 2017. p. 1–6.

WANG, M.; YI, H.; JIANG, F.; LIN, L.; GAO, M. Review on offloading of vehicle edge computing. **Journal of Artificial Intelligence and Technology**, v. 2, n. 4, p. 132–143, 2022. Disponível em: https://doi.org/10.37965/jait.2022.0120.

WANG, T.; OUYANG, X.; SUN, D.; CHEN, Y.; LI, H. Offloading strategy based on graph neural reinforcement learning in mobile edge computing. **Electronics**, MDPI, v. 13, n. 12, p. 2387, 2024.

WANG, Z.; SCHAUL, T.; HESSEL, M.; HASSELT, H. v.; LANCTOT, M.; FREITAS, N. d. Dueling network architectures for deep reinforcement learning. In: **ICML**. [S.l.: s.n.], 2016.

WEI, R.; QIN, T.; HUANG, J.; YANG, Y.; REN, J.; YANG, L. Resource allocation scheduling scheme for task migration and offloading in 6g cybertwin internet of vehicles based on drl. **IET Communications**, John Wiley & Sons, v. 18, p. 1244–1265, 2024.

WHAIDUZZAMAN, M.; SOOKHAK, M.; GANI, A.; BUYYA, R. A survey on vehicular cloud computing. **Journal of Network and Computer Applications**, v. 40, p. 325–344, 2014. Disponível em: https://doi.org/10.1016/j.jnca.2013.08.004.

WILLIAMS, R. J. Simple statistical gradient-following algorithms for connectionist reinforcement learning. **Machine learning**, v. 8, n. 3-4, p. 229–256, 1992.

WU, H.; GU, A.; LIANG, Y. Federated reinforcement learning-empowered task offloading for large models in vehicular edge computing. **IEEE Transactions on Vehicular Technology**, IEEE, v. 74, n. 2, p. 1979–1991, 2025.

WU, J. *et al.* Efficient gan-based federated optimization for vehicular task offloading with mobile edge computing in 6g network. **IEEE Internet of Things Journal**, Feb 2025.

XIE, Y. *et al.* Efficient task offloading in double roadside ris-assisted vehicular edge computing networks using deep reinforcement learning. **IEEE Transactions on Intelligent Transportation Systems**, Aug 2025.

YOU, Q.; TANG, B. Efficient task offloading using particle swarm optimization algorithm in edge computing for industrial internet of things. **Journal of Cloud Computing**, Springer, v. 10, n. 1, p. 41, 2021.

ZHANG, K.; MAO, Y.; LENG, S.; HE, L.; ZHANG, Y.; PENG, X.; VINEL, A. Energy-efficient offloading for mobile edge computing in 5g networks. **IEEE Wireless Communications**, v. 25, n. 2, p. 20–27, 2018.

ZHANG, S.; YI, N.; MA, Y. A survey of computation offloading with task types. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, v. 25, n. 8, p. 8313–8333, 2024.

ZHANG, Y.; DU, P.; WANG, J.; BA, T.; DING, R.; XIN, N. Resource scheduling for delay minimization in multi-server cellular edge computing systems. **IEEE Access**, IEEE, v. 7, p. 86265–86273, 2019.

ZHANG, Y. *et al.* A review of the current task offloading algorithms, strategies and approach in edge computing systems. **Computer Modeling in Engineering & Sciences**, v. 134, n. 1, p. 35–88, 2023.

ZHANG, Y. *et al.* A review of the current task offloading algorithms, strategies and approach in edge computing systems. **Computer Modeling in Engineering & Sciences**, v. 134, n. 1, p. 35–88, 2023.

ZHAO, L.; DONG, X.; HAWBANI, A.; BI, Y.; HE, Q.; LIU, Z. Optimizing task offloading in vec: A pdqkm scheme combining deep reinforcement learning and kuhn-munkres matching. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, 2025.

ZHAO, S. **Mathematical Foundations of Reinforcement Learning**. [S.l.]: Tsinghua University Press and Springer, 2024.

ZHENG, K.; ZHENG, Q.; CHATZIMISIOS, P.; XIANG, W.; ZHOU, Y. Heterogeneous vehicular networking: A survey on architecture, challenges, and solutions. **IEEE Communications Surveys & Tutorials**, v. 17, n. 4, p. 2377–2396, 2015.

ZHOU, Z.; CHEN, X.; LI, E.; ZENG, L.; LUO, K.; ZHANG, J. Edge intelligence: Paving the last mile of artificial intelligence with edge computing. **Proceedings of the IEEE**, v. 107, n. 8, p. 1738–1762, 2019.

APÊNDICE A – LOREM IPSUM

Suspendisse eget dignissim felis, a faucibus velit. Nunc ornare ullamcorper libero, nec placerat sapien ultricies sed. Quisque consequat metus finibus hendrerit iaculis. Pellentesque in eleifend nulla. Nulla facilisi. Mauris lobortis augue justo, eget hendrerit erat fringilla nec. Cras at nisl et massa sollicitudin tempus. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aliquam a justo libero. Nam suscipit erat feugiat sodales ultrices. Duis eget arcu at justo dapibus tempus eget eu enim. Mauris at lacus tortor.

APÊNDICE B – MODELO DE CAPA

Nunc mauris eros, convallis eget blandit non, ultrices vel sem. Donec hendrerit nibh non turpis dictum, at imperdiet lectus vehicula. Donec maximus risus ac leo viverra, in viverra arcu venenatis. Fusce imperdiet tortor nec lorem pharetra ornare. Morbi a sagittis risus. Suspendisse eu felis blandit ipsum bibendum semper varius eget eros. Sed et magna gravida, pharetra dui eu, eleifend neque. Maecenas nunc magna, rhoncus eget urna non, cursus fermentum risus. In blandit justo aliquam, cursus arcu id, maximus magna. Nulla sit amet vehicula velit, sed ultrices turpis. Vivamus vestibulum ante vitae ipsum vestibulum sagittis.

APÊNDICE C – TERMO DE FIEL DEPOSITÁRIO

Pesquisa: ANÁLISE DA MORTALIDADE INFANTIL COM MALFORMAÇÕES CONGÊNITAS.

Pelo presente instrumento que atende às exigências legais, a Sra. Maria Consuelo Martins Saraiva, "fiel depositário" com o cargo de Secretária Municipal de Saúde de Iracema, após ter tomado conhecimento do protocolo de pesquisa intitulado: ANÁLISE DA MORTALIDADE INFANTIL COM MALFORMAÇÕES CONGÊNITAS. Analisando a repercussão desse estudo no contexto da saúde pública e epidemiologia, autoriza Karla Maria da Silva Lima, enfermeira, aluna do Curso de Mestrado Acadêmico em Enfermagem da Universidade Estadual do Ceará (UECE), sob orientação do Prof. Dr. José Maria de Castro, da UECE, ter acesso aos bancos de dados do Sistema de Informação sobre Nascidos Vivos e do Sistema de Informação sobre Mortalidade da Secretaria Municipal de Saúde de Iracema, objeto deste estudo, e que se encontram sob sua total responsabilidade. Fica claro que o Fiel Depositário pode a qualquer momento retirar sua AUTORIZAÇÃO e ciente de que todas as informações prestadas tornar-se-ão confidenciais e guardadas por força de sigilo profissional, assegurando que os dados obtidos da pesquisa serão somente utilizados para estudo.

ANEXO A – EXEMPLO DE ANEXO

Proin tempus turpis id justo sagittis porta a vel dui. Cras id dictum velit. Vivamus a eleifend lectus, non faucibus tortor. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Vestibulum sagittis dapibus tortor, in pellentesque quam porttitor eget. Nunc vel feugiat velit. Sed varius nisl lectus, at pulvinar tellus fermentum eget. Vestibulum euismod volutpat nisi, in fringilla sapien mollis et. Nam laoreet, ante vitae euismod viverra, erat odio hendrerit purus, eu pulvinar ligula sapien vitae felis.

ANEXO B – DINÂMICA DAS CLASSES SOCIAIS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Maecenas vehicula arcu vitae risus varius tincidunt. Phasellus iaculis ultrices risus sit amet cursus. Quisque iaculis ex id iaculis commodo. Phasellus fringilla efficitur orci, ut maximus libero vulputate non. Maecenas fermentum, tortor quis feugiat ultrices, dolor diam molestie felis, sed porttitor tellus dolor ac leo. Vivamus tincidunt dapibus viverra. Duis vulputate pretium tortor ac rhoncus. Quisque id porta dolor. Vivamus sed dignissim quam. Nullam blandit velit et dignissim volutpat. Duis lobortis libero ut risus cursus, id ornare mauris blandit. Sed elementum vel lectus et rutrum. Quisque tempus sodales massa, sed tempor ante. Aenean in ultrices felis.

ÍNDICE

AAA, 82