



**UNIVERSIDADE ESTADUAL DO CEARÁ**  
**CENTRO DE CIÊNCIAS E TECNOLOGIA**  
**PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO**  
**DOUTORADO EM CIÊNCIA DA COMPUTAÇÃO**

**ANTÔNIO SÉRGIO DE SOUSA VIEIRA**

**MODELO DE DECISÃO BASEADO EM LÓGICA FUZZY E APRENDIZADO POR**  
**REFORÇO PROFUNDO PARA O OFFLOADING DE TAREFAS EM REDES**  
**VEICULARES 5G**

**FORTALEZA – CEARÁ**

**2026**

ANTÔNIO SÉRGIO DE SOUSA VIEIRA

MODELO DE DECISÃO BASEADO EM LÓGICA FUZZY E APRENDIZADO POR  
REFORÇO PROFUNDO PARA O OFFLOADING DE TAREFAS EM REDES VEICULARES  
5G

Proposta de qualificação apresentada ao Curso de Doutorado em Ciência da Computação do Programa de Pós-Graduação em Ciência da Computação do Centro de Ciências e Tecnologia da Universidade Estadual do Ceará, como requisito parcial para a defesa de tese.  
Orientador: Dr. Joaquim Celestino Júnior

FORTALEZA – CEARÁ

2026

ANTÔNIO SÉRGIO DE SOUSA VIEIRA

MODELO DE DECISÃO BASEADO EM LÓGICA FUZZY E APRENDIZADO POR  
REFORÇO PROFUNDO PARA O OFFLOADING DE TAREFAS EM REDES VEICULARES  
5G

Proposta de qualificação apresentada ao Curso de Doutorado em Ciência da Computação do Programa de Pós-Graduação em Ciência da Computação do Centro de Ciências e Tecnologia da Universidade Estadual do Ceará, como requisito parcial para a defesa de tese.

Aprovada em:

BANCA EXAMINADORA

---

Dr. Joaquim Celestino Júnior (Orientador)  
Universidade Estadual do Ceará – UECE

---

Membro da Banca Dois  
Universidade do Membro da Banca Dois -  
SIGLA

---

Membro da Banca Três  
Universidade do Membro da Banca Três -  
SIGLA

---

Membro da Banca Quatro  
Universidade do Membro da Banca Quatro -  
SIGLA

---

Membro da Banca Cinco  
Universidade do Membro da Banca Cinco -  
SIGLA

---

Membro da Banca Seis  
Universidade do Membro da Banca Seis -  
SIGLA

## RESUMO

Este trabalho de qualificação propõe e avalia, uma solução para o problema de descarregamento de tarefas em redes de Computação de Borda Veicular (*Vehicular Edge Computing*) (VEC) combinando ranqueamento multicritério por *Technique for Order of Preference by Similarity to Ideal Solution* (TOPSIS) com Aprendizado por Reforço Profundo (*Deep Reinforcement Learning*) (DRL) baseado no algoritmo Ator-Crítico Suave (*Soft Actor-Critic*) (SAC). O desafio central é tomar decisões de descarregamento sob restrições de prazo (*deadline*) em ambientes com número variável de candidatos — Unidade de Borda de Estrada (*Road Side Unit*)s (RSUs) e veículos vizinhos —, o que impede, sem retreinamento, o uso direto de redes neurais com entrada de dimensão fixa. A principal contribuição técnica desta etapa é uma engenharia de estado compacta (vetor 6D) que encapsula as características normalizadas do melhor candidato identificado pelo TOPSIS, garantindo invariância à escala e estabilidade de aprendizado independentemente da densidade veicular. O TOPSIS avalia multicritérios como latência estimada, ocupação de fila, taxa de canal e consumo energético, reduzindo a complexidade do espaço de estados sem perda de informação crítica para a tomada de decisão. O uso do SAC é motivado pela sua regularização por entropia máxima, que previne colapso de política em ambientes não-estacionários, e pela eficiência amostral do aprendizado *off-policy*. Os experimentos, conduzidos em 658 cenários de simulação com comunicação Veículo-para-Tudo (*Vehicle-to-Everything*) (V2X), mostram que a combinação SAC-TOPSIS alcança taxa de cumprimento de prazo de 45,21%, *Success-Weighted Quality* (SWQ) de 0,1484 e função objetivo  $J(\pi) = 0,2454$  — métricas superiores às de cinco outras famílias de algoritmos de DRL e nove heurísticas de referência avaliadas. Como extensão planejada, o TOPSIS será substituído por *Fuzzy-TOPSIS*, incorporando incerteza linguística nos critérios de avaliação dos candidatos, com o objetivo de aprimorar a robustez da representação de estado em cenários de alta mobilidade e informação imprecisa.

**Palavras-chave:** descarregamento de tarefas; computação de borda veicular; aprendizado por reforço profundo; SAC; TOPSIS; *Fuzzy-TOPSIS*; V2X; generalização *zero-shot*; engenharia de estado.

## ABSTRACT

This qualification work proposes and evaluates a solution to the task offloading problem in Vehicular Edge Computing (VEC) networks by combining multicriteria ranking via TOPSIS (*Technique for Order of Preference by Similarity to Ideal Solution*) with Deep Reinforcement Learning (DRL) based on the Soft Actor-Critic (SAC) algorithm. The central challenge is making *offloading* decisions under deadline constraints in environments with a variable number of candidates — Road Side Units (RSUs) and neighboring vehicles — which prevents the direct use of fixed-input neural networks without retraining. The main technical contribution of this stage is a compact state engineering approach (6D vector) that encapsulates the normalized features of the best candidate identified by TOPSIS, guaranteeing scale-invariance and learning stability regardless of vehicle density. TOPSIS evaluates multicriteria such as estimated latency, queue occupancy, channel rate, and energy consumption, reducing the complexity of the state space without losing information critical for decision-making. The use of SAC is motivated by its maximum-entropy regularization, which prevents policy collapse in non-stationary environments, and by the sample efficiency of *off-policy* learning. Experiments conducted over 658 simulation scenarios with Vehicle-to-Everything (V2X) communication show that the SAC-TOPSIS combination achieves a deadline compliance rate of 45.21%, a *Success-Weighted Quality* (SWQ) of 0.1484, and an objective function value of  $J(\pi) = 0.2454$  — metrics superior to those of five other families of DRL algorithms and nine reference heuristics evaluated. As a planned extension, TOPSIS will be replaced by *Fuzzy-TOPSIS*, incorporating linguistic uncertainty into the candidate evaluation criteria, with the aim of improving the robustness of state representation in high-mobility and imprecise-information scenarios.

**Keywords:** task offloading; vehicular edge computing; deep reinforcement learning; SAC; TOPSIS; *Fuzzy-TOPSIS*; V2X; zero-shot generalization; state engineering.

## LISTA DE ILUSTRAÇÕES

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                     |    |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| <b>Figura 1</b> – Formas de descarregamento de tarefas em VEC: total ( <i>full</i> ), parcial ( <i>partial</i> ) e adaptativo ( <i>adaptive</i> ), com seus trade-offs de confiabilidade e complexidade. . . . .                                                                                                                                                                                                                                                    | 21 |
| <b>Figura 2</b> – Principais problemas inerentes ao descarregamento de tarefas veicular: mobilidade e instabilidade do enlace, heterogeneidade de recursos e filas, custos energéticos, incerteza de medições, dependência de tecnologias/protocolos e complexidade <i>NP-hard</i> sob restrições de latência e confiabilidade. . . . .                                                                                                                             | 23 |
| <b>Figura 3</b> – Modelo de sistema básico 3GPP evidenciando os dois grandes blocos operacionais do 5G. . . . .                                                                                                                                                                                                                                                                                                                                                     | 29 |
| <b>Figura 4</b> – Arquitetura Simplificada da Rede 5G (Plano de Controle e Usuário). . . . .                                                                                                                                                                                                                                                                                                                                                                        | 30 |
| <b>Figura 5</b> – Conceito de Fatiamento de Rede (Network Slicing) baseado em NFV/SDN evidenciando o isolamento e parametrização por serviço. . . . .                                                                                                                                                                                                                                                                                                               | 31 |
| <b>Figura 6</b> – Integração do Computação de Borda de Múltiplos Acessos ( <i>Multi-access Edge Computing</i> ) (MEC) à rede Quinta Geração de Redes Móveis ( <i>Fifth Generation</i> ) (5G) distribuindo a função Função de Plano de Usuário ( <i>User Plane Function</i> ) (UPF) localmente visando reduzir a latência de tráfego sensível. . . . .                                                                                                               | 32 |
| <b>Figura 7</b> – Divisão funcional arquitetural da estação base Nó B de Próxima Geração ( <i>Next-Generation Node B</i> ) (gNB) nas unidades Unidade Central ( <i>Central Unit</i> ) (CU) e Unidade Distribuída ( <i>Distributed Unit</i> ) (DU), mostrando a alocação dos protocolos de rádio. . . . .                                                                                                                                                            | 33 |
| <b>Figura 8</b> – Estrutura de implantação Não-Autônoma (Não-Autônomo ( <i>Non-Standalone</i> ) (NSA)) baseada no núcleo legado Núcleo de Pacotes Evoluído ( <i>Evolved Packet Core</i> ) (EPC), separando a controladora rádio 4G <i>Long Term Evolution</i> (4G LTE) do nó secundário Nó B de NR para Acesso de Rádio Terrestre Universal Evoluído ( <i>Evolved Universal Terrestrial Radio Access-New Radio Node B</i> ) (en-gNB) (dividido em CU e DU). . . . . | 33 |

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |    |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| <b>Figura 9</b> – Estrutura de implantação Autônoma (Autônomo ( <i>Standalone</i> ) (SA)) ou Opção 2. O núcleo Núcleo 5G (5G Core) (5GC) conecta-se diretamente à estação base gNB via interface Interface de Próxima Geração ( <i>Next Generation Interface</i> ) (NG). . . . .                                                                                                                                                                                                                                                                                                                                                                                                 | 34 |
| <b>Figura 10</b> – Divisão conceitual do espectro de radiofrequência 5G Novo Rádio ( <i>New Radio</i> ) (NR) nas faixas Faixa de Frequência 1 ( <i>Frequency Range 1</i> ) (FR1) (Sub-6 GHz) e Faixa de Frequência 2 ( <i>Frequency Range 2</i> ) (FR2) (mmWave). . . . .                                                                                                                                                                                                                                                                                                                                                                                                        | 35 |
| <b>Figura 11</b> – Comparativo ilustrativo entre a arquitetura Quarta Geração de Redes Móveis ( <i>Fourth Generation</i> ) (4G) tradicional e o 5G Massive Múltiplas Entradas, Múltiplas Saídas ( <i>Multiple-Input Multiple-Output</i> ) (MIMO). À esquerda, nota-se a limitação dos painéis com poucos elementos e o desperdício de potência. À direita, aproveitando o diminuto comprimento de onda no FR2, o adensamento massivo de antenas gera uma altíssima resolução espacial, permitindo a conformação de feixes ( <i>Beamforming</i> ) eficientes e a multiplexação MIMO de Múltiplos Usuários ( <i>Multi-User Multiple-Input Multiple-Output</i> ) (MU-MIMO). . . . . | 36 |
| <b>Figura 12</b> – Representação do Acesso Múltiplo por Divisão de Frequências Ortogonais ( <i>Orthogonal Frequency-Division Multiple Access</i> ) (OFDMA) no 5G: à esquerda, a estação base (gNB) distribui feixes dedicados a cada usuário; à direita, a grade bidimensional de tempo e frequência exibe como os Blocos de Recursos (Bloco de Recurso ( <i>Resource Block</i> ) (RB)) são alocados simultaneamente a diferentes Equipamento de Usuário ( <i>User Equipment</i> ) (UE). . . . .                                                                                                                                                                                 | 37 |
| <b>Figura 13</b> – Numerologia escalável do 5G NR: a relação inversamente proporcional entre o espaçamento de subportadoras ( $\Delta f = 15 \times 2^{\mu}$ kHz) e a duração útil do símbolo Multiplexação por Divisão de Frequências Ortogonais ( <i>Orthogonal Frequency-Division Multiplexing</i> ) (OFDM) ( $T_u = 1/\Delta f$ ). Numerologias menores favorecem cobertura ampla, enquanto maiores reduzem latência. . . . .                                                                                                                                                                                                                                                | 38 |

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |           |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>Figura 14 – Efeito do multipercurso e da Interferência Inter-Simbólica (<i>Intersymbol Interference</i>) (ISI) em comunicações V2X. (a) Cenário urbano: o sinal da gNB chega ao veículo receptor pelo caminho direto (LOS, instante <math>t_1</math>) e por dois percursos refletidos (no prédio em <math>t_2</math> e no solo em <math>t_3</math>), gerando um espalhamento de atraso <math>\tau_{DS} = t_3 - t_1</math>. (b) Domínio do tempo: o eco atrasado do Símbolo <math>n</math> invade a janela do Símbolo <math>n+1</math>, causando a zona hachurada de ISI. . . . .</b> | <b>39</b> |
| <b>Figura 15 – Mecanismo do Prefixo Cíclico (Prefixo Cíclico (<i>Cyclic Prefix</i>) (CP)) no 5G NR. Em (a), a porção final da parte útil do símbolo é copiada para seu início, parte (b), buscando proteger o sinal de interferências. . . . .</b>                                                                                                                                                                                                                                                                                                                                      | <b>39</b> |
| <b>Figura 16 – Diagramas de constelação dos esquemas de modulação Modulação de Amplitude em Quadratura (<i>Quadrature Amplitude Modulation</i>) (QAM) utilizados no 5G NR. À medida que a ordem da modulação aumenta de (a) para (d), cada símbolo transporta mais bits, elevando a vazão, porém a maior densidade de pontos exige uma Relação Sinal-Interferência-e-Ruído (<i>Signal-to-Interference-plus-Noise Ratio</i>) (SINR) proporcionalmente superior para manter a taxa de erro aceitável. . . . .</b>                                                                         | <b>40</b> |
| <b>Figura 17 – Arquitetura das comunicações 5G C-V2X: coexistência da interface celular Uu (V2I/V2N) com a interface direta PC5 <i>Sidelink</i> (V2V/V2P), integrando o núcleo 5GC, o servidor MEC de borda e os elementos veiculares e pedestres. . . . .</b>                                                                                                                                                                                                                                                                                                                          | <b>42</b> |
| <b>Figura 18 – Estrutura temporal básica da camada física em um <i>slot</i> do 5G NR <i>Sidelink</i>, ilustrando a multiplexação dos canais físicos PSCCH, PSSCH e PSFCH (COX, 2025; GARCIA; AL., 2021). . . . .</b>                                                                                                                                                                                                                                                                                                                                                                    | <b>42</b> |
| <b>Figura 19 – Dinâmica sequencial de operação dos canais físicos PSCCH, PSSCH e PSFCH na interface PC5 do 5G NR <i>Sidelink</i>. A comunicação ocorre em três fases: anúncio de controle, transmissão de dados e confirmação de recepção. Em caso de falha (NACK), o ciclo de dados é repetido via retransmissão HARQ. . . . .</b>                                                                                                                                                                                                                                                     | <b>43</b> |
| <b>Figura 20 – Abstração do Ecossistema IoV: Veículo-para-Veículo (<i>Vehicle-to-Vehicle</i>) (V2V), Veículo-para-Infraestrutura (<i>Vehicle-to-Infrastructure</i>) (V2I), Veículo-para-Rede (<i>Vehicle-to-Network</i>) (V2N) e Veículo-para-Pedestre (<i>Vehicle-to-Pedestrian</i>) (V2P) em Cruzamento . . . . .</b>                                                                                                                                                                                                                                                                 | <b>45</b> |



|                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |           |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>Figura 21 – Arquitetura de Protocolos DSRC / WAVE (IEEE 1609 / 802.11p) . . . .</b>                                                                                                                                                                                                                                                                                                                                                                                     | <b>46</b> |
| <b>Figura 22 – Arquitetura hierárquica em três camadas para computação em borda e nuvem. . . . .</b>                                                                                                                                                                                                                                                                                                                                                                       | <b>48</b> |
| <b>Figura 23 – Fluxograma do processo decisório e ciclo de vida do descarregamento de tarefas. . . . .</b>                                                                                                                                                                                                                                                                                                                                                                 | <b>49</b> |
| <b>Figura 24 – Ciclo básico de interação Agente-Ambiente no Aprendizado por Reforço (<i>Reinforcement Learning</i>) (RL). A cada passo, o agente observa o estado atual, escolhe uma ação, e o ambiente responde com uma recompensa e um novo estado. . . . .</b>                                                                                                                                                                                                          | <b>50</b> |
| <b>Figura 25 – Sequência de interação em um Processo de Decisão de Markov (<i>Markov Decision Process</i>) (MDP). . . . .</b>                                                                                                                                                                                                                                                                                                                                              | <b>52</b> |
| <b>Figura 26 – Dinâmica Ator-Crítico. . . . .</b>                                                                                                                                                                                                                                                                                                                                                                                                                          | <b>55</b> |
| <b>Figura 27 – Taxonomia adaptada para classificação dos trabalhos relacionados em descarregamento computacional veicular, com ênfase na modelagem de Aprendizado por Reforço Profundo (DRL) e ambiente de simulação. . .</b>                                                                                                                                                                                                                                              | <b>60</b> |
| <b>Figura 28 – Representação do ambiente de simulação: um cruzamento veicular contemplando comunicação V2I, V2V e os principais componentes do cenário estocástico. . . . .</b>                                                                                                                                                                                                                                                                                            | <b>74</b> |
| <b>Figura 29 – Arquitetura SAC-TOPSIS: fluxo vertical de decisão. O módulo TOPSIS comprime <math>N</math> candidatos em vetor fixo <math>\mathbb{R}^6</math>; o SAC <i>Actor</i> decide binariamente entre execução local e <i>offload</i> para o <math>\text{rank}_1</math>. A seta tracejada cinza indica <i>bypass</i> direto de <math>C_j</math> e <math>D_j</math>; a tracejada direita mostra o loop de recompensa durante o treinamento <i>offline</i>. . . . .</b> | <b>77</b> |
| <b>Figura 30 – Arquitetura da rede <i>Actor</i> (Perceptron Multicamadas (<i>Multilayer Perceptron</i>) (MLP) <math>6 \rightarrow 64 \rightarrow 64 \rightarrow 2</math>): o vetor de estado compacto <math>S_t</math> produzido pelo TOPSIS alimenta duas camadas ocultas com ativação ReLU; a camada Softmax final emite as probabilidades das ações <math>a_0</math> (LOCAL) e <math>a_1</math> (OFFLOAD <math>\text{rank}_1</math>). . . . .</b>                       | <b>80</b> |
| <b>Figura 31 – SWQ médio por política sobre 661 cenários de teste (<math>\alpha = 0,35, \beta = 0,35, \gamma = 0,30</math>). Barras em cinza representam heurísticas; barras escuras representam políticas DRL. A borda dourada indica a melhor política. Maior é melhor. . . . .</b>                                                                                                                                                                                      | <b>88</b> |

## LISTA DE TABELAS

|                                                                                                                                                                                                                                                               |           |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>Tabela 2 – Comparativo técnico da evolução V2X: do DSRC ao 6G . . . . .</b>                                                                                                                                                                                | <b>47</b> |
| <b>Tabela 3 – Resumo dos aspectos de Padrão de Comunicação, Servidor e Condições<br/>de Ambiente dos trabalhos relacionados . . . . .</b>                                                                                                                     | <b>63</b> |
| <b>Tabela 4 – Classificação dos algoritmos clássicos de DRL quanto à adequação ao<br/>espaço de ação . . . . .</b>                                                                                                                                            | <b>68</b> |
| <b>Tabela 5 – Análise comparativa dos trabalhos relacionados por Função Objetivo,<br/>Estado, Recompensa e Ambiente Simulado . . . . .</b>                                                                                                                    | <b>70</b> |
| <b>Tabela 6 – Distribuição dos 661 cenários de treinamento/teste por taxa de chegada.</b>                                                                                                                                                                     | <b>75</b> |
| <b>Tabela 7 – Parâmetros físicos do ambiente simulado. . . . .</b>                                                                                                                                                                                            | <b>75</b> |
| <b>Tabela 8 – Hiperparâmetros do SAC compartilhados por todas as políticas DRL. .</b>                                                                                                                                                                         | <b>76</b> |
| <b>Tabela 9 – Critérios e pesos do módulo TOPSIS. . . . .</b>                                                                                                                                                                                                 | <b>78</b> |
| <b>Tabela 10 – Design experimental das variantes de ablação. Cada variante difere da<br/>proposta em exatamente um componente. . . . .</b>                                                                                                                    | <b>82</b> |
| <b>Tabela 11 – Resultados do estudo de ablação: médias sobre 661 cenários de teste. .</b>                                                                                                                                                                     | <b>82</b> |
| <b>Tabela 12 – Decomposição causal dos ganhos ao longo do caminho de ablação. . . .</b>                                                                                                                                                                       | <b>85</b> |
| <b>Tabela 13 – Ranking completo das 25 políticas avaliadas em 658 cenários comuns<br/>(ordenado por SWQ decrescente). ★ = usa TOPSIS. . . . .</b>                                                                                                             | <b>92</b> |
| <b>Tabela 14 – Ganho do TOPSIS por família de algoritmo (médias sobre 658 cenários<br/>comuns). <math>\Delta</math>Taxa e <math>\Delta</math>SWQ representam diferença absoluta; <math>\Delta J(\pi)</math> é a<br/>diferença na função objetivo. . . . .</b> | <b>93</b> |
| <b>Tabela 15 – Atividades de pesquisa e cronograma de conclusão (2026–2027). . . . .</b>                                                                                                                                                                      | <b>94</b> |

## LISTA DE ABREVIATURAS E SIGLAS

|        |                                                                                                                                                      |
|--------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3GPP   | <i>3rd Generation Partnership Project</i>                                                                                                            |
| 4G     | Quarta Geração de Redes Móveis ( <i>Fourth Generation</i> )                                                                                          |
| 4G LTE | <i>4G Long Term Evolution</i>                                                                                                                        |
| 5G     | Quinta Geração de Redes Móveis ( <i>Fifth Generation</i> )                                                                                           |
| 5GC    | Núcleo 5G ( <i>5G Core</i> )                                                                                                                         |
| 6G     | Sexta Geração de Redes Móveis ( <i>Sixth Generation</i> )                                                                                            |
| ADS    | Sistemas de Condução Automatizada ( <i>Automated Driving Systems</i> )                                                                               |
| AMF    | Função de Gerenciamento de Acesso e Mobilidade ( <i>Access and Mobility Management Function</i> )                                                    |
| AR     | Autorregressivo ( <i>Autoregressive</i> )                                                                                                            |
| B5G    | Além do 5G ( <i>Beyond 5G</i> )                                                                                                                      |
| BER    | Taxa de Erro de Bit ( <i>Bit Error Rate</i> )                                                                                                        |
| C-MEC  | Computação de Borda de Múltiplos Acessos Assistida por Nuvem ( <i>Cloud-assisted Multi-access Edge Computing</i> )                                   |
| C-V2X  | <i>Cellular Vehicle-to-Everything</i>                                                                                                                |
| CP     | Prefixo Cíclico ( <i>Cyclic Prefix</i> )                                                                                                             |
| CPU    | Unidade Central de Processamento ( <i>Central Processing Unit</i> )                                                                                  |
| CTSRAO | Otimização de Alocação de Recursos e Divisão de Tarefas Nuvem-Terminal ( <i>Cloud-Terminal Task Splitting and Resource Allocation Optimization</i> ) |
| CU     | Unidade Central ( <i>Central Unit</i> )                                                                                                              |
| CUPS   | Separação do Plano de Controle e de Usuário ( <i>Control and User Plane Separation</i> )                                                             |
| D3QN   | Rede Q Profunda Dupla com Dueling ( <i>Dueling Double Deep Q-Network</i> )                                                                           |
| DDPG   | Gradiente de Política Determinístico Profundo ( <i>Deep Deterministic Policy Gradient</i> )                                                          |
| DDQN   | Redes Q-Deep Duplas ( <i>Double Deep Q-Network</i> )                                                                                                 |
| DN     | Rede de Dados ( <i>Data Network</i> )                                                                                                                |
| DQN    | Redes Q-Deep ( <i>Deep Q-Network</i> )                                                                                                               |
| DRL    | Aprendizado por Reforço Profundo ( <i>Deep Reinforcement Learning</i> )                                                                              |
| DSRC   | <i>Dedicated Short-Range Communications</i>                                                                                                          |

|           |                                                                                                                                     |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------|
| DSRC/IEEE | <i>Dedicated Short-Range Communications/Institute of Electrical and Electronics Engineers</i>                                       |
| DT        | Gêmeo Digital ( <i>Digital Twin</i> )                                                                                               |
| DU        | Unidade Distribuída ( <i>Distributed Unit</i> )                                                                                     |
| eMBB      | Banda Larga Móvel Melhorada ( <i>enhanced Mobile Broadband</i> )                                                                    |
| EN-DC     | Conectividade Dupla E-UTRA-NR ( <i>E-UTRA-NR Dual Connectivity</i> )                                                                |
| en-gNB    | Nó B de NR para Acesso de Rádio Terrestre Universal Evoluído ( <i>Evolved Universal Terrestrial Radio Access-New Radio Node B</i> ) |
| eNodeB    | Nó B Evoluído ( <i>Evolved Node B</i> )                                                                                             |
| EPC       | Núcleo de Pacotes Evoluído ( <i>Evolved Packet Core</i> )                                                                           |
| FL        | Aprendizado Federado ( <i>Federated Learning</i> )                                                                                  |
| FR1       | Faixa de Frequência 1 ( <i>Frequency Range 1</i> )                                                                                  |
| FR2       | Faixa de Frequência 2 ( <i>Frequency Range 2</i> )                                                                                  |
| GAN       | Redes Adversárias Generativas ( <i>Generative Adversarial Networks</i> )                                                            |
| gNB       | Nó B de Próxima Geração ( <i>Next-Generation Node B</i> )                                                                           |
| GNN       | Redes Neurais em Grafos ( <i>Graph Neural Networks</i> )                                                                            |
| HARQ      | Solicitação de Repetição Automática Híbrida ( <i>Hybrid Automatic Repeat Request</i> )                                              |
| IA        | Inteligência Artificial ( <i>Artificial Intelligence</i> )                                                                          |
| IoT       | Internet das Coisas ( <i>Internet of Things</i> )                                                                                   |
| IoV       | Internet dos Veículos ( <i>Internet of Vehicles</i> )                                                                               |
| ISI       | Interferência Inter-Simbólica ( <i>Intersymbol Interference</i> )                                                                   |
| ITS       | Sistemas de Transporte Inteligentes ( <i>Intelligent Transport Systems</i> )                                                        |
| ITU       | União Internacional de Telecomunicações ( <i>International Telecommunication Union</i> )                                            |
| L-MADDPG  | MADDPG com Otimização de Lyapunov ( <i>Lyapunov-based Multi-Agent Deep Deterministic Policy Gradient</i> )                          |
| LLM       | Grande Modelo de Linguagem ( <i>Large Language Model</i> )                                                                          |
| LTE       | Evolução de Longo Prazo ( <i>Long Term Evolution</i> )                                                                              |
| LTE-Uu    | Interface de Rádio LTE ( <i>LTE Radio Interface</i> )                                                                               |
| MAC       | Controle de Acesso ao Meio ( <i>Medium Access Control</i> )                                                                         |
| MADDPG    | Ator-Crítico Determinístico Profundo Multiagente ( <i>Multi-Agent Deep Deterministic Policy Gradient</i> )                          |
| MARL      | Aprendizado por Reforço Multiagente ( <i>Multi-Agent Reinforcement Learning</i> )                                                   |

|         |                                                                                                                |
|---------|----------------------------------------------------------------------------------------------------------------|
| MATD3   | Multiagente Twin Delayed DDPG ( <i>Multi-Agent Twin Delayed Deep Deterministic Policy Gradient</i> )           |
| MCDM    | Tomada de Decisão Multicritério ( <i>Multiple-Criteria Decision-Making</i> )                                   |
| MCS     | Esquema de Modulação e Codificação ( <i>Modulation and Coding Scheme</i> )                                     |
| MDP     | Processo de Decisão de Markov ( <i>Markov Decision Process</i> )                                               |
| MEC     | Computação de Borda de Múltiplos Acessos ( <i>Multi-access Edge Computing</i> )                                |
| MIMO    | Múltiplas Entradas, Múltiplas Saídas ( <i>Multiple-Input Multiple-Output</i> )                                 |
| ML      | Aprendizado de Máquina ( <i>Machine Learning</i> )                                                             |
| mMTC    | Comunicações Massivas do Tipo Máquina ( <i>Massive Machine Type Communications</i> )                           |
| mmWave  | Ondas Milimétricas ( <i>Millimeter Wave</i> )                                                                  |
| MN      | Nó Mestre ( <i>Master Node</i> )                                                                               |
| MU-MIMO | MIMO de Múltiplos Usuários ( <i>Multi-User Multiple-Input Multiple-Output</i> )                                |
| NAS     | Estrato de Não-Acesso ( <i>Non-Access Stratum</i> )                                                            |
| NFV     | Virtualização das Funções de Rede ( <i>Network Functions Virtualization</i> )                                  |
| NG      | Interface de Próxima Geração ( <i>Next Generation Interface</i> )                                              |
| NG-RAN  | Rede de Acesso por Rádio de Próxima Geração ( <i>Next Generation Radio Access Network</i> )                    |
| NR      | Novo Rádio ( <i>New Radio</i> )                                                                                |
| NR-Uu   | Interface de Rádio NR ( <i>NR Radio Interface</i> )                                                            |
| NS      | Fatiamento de Rede ( <i>Network Slicing</i> )                                                                  |
| NSA     | Não-Autônomo ( <i>Non-Standalone</i> )                                                                         |
| OBU     | Unidade de Bordo ( <i>On-Board Unit</i> )                                                                      |
| OFDM    | Multiplexação por Divisão de Frequências Ortogonais ( <i>Orthogonal Frequency-Division Multiplexing</i> )      |
| OFDMA   | Acesso Múltiplo por Divisão de Frequências Ortogonais ( <i>Orthogonal Frequency-Division Multiple Access</i> ) |
| P-DQN   | Rede Q Profunda Parametrizada ( <i>Parametrized Deep Q-Network</i> )                                           |
| PC5     | Interface de Comunicação Direta PC5                                                                            |
| PDCP    | Protocolo de Convergência de Protocolo de Dados ( <i>Packet Data Convergence Protocol</i> )                    |
| PDQKM   | DQN Preditivo e Emparelhamento de Kuhn-Munkres ( <i>Predictive DQN and Kuhn-Munkres scheme</i> )               |

|        |                                                                                                                           |
|--------|---------------------------------------------------------------------------------------------------------------------------|
| PHY    | Camada Física ( <i>Physical Layer</i> )                                                                                   |
| POMDP  | Processo de Decisão de Markov Parcialmente Observável ( <i>Partially Observable Markov Decision Process</i> )             |
| PPO    | Otimização de Política Proximal ( <i>Proximal Policy Optimization</i> )                                                   |
| PRB    | Bloco de Recurso Físico ( <i>Physical Resource Block</i> )                                                                |
| PSO    | Otimização por Enxame de Partículas ( <i>Particle Swarm Optimization</i> )                                                |
| QAM    | Modulação de Amplitude em Quadratura ( <i>Quadrature Amplitude Modulation</i> )                                           |
| QDPG   | Gradiente de Política com Q-Learning e DDPG ( <i>Q-learning and Deep Deterministic Policy Gradient</i> )                  |
| QoS    | Qualidade de Serviço ( <i>Quality of Service</i> )                                                                        |
| RB     | Bloco de Recurso ( <i>Resource Block</i> )                                                                                |
| RBS    | Estação Rádio Base ( <i>Radio Base Station</i> )                                                                          |
| RIS    | Superfície Inteligente Reconfigurável ( <i>Reconfigurable Intelligent Surface</i> )                                       |
| RL     | Aprendizado por Reforço ( <i>Reinforcement Learning</i> )                                                                 |
| RLC    | Controle de Enlace de Rádio ( <i>Radio Link Control</i> )                                                                 |
| RLHF   | Aprendizado por Reforço a partir de Feedback Humano ( <i>Reinforcement Learning from Human Feedback</i> )                 |
| RRC    | Controle de Recursos de Rádio ( <i>Radio Resource Control</i> )                                                           |
| RSU    | Unidade de Borda de Estrada ( <i>Road Side Unit</i> )                                                                     |
| S1-C   | Interface do Plano de Controle S1 ( <i>S1 Control Plane Interface</i> )                                                   |
| S1-U   | Interface do Plano de Usuário S1 ( <i>S1 User Plane Interface</i> )                                                       |
| SA     | Autônomo ( <i>Standalone</i> )                                                                                            |
| SAC    | Ator-Crítico Suave ( <i>Soft Actor-Critic</i> )                                                                           |
| SBA    | Arquitetura Baseada em Serviços ( <i>Service Based Architecture</i> )                                                     |
| SCS    | Espaçamento de Subportadoras ( <i>Subcarrier Spacing</i> )                                                                |
| SDAP   | Protocolo de Adaptação de Dados de Serviço ( <i>Service Data Adaptation Protocol</i> )                                    |
| SDN    | Redes Definidas por Software ( <i>Software-Defined Networking</i> )                                                       |
| SIDDPG | DDPG com Iteração de Estados Internos Sequenciais ( <i>Sequential Internal-state Deep Deterministic Policy Gradient</i> ) |
| SINR   | Relação Sinal-Interferência-e-Ruído ( <i>Signal-to-Interference-plus-Noise Ratio</i> )                                    |
| SMF    | Função de Gerenciamento de Sessão ( <i>Session Management Function</i> )                                                  |
| SN     | Nó Secundário ( <i>Secondary Node</i> )                                                                                   |
| SOE    | Eficiência Operacional do Sistema ( <i>System Operation Efficiency</i> )                                                  |

|        |                                                                                                     |
|--------|-----------------------------------------------------------------------------------------------------|
| TD2PG  | <i>Task Descriptor Policy Gradient</i>                                                              |
| TL     | Aprendizado por Transferência ( <i>Transfer Learning</i> )                                          |
| TOPSIS | <i>Technique for Order of Preference by Similarity to Ideal Solution</i>                            |
| UE     | Equipamento de Usuário ( <i>User Equipment</i> )                                                    |
| UPF    | Função de Plano de Usuário ( <i>User Plane Function</i> )                                           |
| URLLC  | Comunicações Ultraconfiáveis de Baixa Latência ( <i>Ultra-Reliable Low-Latency Communications</i> ) |
| Uu     | Interface de Rádio Celular Uu                                                                       |
| V2I    | Veículo-para-Infraestrutura ( <i>Vehicle-to-Infrastructure</i> )                                    |
| V2N    | Veículo-para-Rede ( <i>Vehicle-to-Network</i> )                                                     |
| V2P    | Veículo-para-Pedestre ( <i>Vehicle-to-Pedestrian</i> )                                              |
| V2V    | Veículo-para-Veículo ( <i>Vehicle-to-Vehicle</i> )                                                  |
| V2X    | Veículo-para-Tudo ( <i>Vehicle-to-Everything</i> )                                                  |
| VEC    | Computação de Borda Veicular ( <i>Vehicular Edge Computing</i> )                                    |
| X2     | Interface X2 ( <i>X2 Interface</i> )                                                                |

## SUMÁRIO

|            |                                                                                                                      |           |
|------------|----------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1</b>   | <b>INTRODUÇÃO . . . . .</b>                                                                                          | <b>18</b> |
| <b>1.1</b> | <b>Contextualização . . . . .</b>                                                                                    | <b>18</b> |
| <b>1.2</b> | <b>Motivação . . . . .</b>                                                                                           | <b>20</b> |
| 1.2.1      | Definição do Problema . . . . .                                                                                      | 20        |
| <b>1.3</b> | <b>Questões de Pesquisa . . . . .</b>                                                                                | <b>22</b> |
| <b>1.4</b> | <b>Hipóteses . . . . .</b>                                                                                           | <b>24</b> |
| <b>1.5</b> | <b>Objetivos . . . . .</b>                                                                                           | <b>25</b> |
| 1.5.1      | Objetivo Geral . . . . .                                                                                             | 25        |
| 1.5.2      | Objetivos Específicos . . . . .                                                                                      | 25        |
| <b>1.6</b> | <b>Contribuições Esperadas . . . . .</b>                                                                             | <b>26</b> |
| <b>1.7</b> | <b>Publicação . . . . .</b>                                                                                          | <b>27</b> |
| <b>1.8</b> | <b>Organização do Trabalho . . . . .</b>                                                                             | <b>27</b> |
| <b>2</b>   | <b>FUNDAMENTAÇÃO TEÓRICA . . . . .</b>                                                                               | <b>28</b> |
| <b>2.1</b> | <b>Arquitetura e Modelagem 5G V2I e C-V2X . . . . .</b>                                                              | <b>28</b> |
| <b>2.2</b> | <b>A Internet de Veículos (IoV) e as Redes Veiculares . . . . .</b>                                                  | <b>43</b> |
| <b>2.3</b> | <b>Descarregamento de Tarefas . . . . .</b>                                                                          | <b>47</b> |
| <b>2.4</b> | <b>Aprendizado por Reforço . . . . .</b>                                                                             | <b>50</b> |
| 2.4.1      | Policy Gradients e REINFORCE . . . . .                                                                               | 55        |
| 2.4.2      | Actor-Critic, Otimização de Política Proximal ( <i>Proximal Policy Optimization</i> )<br>(PPO), TRPO e SAC . . . . . | 55        |
| 2.4.3      | Avanços e Extensões . . . . .                                                                                        | 56        |
| <b>2.5</b> | <b>TOPSIS e Fuzzy-TOPSIS . . . . .</b>                                                                               | <b>56</b> |
| 2.5.1      | O Algoritmo TOPSIS . . . . .                                                                                         | 56        |
| 2.5.1.0.1  | <i>Passo 1 — Normalização vetorial. . . . .</i>                                                                      | <i>56</i> |
| 2.5.1.0.2  | <i>Passo 2 — Matriz normalizada ponderada. . . . .</i>                                                               | <i>57</i> |
| 2.5.1.0.3  | <i>Passo 3 — Soluções ideais positiva e negativa. . . . .</i>                                                        | <i>57</i> |
| 2.5.1.0.4  | <i>Passo 4 — Distâncias à PIS e NIS. . . . .</i>                                                                     | <i>57</i> |
| 2.5.1.0.5  | <i>Passo 5 — Coeficiente de proximidade. . . . .</i>                                                                 | <i>58</i> |
| 2.5.2      | Extensão <i>Fuzzy</i> do TOPSIS . . . . .                                                                            | 58        |
| <b>3</b>   | <b>REVISÃO DE LITERATURA . . . . .</b>                                                                               | <b>60</b> |
| <b>3.1</b> | <b>Padrão de Comunicação . . . . .</b>                                                                               | <b>60</b> |



|            |                                                                         |           |
|------------|-------------------------------------------------------------------------|-----------|
| 3.1.1      | Tecnologia . . . . .                                                    | 61        |
| 3.1.2      | Servidor . . . . .                                                      | 61        |
| <b>3.2</b> | <b>Problema . . . . .</b>                                               | <b>64</b> |
| 3.2.1      | Estratégia . . . . .                                                    | 65        |
| <b>3.3</b> | <b>Considerações Finais . . . . .</b>                                   | <b>72</b> |
| <b>4</b>   | <b>PROPOSTA DE SOLUÇÃO . . . . .</b>                                    | <b>73</b> |
| <b>4.1</b> | <b>Ambiente . . . . .</b>                                               | <b>73</b> |
| 4.1.1      | Simulador de Eventos Discretos . . . . .                                | 73        |
| 4.1.2      | Cenários de Teste e Treinamento . . . . .                               | 74        |
| 4.1.3      | Protocolo de Treinamento e Hiperparâmetros . . . . .                    | 75        |
| <b>4.2</b> | <b>Visão Geral da Arquitetura e Formulação do Problema . . . . .</b>    | <b>76</b> |
| <b>4.3</b> | <b>Módulo TOPSIS e a Engenharia de Estado Compacto . . . . .</b>        | <b>77</b> |
| 4.3.1      | Avaliação Multicritério . . . . .                                       | 78        |
| 4.3.2      | O Estado Compacto 6D Invariante à Escala . . . . .                      | 78        |
| 4.3.3      | Seleção da Ação . . . . .                                               | 79        |
| <b>4.4</b> | <b>Modelagem da Recompensa e Seleção do Algoritmo . . . . .</b>         | <b>79</b> |
| 4.4.1      | Engenharia de Recompensa ( <i>Reward Shaping</i> ) . . . . .            | 79        |
| 4.4.2      | Justificativa do Algoritmo SAC . . . . .                                | 80        |
| <b>4.5</b> | <b>Complexidade Computacional . . . . .</b>                             | <b>81</b> |
| <b>4.6</b> | <b>Estudo de Ablação . . . . .</b>                                      | <b>81</b> |
| 4.6.1      | Descrição Detalhada das Variantes . . . . .                             | 81        |
| 4.6.2      | Decomposição Causal . . . . .                                           | 85        |
| 4.6.3      | Análise dos Resultados . . . . .                                        | 86        |
| 4.6.4      | Métrica de Efetividade: <i>Success-Weighted Quality</i> (SWQ) . . . . . | 86        |
| <b>4.7</b> | <b>Por que o TOPSIS agrega valor ao SAC mas não ao PPO? . . . . .</b>   | <b>87</b> |
| 4.7.1      | O problema do aprendizado redundante no PPO-TOPSIS . . . . .            | 88        |
| 4.7.2      | Colapso de política induzido pelo sinal TOPSIS . . . . .                | 89        |
| 4.7.3      | Assimetria de eficiência amostral com cenário único . . . . .           | 89        |
| 4.7.4      | Síntese: complementaridade estrutural SAC–TOPSIS . . . . .              | 90        |
| <b>4.8</b> | <b>Avaliação Comparativa de Políticas . . . . .</b>                     | <b>91</b> |
| <b>5</b>   | <b>CRONOGRAMA DE PESQUISA E PLANO DE PUBLICAÇÃO . . . . .</b>           | <b>94</b> |
| <b>5.1</b> | <b>Cronograma de Pesquisa . . . . .</b>                                 | <b>94</b> |
| <b>5.2</b> | <b>Plano de Publicação . . . . .</b>                                    | <b>94</b> |

|            |                                       |           |
|------------|---------------------------------------|-----------|
| <b>6</b>   | <b>CONCLUSÕES . . . . .</b>           | <b>95</b> |
| <b>6.1</b> | <b>Resumo do Progresso . . . . .</b>  | <b>95</b> |
| <b>6.2</b> | <b>Considerações Finais . . . . .</b> | <b>95</b> |
|            | <b>REFERÊNCIAS . . . . .</b>          | <b>96</b> |

# 1 INTRODUÇÃO

Este capítulo apresenta uma visão geral do trabalho, descrevendo o contexto e os desafios que o motivaram (Seção 1.1 e Seção 1.2). A partir disso, formaliza-se o problema de pesquisa (Seção 1.2.1), as questões norteadoras (Seção 1.3) e as hipóteses elencadas (Seção 1.4). Por fim, são traçados os objetivos (Seção 1.5), as contribuições esperadas (Seção 1.6), as publicações decorrentes da pesquisa (Seção 1.7) e a forma como o documento está estruturado (Seção 1.8).

## 1.1 Contextualização

A convergência entre tecnologias de comunicação, eletrificação veicular e condução autônoma tem moldado um novo paradigma para o setor de transportes. O conceito de Internet dos Veículos (*Internet of Vehicles*) (IoV) transforma veículos em sistemas computacionais sofisticados, capazes de viabilizar diversas aplicações de Sistemas de Transporte Inteligentes (*Intelligent Transport Systems*) (ITS) (RANI; SHARMA, 2023).

Veículos modernos são equipados com múltiplos sensores, unidades de processamento e interfaces de comunicação, permitindo a coleta e o processamento de grandes volumes de dados. Contudo, a complexidade das aplicações e a quantidade crescente de dados a serem processados podem exceder a capacidade computacional das Unidade de Bordo (*On-Board Unit*s) (OBUs) instaladas.

Uma solução imediata seria aumentar a capacidade computacional dessas OBUs, possibilitando maior processamento local. No entanto, o atual período de transição tecnológica resulta em cenários heterogêneos, no qual coexistem OBUs com diferentes capacidades computacionais (LUO *et al.*, 2024) e distintas tecnologias de comunicação (ZHENG *et al.*, 2015). Essa diversidade representa um desafio para a implementação de aplicações veiculares em larga escala, especialmente no contexto das cidades inteligentes (*Smart Cities*) (LUO *et al.*, 2024).

Nesse ambiente fortemente dinâmico e caótico, muitas aplicações, em particular aquelas voltadas à condução autônoma, impõem requisitos rigorosos de latência (HE *et al.*, 2025). A execução integral do processamento nos dispositivos embarcados frequentemente inviabiliza o atendimento a tais requisitos, devido às limitações físicas de energia e capacidade computacional (LUO *et al.*, 2024).

Para superar essas restrições, destaca-se a VEC, um paradigma onde servidores computacionalmente robustos são posicionados próximos aos veículos, reduzindo de forma

significativa a latência de processamento (LIU *et al.*, 2021). Tecnologias relacionadas, como a Computação em Nuvem Veicular (*Vehicular Cloud Computing*) (VCC) (WHAIDUZZAMAN *et al.*, 2014) e a Computação em Névoa Veicular (*Vehicular Fog Computing*) (VFC) (KESHARI; SINGH; MAURYA, 2022), ampliam o escopo do processamento distribuído, oferecendo suporte adicional em diferentes níveis de proximidade e escalabilidade.

O descarregamento de tarefas surge como o mecanismo central para operacionalizar a comunicação e o processamento colaborativo entre veículos e essas arquiteturas distribuídas. Essa técnica consiste em migrar tarefas computacionais para nós mais capazes, como servidores de borda ou outros veículos com maior poder de processamento (WANG *et al.*, 2022), possibilitando que veículos com recursos limitados executem aplicações veiculares complexas.

O principal desafio, entretanto, está em decidir quando e para onde descarregar as tarefas, considerando múltiplos fatores conflitantes, como tempo limite de processamento, custo energético, balanceamento de carga e qualidade do enlace de comunicação. Abordagens determinísticas, baseadas exclusivamente em heurísticas, apresentam desempenho limitado diante da alta variabilidade espacial e temporal do ambiente veicular (AHMED *et al.*, 2022). Mobilidade intensa, flutuações do canal e mudanças abruptas na carga computacional tornam as decisões estáticas rapidamente obsoletas, comprometendo a eficiência do sistema.

Essa limitação tem impulsionado a busca por soluções adaptativas e mais robustas, baseadas em aprendizado de máquina e sistemas inteligentes (MAO *et al.*, 2017; ZHANG *et al.*, 2018; ZHOU *et al.*, 2019; HUANG *et al.*, 2020; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024). Diante desse cenário, este trabalho de qualificação propõe uma solução para o descarregamento de tarefas em redes VEC que integra ranqueamento multicritério por TOPSIS com DRL baseado no algoritmo SAC. O TOPSIS avalia multicritérios como latência estimada, ocupação de fila, taxa de canal e consumo energético, reduzindo o conjunto variável de candidatos ao descarregamento — RSUs e veículos vizinhos — a um vetor de estado compacto e de dimensão fixa (6D), contornando o problema da entrada variável nas redes neurais. Com o melhor candidato já identificado pelo TOPSIS, o SAC aprende uma política de decisão binária (descarregar para esse candidato ou executar localmente), beneficiando-se da regularização por entropia máxima para manter a exploração em ambientes não-estacionários. Como extensão planejada, o TOPSIS será substituído por *Fuzzy-TOPSIS*, incorporando incerteza linguística aos critérios de avaliação dos candidatos.

## 1.2 Motivação

## 1.3 Definição do Problema

Diante das limitações de processamento local e da elevada variabilidade do ambiente veicular, o problema central investigado neste trabalho pode ser formulado da seguinte maneira:

**Como tomar decisões de descarregamento de tarefas em redes VEC/V2X, com número variável de candidatos (RSUs e veículos vizinhos), de forma confiável e adaptativa, cumprindo restrições de prazo e minimizando latência e consumo energético, sem necessidade de retreinamento diante de variações na densidade veicular?**


Estudos recentes reforçam que a alta mobilidade, a intermitência dos enlaces e a heterogeneidade de recursos tornam esse desafio ainda mais complexo (LIU *et al.*, 2021; MAO *et al.*, 2017; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024).

Para delimitar o escopo da solução proposta, é importante destacar que o problema de descarregamento de tarefas, em sua essência, configura-se como um problema de otimização *NP-hard* (MAO *et al.*, 2017; WANG *et al.*, 2017). Isso implica que soluções exatas em tempo polinomial são inviáveis para cenários dinâmicos como o veicular, o que direciona a busca por métodos de baixa complexidade computacional e boa capacidade de adaptação.

Outro aspecto importante refere-se a maneira na qual o descarregamento é realizado, podendo ser classificado em três categorias principais: descarregamento total (*full offloading*), descarregamento parcial (*partial offloading*) e descarregamento adaptativo (*adaptive offloading*) (WANG *et al.*, 2022) como pode ser observado na Figura 1. Cada abordagem apresenta vantagens e desvantagens específicas, influenciando diretamente a formulação do problema e as estratégias de solução adotadas.

Nesse contexto, a literatura apresenta diversas abordagens para modelar e melhorar a tomada de decisão de descarregamento de tarefas, por exemplo: programação linear e inteira para cenários de MEC (KHAN *et al.*, 2020), meta-heurísticas como algoritmos genéticos (LI; ZHU, 2020), PSO (YOU; TANG, 2021) e colônia de formigas (KISHOR; CHAKARBARTY, 2022) para problemas de grande escala, além de abordagens baseadas em aprendizado de máquina e aprendizado por reforço profundo, adequadas para ambientes altamente variáveis e parcialmente observáveis (HUANG *et al.*, 2020; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024).

**Figura 1 – Formas de descarregamento de tarefas em VEC: total (*full*), parcial (*partial*) e adaptativo (*adaptive*), com seus trade-offs de confiabilidade e complexidade.**



Fonte: Elaborado pelo autor

Outra consideração fundamental diz respeito à modelagem do ambiente veicular. Cada solução proposta na literatura assume combinações específicas de tecnologias de comunicação, capacidades computacionais e modelos de consumo energético, o que impacta diretamente a forma como o problema é otimizado (LIU *et al.*, 2021). Além disso, deve-se definir se o descarregamento será realizado apenas para servidores de borda, para veículos vizinhos (descarregamento colaborativo) ou para ambos, como no paradigma de VFC (KESHARI; SINGH; MAURYA, 2022). Essa escolha é influenciada pela disponibilidade de recursos, pelo perfil da aplicação e pela estabilidade dos enlaces, variando conforme o cenário de estudo.

A mobilidade veicular constitui outro elemento crítico. Diferentes cenários, como os urbanos, suburbanos e rodoviários, apresentam padrões distintos de flutuação do canal, densidade de veículos e comportamento do tráfego. Em áreas urbanas, fatores como congestionamentos, presença de pedestres, ônibus e motocicletas podem alterar significativamente a dinâmica da conectividade e, conseqüentemente, as estratégias de descarregamento (HE *et al.*, 2025; LUO *et al.*, 2024). Tais aspectos precisam ser considerados para que a tomada de decisão seja realista e eficaz.

A viabilização do processo de decisão depende de mecanismos eficientes de comunicação e descoberta de recursos. Neste trabalho, assume-se comunicação via 5G NR entre os veículos e os servidores de borda, e comunicação V2X entre os veículos, alinhado às diretrizes das arquiteturas 3GPP Release 16/17 (3GPP, 2022). Além disso, protocolos de descoberta e anúncios de recursos são necessários para que os veículos obtenham informações sobre capacidade de CPU, características relacionadas ao estado energético e qualidade do enlace dos

dispositivos vizinhos (ZHOU *et al.*, 2019; LIU *et al.*, 2021).

Outro ponto essencial refere-se ao perfil das aplicações beneficiadas pelo descarregamento. A popularização de *hardware* embarcado mais poderoso em OBUs permite o processamento local de aplicações leves; contudo, aplicações com baixa carga de dados, mas com alta demanda computacional, como visão computacional, detecção de objetos, fusão sensorial, criptografia e algoritmos de navegação autônoma, são candidatas naturais ao descarregamento (SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024). Para evitar latências excessivas, é necessário equilibrar o custo de transmissão com o ganho de processamento externo, preservando as restrições temporais impostas pela aplicação.

Somente após a coleta e integração dessas informações é possível realizar a tomada de decisão sobre o descarregamento. Essa decisão deve considerar a incerteza inerente às medições, a rápida variação do ambiente e a necessidade de minimizar falhas. Assim, soluções adaptativas baseadas em aprendizado de máquina e DRL têm sido exploradas como alternativas promissoras para lidar com a incerteza, o dinamismo e a complexidade dos cenários veiculares (HUANG *et al.*, 2020; SHI; CHEN; ZHU, 2023; NIETO *et al.*, 2024). A combinação dessas abordagens com métodos de ranqueamento multicritério — como TOPSIS e *Fuzzy*-TOPSIS — representa uma direção promissora para aprimorar a qualidade da representação de estado e a robustez das decisões em ambientes veiculares.

De forma geral pode-se resumir os problemas enfrentados através da Figura 2 onde uma decisão de descarregamento de tarefa deve considerar o cenário observado, as tecnologias de comunicação empregadas, as aplicações utilizadas, a incerteza do ambiente, o custo e o objetivo buscado.


#### 1.4 Questões de Pesquisa

Este trabalho busca responder às seguintes questões de pesquisa, formuladas a partir das limitações inerentes ao ambiente veicular, da complexidade do problema de descarregamento de tarefas e da necessidade de garantir confiabilidade, eficiência energética e baixa latência em sistemas VEC/V2X:

**QP1. Como realizar o descarregamento de tarefas em ambientes VEC/V2X de maneira confiável e adaptativa, considerando a alta variabilidade da mobilidade veicular, do canal de comunicação e da carga computacional?**

**QP2. De que forma a integração de ranqueamento multicritério por TOPSIS**

**Figura 2 – Principais problemas inerentes ao descarregamento de tarefas veicular: mobilidade e instabilidade do enlace, heterogeneidade de recursos e filas, custos energéticos, incerteza de medições, dependência de tecnologias/protocolos e complexidade *NP-hard* sob restrições de latência e confiabilidade.**



Fonte: Elaborado pelo autor

com DRL baseado em SAC pode melhorar a tomada de decisão de descarregamento em cenários veiculares dinâmicos, contornando o problema da entrada variável nas redes neurais e mantendo estabilidade de aprendizado independentemente da densidade veicular?

**QP3.** Em que medida a substituição do TOPSIS clássico por *Fuzzy-TOPSIS* — incorporando incerteza linguística nos critérios de avaliação dos candidatos ao descarregamento — aprimora a robustez da representação de estado e o desempenho do agente SAC em cenários de alta mobilidade e informação imprecisa?

**QP4.** Quais são os impactos do uso conjunto de comunicação 5G NR e V2X, modelados no simulador NS-3 versão 3.42 com o módulo 5G-LENA, no desempenho da solução *SAC-Fuzzy-TOPSIS*, especialmente na redução



da latência, no consumo energético e na taxa de cumprimento de prazo (*deadline*)?

**QP5.** Como diferentes perfis de aplicação veicular, especialmente aquelas com baixa carga de dados e alta demanda computacional, influenciam a decisão de quando, para onde e quanto descarregar, considerando limites de latência, balanceamento de carga e consumo energético?

## 1.5 Hipóteses

A partir das questões acima e da fundamentação teórica apresentada, formulam-se as seguintes hipóteses de pesquisa:

- H1.** A combinação de TOPSIS com SAC é capaz de produzir um modelo de decisão adaptativo que supera métodos puramente determinísticos ou heurísticos em cenários VEC/V2X altamente dinâmicos, graças à representação de estado compacta (6D) e à regularização por entropia máxima do SAC.
- H2.** O ranqueamento multicritério por TOPSIS reduz o impacto da variabilidade do número de candidatos ao descarregamento, permitindo que o agente SAC generalize para cenários com densidades veiculares distintas sem necessidade de retreinamento.
- H3.** A substituição do TOPSIS clássico por *Fuzzy*-TOPSIS aprimora a robustez da representação de estado ao incorporar incerteza linguística nos critérios de avaliação, resultando em maior taxa de cumprimento de prazo e melhor função objetivo  $J(\pi)$  em cenários de alta mobilidade e informação imprecisa.
- H4.** A validação da arquitetura SAC-*Fuzzy*-TOPSIS no simulador NS-3 versão 3.42, com modelagem realista de 5G NR e comunicação V2X (*sidelink*), confirmará a viabilidade da solução proposta em condições de rede mais próximas do ambiente real, preservando as vantagens de generalização observadas na etapa intermediária.
- H5.** Aplicações com baixa carga de dados e alta demanda computacional apresentam o maior ganho com o descarregamento, desde que o modelo consiga estimar adequadamente o custo energético e o impacto na latência de processamento.

## 1.6 Objetivos

### 1.6.1 Objetivo Geral

Desenvolver e avaliar uma solução completa de descarregamento de tarefas em redes VEC/V2X baseada na arquitetura SAC-*Fuzzy*-TOPSIS, validada no simulador NS-3 versão 3.42 com modelagem realista de 5G NR e comunicação V2X. Como etapa intermediária — objeto desta qualificação — propõe-se e valida-se a combinação de ranqueamento multicritério por TOPSIS com DRL baseado no algoritmo SAC, produzindo um vetor de estado compacto (6D) e invariante à escala que permite generalização *zero-shot* a cenários com densidades veiculares variáveis. A conclusão do trabalho prevê a substituição do TOPSIS clássico por *Fuzzy*-TOPSIS, incorporando incerteza linguística nos critérios de avaliação dos candidatos ao descarregamento, e a migração da validação para o NS-3 3.42.

### 1.6.2 Objetivos Específicos

- OE1.** Realizar uma revisão sistemática de algoritmos de descarregamento de tarefas em cenários VEC, focando em abordagens de DRL, métodos multicritério e técnicas de engenharia de estado.
- OE2.** Projetar e implementar um módulo TOPSIS para ranqueamento multicritério dos candidatos ao descarregamento (RSUs e veículos vizinhos), reduzindo o espaço de estado a um vetor 6D normalizado e invariante à escala, independentemente da densidade veicular — constituindo a etapa intermediária desta qualificação.
- OE3.** Desenvolver e treinar um agente SAC que utilize o vetor de estado produzido pelo TOPSIS para aprender uma política de descarregamento que otimize simultaneamente latência, consumo energético e taxa de cumprimento de prazo (*deadline*), validando a arquitetura SAC-TOPSIS em simulador customizado com comunicação V2X.
- OE4.** Estender o módulo de ranqueamento para *Fuzzy*-TOPSIS, incorporando incerteza linguística nos critérios de avaliação dos candidatos, e integrar a arquitetura SAC-*Fuzzy*-TOPSIS ao simulador NS-3 versão 3.42, com 5G-LENA e suporte a V2X, para validação final e comparação sistemática com heurísticas e demais algoritmos de DRL.

## 1.7 Contribuições Esperadas

Espera-se que este trabalho produza contribuições relevantes tanto do ponto de vista científico quanto do ponto de vista prático, sobretudo no contexto de sistemas veiculares inteligentes e computação de borda. As principais contribuições previstas são:

- CE1. Proposição e validação intermediária da arquitetura SAC-TOPSIS, que combina ranqueamento multicritério com DRL de entropia máxima, demonstrando tomada de decisão adaptativa e generalização *zero-shot* a cenários de densidades veiculares distintas. Essa etapa fundamenta e antecede a contribuição final: a arquitetura SAC-Fuzzy-TOPSIS validada no NS-3 3.42.**
- CE2. Modelagem detalhada do ambiente de comunicação e processamento veicular, incluindo enlaces 5G NR (com alinhamento às diretrizes do 3GPP Release 16/17), comunicação V2X sidelink, parâmetros de mobilidade e heterogeneidade computacional entre veículos e servidores de borda. Essa modelagem fornece uma plataforma de simulação realista para decisões de descarregamento.**
- CE3. Desenvolvimento do módulo TOPSIS para avaliação multicritério dos candidatos ao descarregamento, considerando critérios como latência estimada, ocupação de fila, taxa de canal e consumo energético; e, como etapa final da dissertação, desenvolvimento do módulo Fuzzy-TOPSIS, que incorporará incerteza linguística para maior robustez em cenários de alta mobilidade e informação imprecisa.**
- CE4. Treinamento e avaliação do agente SAC, cujo mecanismo de regularização por entropia máxima previne o colapso de política em ambientes não-estacionários e cuja aprendizagem *off-policy* confere eficiência amostral superior à de algoritmos *on-policy* como o PPO.**
- CE5. Implementação e avaliação da arquitetura SAC-TOPSIS em simulador customizado com comunicação V2X (etapa intermediária), e implementação final da arquitetura SAC-Fuzzy-TOPSIS no NS-3 versão 3.42 com 5G-LENA, avaliando métricas como taxa de cumprimento de prazo, *Success-Weighted Quality* (SWQ) e função objetivo  $J(\pi)$  em cenários de simulação distintos.**
- CE6. Comparação sistemática com métodos de referência da literatura, incluindo**

heurísticas tradicionais e outras famílias de algoritmos de DRL, destacando os ganhos obtidos pela arquitetura SAC-TOPSIS na etapa intermediária e pela arquitetura SAC-Fuzzy-TOPSIS na validação final.

**CE7. Produção de um conjunto de diretrizes práticas para pesquisadores e engenheiros interessados em projetar sistemas de descarregamento de tarefas veicular, evidenciando cenários onde a arquitetura SAC-Fuzzy-TOPSIS apresenta maior vantagem em relação a heurísticas e algoritmos de DRL sem ranqueamento multicritério.**

## 1.8 Publicação

Como parte do desenvolvimento deste trabalho, foi submetido e aceito um artigo no periódico internacional *Journal of Cloud Computing* (Springer), classificado como Q1 nas bases *Scopus/SJR* e posicionado no percentil superior da área de *Computer Networks and Communications*. O artigo, intitulado “FOFF: descarregamento de tarefas eficiente energeticamente em redes veiculares baseadas em VEC usando fuzzy TOPSIS” (VIEIRA; SOUZA; JÚNIOR, 2025), apresenta uma versão preliminar do modelo híbrido de descarregamento de tarefas proposto nesta dissertação, incluindo a arquitetura conceitual e os primeiros resultados derivados de experimentos em simulação. A publicação serviu tanto como validação da relevância científica da abordagem quanto como etapa intermediária para o refinamento metodológico, a ampliação dos cenários simulados e o aprofundamento das análises apresentadas nos capítulos seguintes.

## 1.9 Organização do Trabalho

## 2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos teóricos que sustentam esta pesquisa, organizados para construir uma base sólida sobre a qual a proposta é desenvolvida. A Seção 2.1 detalha a arquitetura e a modelagem das comunicações 5G, com ênfase nas interfaces V2I e *Sidelink* (V2V). Em seguida, a Seção 2.2 apresenta as Redes Veiculares sob o prisma da Inteligência e do ecossistema de Internet dos Veículos (IoV).

### 2.1 Arquitetura e Modelagem 5G V2I e C-V2X

Nesta seção, analisam-se as arquiteturas 5G NR e 5G NR V2X, fundamentadas nas especificações do Release 16 do *3rd Generation Partnership Project* (3GPP) (STUDY..., 2020).

A quinta geração de comunicações móveis celulares, o 5G, representou um avanço tecnológico disruptivo. Ele foi projetado para revolucionar não apenas o setor de telecomunicações, mas também a sociedade como um todo (STALLINGS, 2021). Essa geração teve por objetivo entregar altas taxas de dados, maior confiabilidade, cobertura aprimorada e latências bem menores em comparação com as tecnologias antecessoras, como a Evolução de Longo Prazo (*Long Term Evolution*) (LTE) (STALLINGS, 2021; 5G..., 2020).

As especificações técnicas e diretrizes de avaliação do 5G foram fundamentadas pelo padrão internacional IMT-2020, enquanto que a União Internacional de Telecomunicações (*International Telecommunication Union*) (ITU) ficou encarregada de sua avaliação e monitoramento (ASPLUND *et al.*, 2025; COX, 2025; ITU-R, 2015; ITU-R, 2017; ITU-R, 2021).

Para satisfazer os requisitos estipulados no IMT-2020, o 3GPP definiu toda a arquitetura lógica e física do 5G em sucessivos lançamentos, denominados de “Releases” (STALLINGS, 2021; ASPLUND *et al.*, 2025; COX, 2025; ITU-R, 2015; ITU-R, 2017; ITU-R, 2021).

Ele foi idealizado para funcionar em três grandes cenários de uso, vitais para a implantação das futuras infraestruturas digitais das cidades e da indústria (IOANNOU *et al.*, 2025). Estas características são fundamentais para viabilizar os ITS, que exigem comunicações capazes de suportar casos de uso avançados, como o *platooning*<sup>1</sup> e a direção autônoma de Nível 4 e 5, estágios onde o Sistemas de Condução Automatizada (*Automated Driving Systems*) (ADS) detém o controle total e permanente da tarefa dinâmica de direção (SAE International, 2021).

O primeiro cenário, conhecido como Banda Larga Móvel Melhorada (*enhanced*


<sup>1</sup> Refere-se à aplicação de ITS que vincula eletronicamente dois ou mais veículos para que trafeguem de forma coordenada, mantendo uma distância mínima e constante entre si.

*Mobile Broadband*) (eMBB), busca atender a demanda por serviços que exigem altas taxas de transferência de dados, como realidade aumentada e streaming de vídeo em alta definição. Para isso, o 5G foi projetado para suportar picos de taxas de transferência de até 20 Gbps no *downlink* e 10 Gbps no *uplink* (STALLINGS, 2021; ASPLUND *et al.*, 2025; COX, 2025; ITU-R, 2015; ITU-R, 2017; ITU-R, 2021).

O segundo cenário é o de Comunicações Massivas do Tipo Máquina (*Massive Machine Type Communications*) (mMTC), que foi formulado para interconectar eficientemente o ecossistema da Internet das Coisas (*Internet of Things*) (IoT), suportando um grande número de dispositivos interligados que requerem economia rigorosa de energia e baixo custo operacional (MORAIS, 2025; RAGHAVAN *et al.*, 2025).

O terceiro cenário é o de Comunicações Ultraconfiáveis de Baixa Latência (*Ultra-Reliable Low-Latency Communications*) (URLLC), sendo este essencial para aplicações que demanda atrasos a frações de milissegundos e taxas de erro na casa de  $10^{-5}$ , como controle robótico, ITS ou qualquer aplicação que demande alta confiabilidade e baixa latência (RAGHAVAN *et al.*, 2025; SHEIKH; BHAT; MASOODI, 2026).

Para suportar tais exigências, a arquitetura do 5G foi subdividida em dois grandes blocos: (i) a Rede de Acesso por Rádio de Próxima Geração (*Next Generation Radio Access Network*) (NG-RAN) e (ii) o 5GC (STALLINGS, 2021) (Figura 3).




**Figura 3 – Modelo de sistema básico 3GPP evidenciando os dois grandes blocos operacionais do 5G.**

Fonte: Baseado no modelo de sistema 3GPP (FOWDUR *et al.*, 2025).

O 5GC implementa o modelo de Arquitetura Baseada em Serviços (*Service Based Architecture*) (SBA), onde diversas funções de rede comunicam-se através de requisições de serviço em interfaces bem padronizadas (STALLINGS, 2021). A Figura 4 ilustra alguns serviços que se integram entre si e com os outros elementos do 5G além da divisão entre Separação do Plano de Controle e de Usuário (*Control and User Plane Separation*) (CUPS).

Na Figura 4, o componente Função de Gerenciamento de Acesso e Mobilidade (*Access and Mobility Management Function*) (AMF) é o responsável por gerenciar o acesso do usuário à rede, sua mobilidade contínua (rastreamento de localização e transição entre antenas) e o estado de suas conexões através do protocolo Estrato de Não-Acesso (*Non-Access Stratum*)



**Figura 4 – Arquitetura Simplificada da Rede 5G (Plano de Controle e Usuário).**

Fonte: Elaborado pelo autor.


(NAS). Já o Função de Gerenciamento de Sessão (*Session Management Function*) (SMF) é responsável por estabelecer e gerenciar o tráfego de dados do usuário, isto inclui a conexão do usuário com a rede, a alocação de endereços IP, o fornecimento de regras de como os pacotes de dados devem ser roteados, inspecionados ou bloqueados, além do monitoramento do tráfego e geração de relatórios de uso de dados (FOWDUR *et al.*, 2025).

Nas especificações do 3GPP foram definidas nomenclaturas, ou pontos de referência, que identificam as interfaces lógicas de comunicação entre os elementos da arquitetura 5G. Elas são identificadas pela união da letra "N" seguido de um número (STALLINGS, 2021; FOWDUR *et al.*, 2025). A seguir, são apresentadas as principais interfaces lógicas e suas definições:

- **N1:** Conexão lógica fim a fim. É a interface de sinalização entre o UE e a AMF.
- **N2:** Interface exclusiva de sinalização do Plano de Controle que interliga a estação rádio base (NG-RAN) à AMF do núcleo.
- **N3:** Interface responsável por transportar o tráfego de dados entre a rede de acesso (NG-RAN) e a UPF.
- **N4:** Interface de comunicação que viabiliza a separação dos planos de controle e usuário (CUPS); é através dela que a SMF envia as regras de roteamento, processamento e liberação de pacotes para a UPF.
- **N6:** Interface que conecta a UPF diretamente às Rede de Dados (*Data Network*) (DN) externas, como a Internet pública ou intranets de clientes.

A arquitetura do 5GC, por conta de sua modularidade, viabiliza o conceito de Fatiamento de Rede (*Network Slicing*) (NS). Tal conceito possibilita a criação de redes virtuais

independentes, isoladas e que operam em paralelo sobre uma infraestrutura física compartilhada (STALLINGS, 2021). Graças à abstração de *hardware* permitida pelas tecnologias de Redes Definidas por Software (*Software-Defined Networking*) (SDN) e Virtualização das Funções de Rede (*Network Functions Virtualization*) (NFV), cada rede virtual individual (*slice*) adquire um conjunto dedicado de recursos físicos e funções de rede (STALLINGS, 2021). Dessa forma, cada *slice* (Figura 5) pode ser parametrizado em termos de latência, largura de banda, mobilidade e segurança, oferecendo atributos específicos e blindando o desempenho de um cenário de uso contra congestionamentos em serviços paralelos, viabilizando o diversificado ecossistema digital do 5G (STALLINGS, 2021).



**Figura 5 – Conceito de Fatiamento de Rede (Network Slicing) baseado em NFV/SDN evidenciando o isolamento e parametrização por serviço.**


Fonte: Elaborado pelo autor.

Enquanto a tecnologia NFV abstrai as capacidades de computação, armazenamento e funções de rede via *software*, dispensando hardwares físicos proprietários, a SDN isola o plano de dados do plano de controle nos dispositivos de rede, consolidando as rotas a partir de um controlador centralizado e programável (STALLINGS, 2021).

Para garantir baixas latências, foi necessário distribuir as funções de processamento e armazenamento da nuvem para dispositivos mais próximos do cliente do serviço. Na prática, isto significou que as aplicações não precisariam mais enviar seus dados para *datacenters* distantes, sendo penalizadas com latências elevadas. Essa solução foi materializada com a integração do MEC à rede móvel 5G, onde a UPF é distribuída localmente para rotear os dados diretamente aos servidores periféricos, possibilitando a resposta em tempo real. A Figura 6 ilustra a arquitetura do 5GC com a integração do MEC.

Na rede de acesso 5G, a gNB atua como a Estação Rádio Base (*Radio Base Station*)






**Figura 6 – Integração do MEC à rede 5G distribuindo a função UPF localmente visando reduzir a latência de tráfego sensível.**

Fonte: Elaborado pelo autor.

(RBS) responsável por fornecer a interface aérea, gerenciando a transmissão e a recepção de dados entre o UE e a rede núcleo (FOWDUR *et al.*, 2025; COX, 2025). Quanto à sua infraestrutura, a gNB evoluiu em relação ao Nó B Evoluído (*Evolved Node B*) (eNodeB) (rede de acesso do 4G LTE) adotando uma arquitetura modular. Essa nova estrutura separa suas funções base em duas unidades (divisão funcional): a CU e as DUs.

A CU é responsável pelo processamento de serviços em tempo não real e hospeda os protocolos de maior nível da pilha de rádio, como o Controle de Recursos de Rádio (*Radio Resource Control*) (RRC) (para controle de mobilidade e conexões), o Protocolo de Convergência de Protocolo de Dados (*Packet Data Convergence Protocol*) (PDCP) e o Protocolo de Adaptação de Dados de Serviço (*Service Data Adaptation Protocol*) (SDAP) (responsáveis pela criptografia e mapeamento de Qualidade de Serviço (*Quality of Service*) (QoS)). Por outro lado, as DUs são alocadas localmente, mais próximas às antenas, para executar serviços estritamente de tempo real. Elas hospedam os protocolos de camadas inferiores, como o Controle de Enlace de Rádio (*Radio Link Control*) (RLC), Controle de Acesso ao Meio (*Medium Access Control*) (MAC) e a camada Física (Camada Física (*Physical Layer*) (PHY)), lidando diretamente com o agendamento de recursos de rádio em milissegundos, correção rápida de erros e o processamento digital dos sinais. A Figura 7 ilustra essa divisão funcional da gNB.


Estas mudanças na arquitetura da rede forçaram as operadoras a elaborar um plano estratégico para migrar do 4G LTE para o 5G, formalmente designado como Opção 3. Inicialmente, a ideia foi aproveitar a infraestrutura existente do 4G LTE como base, adotando o modelo de implantação NSA. O modelo NSA mantém o uso do núcleo de pacotes do 4G



**Figura 7 – Divisão funcional arquitetural da estação base gNB nas unidades CU e DU, mostrando a alocação dos protocolos de rádio.**

Fonte: Elaborado pelo autor.

LTE, conhecido como EPC, e fornece Conectividade Dupla E-UTRA-NR (*E-UTRA-NR Dual Connectivity*) (EN-DC) ao usuário. Nesse arranjo, a estação base LTE (eNodeB) atua como nó mestre, utilizando o UPF do EPC para gerenciar a sinalização (como autenticação, mobilidade e estabelecimento da conexão). Simultaneamente, a estação 5G (en-gNB) atua como nó secundário dedicado ao Plano de Usuário, fornecendo a interface de rádio de alta capacidade para reforçar o fluxo de dados brutos da internet (Figura 8). A Figura 8 ilustra essa migração.




**Figura 8 – Estrutura de implantação Não-Autônoma (NSA) baseada no núcleo legado EPC, separando a controladora rádio 4G LTE do nó secundário en-gNB (dividido em CU e DU).**

Fonte: Elaborado pelo autor.

Ainda na Figura 8, as interfaces lógicas S1 (Interface do Plano de Controle S1 (*S1 Control Plane Interface*) (S1-C) e Interface do Plano de Usuário S1 (*S1 User Plane Interface*) (S1-U)) ligam a rede de acesso ao núcleo EPC. A S1-C transporta o tráfego do plano de controle (sinalização), enquanto a S1-U transporta pacotes de dados do usuário. Já a interface Interface X2 (*X2 Interface*) (X2) conecta diretamente o eNodeB e o en-gNB, permitindo que o Nó Mestre (*Master Node*) (MN) coordene o Nó Secundário (*Secondary Node*) (SN), gerencie a mobilidade e divida o fluxo de dados do usuário entre as duas torres. As interfaces Interface de Rádio LTE (*LTE Radio Interface*) (LTE-Uu) e Interface de Rádio NR (*NR Radio Interface*) (NR-Uu) são as interfaces aéreas de conexão de rádio que conectam o UE às torres 4G e 5G, respectivamente.

O segundo passo em direção ao uso pleno do 5G é a migração para o modelo SA, cenário formalmente designado como Opção 2. Nessa arquitetura, a estação base gNB conecta-se diretamente ao núcleo 5GC através da interface lógica NG, concretizando suas funcionalidades sem qualquer dependência da infraestrutura legada do 4G LTE (Figura 9).




**Figura 9 – Estrutura de implantação Autônoma (SA) ou Opção 2. O núcleo 5GC conecta-se diretamente à estação base gNB via interface NG.**

Fonte: Elaborado pelo autor.

No modelo SA, as conexões sem fio com o usuário final operam através de uma interface aérea, conhecida como 5G NR. Nela, o espectro de radiofrequência suporta maiores larguras de banda. Para tanto, as operações foram divididas em duas faixas de frequência: (i) a FR1 e (ii) a FR2.

O intervalo de radiofrequência FR1 abrange o espectro da faixa sub-6 GHz, partindo

de 410 MHz até 7.125 GHz, o que possibilita um balanço entre penetração em ambientes internos e uma boa capacidade de cobertura. Em relação a largura de banda, o FR1 suporta até 100 MHz. Já o intervalo de radiofrequência FR2, cujas frequências são conhecidas como Ondas Milimétricas (*Millimeter Wave*) (mmWave), estendem-se de 24.25 GHz a 71 GHz e suporta até 400 MHz de largura de banda. A Figura 10 sintetiza conceitualmente essa divisão de frequências no espectro da interface NR.




**Figura 10 – Divisão conceitual do espectro de radiofrequência 5G NR nas faixas FR1 (Sub-6 GHz) e FR2 (mmWave).**

Fonte: Elaborado pelo autor.

No 4G tradicional, eram utilizadas antenas MIMO com até 8 elementos, mas tal configuração revelou-se inadequada para as operações em faixas de frequência milimétricas. Portanto, no 5G, aproveitando-se do diminuto comprimento de onda dessas frequências, foi possível aumentar o número de elementos de antena consideravelmente, integrando dezenas ou centenas de elementos (como 64, 128 ou 256) em um único painel. Essa configuração é conhecida como *Massive MIMO*. Ela é altamente densa e atua em conjunto para gerar ganhos consideráveis, compensando a atenuação natural do sinal nas faixas do FR2.

A eficácia do *Massive MIMO* depende de uma técnica de filtragem espacial dos sinais conhecida como conformação de feixes (*Beamforming*). As antenas, em vez de irradiar a energia do rádio em todas as direções, direcionam o sinal de forma precisa para o dispositivo do usuário. Isso evita que o sinal cause interferência a usuários próximos e mitiga o desperdício de potência em rotas desnecessárias, o que eleva a eficiência energética do sistema e entrega conexões mais eficientes ao usuário pontual e em movimento. Além disso, a altíssima resolução espacial do *Massive MIMO* confere ao sistema a capacidade de mapear a assinatura espacial do canal, distinguindo e separando diferentes ângulos de propagação com extrema precisão. É essa característica que permite realizar a multiplexação espacial para atender a múltiplos usuários simultaneamente sobre o mesmo recurso de tempo e frequência (MU-MIMO).

Os sinais e dados enviados ao UE a partir da RBS utilizam o esquema de acesso




**Figura 11 – Comparativo ilustrativo entre a arquitetura 4G tradicional e o 5G Massive MIMO. À esquerda, nota-se a limitação dos painéis com poucos elementos e o desperdício de potência. À direita, aproveitando o diminuto comprimento de onda no FR2, o adensamento massivo de antenas gera uma altíssima resolução espacial, permitindo a conformação de feixes (*Beamforming*) eficientes e a multiplexação MU-MIMO.**

múltiplo OFDMA. O OFDMA divide a largura de banda total em múltiplas subportadoras ortogonais, eliminando a interferência entre elas. Os recursos são gerenciados pela estação base como uma matriz bidimensional de tempo e frequência e agrupados em RB, em que cada bloco contém 12 subportadoras. Dessa forma, a rede entrega diferentes fatias do espectro a diferentes usuários de forma simultânea, o que aumenta a eficiência espectral da transmissão e a qualidade da experiência do usuário. A Figura 12 ilustra o funcionamento do OFDMA onde são alocados RB para quatro UE diferentes.

Diferente do LTE, que limitava o Espaçamento de Subportadoras (*Subcarrier Spacing*) (SCS) ao valor fixo de 15 kHz, o 5G NR utiliza um mecanismo capaz de flexibilizar o espaçamento de subportadoras (STALLINGS, 2021). Através da numerologia escalável  $\mu \in \{0, 1, 2, 3, 4, 5, 6\}$ , é possível obter diferentes valores de SCS (Equação 2.1), viabilizando a adaptação da rede a diferentes faixas de frequência e cenários de uso (ASPLUND *et al.*, 2025; COX, 2025).

$$\Delta f = 15 \times 2^\mu \text{ kHz} \quad (2.1)$$




**Figura 12 – Representação do OFDMA no 5G: à esquerda, a estação base (gNB) distribui feixes dedicados a cada usuário; à direita, a grade bidimensional de tempo e frequência exibe como os Blocos de Recursos (RB) são alocados simultaneamente a diferentes UE.**

Fonte: Elaborado pelo autor.

Por conta da relação inversamente proporcional entre tempo e frequência,  $T_u = \frac{1}{\Delta f}$ , o aumento do parâmetro  $\mu$  alarga a banda ocupada pela subportadora, reduzindo exponencialmente a duração útil do símbolo OFDM (COX, 2025). A Figura 13 ilustra essa dinâmica: à medida que  $\mu$  é incrementado em uma unidade, o espaçamento entre as subportadoras duplica e, consequentemente, a duração temporal do símbolo OFDM cai pela metade (STALLINGS, 2021).

Outro aspecto importante da numerologia escalável do 5G NR é a flexibilidade da duração do *slot*. Ela permite que a rede adapte dinamicamente a transmissão aos cenários de uso. Ao utilizar espaçamentos maiores de subportadoras (símbolos mais curtos), reduz-se a latência na rede e mitigam-se distorções de sinal em altas frequências, como o ruído de fase e o espalhamento Doppler em veículos de alta velocidade (GARCIA; AL., 2021). Em contrapartida, o uso de espaçamentos menores preserva símbolos mais longos, aumentando a tolerância da rede em células de grande cobertura (STALLINGS, 2021).

Para mitigar a ISI, a porção final do símbolo OFDM é copiada e inserida em seu próprio início. Essa técnica é conhecida por CP. Se a duração do CP ( $T_{CP}$ ) for maior que o Espalhamento de Atraso ( $\tau_{DS}$ ) do canal, os ecos do multipercursos são totalmente absorvidos, permitindo que o receptor processe o sinal sem interferências. Fisicamente, a duração total de um símbolo na interface aérea é dada por  $T_s = \frac{1}{\Delta f} + T_{CP}$ , como ilustrado na Figura 15.



**Figura 13 – Numerologia escalável do 5G NR: a relação inversamente proporcional entre o espaçamento de subportadoras ( $\Delta f = 15 \times 2^\mu \text{ kHz}$ ) e a duração útil do símbolo OFDM ( $T_u = 1/\Delta f$ ). Numerologias menores favorecem cobertura ampla, enquanto maiores reduzem latência.**

Fonte: Elaborado pelo autor com base em (COX, 2025; STALLINGS, 2021).

Na camada física do 5G, a informação digital é mapeada em ondas eletromagnéticas utilizando esquemas de QAM. Para o dimensionamento dinâmico da transmissão, o 3GPP especifica tabelas de Esquema de Modulação e Codificação (*Modulation and Coding Scheme*) (MCS) que associam um índice a um esquema de modulação específico (como QPSK, 16-QAM, 64-QAM e 256-QAM) e à sua respectiva taxa de codificação (*code rate*). Cada esquema empacota uma quantidade crescente de bits em um único símbolo transmitido — variando de 2 bits no QPSK a 8 bits no 256-QAM —, o que contribui diretamente para a elevação da vazão de dados e da eficiência espectral da rede.


No entanto, à medida que a ordem de modulação aumenta e um único símbolo empacota mais bits, os pontos no diagrama de constelação tornam-se mais densos e próximos uns dos outros (Figura 16). Isso torna o sinal altamente vulnerável, exigindo uma SINR excepcional para evitar que distorções no canal causem a leitura errônea de um símbolo, o que elevaria severamente a Taxa de Erro de Bit (*Bit Error Rate*) (BER).

Para contornar esse problema de degradação, a rede utiliza o mecanismo de Adaptação de Enlace (*Link Adaptation*). O sistema avalia continuamente a qualidade do canal e, sob condições adversas (como na borda da célula), obriga o transmissor a regredir dinamicamente





para esquemas de modulação mais simples e com maior espaçamento entre os pontos, como o QPSK. Apesar de o QPSK transportar apenas 2 bits por símbolo – reduzindo a vazão de dados –, ele é extremamente resiliente contra ruídos e interferências, assegurando a confiabilidade da entrega dos pacotes.



**Figura 16 – Diagramas de constelação dos esquemas de modulação QAM utilizados no 5G NR. À medida que a ordem da modulação aumenta de (a) para (d), cada símbolo transporta mais bits, elevando a vazão, porém a maior densidade de pontos exige uma SINR proporcionalmente superior para manter a taxa de erro aceitável.**

Fonte: Elaborado pelo autor com base em (COX, 2025).

O próximo passo natural, depois dessa evolução na arquitetura da comunicação móvel, foi o aprimoramento da comunicação direta entre os UE. No que tange à comunicação veicular, a tecnologia de quinta geração trouxe avanços significativos, consolidando o paradigma **C-V2X (Cellular Vehicle-to-Everything)** (GARCIA; AL., 2021). Ao herdar a robustez do 5G NR, o *Cellular Vehicle-to-Everything* (C-V2X) supera as limitações de tecnologias baseadas em redes *ad-hoc* (como o *Dedicated Short-Range Communications/Institute of Electrical and Electronics*


*Engineers* (DSRC/IEEE) 802.11p), garantindo a latência e a confiabilidade necessárias para aplicações críticas de segurança e condução autônoma.

O C-V2X opera fundamentalmente sobre duas interfaces: (i) a **Uu**, conectando o veículo à infraestrutura da rede celular (V2I/V2N), e (ii) a **PC5 (Sidelink)**, que estabelece um enlace direto veículo-veículo (V2V) e veículo-pedestre (V2P) sem que os dados precisem transitar pelas antenas ou pelo núcleo da rede 5GC. No *Release* 16 do 3GPP, o *Sidelink* do 5G NR foi aprimorado para suportar não apenas transmissões abertas (*broadcast*), mas também comunicações *unicast* e *groupcast*, garantindo maior controle de QoS em manobras cooperativas, como a formação de pelotões (*platooning*).

O gerenciamento do acesso ao meio e a reserva de recursos de rádio no Interface de Comunicação Direta PC5 (PC5) *Sidelink* operam sob dois modos distintos. No **Modo 1**, a alocação de recursos é centralizada. A estação base (gNB) agenda os recursos para os veículos através da interface celular (Interface de Rádio Celular Uu (Uu)), garantindo uma baixa ocorrência de colisões, mas exigindo que os veículos estejam sob cobertura celular ininterrupta. No **Modo 2**, os próprios veículos gerenciam os recursos de rádio de forma autônoma através de sensoramento prévio do canal (*Channel Sensing*). A Figura 17 apresenta essas conexões.


Para viabilizar essa comunicação direta, a camada física da PC5 organiza a troca de dados em três canais físicos complementares que operam sequencialmente dentro de um mesmo *slot* de transmissão: o **PSCCH** (*Physical Sidelink Control Channel*), o **PSSCH** (*Physical Sidelink Shared Channel*), que transporta efetivamente a carga útil de dados e o **PSFCH** (*Physical Sidelink Feedback Channel*). A Figura 18 ilustra a coexistência e a multiplexação temporal desses canais dentro de um *slot* do 5G NR *Sidelink*.

O canal de controle (**PSCCH**) anuncia publicamente a reserva de recursos de tempo e frequência (Bloco de Recurso Físico (*Physical Resource Block*) (PRB)), permitindo aos veículos vizinhos realizarem o sensoramento do meio para evitar colisões de dados e encontrar blocos de rádio livres para transmissão. Em seguida, o canal compartilhado (**PSSCH**) transmite a carga útil da aplicação e as instruções para o destinatário processar e responder às requisições. Essas instruções incluem o identificador do emissor, um indicador que avisa ao receptor se o pacote contém novos dados ou é uma retransmissão, o tipo de comunicação (*broadcast*, *unicast* ou *groupcast*), dados geográficos e uma requisição ao receptor sobre as condições físicas do enlace de dados. Por último, o canal de *feedback* (**PSFCH**) opera confirmando ou não, quase que instantaneamente, o sucesso ou a falha da recepção daquele pacote (ACK/NACK). A Figura 19 ilustra essa dinâmica sequencial entre dois veículos.




**Figura 17 – Arquitetura das comunicações 5G C-V2X: coexistência da interface celular Uu (V2I/V2N) com a interface direta PC5 Sidelink (V2V/V2P), integrando o núcleo 5GC, o servidor MEC de borda e os elementos veiculares e pedestres.**

Fonte: Elaborado pelo autor com base em (GARCIA; AL., 2021; COX, 2025).



**Figura 18 – Estrutura temporal básica da camada física em um slot do 5G NR Sidelink, ilustrando a multiplexação dos canais físicos PSCCH, PSSCH e PSFCH (COX, 2025; GARCIA; AL., 2021).**

**Figura 19 – Dinâmica sequencial de operação dos canais físicos PSCCH, PSSCH e PSFCH na interface PC5 do 5G NR Sidelink. A comunicação ocorre em três fases: anúncio de controle, transmissão de dados e confirmação de recepção. Em caso de falha (NACK), o ciclo de dados é repetido via retransmissão HARQ.**



Fonte: Elaborado pelo autor com base em (GARCIA; AL., 2021; COX, 2025).

## 2.2 A Internet de Veículos (IoV) e as Redes Veiculares

A evolução das Redes de Comunicação Veicular nas últimas décadas é marcada por uma transição clara entre paradigmas tecnológicos. Inicialmente, o foco concentrava-se nas Redes Ad Hoc Veiculares (VANETs, *Vehicular Ad hoc NETworks*), priorizando a conectividade direta entre os veículos. Com o amadurecimento da Internet das Coisas (IoT, *Internet of Things*), iniciou-se um processo de convergência que resultou no atual ecossistema da Internet dos Veículos (IoV, *Internet of Vehicles*) (PARRA *et al.*, 2025; ABD-ELNABY *et al.*, 2024). Enquanto o estágio inicial das VANETs visava a comunicação básica, a IoV contemporânea integra sensores embarcados, Inteligência Artificial (IA) e Redes Definidas por Software (SDN) para viabilizar

Sistemas de Transporte Inteligentes (ITS) verdadeiramente autônomos e conectados.


As VANETs emergiram como uma evolução das redes móveis ad hoc (MANETs, *Mobile Ad hoc NETWORKs*). No entanto, seu grande diferencial é a alta mobilidade dos nós, o que impõe desafios rigorosos em termos de conectividade e latência. Diferente das MANETs, os enlaces nas redes veiculares surgem e desaparecem rapidamente. Para aplicações de segurança crítica, como alertas de colisão, atrasos na comunicação são intoleráveis. Consequentemente, novas tecnologias de comunicação foram desenvolvidas para atender às exigências das VANETs e da futura IoV, destacando-se o DSRC (*Dedicated Short-Range Communications*) e o C-V2X (*Cellular Vehicle-to-Everything*).

À medida que as redes veiculares evoluíam, os sistemas de IoT se expandiam pelas infraestruturas urbanas. Cada vez mais, dispositivos com sensores foram instalados em semáforos, estações meteorológicas, equipamentos públicos e até mesmo sendo carregados por pedestres (ABD-ELNABY *et al.*, 2024). A IoV surge da consolidação deste cenário, sendo definida como uma rede heterogênea de grande escala que possibilita a comunicação entre veículos, infraestrutura, pedestres e a nuvem (ANSARI, 2020). O compartilhamento destas informações amplia a observação do ambiente (NAIK *et al.*, 2019), otimiza a orquestração do tráfego (SÁNCHEZ *et al.*, 2025) e aprimora os sistemas de segurança (ABD-ELNABY *et al.*, 2024).

O ecossistema IoV, referenciado como *Vehicle-to-Everything* (V2X), é estruturado por quatro interfaces de comunicação que determinam a topologia e o alcance da troca de dados. A interface **Vehicle-to-Vehicle (V2V)** viabiliza a comunicação direta entre veículos, configurando-se como um requisito crítico para sistemas de segurança ativa e alertas de colisão iminente. A comunicação **Vehicle-to-Infrastructure (V2I)** conecta o veículo aos equipamentos da infraestrutura viária (RSUs, *Road Side Units*), provendo tanto dados locais de tráfego quanto o acesso a recursos de computação robustos com baixa latência. Para cenários que demandam coordenação global ou acesso a um poder de armazenamento e processamento massivo, a interface **Vehicle-to-Network (V2N)** estabelece o enlace celular com a rede núcleo da operadora, encaminhando o tráfego para a nuvem em detrimento do aumento da latência. Por fim, a interface **Vehicle-to-Pedestrian (V2P)** integra pedestres à rede por meio de dispositivos móveis, ampliando a consciência situacional do sistema de transporte.

Neste cenário, a viabilização da IoV é intrinsecamente dependente da maturidade de tecnologias de rádio robustas. Historicamente, o marco inicial no desenvolvimento de sistemas de comunicação de baixa latência ocorreu no final da década de 1990, com a alocação de


**Figura 20 – Abstração do Ecossistema IoV: V2V, V2I, V2N e V2P em Cruzamento**



Fonte: Elaborado pelo autor

75MHz do espectro na banda 5.9GHz para sistemas de transporte inteligente (ZHENG *et al.*, 2015). A motivação na época, residia na incapacidade das redes celulares em atender aos requisitos de segurança viária (latências proibitivas e instabilidade de conexão), somada às limitações de interferência das bandas não licenciadas *Industrial, Scientific, and Medical* (ISM). Sob uma perspectiva técnica, o DSRC consolidou-se não como um protocolo isolado, mas como um arcabouço regulatório e tecnológico que, ao integrar a camada física IEEE 802.11p à arquitetura *Wireless Access in Vehicular Environments* (WAVE) — responsável por definir como as mensagens de segurança são estruturadas, criptografadas e um conjunto de padrões de interface de comunicação V2V e V2I — definiu os parâmetros fundamentais para aplicações de segurança ativa e sistemas de tarifação eletrônica (Figura 21).

A partir do legado do DSRC, a evolução tecnológica da comunicação veicular ramificou-se em dois eixos técnicos distintos. O primeiro, o padrão **IEEE 802.11bd** (*Next Generation V2X - NGV*), surge como uma melhoria incremental do IEEE 802.11p. Conforme (NAIK; CHOUDHURY; PARK, 2019), a demanda por maior vazão de dados (*throughput*) e a necessidade de robustez contra o desvanecimento rápido em cenários de alta mobilidade foram os principais motivadores desta evolução, integrando técnicas para suporte a velocidades de até 250 km/h.

**Figura 21 – Arquitetura de Protocolos DSRC / WAVE (IEEE 1609 / 802.11p)**

Fonte: Adaptado de (ZHENG *et al.*, 2015)

O segundo eixo representa uma mudança de paradigma com o surgimento do **C-V2X** (*Cellular V2X*) e sua posterior transição para o **5G NR-V2X** e o horizonte do **6G** (RODRÍGUEZ-PIÑEIRO *et al.*, 2025). As limitações do DSRC em termos de escalabilidade e custo de implantação impulsionaram o desenvolvimento do C-V2X pelo 3GPP (CHEN; AL., 2017). Sob uma perspectiva regulatória atual, a disputa tecnológica foi amplamente resolvida em mercados-chave; nos Estados Unidos, a FCC estabeleceu o C-V2X como padrão obrigatório para segurança ITS com descontinuação oficial do DSRC em dezembro de 2026 (Federal Communications Commission (FCC), 2024), enquanto no Brasil a ANATEL, através da Resolução nº 772/2025 (Agência Nacional de Telecomunicações (Anatel), 2025b), harmonizou os requisitos técnicos nacionais com os padrões globais celular e radar automotivo (Agência Nacional de Telecomunicações (Anatel), 2025a). A Tabela 2 sintetiza a evolução e as divergências técnicas entre essas abordagens.

As redes veiculares evoluíram com a integração à IoV, transitando da incerteza tecnológica para uma realidade onde a superioridade do C-V2X é um fato regulatório consolidado (ANSARI, 2020). Embora o DSRC possua validação extensiva em segurança básica, a indústria convergiu para o ecossistema celular em função de sua projeção escalonável em direção ao 5G NR em frequências milimétricas (mmWave, FR2) e aos futuros padrões 6G operando em faixas Terahertz (THz) (NAIK *et al.*, 2019). Entretanto, o transplante das arquiteturas de rádio para bandas de frequência tão elevadas introduz barreiras operacionais agressivas, como deficiências estruturais de difração, elevada taxa de absorção atmosférica e severas falhas (*outage*) originadas pelo bloqueio dinâmico gerado pelo próprio tráfego (veículos de grande porte e pedestres), demandando arranjos de antenas estritamente direcionais e complexas matrizes estocásticas e de teoria de filas para modelar matematicamente sua real confiabilidade (MOLTCHANOV *et al.*,

**Tabela 2 – Comparativo técnico da evolução V2X: do DSRC ao 6G**

| Atributo         | DSRC (11p)  | NGV (11bd)  | C-V2X (5G NR)   | 6G-V2X (Exp.)     |
|------------------|-------------|-------------|-----------------|-------------------|
| Acesso MAC       | CSMA/CA     | CSMA/CA+    | CP-OFDM         | Holístico/Cognit. |
| Código Canal     | BCC         | LDPC        | LDPC            | Polar / AI-based  |
| Latência         | 100 ms      | < 50 ms     | 3 - 10 ms       | < 1 ms            |
| Taxa Dados       | 6 - 27 Mbps | Até 90 Mbps | Mbps a Gbps     | > 1 Tbps          |
| Transmissão      | Broadcast   | Broadcast   | Uni/Groupcast   | Semântica / ISAC  |
| Conectividade    | Ad-hoc      | Ad-hoc      | Nativa Sidelink | Integrada (Sat.)  |
| Robustez Doppler | Moderada    | Alta        | Muito Alta      | Extrema           |
| Sincronização    | Não exigida | Não exigida | Exigida (GNSS)  | Pevasiva (AI)     |

Fonte: Elaborado pelo autor com base em (NAIK *et al.*, 2019; ABD-ELNABY *et al.*, 2024; SÁNCHEZ *et al.*, 2025)

Nota: BC: *Broadcast*; CP-OFDM: *Cyclic Prefix Orthogonal Frequency Division Multiplexing*; GNSS: *Global Navigation Satellite System*; ISAC: *Integrated Sensing and Communication*; LDPC: *Low-Density Parity-Check*; NGV: *Next Generation V2X*.

2022). Consequentemente, a pesquisa atual concentra-se em preencher os hiatos dos mecanismos de serviço (*service-level performance*) propondo sub-rogação de tráfego, reservas de banda vitais, sistemas híbridos de predição e gestão inteligente de espectro — como Redes de Atenção para Grafos (GAT) e Aprendizado por Reforço Multiagente (MARL) — com a finalidade de otimizar a coexistência multitecnologia e manter a operação em tempo real irrestrita (TURCANU; AL., 2016).

### 2.3 Descarregamento de Tarefas


#### Arquitetura e Funcionamento do Descarregamento de Tarefas

O **descarregamento de tarefas** (ou descarregamento de tarefas computacionais) é uma estratégia que visa transferir a responsabilidade de computar tarefas complexas de dispositivos com recursos limitados para nós de processamento remoto mais poderosos. O objetivo é contornar as restrições locais de bateria, armazenamento e processamento, com o intuito de reduzir o consumo de energia, minimizar a latência e melhorar o desempenho e a qualidade do serviço (QoS) para o usuário.

Em termos de infraestrutura, geralmente o descarregamento de tarefas é implementado em uma hierarquia de três camadas (A. . . , 2022; THE. . . , 2023). A primeira é composta pelos dispositivos dos usuários (como *smartphones* e sensores IoT) que demandam a execução de tarefas (MOBILE. . . , 2024). A segunda é composta por dispositivos próximos ao usuário que atuam como extensão da nuvem tradicional, fornecendo serviços de computação com tempos



de resposta ultrarrápidos (baixa latência) e aliviando o tráfego nos links de comunicação de longa distância (ZHANG *et al.*, 2023a). A terceira é composta por servidores de nuvem tradicionais que dispõem de recursos computacionais e de armazenamento virtualmente ilimitados (REFERENCE... , 2022).




**Figura 22 – Arquitetura hierárquica em três camadas para computação em borda e nuvem.**

Vale ressaltar que a estratégia de descarregamento pode atuar com **descarregamento total (*full offloading*)** — onde a execução integral de tarefas não fracionáveis é feita no servidor remoto — ou com **descarregamento parcial (*partial offloading*)**, onde algoritmos dividem as sub-tarefas da aplicação para que ocorram computações paralelas tanto localmente quanto nos nós de borda simultaneamente (BOUKERCHE; SOTO, 2020; ZHANG; YI; MA, 2024; ZHANG *et al.*, 2023b; MACH; BECVAR, 2017).

O processo de funcionamento do descarregamento de tarefas ocorre em uma sequência de etapas, iniciando-se com a geração da tarefa (ZHANG; YI; MA, 2024). Quando a estratégia de descarregamento parcial é adotada, as aplicações são particionadas e dividem a tarefa em duas categorias: componentes não descarregáveis, que obrigatoriamente devem ser executados localmente (como interfaces de usuário ou acesso a sensores), e componentes computacionalmente intensivos, que podem ser descarregados para execução em servidores remotos (MACH; BECVAR, 2017; ZHANG *et al.*, 2023b). Em seguida, realiza-se a fase de decisão, frequentemente apontada como a mais complexa, onde um algoritmo avalia, segundo

sua política de funcionamento, se é vantajoso descarregar a tarefa para processamento remoto ou mantê-la local. Caso a decisão seja pelo processamento remoto, o dispositivo negocia a execução da tarefa através de protocolos de comunicação. Após a confirmação da alocação de recursos, o dispositivo transmite os dados (e o código, se necessário) para o servidor escolhido e aguarda o processamento. Por fim, os resultados são retornados e incorporados à aplicação original de forma transparente para o usuário (BOUKERCHE; SOTO, 2020).



**Figura 23 – Fluxograma do processo decisório e ciclo de vida do descarregamento de tarefas.**


Vale ainda ressaltar que, durante o processo de geração e modelagem das tarefas, a aplicação pode especificar parâmetros essenciais como a complexidade computacional exigida (frequentemente medida em ciclos de CPU) e o prazo máximo tolerável (*deadline* ou restrição de latência) (LIN *et al.*, 202x; WANG *et al.*, 2024). Esse limite temporal é estipulado para garantir que todo o ciclo de descarregamento remoto — o qual engloba a transmissão de dados, a espera em filas de recursos (*queuing delay*), o processamento e o retorno dos resultados — seja concluído sem causar degradação na qualidade do serviço ofertado ao usuário (ZHANG *et al.*, 2023b).

## 2.4 Aprendizado por Reforço

### Fundamentos

O RL é um paradigma de Aprendizado de Máquina (*Machine Learning*) (ML) onde o treinamento dos modelos se dá com a interação direta com o ambiente através de ações e a observação da recompensa ou penalização por tal ato (SUTTON; BARTO, 2018). Nela, o agente (aquele que procura aprender as relações intrínsecas do problema que se busca resolver) não tem acesso a nenhum supervisor que indique qual a melhor ação a ser tomada, e nem mesmo a um conjunto de dados de partida rotulados para que ele possa analisar e buscar reconhecer padrões (HU, 2024; SUTTON; BARTO, 2018).

De maneira geral, o aprendizado em problemas de RL ocorre por meio de um ciclo de interação contínua entre o agente e o ambiente, dinâmica que pode ser observada na Figura 24 (HU, 2024; SUTTON; BARTO, 2018). Embora esse mecanismo iterativo de tentativa e erro seja conceitualmente simples, ele serve de base para o desenvolvimento de modelos de Inteligência Artificial (*Artificial Intelligence*) (IA) capazes de resolver problemas complexos de tomada de decisão em áreas desafiadoras, como robótica, condução autônoma e jogos de alto desempenho (HU, 2024). Além disso, essa mesma interação tem sido fundamental para auxiliar no treinamento e alinhamento de Grande Modelo de Linguagem (*Large Language Model*)s (LLMs), empregando algoritmos de otimização de políticas aliados ao Aprendizado por Reforço a partir de Feedback Humano (*Reinforcement Learning from Human Feedback*) (RLHF) para refinar e instruir sistemas avançados, a exemplo do InstructGPT e do ChatGPT (OUYANG *et al.*, 2022; HU, 2024).



**Figura 24 – Ciclo básico de interação Agente-Ambiente no RL. A cada passo, o agente observa o estado atual, escolhe uma ação, e o ambiente responde com uma recompensa e um novo estado.**

Fonte: Elaborado pelo autor com base em (HU, 2024; SUTTON; BARTO, 2018).

## Processos de Decisão de Markov (MDP) e seus Componentes


Um MDP é uma estrutura matemática utilizada para modelar problemas de tomada de decisão sequencial sob incerteza. Um problema modelado sob o paradigma MDP é frequentemente representado pela tupla  $(S, A, P, R, \gamma)$ . Nela,  $S$  representa o espaço de estados, contendo todas as configurações possíveis do ambiente, e  $A$  denota o espaço de ações disponíveis para o agente (HU, 2024). A função de transição,  $P(s'|s, a)$ , define a probabilidade de o ambiente transitar para um estado sucessor  $s'$  dado que a ação  $a$  foi tomada no estado atual  $s$ . Por sua vez, a Função de Recompensa ( $R$ ) especifica a retribuição numérica imediata (que pode ser positiva ou negativa) indicando o ganho ou custo da transição (SUTTON; BARTO, 2018; HU, 2024). A recompensa esperada para um par estado-ação é formalmente expressa por  $R(s, a) = \mathbb{E}[R_t | S_t = s, A_t = a]$  (HU, 2024).

O parâmetro  $\gamma \in [0, 1]$  atua como um fator de desconto, controlando o peso que o agente dará às recompensas futuras em comparação às imediatas (SUTTON; BARTO, 2018). Além disso, o agente pode seguir uma estratégia para mapear estados e tomar suas ações, mecanismo este conhecido como política ( $\pi$ ) (HU, 2024). A dinâmica desse sistema atende rigorosamente à Propriedade de Markov, a qual postula que o futuro independe do passado dado o estado e a ação presentes (SUTTON; BARTO, 2018). Por fim, em cenários onde o agente não observa o estado real, mas recebe apenas uma observação corrompida ou baseada em probabilidades, o modelo é generalizado para os Processo de Decisão de Markov Parcialmente Observável (*Partially Observable Markov Decision Process*s) (POMDPs) (SUTTON; BARTO, 2018; HU, 2024).

## Retorno Esperado, Fator de Desconto e Horizontes

O MDP é capaz de modelar problemas que possuem um final natural bem definido, conhecidos na literatura como tarefas episódicas (Horizonte Finito), como uma partida de xadrez, ou problemas em que o agente continua interagindo com o ambiente perpetuamente, chamados de tarefas contínuas (Horizonte Infinito) (SUTTON; BARTO, 2018; HU, 2024). Em tarefas episódicas, que finalizam em um passo de tempo terminal  $T$ , o agente busca maximizar o retorno cumulativo simples, dado pela soma  $G_t = R_{t+1} + R_{t+2} + \dots + R_T$  (SUTTON; BARTO, 2018).

No entanto, para tarefas contínuas (Horizonte Infinito), a simples soma das recompensas ao longo do tempo poderia divergir e tender ao infinito (HU, 2024; SUTTON; BARTO, 2018). Para solucionar esse problema, aplica-se o Fator de Desconto  $\gamma \in [0, 1)$  (SUTTON;



**Figura 25 – Sequência de interação em um MDP.**

Fonte: Elaborado pelo autor com base em (SUTTON; BARTO, 2018).

BARTO, 2018; ZHAO, 2024). O Retorno Descontado  $G_t$ , iniciado no passo  $t$ , é calculado como a soma infinita das recompensas futuras, onde cada recompensa é penalizada exponencialmente pelo quão distante no futuro ela for recebida (SUTTON; BARTO, 2018):

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \quad (2.2)$$

Para garantir matematicamente que o valor desse retorno descontado seja finito, utiliza-se a convergência das séries geométricas (SUTTON; BARTO, 2018; ZHAO, 2024). Caso a recompensa máxima possível do ambiente seja um valor constante  $R$  não nulo (por exemplo, se o agente receber  $+1$  a cada passo), a soma infinita converge limitando o retorno a  $G_t = \sum_{k=0}^{\infty} \gamma^k R = \frac{R}{1-\gamma}$  (SUTTON; BARTO, 2018; ZHAO, 2024).

Além disso, uma propriedade algébrica fundamental do retorno em RL é que a Equação 2.2 pode ser reescrita de forma exata como uma relação recursiva (HU, 2024; SUTTON; BARTO, 2018). Ela separa a recompensa imediatamente recebida do retorno descontado do próximo passo de tempo (SUTTON; BARTO, 2018; HU, 2024).

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = R_{t+1} + \gamma G_{t+1} \quad (2.3)$$

Esta decomposição recursiva forma a base matemática que torna possíveis as Equações de Bellman e a atualização iterativa das estimativas das funções de valor nos algoritmos de aprendizado (HU, 2024; SUTTON; BARTO, 2018). Em última análise, o objetivo central do agente é maximizar o retorno esperado  $\mathbb{E}[G_t]$ , ponderando tanto a dinâmica estocástica do ambiente quanto as ações definidas pela sua política, que pode ser determinística ( $a = \pi(s)$ ) ou estocástica ( $\pi(a|s) = P(A_t = a|S_t = s)$ ) (SUTTON; BARTO, 2018; HU, 2024).

### Funções de Valor e Equações de Bellman

Em problemas de RL, o agente avalia o quão bom é o seu comportamento ao seguir uma determinada política por meio da estimativa do retorno esperado a longo prazo (SUTTON; BARTO, 2018). Para quantificar formalmente esse desempenho, a literatura estabelece duas abordagens principais: estimar o valor de estar no estado atual ( $s$ ), ou estimar o valor de selecionar uma ação específica ( $a$ ) a partir desse estado ( $s$ ) (HU, 2024; SUTTON; BARTO, 2018). A primeira estimativa é calculada utilizando a Função de Valor de Estado ( $V^\pi$ ), enquanto a segunda é obtida por meio da Função de Valor de Ação ( $Q^\pi$ ) (HU, 2024; SUTTON; BARTO, 2018). Ambas as funções fundamentam-se em uma propriedade de consistência recursiva, expressas matematicamente pelas Equações de Expectativa de Bellman (SUTTON; BARTO, 2018):

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma V^\pi(s')] \quad (2.4)$$

$$Q^\pi(s,a) = \sum_{s',r} p(s',r|s,a) \left[ r + \gamma \sum_{a'} \pi(a'|s') Q^\pi(s',a') \right] \quad (2.5)$$

Também é possível definir a Função de Vantagem (*Advantage*), que mede quão melhor é uma ação isolada comparada à média das demais ações daquele estado (WANG *et al.*, 2016):

$$A^\pi(s,a) = Q^\pi(s,a) - V^\pi(s) \quad (2.6)$$

### Métodos de Aprendizado e Diferença Temporal

De forma geral, durante o ciclo de interação, o agente enfrenta o **Dilema Exploração-Exploração** (*Exploration-Exploitation Dilemma*), precisando decidir continuamente entre explorar o ambiente para descobrir novas ações e estados, e explorar o conhecimento já adquirido para

maximizar sua recompensa cumulativa (SUTTON; BARTO, 2018; HU, 2024). O balanceamento adequado entre essas duas estratégias é fundamental para evitar a convergência prematura para comportamentos subótimos e garantir a descoberta das melhores decisões (HU, 2024).

Quanto ao conhecimento prévio sobre as dinâmicas do ambiente (as regras de transição e recompensa), a literatura divide os métodos em duas categorias principais (SUTTON; BARTO, 2018; MOERLAND *et al.*, 2023). Em abordagens *Model-Based* (Baseadas em Modelo), o agente possui ou aprende um modelo matemático do ambiente, permitindo o uso de técnicas de planejamento como a Programação Dinâmica para simular trajetórias e antecipar ações (SUTTON; BARTO, 2018; HU, 2024). Por outro lado, nas abordagens *Model-Free* (Livres de Modelo), o agente não constrói um modelo das regras do jogo, mas aprende as funções de valor ou as políticas diretamente a partir da experiência obtida por tentativa e erro no ambiente (HU, 2024; SUTTON; BARTO, 2018).

Para resolver problemas *Model-Free*, destacam-se duas estratégias: os *Métodos de Monte Carlo*, que atualizam as estimativas de valor apenas ao final de um episódio, utilizando o retorno total e real acumulado (SUTTON; BARTO, 2018; HU, 2024) e através da *Aprendizagem por Diferença Temporal (TD Learning)*, que atualiza suas estimativas a cada passo, utilizando o retrocesso (*bootstrapping*) embasado na estimativa de valor do próximo estado e na recompensa imediata (SUTTON; BARTO, 2018).

### Aprendizagem por Reforço Profundo (DRL)

A era profunda começa integrando Redes Neurais à função Q. A clássica **Rede Q Profunda (Redes Q-Deep (Deep Q-Network) (DQN))** (MNIH *et al.*, 2015) minimiza o Erro TD usando um Replay Buffer e Redes Alvo ( $\theta^-$ ) estáticas:

$$L(\theta) = \mathbb{E}_{(s,a,r,s') \sim D} \left[ \left( r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (2.7)$$

Evoluções incluem a **Repetição de Experiência Priorizada (PER)**, que amostra transições com base na magnitude do erro TD em vez de uniforme (SCHAUL *et al.*, 2016), a já citada **Double DQN**, e a **Dueling DQN** que ramifica a rede neural final estimando separadamente valor ( $V$ ) e vantagem ( $A$ ) (WANG *et al.*, 2016).

### 2.4.1 Policy Gradients e REINFORCE


Nos **Gradientes de Política**, não calculamos o valor para extrair política; otimizamos diretamente uma política parametrizada  $\pi_\theta$ . O **Teorema do Gradiente de Política** embasa essas atualizações estocásticas. Utiliza-se o **Truque da Razão de Verossimilhança**  $\nabla_\theta P = P \nabla_\theta \log P$  para derivar a expectativa (SUTTON; BARTO, 2018):

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(A_t|S_t) Q^\pi(S_t, A_t)] \quad (2.8)$$

A versão de Monte Carlo é o famoso **Algoritmo REINFORCE**, trocando  $Q^\pi$  pelo retorno do episódio amostrado  $G_t$  (WILLIAMS, 1992).

### 2.4.2 Actor-Critic, PPO, TRPO e SAC

Para diminuir a alta variância dos gradientes, introduzem-se as **Arquiteturas Ator-Crítico** (SUTTON; BARTO, 2018): o Ator ajusta as probabilidades  $\pi(a|s)$ , enquanto o Crítico estima o valor  $V(s)$  que atua como *baseline* para um Erro TD redutor de ruído de gradiente. Tais arquiteturas permitiram resolver **Espaços de Ação Contínuos**.



**Figura 26 – Dinâmica Ator-Crítico.**

Fonte: Elaborado pelo autor com base em (SUTTON; BARTO, 2018).

Para mitigar o colapso por passos muito largos nas atualizações de gradiente contínuo:

- **TRPO:** Impõe uma restrição (Trust Region) usando Divergência KL para travar passos agressivos (SCHULMAN *et al.*, 2015).
- **PPO:** Muito mais simples que TRPO, ele "corta"(clip) a função objetivo de modo a desincentivar uma política nova de se afastar demais da antiga (SCHULMAN *et al.*, 2017):

$$L^{CLIP}(\theta) = \mathbb{E} [\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)] \quad (2.9)$$



onde  $r_t(\theta) = \frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}$ .

- **DDPG:** Ator-Crítico para espaços determinísticos contínuos usando técnicas de replay do DQN (SUTTON; BARTO, 2018).
- **SAC:** Abordagem focada em regularização de entropia; o agente tenta escalar recompensas ao máximo mas preservando a máxima entropia (agindo aleatoriamente onde possível) (HAARNOJA *et al.*, 2018).

### 2.4.3 Avanços e Extensões

Dentre outras áreas sofisticadas constam o **Aprendizado por Reforço Multi-Agente (MARL)**, onde agentes interagem no mesmo ambiente. O **Independent Q-Learning** treina agentes individuais tratando os outros como parte estacionária do ambiente, o que na prática gera um POMDP instável. O **Curriculum Learning** ataca a **Lida com Recompensas Esparsas** submetendo o agente a tarefas crescentemente difíceis. **Aprendizado por Reforço Inverso (IRL)** decodifica a função de recompensa baseando-se num especialista humano, enquanto o **Aprendizado por Reforço Offline** procura aprender comportamentos unicamente consumindo um dataset preexistente gigante, sem tocar ou explorar ativamente o simulador ao vivo.

## 2.5 TOPSIS e Fuzzy-TOPSIS

### 2.5.1 O Algoritmo TOPSIS

O **TOPSIS** (*Technique for Order of Preference by Similarity to Ideal Solution*) é um método Tomada de Decisão Multicritério (*Multiple-Criteria Decision-Making*) (MCDM) que ranqueia alternativas pela proximidade relativa à **Solução Ideal Positiva** (PIS — melhor valor possível em cada critério) e pela distância à **Solução Ideal Negativa** (NIS — pior valor possível). Uma alternativa é preferível se estiver simultaneamente próxima da PIS e distante da NIS.

Seja  $\mathbf{X} \in \mathbb{R}^{m \times n}$  a matriz de decisão com  $m$  candidatos e  $n = 4$  critérios: latência ( $\tau$ ), carga de Unidade Central de Processamento (*Central Processing Unit*) (CPU) ( $\rho_{cpu}$ ), taxa de dados ( $C$ ) e energia ( $E$ ). O procedimento se desenvolve em cinco passos.

#### 2.5.1.0.1 Passo 1 — Normalização vetorial.

Normaliza cada coluna para remover efeitos de escala:

$$r_{ij} = \frac{x_{ij}}{\sqrt{\sum_{k=1}^m x_{kj}^2}}. \quad (2.10)$$

2.5.1.0.2 *Passo 2 — Matriz normalizada ponderada.*

Aplica os pesos  $\mathbf{w} = [w_1, w_2, w_3, w_4]^T$  com  $\sum_j w_j = 1$ :

$$v_{ij} = w_j \cdot r_{ij}. \quad (2.11)$$

Os pesos adotados são  $\mathbf{w} = [0,35; 0,25; 0,25; 0,15]$  para  $[\tau, \rho_{cpu}, C, E]$ , respectivamente, conforme justificado na Seção 4.3.1.

2.5.1.0.3 *Passo 3 — Soluções ideais positiva e negativa.*

Os critérios são classificados em *custo* (minimizar: latência, carga, energia) e *benefício* (maximizar: taxa de dados):

$$A_j^+ = \begin{cases} \min_i v_{ij} & \text{se critério } j \text{ é custo} \\ \max_i v_{ij} & \text{se critério } j \text{ é benefício} \end{cases}, \quad (2.12)$$

$$A_j^- = \begin{cases} \max_i v_{ij} & \text{se critério } j \text{ é custo} \\ \min_i v_{ij} & \text{se critério } j \text{ é benefício} \end{cases}. \quad (2.13)$$

2.5.1.0.4 *Passo 4 — Distâncias à PIS e NIS.*

A distância de cada candidato  $i$  às soluções ideais é calculada pela **norma  $L_2$  Euclidiana**:

$$d_i^+ = \sqrt{\sum_{j=1}^n (v_{ij} - A_j^+)^2}, \quad (2.14)$$

$$d_i^- = \sqrt{\sum_{j=1}^n (v_{ij} - A_j^-)^2}. \quad (2.15)$$

A escolha da norma  $L_2$  segue a formulação original de Hwang e Yoon (1981) e possui uma propriedade geométrica fundamental para o problema de descarregamento. Considere dois

candidatos  $A$  e  $B$  com desvios em relação à PIS:  $A$  apresenta desvio  $\delta$  em um único critério (e.g., latência muito alta) e zero nos demais;  $B$  apresenta desvio  $\delta/\sqrt{n}$  em todos os  $n = 4$  critérios igualmente. Pela norma  $L_1$ , ambos têm distância  $\delta$  à PIS — portanto seriam indiferentes. Pela norma  $L_2$ :

$$d_A^+ = \sqrt{\delta^2 + 0 + 0 + 0} = \delta, \quad (2.16)$$

$$d_B^+ = \sqrt{n \cdot (\delta/\sqrt{n})^2} = \delta. \quad (2.17)$$

A distância euclidiana é idêntica nos dois casos, mas a geometria da  $L_2$  introduz uma curvatura que favorece, no ranqueamento final pelo coeficiente  $C^*$ , soluções Pareto-balanceadas sobre soluções extremistas. Isso ocorre porque a superfície de nível da  $L_2$  é esférica: candidatos com desvios distribuídos igualmente entre critérios habitam a mesma esfera que candidatos com desvio concentrado em um critério — mas a projeção nos critérios custo/benefício faz com que os primeiros recebam menor penalidade total no cálculo conjunto de  $d^+$  e  $d^-$ . Para o cenário VEC, onde um servidor com latência extremamente alta e fila cheia e baixa taxa de dados deve ser severamente penalizado, a  $L_2$  garante que afastamentos simultâneos em múltiplos critérios sejam superlinearmente penalizados em relação a afastamentos isolados — propriedade que a  $L_1$  (soma linear) não possui.

#### 2.5.1.0.5 Passo 5 — Coeficiente de proximidade.

O escore final de cada candidato é:

$$C_i^* = \frac{d_i^-}{d_i^+ + d_i^-} \in [0, 1]. \quad (2.18)$$

O coeficiente  $C_i^* \rightarrow 1$  indica que o candidato  $i$  está próximo da solução ideal e distante da anti-ideal (preferível);  $C_i^* \rightarrow 0$  indica o oposto. O ranqueamento final dos candidatos é determinado por  $C_i^*$  em ordem decrescente.

#### 2.5.2 Extensão Fuzzy do TOPSIS

Em ambientes VEC, estimativas de qualidade de canal chegam com atraso de um passo de tempo (o agente observa as condições do canal do instante  $t - 1$  ao tomar a decisão em  $t$ ), e ocupações de fila são observadas com ruído de sondagem. Esta incerteza de medição abre espaço para uma generalização natural do TOPSIS: a extensão *fuzzy* via **Números Fuzzy Triangulares** (*Triangular Fuzzy Numbers*, TFNs).

Nesta extensão, cada valor  $x_{ij}$  da matriz de decisão é modelado como um TFN  $\tilde{x}_{ij} = (L_{ij}, M_{ij}, U_{ij})$ , onde  $L_{ij}$  é o limite inferior,  $M_{ij}$  é o valor modal e  $U_{ij}$  é o limite superior do intervalo de confiança. A **fuzzificação** é realizada a partir da estatística da coluna  $j$ :

$$L_{ij} = x_{ij} - \sigma_{\text{frac}} \cdot \hat{\sigma}_j, \quad (2.19)$$

$$M_{ij} = x_{ij}, \quad (2.20)$$

$$U_{ij} = x_{ij} + \sigma_{\text{frac}} \cdot \hat{\sigma}_j, \quad (2.21)$$

onde  $\hat{\sigma}_j$  é o desvio padrão empírico da coluna  $j$  e  $\sigma_{\text{frac}} \in [0, 1]$  é um hiperparâmetro de fuzzificação. A **defuzzificação** pelo centroide recupera um valor escalar:

$$\bar{x}_{ij} = \frac{L_{ij} + M_{ij} + U_{ij}}{3} = x_{ij}, \quad (2.22)$$

que neste caso resulta exatamente no valor original (pois o TFN é simétrico em torno de  $M_{ij}$ ), porém a estrutura *fuzzy* influencia os cálculos intermediários de PIS e NIS ao considerar os extremos do intervalo.


A justificativa para esta extensão é de natureza teórica: quando dois candidatos possuem escores  $C^*$  muito próximos, qualquer perturbação de medição pode inverter o ranqueamento, gerando inconsistência na política do agente (FARIMANI *et al.*, 2024). A extensão *fuzzy* modela este intervalo de incerteza via TFN, prevenindo inversões instáveis de ranqueamento ao considerar explicitamente os extremos do intervalo de confiança de cada medição.

A propriedade de unificação paramétrica é central para a arquitetura proposta: quando  $\sigma_{\text{frac}} = 0$ , tem-se  $L_{ij} = M_{ij} = U_{ij} = x_{ij}$ , e o método reduz-se exatamente ao TOPSIS padrão. Esta parametrização permite que o mesmo módulo opere tanto no modo determinístico quanto no modo *fuzzy*, com a transição controlada por um único hiperparâmetro — sem qualquer alteração estrutural da arquitetura. Na presente proposta, adota-se  $\sigma_{\text{frac}} = 0,0$ , correspondendo ao TOPSIS determinístico padrão. A extensão *fuzzy* está disponível como grau de liberdade de projeto para adaptação a ambientes com maior incerteza de medição, sem custo de redesenho do sistema.

### 3 REVISÃO DE LITERATURA

Este capítulo tem como objetivo apresentar uma revisão bibliográfica aprofundada dos trabalhos recentes e relevantes para o desenvolvimento desta proposta. Os critérios de seleção englobaram pesquisas focadas na interseção entre comunicação veicular emergente e soluções de aprendizado de máquina adaptativo voltadas para o descarregamento de tarefas dinâmico.

Para classificar e relacionar o estado da arte das soluções de descarregamento de tarefas em ambientes de VEC e MEC, adotou-se uma versão adaptada da taxonomia proposta em (SOUZA *et al.*, 2020), sendo ela dividida em duas vertentes estruturais: **Padrão de Comunicação**, que avalia as tecnologias de rede e os servidores utilizados; e **Problema**, que analisa as estratégias com ênfase em modelos DRL. Dessa maneira, os artigos relacionados foram classificados conforme a Figura 27.



**Figura 27 – Taxonomia adaptada para classificação dos trabalhos relacionados em descarregamento computacional veicular, com ênfase na modelagem de Aprendizado por Reforço Profundo (DRL) e ambiente de simulação.**

Fonte: Adaptado de Souza *et al.* (2020).

#### 3.1 Padrão de Comunicação

No descarregamento de tarefas, o cenário de comunicação celular vem ganhando bastante destaque. Neste quesito, suas tecnologias vêm evoluindo rapidamente e ditam a maioria das pesquisas aqui apresentadas. A seguir são apresentados alguns trabalhos que utilizam tecnologias 5G e além (Além do 5G (*Beyond 5G*) (B5G)/Sexta Geração de Redes Móveis (*Sixth Generation*) (6G)) para atender às exigentes demandas relacionadas a aplicações veiculares.

### 3.1.1 Tecnologia

A evolução das tecnologias de comunicação veicular destaca a transição de padrões tradicionais, como o *Dedicated Short-Range Communications* (DSRC) e o IEEE 802.11bd, para a comunicação celular aliada à IA. Essa mudança visa, sobretudo, possibilitar baixas latências e alta vazão de dados em cenários de alta mobilidade, contribuindo para resolver o problema de descarregamento de tarefas. Nesse contexto, diversos trabalhos, como os de (MOGHADDASI *et al.*, 2023; SIDWINI *et al.*, 2024; LI *et al.*, 2025; MEGHAMALA; PAUL; KUMAR, 2025), utilizam interfaces C-V2X e arquiteturas de borda para o compartilhamento de informações em aplicações veiculares avançadas.

O estudo de (MOGHADDASI *et al.*, 2023) propõe um algoritmo de DRL, especificamente o Redes Q-Deep Duplas (*Double Deep Q-Network*) (DDQN), em redes 5G para solucionar o problema de descarregamento de tarefas utilizando a comunicação V2I para alcançar eficiência energética e a diminuição da latência. O trabalho de (SIDWINI *et al.*, 2024) explora o uso de algoritmos avançados de DRL, como o SAC, para otimizar o descarregamento dinâmico entre dispositivos locais, servidores de borda e a nuvem, equilibrando o consumo de energia e o atraso na execução. Em um cenário direcionado aos sistemas 6G, (LI *et al.*, 2025) introduz um esquema inteligente baseado em DQN em redes V2X assistidas por MEC para otimizar conjuntamente a associação aos servidores, a taxa de descarregamento de tarefas e a aceleração dos veículos. Essa abordagem visa minimizar o atraso do sistema e evitar colisões de trânsito, utilizando uma função de recompensa segmentada que respeita restrições de atraso, energia e segurança. Por fim, (MEGHAMALA; PAUL; KUMAR, 2025) propõe um *framework* de Aprendizado por Reforço Multiagente (*Multi-Agent Reinforcement Learning*) (MARL) para redes 5G que combina o algoritmo SAC com arquiteturas hierárquicas (Multiagente Twin Delayed DDPG (*Multi-Agent Twin Delayed Deep Deterministic Policy Gradient*) (MATD3) e *Task Descriptor Policy Gradient* (TD2PG)). Essa solução visa a alocação dinâmica de subcanais, potência de transmissão e recursos computacionais em servidores MEC, levando em consideração a mobilidade dos usuários e o isolamento das fatias de rede (*network slicing*).

### 3.1.2 Servidor

Quando há necessidade de transferência de responsabilidade de processamento de tarefas, existem três opções viáveis: processar as tarefas em (i) um dispositivo de infraestrutura de borda, (ii) recursos ociosos das unidades processadoras dos veículos vizinhos, ou (iii) uma

robusta infraestrutura de nuvem, que apresenta maior capacidade, mas latência consideravelmente superior. A seguir, é descrito como as principais opções locais foram modeladas.

## MEC

Servidores MEC contribuem significativamente para atender exigências de URLLC em 5G NR. Eles ficam localizados na borda da rede e podem ser constituídos de equipamentos robustos, capazes de auxiliar no processamento pesado de tarefas delegadas por outros dispositivos com recursos limitados.

Nesse contexto, esses servidores frequentemente estão conectados a RSU e estações base para oferecer suporte computacional de baixa latência aos veículos. Aproveitando essa infraestrutura de borda, o estudo de (ZHAO *et al.*, 2025) propõe o esquema DQN Preditivo e Emparelhamento de Kuhn-Munkres (*Predictive DQN and Kuhn-Munkres scheme*) (PDQKM) para otimizar o descarregamento de múltiplas tarefas, permitindo reduzir a latência total do sistema. Por outro lado, o trabalho de (WU *et al.*, 2025) utiliza Redes Adversárias Generativas (*Generative Adversarial Networks*) (GAN) para expandir amostras de tarefas evitando o desequilíbrio de dados, criando um modelo de Aprendizado Federado (*Federated Learning*) (FL) para realizar o descarregamento de tarefas de forma energeticamente eficiente em servidores MEC. O estudo de (MOHAMMAD *et al.*, 2025) apresenta o *framework* EMEC-IoVTOF, que integra DRL com a técnica de Otimização por Enxame de Partículas (*Particle Swarm Optimization*) (PSO) para otimizar a alocação de recursos em sistemas IoV. A solução calcula custos de descarregamento para evitar a convergência para ótimos locais, conseguindo reduções significativas de latência e consumo de energia, além de contornar restrições de largura de banda em cenários veiculares dinâmicos. Por sua vez, o estudo de (LIU *et al.*, 2024) utiliza o método de aproximação de Bernstein para converter restrições probabilísticas de interferência em formato tratável, minimizando uma função de utilidade que equilibra atrasos na transmissão e na computação para o Computação de Borda de Múltiplos Acessos Assistida por Nuvem (*Cloud-assisted Multi-access Edge Computing*) (C-MEC).

## VEC

VEC distribui poder computacional formando micro-nuvens entre os próprios veículos na estrada, empregando recursos ociosos de suas unidades embarcadas (OBU) para auxiliar vizinhos próximos através de canais de comunicação direta, frequentemente desassociados de

infraestruturas estáticas da pista. O estudo de (XIE *et al.*, 2025) propõe utilizar Superfície Inteligente Reconfigurável (*Reconfigurable Intelligent Surface*) (RIS) juntamente com VEC para reduzir custos de implantação, ao mesmo tempo que busca maximizar Eficiência Operacional do Sistema (*System Operation Efficiency*) (SOE) via algoritmo PPO, otimizando conjuntamente decisões de descarregamento, alocação de recursos computacionais e vetores de mudança de fase. Por sua vez, (WU; GU; LIANG, 2025) utiliza FL e Ator-Crítico Determinístico Profundo Multiagente (*Multi-Agent Deep Deterministic Policy Gradient*) (MADDPG), empregando mecanismos de incentivo baseados em reputação para determinar a proporção ideal de recursos cedidos por veículos vizinhos, visando minimizar latência e consumo de energia e garantindo alta taxa de conclusão em tarefas computacionalmente intensivas. O trabalho de (LONG *et al.*, 2025) desenvolve o algoritmo Otimização de Alocação de Recursos e Divisão de Tarefas Nuvem-Terminal (*Cloud-Terminal Task Splitting and Resource Allocation Optimization*) (CTSTAO), que integra dispositivos finais, borda veicular e nuvem para realizar descarregamento parcial de tarefas, separando o problema em subproblemas convexos para otimizar de forma colaborativa o *task splitting* (taxa de divisão de tarefas) e a alocação de recursos computacionais, alcançando equilíbrio de desempenho global do sistema. Em (ABBAS; XU; ZHANG, 2024), propõe-se um algoritmo baseado em aprendizado descentralizado colaborativo, que orquestra a execução concorrente de tarefas fragmentadas pelos veículos presentes na área de cobertura, otimizando conjuntamente a alocação de canais sem fio com os recursos computacionais. Dessa forma, minimiza-se a latência total e o consumo de energia em ambientes veiculares dinâmicos.

## Discussão

**Tabela 3 – Resumo dos aspectos de Padrão de Comunicação, Servidor e Condições de Ambiente dos trabalhos relacionados**

| Referência                        | Tecnologia |                | Servidor |     |       | Observabilidade Parcial<br>(Incerteza de Estado) | Canal Perfeito | Carga de Trabalho<br>(Diferentes regimes) |
|-----------------------------------|------------|----------------|----------|-----|-------|--------------------------------------------------|----------------|-------------------------------------------|
|                                   | V2I        | Sidelink (V2V) | MEC      | VEC | Nuvem |                                                  |                |                                           |
| (MOGHADDASI <i>et al.</i> , 2023) | ✓          |                | ✓        |     |       |                                                  | ✓              | ✓                                         |
| (SIDWINI <i>et al.</i> , 2024)    | ✓          |                | ✓        |     | ✓     |                                                  | ✓              |                                           |
| (LI <i>et al.</i> , 2025)         |            | ✓              | ✓        |     |       |                                                  | ✓              |                                           |
| (MEGHAMALA; PAUL; KUMAR, 2025)    | ✓          |                | ✓        |     |       |                                                  | ✓              |                                           |
| (ZHAO <i>et al.</i> , 2025)       | ✓          |                | ✓        |     |       |                                                  | ✓              |                                           |
| (WU <i>et al.</i> , 2025)         | ✓          |                | ✓        |     |       |                                                  | ✓              |                                           |
| (MOHAMMAD <i>et al.</i> , 2025)   |            | ✓              | ✓        |     |       |                                                  | ✓              |                                           |
| (LIU <i>et al.</i> , 2024)        | ✓          |                | ✓        |     | ✓     |                                                  |                |                                           |
| (XIE <i>et al.</i> , 2025)        | ✓          |                |          | ✓   |       |                                                  | ✓              |                                           |
| (WU; GU; LIANG, 2025)             |            | ✓              |          | ✓   |       |                                                  | ✓              |                                           |
| (LONG <i>et al.</i> , 2025)       | ✓          | ✓              |          | ✓   | ✓     |                                                  | ✓              |                                           |
| (ABBAS; XU; ZHANG, 2024)          | ✓          |                |          | ✓   |       |                                                  | ✓              |                                           |

Fonte: Elaborado pelo autor



Analisando a Tabela 3, constata-se forte tendência de padronização de tecnologias celulares avançadas para comunicação veicular. Grande parte dos trabalhos recentes analisados concentra-se na utilização de conectividade V2I via redes 5G e 6G. Em relação à comunicação entre os nós, embora o padrão C-V2X englobe diferentes interfaces, diversos trabalhos referem-se estritamente à utilização das interfaces *Sidelink* destas comunicações para troca direta de dados (V2V). Já em relação à infraestrutura, a adoção de servidores MEC centralizados em unidades RSU ainda é predominante, mas observa-se tendência crescente de pesquisas que exploram VEC, tratando os próprios veículos como provedores de recursos. Trabalhos como os de (LIU *et al.*, 2024) e (LONG *et al.*, 2025) adotam arquiteturas colaborativas integrando MEC com nuvem e VEC com nuvem, respectivamente.

Outro aspecto identificado foi a ausência de tratamento para a observabilidade parcial, caracterizada na tabela pela coluna "Incerteza de Estado". Todos os trabalhos identificados na tabela modelam o ambiente assumindo conhecimento perfeito do cenário, como a disponibilidade de CPU dos servidores no exato momento da tomada de decisão. Dessa forma, agentes independentes podem decidir descarregar tarefas para um mesmo servidor simultaneamente com base em informações desatualizadas. Além disso, não há menção nos trabalhos sobre imperfeições do canal de comunicação. Portanto, assumir tais características cria políticas de decisão pouco robustas frente à dinâmica real.

Outra limitação identificada diz respeito à modelagem de cargas de trabalho. Com exceção do estudo de (MOGHADDASI *et al.*, 2023), os demais trabalhos avaliam seus algoritmos sob regimes de tráfego constantes ou com taxa de chegada fixa por episódio. Em cenários de tráfego reais, eventos imprevisíveis podem causar rajadas instantâneas (*bursts*) no envio de pacotes críticos, alterando a distribuição de chegada das tarefas. Modelos DRL treinados exclusivamente sem variação dinâmica de carga tendem a sofrer degradação de desempenho com tais mudanças de regime.

Nesse contexto, o modelo proposto neste trabalho visa endereçar essas lacunas ao modelar, desde a concepção do ambiente, tais dificuldades e estocasticidades inerentes a redes veiculares reais, conforme a adoção das tecnologias supramencionadas.

### 3.2 Problema

Com a infraestrutura de comunicação estabilizada, a escolha de abordagens apropriadas constituem um passo crítico para a garantia dos requisitos no ambiente veicular. A

formulação de soluções para o descarregamento de tarefas dinâmico e em tempo real apresenta elevada complexidade. Para contornar essa dificuldade, diversos trabalhos na literatura optam por simplificar o escopo, desenvolvendo abordagens focadas em uma única métrica, como a minimização exclusiva da latência ou do consumo de energia (FENG *et al.*, 2017; HOU *et al.*, 2016; REN *et al.*, 2018; REN *et al.*, 2019; ZHANG *et al.*, 2019). No entanto, o estudo de (QIN *et al.*, 2020) enfatiza que otimizar um único objetivo isoladamente não reflete a realidade das redes, enquanto (ZHANG; YI; MA, 2024) reitera que a busca por um compromisso dinâmico entre tempo de resposta e consumo energético transforma a alocação em um problema incerto de otimização multiobjetivo NP-difícil. Diante dessa constatação, observa-se a necessidade do desenvolvimento de políticas que considerem múltiplos critérios simultaneamente, com o intuito de projetar propostas robustas e capazes de atender às demandas operacionais e funcionais de longo prazo.

A modelagem de um cenário realista precisa lidar fundamentalmente com incertezas espaciais da rede. A alta velocidade dos veículos altera significativamente a infraestrutura veicular, mascarando os estados reais e comprometendo a acurácia dos dados divulgados pelos nós de computação (LIU *et al.*, 2024). A somatória entre a imprevisibilidade de processos no interior da borda (ABBAS; XU; ZHANG, 2024) e o natural decréscimo de precisão proveniente do atraso por telemetria exige uma abordagem maleável. Decisões sustentadas integralmente por lógicas determinísticas tornam-se insatisfatórias, contribuindo para que os modelos não atendam adequadamente os requisitos de qualidade no descarregamento de tarefas (KANDALI *et al.*, 2025; ZHAO *et al.*, 2025).

### 3.2.1 Estratégia

Para contornar grande parte dos vieses supracitados, a literatura contemporânea aponta uma considerável substituição do uso de heurísticas e meta-heurísticas por soluções mais sofisticadas e adaptativas. A respeito desta transformação, destaca-se a utilização de DRL, por conta de sua capacidade de aprimorar sequências de ações de longo prazo extraídas através de intensas interações com ambiente simulado.

De fato, o escopo científico atual tem explorado ativamente o uso de diversas estratégias integradas ao DRL. Uma delas é a integração com aprendizado FL, que permite o treinamento colaborativo de modelos DRL entre múltiplos agentes, preservando a privacidade dos dados locais (CHEN *et al.*, 2025). Outra frente mescla esquemas DRL com tecnologia

Gêmeo Digital (*Digital Twin*) (DT), possibilitando que soluções sejam testadas e simuladas virtualmente antes da execução no ambiente físico (WEI *et al.*, 2024). Para lidar com o vasto espaço de estados e com cenários altamente variáveis, pesquisas recentes fundem arquiteturas DRL com redes Redes Neurais em Grafos (*Graph Neural Networks*) (GNN) para capturar de forma eficiente as relações e as dependências espaciais entre os nós veiculares (WANG *et al.*, 2024; TANG *et al.*, 2024). Adicionalmente, métodos Aprendizado por Transferência (*Transfer Learning*) (TL) têm sido utilizados para acelerar a adaptação de veículos recém-conectados em infraestruturas baseadas em SDN, onde a separação entre os planos de controle e de dados facilita a gerência global (BAKER *et al.*, 2024). Por fim, destaca-se a incorporação da teoria de otimização de Lyapunov acoplada a métodos DRL para garantir matematicamente a estabilidade contínua das filas de tarefas a longo prazo (KUMAR; ZHAO; FERNANDO, 2023).

### **Função Objetivo**

Além do compromisso entre a minimização da latência de processamento e a redução do consumo de energia, a literatura recente incorpora a otimização de custos operacionais e financeiros da rede (MA *et al.*, 2025). A estabilidade das filas de tarefas (*queue stability*) a longo prazo também é um objetivo considerado, frequentemente abordado por meio da otimização de Lyapunov acoplada a técnicas de aprendizado (KUMAR; ZHAO; FERNANDO, 2023). Outros estudos buscam maximizar a taxa de sucesso das tarefas sob restrições de prioridade e da capacidade dos nós de computação (KUMARI *et al.*, 2025). Adicionalmente, o gerenciamento de confiança (*trust management*) dos nós de borda desponta como um objetivo crítico em infraestruturas SDN para evitar descarregamentos falhos ou maliciosos (BAKER *et al.*, 2024).

### **Engenharia de Estado e Recompensa**

No MDP, a engenharia do espaço de estado não busca prever matematicamente as transições do sistema, uma vez que algoritmos DRL se destacam justamente por gerenciar o controle em ambientes estocásticos e dinâmicos sem conhecimento prévio dessas transições (FAN; CAI, 2024). Em vez disso, o estado é projetado para permitir que o agente avalie diretamente a dinâmica da rede com base nos resultados observados. Para isso, o espaço de estado deve utilizar métricas além das básicas, incorporando variáveis que capturem a dinamicidade dos nós de computação (KUMAR; ZHAO; FERNANDO, 2023) ou até mesmo escores de confiança dos dispositivos candidatos (BAKER *et al.*, 2024). A literatura recente expande ainda mais essa

abstração ao integrar as características das tarefas — englobando requisitos de recursos, níveis de prioridade e prazos máximos toleráveis (*deadlines*) (FAN; CAI, 2024; WEI *et al.*, 2024). Além disso, para refinar a percepção física, as pesquisas incluem o ângulo de desvio e a orientação direcional dos veículos em relação aos servidores. Essa consciência espacial de granularidade fina complementa o estado atual, otimizando a escolha do nó alvo de forma proativa (FARIMANI *et al.*, 2024).

A respeito da função de recompensa, é uma boa prática (SUTTON; BARTO, 2018) realizar o dimensionamento adequado (*scaling*) das métricas e a normalização dos dados para evitar que uma única variável domine o processo de convergência. Além disso, alguns trabalhos utilizam pesos dinâmicos em vez de estáticos, ajustando-os em tempo real de acordo com as condições momentâneas da rede e com o nível de urgência das tarefas (KUMARI *et al.*, 2025; FAN; CAI, 2024; SHI; CHEN; ZHU, 2023). Já a penalização para quando um agente escolhe uma ação ruim — como a violação do tempo máximo tolerável (*deadline*) ou quebras de comunicação por evasão de cobertura — é integrada à recompensa para guiar o agente a priorizar o cumprimento dos requisitos de latência e confiabilidade. Também se observa uma forte transição para mecanismos de recompensa globais, nos quais os agentes colaboram buscando a eficiência sistêmica da rede, mesmo que em detrimento do custo ótimo individual imediato (FARIMANI *et al.*, 2024). Em cenários de descarregamento parcial, a recompensa é formulada dividindo a ação em múltiplos estágios sequenciais, avaliando o impacto do particionamento da tarefa de forma independente da alocação de recursos (TIAN *et al.*, 2025). Por fim, a teoria de Lyapunov é frequentemente utilizada na recompensa por meio de funções *drift-plus-penalty*, garantindo matematicamente que o agente seja penalizado caso a redução excessiva do consumo energético coloque em risco a estabilidade das filas do sistema a longo prazo (KUMAR; ZHAO; FERNANDO, 2023).

## Modelos

No que tange aos modelos, existem diversos trabalhos focados em otimizar a forma como o agente observa o estado e seleciona ações eficientemente. Variantes baseadas em valor, como redes DQN aprimoradas, realizam a seleção de servidores reconhecendo que nem todas as tarefas computacionais geradas possuem a mesma importância ou urgência (KUMARI *et al.*, 2025). Para espaços de ação contínuos, arquiteturas Ator-Crítico dominam o cenário. O algoritmo SAC é empregado para evitar a convergência prematura para ótimos locais, utilizando

a maximização da entropia estocástica para explorar melhor as opções de descarregamento e *caching* (BAO *et al.*, 2025). Para lidar com o problema de espaços de ação híbridos — nos quais decisões discretas de seleção de servidor são combinadas com a alocação contínua de recursos computacionais —, alguns trabalhos propõem métodos como o algoritmo Rede Q Profunda Parametrizada (*Parametrized Deep Q-Network*) (P-DQN) (MA *et al.*, 2025) ou mesmo fusões entre modelos, como o Gradiente de Política com Q-Learning e DDPG (*Q-learning and Deep Deterministic Policy Gradient*) (QDPG), que une as arquiteturas Gradiente de Política Determinístico Profundo (*Deep Deterministic Policy Gradient*) (DDPG) e Rede Q Profunda Dupla com Dueling (*Dueling Double Deep Q-Network*) (D3QN) aliadas a algoritmos de clusterização *K-Means* (WEI *et al.*, 2024). Em sistemas compostos por múltiplos agentes, o modelo MADDPG com Otimização de Lyapunov (*Lyapunov-based Multi-Agent Deep Deterministic Policy Gradient*) (L-MADDPG) utiliza a otimização de Lyapunov para garantir matematicamente a estabilidade do sistema a longo prazo (KUMAR; ZHAO; FERNANDO, 2023), enquanto abordagens como o modelo DDPG com Iteração de Estados Internos Sequenciais (*Sequential Internal-state Deep Deterministic Policy Gradient*) (SIDDPG) iteram múltiplos estados internamente para refinar o particionamento de sub-tarefas de forma sequencial (TIAN *et al.*, 2025). A Tabela 4 mapeia alguns algoritmos DRL ao tipo de espaço de ação adequado.

**Tabela 4 – Classificação dos algoritmos clássicos de DRL quanto à adequação ao espaço de ação**

| Algoritmo DRL                                                                             | Espaço de Ação      | Referência Base                                           |
|-------------------------------------------------------------------------------------------|---------------------|-----------------------------------------------------------|
| DQN ( <i>Deep Q-Network</i> )                                                             | Discreto            | (UDDIN; ZHANG; SAKR, 2025; FARIMANI <i>et al.</i> , 2024) |
| Double DQN                                                                                | Discreto            | (UDDIN; ZHANG; SAKR, 2025)                                |
| Dueling DQN                                                                               | Discreto            | (UDDIN; ZHANG; SAKR, 2025)                                |
| DDPG ( <i>Deep Deterministic Policy Gradient</i> )                                        | Contínuo            | (UDDIN; ZHANG; SAKR, 2025; FARIMANI <i>et al.</i> , 2024) |
| <i>Twin Delayed Deep Deterministic Policy Gradient</i> (TD3) ( <i>Twin Delayed DDPG</i> ) | Contínuo            | (UDDIN; ZHANG; SAKR, 2025)                                |
| PPO ( <i>Proximal Policy Optimization</i> )                                               | Discreto e Contínuo | (UDDIN; ZHANG; SAKR, 2025)                                |
| TRPO ( <i>Trust Region Policy Optimization</i> )                                          | Discreto e Contínuo | (UDDIN; ZHANG; SAKR, 2025)                                |
| SAC ( <i>Soft Actor-Critic</i> )                                                          | Contínuo            | (UDDIN; ZHANG; SAKR, 2025; FARIMANI <i>et al.</i> , 2024) |

Fonte: Elaborado pelo autor

## Ambiente Simulado

O treinamento e a validação de algoritmos de aprendizado DRL voltados para redes veiculares exigem ambientes simulados capazes de replicar a natureza não estacionária e volátil do mundo real. Diferente de aplicações computacionais estáticas, os modelos precisam interagir com um ecossistema que engloba tanto a física da movimentação quanto a complexidade das

comunicações sem fio e da carga de processamento (UDDIN; ZHANG; SAKR, 2025).

Para modelar a mobilidade com precisão, simuladores de tráfego microscópico, como o *SUMO* (Simulation of Urban MObility) (LOPEZ *et al.*, 2018) e o *PTV Vissim* (PTV Group, 2020), são amplamente adotados na literatura (SOUZA *et al.*, 2021; KUMAR; ZHAO; FERNANDO, 2023). Ferramentas desse tipo permitem a criação de malhas rodoviárias e urbanas e simulam o comportamento dinâmico dos veículos por meio de modelos matemáticos, capturando variações de velocidade, aceleração e respostas a semáforos (LI *et al.*, 2025). Em paralelo, a dinâmica das comunicações — que inclui o desvanecimento do canal, perdas de propagação e bloqueios físicos (condições de visada *LoS/NLoS*) — é frequentemente emulada por simuladores de rede de eventos discretos, destacando-se o ns-3, o qual costuma ser integrado ao SUMO para formar plataformas de co-simulação (SOUZA *et al.*, 2021; UDDIN; ZHANG; SAKR, 2025).

Em relação ao treinamento do modelo de inteligência artificial, o ambiente de simulação é abstraído matematicamente para que o agente observe os estados e tome decisões. Para viabilizar esse treinamento, trabalhos recentes constroem ambientes customizados baseados em padrões como o *OpenAI Gym* (recentemente sucedido pelo *Gymnasium*) (BROCKMAN *et al.*, 2016), que gerenciam o ciclo de observação do estado, execução da ação e recebimento da recompensa (UDDIN; ZHANG; SAKR, 2025) para treinar e otimizar os pesos das redes neurais (MOGHADDASI; RAJABI; GHAREHCHOPOGH, 2024; KUMAR; ZHAO; FERNANDO, 2023; WU *et al.*, 2025).

Por fim, para evitar que o treinamento ocorra de forma puramente teórica, a literatura atual enfatiza o uso de dados do mundo real (*real-world traces*) dentro do ambiente de simulação (FARIMANI *et al.*, 2024). Algumas abordagens incorporam trajetórias extraídas de frotas reais ou bases de dados de servidores comerciais — como o *Google Cluster Dataset* — para emular as flutuações estocásticas na geração de tarefas e a exigência de recursos de CPU, Memória e Largura de Banda (LONG *et al.*, 2025). Essa imersão de dados reais no ambiente simulado garante que as políticas de descarregamento aprendidas pelo agente DRL sejam aplicáveis e estáveis diante das dinâmicas de arquiteturas VEC no mundo físico.

## Discussão

**Tabela 5 – Análise comparativa dos trabalhos relacionados por Função Objetivo, Estado, Recompensa e Ambiente Simulado**

| Referência                      | Função Objetivo |         |           |            | Estado |          |            |        | Recompensa    |           |           |             | Ambiente Simulado |            |        |             |           |
|---------------------------------|-----------------|---------|-----------|------------|--------|----------|------------|--------|---------------|-----------|-----------|-------------|-------------------|------------|--------|-------------|-----------|
|                                 | Latência        | Energia | Utilidade | Financeiro | Tarefa | Recursos | Tendências | Escore | Escalonamento | Pesos     |           | Penalização |                   | Mobilidade |        | DES         |           |
|                                 |                 |         |           |            |        |          |            |        |               | Estáticos | Dinâmicos | Discreta    | Contínua          | SUMO       | Vissim | Customizado | Simulador |
| (BAKER <i>et al.</i> , 2024)    | ✓               | ✓       | ✓         |            |        | ✓        |            | ✓      | ✓             | ✓         |           | ✓           |                   |            |        | ✓           |           |
| (WEI <i>et al.</i> , 2024)      | ✓               | ✓       |           |            | ✓      | ✓        |            |        | ✓             | ✓         |           |             | ✓                 |            |        | ✓           |           |
| (CHEN <i>et al.</i> , 2025)     | ✓               |         |           |            |        | ✓        | ✓          |        |               | ✓         |           | ✓           |                   |            |        | ✓           |           |
| (MA <i>et al.</i> , 2025)       | ✓               | ✓       |           | ✓          |        | ✓        |            |        | ✓             | ✓         |           | ✓           |                   |            |        | ✓           |           |
| (KUMAR; ZHAO; FERNANDO, 2023)   | ✓               | ✓       | ✓         |            |        | ✓        | ✓          |        | ✓             |           |           |             | ✓                 | ✓          | ✓      | ✓           |           |
| (KUMARI <i>et al.</i> , 2025)   | ✓               | ✓       | ✓         |            | ✓      | ✓        |            |        | ✓             |           | ✓         | ✓           |                   |            |        | ✓           |           |
| (TIAN <i>et al.</i> , 2025)     | ✓               | ✓       |           |            |        | ✓        |            |        | ✓             | ✓         |           | ✓           | ✓                 |            |        | ✓           |           |
| (BAO <i>et al.</i> , 2025)      | ✓               | ✓       |           |            |        | ✓        |            |        | ✓             | ✓         |           |             | ✓                 |            |        | ✓           |           |
| (FAN; CAI, 2024)                | ✓               | ✓       |           |            | ✓      | ✓        |            |        |               |           | ✓         | ✓           |                   |            |        | ✓           |           |
| (FARIMANI <i>et al.</i> , 2024) | ✓               | ✓       | ✓         |            |        |          | ✓          |        |               |           |           | ✓           |                   |            |        | ✓           |           |
| (SHI; CHEN; ZHU, 2023)          | ✓               | ✓       |           |            |        |          |            |        |               |           | ✓         |             |                   |            |        | ✓           |           |

Fonte: Elaborado pelo autor

Segundo (MIRIYALA; CHIRRA, 2026), apesar dos notáveis avanços proporcionados pela integração do DRL no descarregamento de tarefas, a literatura recente aponta limitações que dificultam que os modelos teóricos sejam utilizados no mundo real. Uma análise rigorosa conduzida por (MIRIYALA; CHIRRA, 2026) revela que a maioria das abordagens atuais sofre de simplificações excessivas na modelagem do ambiente. Frequentemente, os trabalhos utilizam representações de estado baseadas em vetores planos (*flat vectors*), o que ignora as complexas relações estruturais e topológicas entre os veículos e a infraestrutura. Essa lacuna evidencia a necessidade de incorporar arquiteturas diferentes, como as GNN para extrair representações topológicas antes da tomada de decisão. Além disso, os ambientes simulados costumam assumir canais de comunicação idealizados e conectividade persistente, negligenciando falhas físicas comuns nas redes veiculares, como quedas intermitentes de conexão (*dropouts*) (MIRIYALA; CHIRRA, 2026).

Outra lacuna está relacionada a carga computacional imposta pelos próprios modelos de aprendizado de máquina. Grande parte das pesquisas assume que os servidores de borda possuem recursos substanciais de *hardware*, deixando um vácuo no estudo onde dispositivos possuem severas restrições energéticas, de memória e de processamento (teto operacional de *FLOPS*). Para contornar esse obstáculo e viabilizar a implantação, (MIRIYALA; CHIRRA, 2026) destacam que pesquisas futuras devem focar no desenvolvimento de arquiteturas e representações mais leves, aplicando técnicas de compressão de modelos.

No que tange à adaptabilidade dos algoritmos, observa-se que as políticas DRL são tradicionalmente treinadas e permanecem imutáveis durante a implantação em produção. Contudo, em cenários veiculares não estacionários, onde o ambiente sofre alterações constantes devido a mudanças de distribuição das cargas (*distribution shifts*), tais políticas estáticas divergem e rapidamente se tornam obsoletas e ineficientes (MIRIYALA; CHIRRA, 2026). Identifica-se que há espaço na exploração de mecanismos de adaptação *online* de modo a evoluir a política computada pelo modelo.

Por fim, a transição destas propostas para sistemas reais esbarra na falta de avaliação comparativa confiável (*benchmarking*). A disparidade entre os estudos dificulta extrapolações e comparações parciais justas sobre as potenciais eficiências obtidas. (MIRIYALA; CHIRRA, 2026) criticam o fato de que a literatura tende a se atentar demasiadamente com as constatações de performance baseadas no treinamento ideal dos agentes.



### **3.3 Considerações Finais**

Conforme discutido ao longo deste capítulo, as abordagens baseadas em DRL têm se solidificado como a direção mais promissora para o gerenciamento de recursos em arquiteturas de borda veicular. A integração com técnicas emergentes demonstra que há flexibilidade suficiente para abarcar os altos desafios impostos pelos cenários veiculares práticos. No entanto, as lacunas destacadas — como a predominância de simulações com observabilidade perfeita e cenários determinísticos — salientam a necessidade crítica de propostas que incorporem incerteza, variação de rajadas e carga de trabalho. Este alinhamento direciona o desenvolvimento da solução apresentada nos capítulos seguintes, projetada com vistas a preencher estas falhas e entregar maior robustez.

## 4 PROPOSTA DE SOLUÇÃO


Este capítulo apresenta uma proposta de solução para o problema de descarregamento de tarefas em ambientes veiculares, contemplando a comunicação tanto com dispositivos de borda quanto diretamente entre os dispositivos instalados nos veículos. Um desafio central abordado nesta modelagem é a não estacionariedade, um fenômeno intrínseco aos sistemas multiagente resultante da interação e da coadaptação contínua entre os diversos agentes (ALBRECHT; CHRISTIANOS; SCHÄFER, 2024). Para garantir que a simulação espelhe com precisão as restrições do mundo físico, o modelo incorpora comportamentos complexos e variáveis de incerteza, tais como a mobilidade dinâmica veicular, cargas de trabalho baseadas em traços reais de uso, limitações de processamento (*throttling*) e atrasos na propagação de informações (ALBRECHT; CHRISTIANOS; SCHÄFER, 2024). Consequentemente, a introdução desses elementos estabelece um ambiente de simulação rigoroso e estocástico, projetado para imitar as limitações operacionais e os ruídos de comunicação enfrentados em cenários reais (ALBRECHT; CHRISTIANOS; SCHÄFER, 2024).

### 4.1 Ambiente

#### 4.1.1 Simulador de Eventos Discretos

O ambiente de treinamento e avaliação é implementado como um **Simulador de Eventos Discretos** (*Discrete Event Simulation*, DES) desenvolvido em C++20 com co-rotinas, utilizando a biblioteca `simcpp20`. Cada tarefa gerada pelos veículos é modelada como um processo concorrente que: (i) aguarda o instante de chegada  $t_j$ ; (ii) consome o estado global do sistema para construir o vetor de observação; (iii) executa a política de escalonamento; (iv) atualiza as filas dos servidores; e (v) registra as métricas reais de JCT e energia ao término.

O servidor RSU é modelado como um processador DVFS de frequência nominal  $F_{\text{RSU}} = 1,2\text{GHz}$ , com fila compartilhada de capacidade  $Q_{\text{max}} = 100$  tarefas. Os veículos possuem frequências heterogêneas, amostradas no intervalo  $[0,3; 1,5]\text{GHz}$ , conforme o arquivo `vehicle_clocks.csv` de cada cenário. A comunicação V2I utiliza largura de banda  $B = 20\text{MHz}$ , potência de transmissão  $P_{\text{tx}} = 0,2\text{W}$  e modelo de perda de percurso conforme 3GPP TR 38.901 (UMi Street Canyon). As mesmas especificações valem para V2V, com altura de antena de 1,5m e fator de ruído de 9dB.



**Figura 28 – Representação do ambiente de simulação: um cruzamento veicular contemplando comunicação V2I, V2V e os principais componentes do cenário estocástico.**

#### 4.1.2 Cenários de Teste e Treinamento

Os cenários são gerados sinteticamente a partir de variações de taxa de chegada de tarefas (*tasks per second*, tps) e sementes de aleatoriedade distintas. O conjunto total compreende **661 cenários**, distribuídos conforme a Tabela 6.

Cada cenário é representado por três arquivos: `workload_distribuido.csv` (tarefas com  $C_j$  em ciclos de CPU,  $D_j$  em segundos e posição geográfica), `vehicle_clocks.csv` (frequência e coeficiente de energia de cada veículo) e `system_params.csv` (parâmetros físicos fixos do ambiente). Os parâmetros físicos globais compartilhados por todos os cenários estão listados na Tabela 7.

**Tabela 6 – Distribuição dos 661 cenários de treinamento/teste por taxa de chegada.**

| Taxa (tps)   | Qtd. cenários | Tarefas/cenário |
|--------------|---------------|-----------------|
| 10           | 60            | 100             |
| 15           | 90            | 150             |
| 20           | 121           | 200             |
| 25           | 150           | 250             |
| 30           | 180           | 300             |
| 45           | 60            | 450             |
| <b>Total</b> | <b>661</b>    | —               |

**Tabela 7 – Parâmetros físicos do ambiente simulado.**

| Parâmetro     | Descrição                                 | Valor              |
|---------------|-------------------------------------------|--------------------|
| $F_{RSU}$     | Frequência de clock da RSU                | 1,2 GHz            |
| $F_{veh}$     | Freq. dos veículos (heterogênea)          | $[0,3; 1,5]$ GHz   |
| $B_{V2I/V2V}$ | Largura de banda dos canais               | 20 MHz             |
| $P_{tx}$      | Potência de transmissão V2I e V2V         | 0,2 W              |
| $R_{max}$     | Raio de cobertura RSU                     | 300 m              |
| $V_{V2V}$     | Alcance V2V                               | 300 m              |
| $\alpha_c$    | Coef. energia dinâmica (CMOS)             | $6 \times 10^{-9}$ |
| $\eta_{DL}$   | Fator de multiplicação do <i>deadline</i> | $1,2 \times D_j$   |
| $Q_{max}$     | Capacidade máxima das filas               | 100 tarefas        |

#### 4.1.3 Protocolo de Treinamento e Hiperparâmetros

O treinamento de cada política DRL é conduzido em modo **offline**, interagindo exclusivamente com o simulador, sem nenhum acesso ao ambiente real. O protocolo é o seguinte:

1. **Cenário de treino:** Um único cenário de 100 tarefas a 10 tps (*cenario\_v2x\_10tps\_w01*) é utilizado durante todo o treinamento. A generalização para outros volumes e taxas é avaliada nas 661 instâncias de teste (*zero-shot*).
2. **Episódios:** Cada episódio corresponde a uma simulação completa do cenário (100 transições). O treinamento dura **400 episódios** (40 000 transições no total).
3. **Atualização:** A cada nova transição armazenada no *replay buffer* (capacidade = 50 000), o agente executa uma atualização dos pesos via mini-lote de 1 024 amostras, após um aquecimento de 1 024 transições.

A Tabela 8 lista os hiperparâmetros do SAC utilizados em todos os experimentos.

**Tabela 8 – Hiperparâmetros do SAC compartilhados por todas as políticas DRL.**

| Hiperparâmetro          | Descrição                                  | Valor              |
|-------------------------|--------------------------------------------|--------------------|
| $\eta$ (lr)             | Taxa de aprendizado (Adam)                 | $3 \times 10^{-4}$ |
| $\gamma$                | Fator de desconto                          | 0,99               |
| $\tau$                  | Taxa de atualização <i>soft</i>            | 0,005              |
| $\alpha_{\text{ent}}$   | Temperatura de entropia                    | 0,10               |
| $ \mathcal{B} $         | Capacidade do <i>replay buffer</i>         | 50000              |
| $B$                     | Tamanho do mini-lote                       | 1024               |
| <i>warmup</i>           | Transições antes do 1º update              | 1024               |
| Neurônios por camada    | Arquitetura MLP (2 camadas ocultas)        | 64                 |
| $\alpha$ (custo JCT)    | Peso do JCT na função objetivo             | 0,35               |
| $\beta$ (custo energia) | Peso da energia na função objetivo         | 0,35               |
| $\gamma_p$ (penalidade) | Penalidade por violação de <i>deadline</i> | 0,30               |

#### 4.2 Visão Geral da Arquitetura e Formulação do Problema

O problema de descarregamento em redes VEC é formulado como um Processo de Decisão de Markov Parcialmente Observável (POMDP). O objetivo central é maximizar a taxa de tarefas concluídas dentro do prazo rigoroso (*deadline*), ponderada com o custo energético e de latência. A natureza parcialmente observável decorre dos inevitáveis atrasos na telemetria das filas remotas, das flutuações de canal e da alta mobilidade dos veículos (UDDIN; ZHANG; SAKR, 2025; FARIMANI *et al.*, 2024).

O critério de otimização é expresso formalmente como:


$$\max_{\pi} J(\pi) = w_s \cdot \underbrace{\mathbb{E}_{\pi}[\mathbf{1}(\text{JCT}_i \leq D_i)]}_{\text{taxa de sucesso}} - w_c \cdot \underbrace{\mathbb{E}_{\pi} \left[ \frac{\alpha \text{JCT}_i + \beta E_i}{D_i + \beta E_{\max}} \right]}_{\text{custo normalizado}} \quad (4.1)$$

onde  $w_s = 0,60 > w_c = 0,40$  refletem a primazia da taxa de sucesso sobre a eficiência de custo, e os pesos internos são  $\alpha = \beta = 0,35$ .

Para resolver esse problema, a arquitetura proposta é dividida em duas fases:

- **Fase de Treinamento (Offline):** O algoritmo SAC (*Soft Actor-Critic*) interage com um simulador estocástico para otimizar os pesos de uma rede neural Perceptron Multicamadas (MLP). O ambiente simula a heterogeneidade dos servidores, a dinâmica autorregressiva (AR-1) das filas e as perdas de percurso realistas baseadas nos padrões 3GPP TR 38.901.
- **Fase de Implantação (Online):** Em tempo real, o módulo TOPSIS ranqueia os  $N$  candidatos disponíveis (servidores RSU ou veículos vizinhos V2V), convertendo-os em um vetor de estado compacto de 6 dimensões  $\mathbf{S}_t \in \mathbb{R}^6$ . A MLP treinada recebe esse vetor e emite a decisão binária  $a_t \in \{0, 1\}$  (executar localmente ou descarregar para o candidato de maior escore).

A Figura 29 ilustra o fluxo completo de decisão da arquitetura SAC-TOPSIS em tempo de inferência.



**Figura 29 – Arquitetura SAC-TOPSIS: fluxo vertical de decisão. O módulo TOPSIS comprime  $N$  candidatos em vetor fixo  $\mathbb{R}^6$ ; o SAC Actor decide binariamente entre execução local e offload para o  $rank_1$ . A seta tracejada cinza indica bypass direto de  $C_j$  e  $D_j$ ; a tracejada direita mostra o loop de recompensa durante o treinamento offline.**

### 4.3 Módulo TOPSIS e a Engenharia de Estado Compacto

Um dos maiores desafios em VEC é a variabilidade do número de candidatos ( $N$ ) ao longo do tempo. Abordagens baseadas em Grafos (GNN) resolvem isso ao custo de alta complexidade computacional (MIRIYALA; CHIRRA, 2026). A nossa abordagem propõe uma extração de características invariante à escala através do TOPSIS, que reduz os  $N$  candidatos a um único vetor de estado de dimensão fixa, independente de  $N$ .

#### 4.3.1 Avaliação Multicritério

O TOPSIS avalia os  $N$  nós candidatos por meio de três critérios, todos do tipo **custo** (minimizar), conforme a Tabela 9.

**Tabela 9 – Critérios e pesos do módulo TOPSIS.**

| Critério | Descrição                                       | Tipo  | Peso         |
|----------|-------------------------------------------------|-------|--------------|
| $C_1$    | Tempo de conclusão estimado ( $\widehat{JCT}$ ) | Custo | $w_1 = 0,40$ |
| $C_2$    | Energia total (processamento + transmissão)     | Custo | $w_2 = 0,30$ |
| $C_3$    | Distância física ao executor (m)                | Custo | $w_3 = 0,30$ |

O procedimento segue os passos clássicos do TOPSIS: (i) normalização vetorial da matriz de decisão por norma  $L_2$  de cada coluna; (ii) ponderação por  $w_j$ ; (iii) identificação das soluções ideal positiva  $A^+$  (mínimo de cada critério) e ideal negativa  $A^-$  (máximo), ambas calculadas por minimização; (iv) cômputo das distâncias Manhattan ( $L_1$ ) de cada alternativa a  $A^+$  e  $A^-$ ; (v) escore de proximidade:

$$C_i^* = \frac{d_i^-}{d_i^+ + d_i^-} \in [0, 1], \quad d_i^\pm = \sum_{j=1}^3 |v_{ij} - a_j^\pm| \quad (4.2)$$

onde  $v_{ij}$  é o elemento normalizado e ponderado. O candidato de maior  $C_i^*$  ( $rank_1$ ) é selecionado como alvo de *offload*.

#### 4.3.2 O Estado Compacto 6D Invariante à Escala

Independentemente de existirem 2 ou 50 candidatos, o estado entregue à rede neural é sempre um vetor fixo de 6 dimensões construído a partir do resultado do TOPSIS:

$$\mathbf{S}_t = \left[ \Delta_{\text{obj}}, \frac{\widehat{JCT}_{\text{local}}}{D_i}, \frac{\widehat{JCT}_{\text{rank}_1}}{D_i}, \frac{|Q_{\text{rank}_1}|}{Q_{\text{max}}}, \frac{|Q_{\text{local}}|}{Q_{\text{max}}}, \frac{C_j}{C_{\text{max}}} \right] \in \mathbb{R}^6 \quad (4.3)$$

Cada dimensão carrega uma semântica irreduzível para a decisão:

1.  $\Delta_{\text{obj}}$ : **vantagem relativa do offload** — diferença normalizada entre o custo estimado de execução local e o custo do candidato  $rank_1$  segundo o TOPSIS. Valor positivo indica que o *offload* é vantajoso.
2.  $\widehat{JCT}_{\text{local}}/D_i$ : **urgência local** — razão entre o tempo de conclusão estimado localmente e o prazo. Valores  $> 1,0$  sinalizam violação iminente.
3.  $\widehat{JCT}_{\text{rank}_1}/D_i$ : **urgência do offload** — razão análoga para o melhor candidato; permite ao agente comparar diretamente as duas opções.

4.  $|Q_{\text{rank}_1}|/Q_{\text{max}}$ : **congestionamento do candidato de maior escore** — fila do nó classificado em primeiro lugar pelo TOPSIS (RSU ou veículo V2V), normalizada por  $Q_{\text{max}} = 25$  tarefas; sinal de deterioração futura da latência de *offload* caso o agente decida descarregar.
5.  $|Q_{\text{local}}|/Q_{\text{max}}$ : **congestionamento do veículo** — ocupação da fila local, reflete o custo de aguardar execução no próprio dispositivo.
6.  $C_j/C_{\text{max}}$ : **complexidade da tarefa** — número de ciclos de CPU normalizados, ancora o contexto computacional da decisão.

#### 4.3.3 Seleção da Ação

O agente SAC opera sobre um espaço de ação discreto binário  $a_t \in \{0, 1\}$ . O mapeamento entre ação e modo de execução é mediado pelo resultado do TOPSIS:

$$\text{modo}_t = \begin{cases} \text{LOCAL} & \text{se } a_t = 0 \\ \text{rank}_1 \in \{\text{RSU}, \text{V2V}\} & \text{se } a_t = 1 \end{cases} \quad (4.4)$$

Quando  $a_t = 1$ , a tarefa é encaminhada ao candidato de maior  $C_i^*$  (Equação 4.2), que pode ser o servidor RSU (via V2I) ou um veículo vizinho (via V2V), conforme determinado pelo TOPSIS antes da inferência da rede neural. Caso nenhum candidato de *offload* seja viável ( $N = 0$ ),  $a_t = 1$  é tratado como LOCAL por *fallback*. Essa separação de responsabilidades — TOPSIS decide *para onde* descarregar, SAC decide *se* descarregar — reduz o espaço de busca do agente de  $N + 1$  para 2 ações, independente de  $N$ .

**Generalização Zero-Shot:** Como o TOPSIS comprime qualquer conjunto de  $N$  candidatos em um único vetor  $\mathbb{R}^6$  constante, a política treinada interpola naturalmente para cenários com topologias distintas sem retreinamento.


A Figura 30 detalha como o vetor  $\mathbf{S}_t$  alimenta a rede *Actor* do SAC e como a camada de saída produz a decisão binária.

## 4.4 Modelagem da Recompensa e Seleção do Algoritmo

### 4.4.1 Engenharia de Recompensa (*Reward Shaping*)

A função de recompensa é formulada para alinhar diretamente o sinal de aprendizado com o objetivo da Equação 4.1: dar primazia à taxa de sucesso e depois minimizar o custo. A





**Figura 30 – Arquitetura da rede Actor (MLP 6 → 64 → 64 → 2): o vetor de estado compacto  $S_t$  produzido pelo TOPSIS alimenta duas camadas ocultas com ativação ReLU; a camada Softmax final emite as probabilidades das ações  $a_0$  (LOCAL) e  $a_1$  (OFFLOAD rank<sub>1</sub>).**

recompensa por tarefa é estruturada em dois regimes disjuntos:

$$r_t = \begin{cases} 1,0 - 0,5 \cdot \frac{\alpha \widehat{JCT}_t + \beta E_t}{\alpha D_i + \beta E_{\max}}, & \text{se } \widehat{JCT}_t \leq D_i \quad (\in [0,5, 1,0]) \\ -1,0 - \min\left(1,0, \frac{\widehat{JCT}_t - D_i}{D_i}\right), & \text{se } \widehat{JCT}_t > D_i \quad (\in [-2,0, -1,0]) \end{cases} \quad (4.5)$$

A hierarquia de sinal da Equação 4.5 implementa diretamente os pesos  $w_s > w_c$  da Equação 4.1: a lacuna mínima entre qualquer recompensa de falha e qualquer recompensa de sucesso é 1,5 unidades, o que torna o respeito ao *deadline* a barreira dominante na superfície de decisão. Dentro do regime de sucesso, a recompensa é continuamente modulada pelo custo normalizado  $(\alpha JCT + \beta E)$ , incentivando a eficiência mesmo quando o prazo é cumprido. O fator de desconto temporal foi fixado em  $\gamma = 0,99$  para que o agente antecipe o efeito cascata do enfileiramento de tarefas.

#### 4.4.2 Justificativa do Algoritmo SAC

A função de recompensa bimodal da Equação 4.5 induz uma superfície de decisão com descontinuidade severa na fronteira  $\widehat{JCT} = D_i$ . Algoritmos baseados em valor, como o DQN, são propensos à superestimação catastrófica de  $Q$ -values próximos a essa fronteira (MIRIYALA; CHIRRA, 2026). Algoritmos *on-policy* como o PPO apresentam baixa eficiência amostral em ambientes com recompensa esparsa por região de falha.

O SAC (*Soft Actor-Critic*) resolve ambos os problemas simultaneamente. Sua formulação entrópica maximiza  $J(\pi) + \alpha_{\text{temp}} \mathcal{H}(\pi)$ , o que garante exploração robusta nas vizinhanças da fronteira de *deadline* sem convergência prematura. O uso de *twin Q-networks*

(redes  $Q_1$  e  $Q_2$ ) com atualização via mínimo reduz viés de superestimação. Por ser *off-policy*, o SAC reutiliza experiências passadas via *replay buffer*, conferindo eficiência amostral superior ao PPO em ambientes com recompensa rara, como o regime de sucesso deste problema.

## 4.5 Complexidade Computacional

Ao evitar o uso de GNNs e optar pelo condicionamento via TOPSIS, a complexidade assintótica de tomada de decisão a cada instante de tempo é regida quase exclusivamente pela ordenação dos  $N$  candidatos, operando em  $O(N \log N)$ . A inferência da MLP (*Actor network*), com duas camadas ocultas de 64 neurônios e entrada de 6 dimensões, possui complexidade  $O(1)$  e ocupa menos de 0,1 MB de memória, tornando a abordagem altamente escalável e compatível com os requisitos de latência de *hardware* de borda do ecossistema 6G.

## 4.6 Estudo de Ablação

Um **estudo de ablação** é uma técnica experimental de análise causal que consiste em remover ou substituir sistematicamente um componente do sistema proposto — mantendo todos os demais fixos — e medir o impacto no desempenho. Cada variante responde à pergunta: "*quanto esse componente contribui para o resultado?*" Se o desempenho cai significativamente com sua remoção, o componente é essencial; se cai pouco, pode ser redundante. A técnica é amplamente empregada em aprendizado de máquina para validar que cada escolha de design — arquitetura, função de recompensa, representação de estado — justifica sua presença no sistema final.

Para isolar a contribuição de cada componente do SAC-TOPSIS, realizou-se um estudo de ablação controlado com quatro variantes treinadas e avaliadas nas mesmas 661 instâncias de cenário. Cada variante remove ou substitui um único componente de design em relação à proposta completa, mantendo os demais fixos. A Tabela 10 descreve o design experimental e a Tabela 11 apresenta os resultados consolidados.

### 4.6.1 Descrição Detalhada das Variantes

#### ***SAC-Base — Referência***

O SAC-Base é o ponto de partida do estudo e serve de referência para medir o ganho de cada componente. Utiliza um estado bruto de 11 dimensões que concatena diretamente as

**Tabela 10 – Design experimental das variantes de ablação. Cada variante difere da proposta em exatamente um componente.**

| Política          | Espaço de estado   | Ação           | Recompensa            | TOPSIS         |
|-------------------|--------------------|----------------|-----------------------|----------------|
| SAC-Base          | 11D (bruto)        | 3 classes      | WSM                   | —              |
| SAC-A1            | 11D (bruto)        | binária        | WSM                   | —              |
| SAC-S1            | 6D (manual)        | 3 classes      | WSM                   | —              |
| SAC-R1            | 11D (bruto)        | 3 classes      | Deadline-aware        | —              |
| SAC-T1            | 6D (TOPSIS)        | 3 classes      | Deadline-aware        | Feature        |
| <b>SAC-TOPSIS</b> | <b>6D (TOPSIS)</b> | <b>binária</b> | <b>Deadline-aware</b> | <b>Decisão</b> |

**Tabela 11 – Resultados do estudo de ablação: médias sobre 661 cenários de teste.**

| Política          | Taxa <i>deadline</i> (%) | JCT médio (s) | Energia média (J) |
|-------------------|--------------------------|---------------|-------------------|
| SAC-Base          | 4,6                      | 57,1          | 2422              |
| SAC-A1            | 39,2                     | 13,7          | 2106              |
| SAC-S1            | 28,8                     | 39,2          | 2028              |
| SAC-R1            | 38,4                     | 13,3          | 3153              |
| SAC-T1            | 33,1                     | 11,5          | 2612              |
| <b>SAC-TOPSIS</b> | <b>45,3</b>              | <b>6,6</b>    | <b>2582</b>       |

métricas do ambiente sem nenhum pré-processamento multicritério:

$$\mathbf{s}^{\text{base}} = \left[ \frac{C_j}{C_{\max}}, \frac{D_j}{10}, \frac{d_{\text{RSU}}}{300}, \frac{f_{\text{dvfs}}}{f_{\text{RSU}}}, \frac{|Q_{\text{RSU}}|}{25}, \frac{T_{\text{cpu}} - 300}{100}, \frac{f_{\text{local}}}{f_{\text{RSU}}}, \frac{|Q_{\text{local}}|}{25}, \frac{f_{\text{V2V}}}{f_{\text{RSU}}}, \frac{|Q_{\text{V2V}}|}{25}, \frac{d_{\text{V2V}}}{300} \right] \quad (4.6)$$

onde  $d$  denota distância,  $f$  frequência de processamento,  $Q$  ocupação de fila e  $T_{\text{cpu}}$  temperatura do processador. Quando nenhum vizinho V2V está disponível, as três últimas componentes recebem o valor sentinela  $-1,0$  para distinguir "ausência de V2V" de "V2V com métrica zero".

O espaço de ação é ternário  $a_t \in \{0 = \text{LOCAL}, 1 = \text{RSU}, 2 = \text{V2V}\}$ : o agente deve aprender simultaneamente a *decisão* de descarregar e a *escolha do destino*. A recompensa usa o Método de Soma Ponderada (WSM) com pesos iguais sobre três critérios — JCT estimado, energia total e ocupação de fila do executor escolhido — normalizados pelo valor máximo de cada coluna e mapeados para  $[-1, 1]$ :

$$r_t^{\text{wsm}} = 2 \max \left( 0, \min \left( 1, 1 - \frac{1}{3} \sum_{j=1}^3 \tilde{x}_{aj} \right) \right) - 1, \quad \tilde{x}_{aj} = \frac{x_{aj}}{\max_i x_{ij}} \quad (4.7)$$

Esse sinal não distingue violações de *deadline* de execuções lentas porém viáveis: uma ação que ultrapassa o prazo com custo moderado pode receber recompensa positiva, desorientando o aprendizado em ambientes com prazos rígidos.

### SAC-A1 — Redução do Espaço de Ação sem TOPSIS

A variante A1 mantém inalterados o estado 11D (Equação 4.6) e a recompensa WSM (Equação 4.7), alterando *apenas* o espaço de ação para binário  $a_t \in \{0 = \text{LOCAL}, 1 = \text{OFFLOAD}\}$ . Quando  $a_t = 1$ , o destino de *offload* é determinado por uma regra de prioridade estática — RSU primeiro (se viável), V2V caso contrário — sem qualquer análise multicritério:

$$\text{modo}_t^{\text{A1}} = \begin{cases} \text{LOCAL} & \text{se } a_t = 0 \\ \text{RSU} & \text{se } a_t = 1 \text{ e RSU viável} \\ \text{V2V} & \text{se } a_t = 1, \text{ RSU inviável e V2V viável} \\ \text{LOCAL} & \text{se } a_t = 1 \text{ e nenhum } \textit{offload} \text{ viável (fallback)} \end{cases} \quad (4.8)$$

O objetivo é isolar o efeito de reduzir o espaço de busca de 3 para 2 ações, sem nenhum critério inteligente de escolha de destino. A regra RSU  $\succ$  V2V é estática e ignora as condições dinâmicas de fila e distância no momento da decisão.

### SAC-S1 — Estado Compacto 6D Manual sem TOPSIS

A variante S1 mantém o espaço de ação ternário e a recompensa WSM do *baseline*, mas substitui o estado 11D por um vetor compacto de 6 dimensões construído manualmente com *features* de maior relevância semântica:

$$\mathbf{S}^{\text{S1}} = \left[ \frac{C_j}{C_{\max}}, \min\left(1, \frac{\widehat{\text{JCT}}_{\text{local}}}{D_i}\right), \frac{d_{\text{RSU}}}{300}, \min\left(1, \frac{|Q_{\text{RSU}}|}{25}\right), \min\left(1, \frac{|Q_{\text{local}}|}{25}\right), \frac{f_{\text{local}}}{f_{\text{RSU}}} \right] \quad (4.9)$$

A segunda componente — urgência relativa  $\widehat{\text{JCT}}_{\text{local}}/D_i$  — comprime em uma única dimensão a pergunta "a execução local vai estourar o prazo?", substituindo as entradas brutas de *deadline* ( $D_j$ ) e frequência separadas do estado 11D. Comparado ao estado bruto, S1 elimina as redundâncias entre frequência e JCT e satura as filas em 1,0 para evitar valores fora da escala. Nota-se que S1 não inclui informações de V2V (frequência, fila, distância do vizinho), forçando o agente a decidir entre RSU e V2V apenas pela congestão do RSU. A ausência do TOPSIS significa que nenhum escore multicritério está disponível; o estado captura urgência e congestão local, mas não a vantagem objetiva do *offload*.

### SAC-R1 — Recompensa Deadline-Aware sem Mudança de Estado ou Ação

A variante R1 mantém o estado 11D (Equação 4.6) e o espaço de ação ternário idênticos ao *baseline*, alterando *apenas* a função de recompensa para a formulação sensível ao prazo:

$$r_t^{R1} = \begin{cases} 1,0 - 0,5 \cdot \frac{\alpha \widehat{JCT}_t + \beta E_t}{\alpha D_i + \beta E_{\max}}, & \widehat{JCT}_t \leq D_i \quad (\in [0,5, 1,0]) \\ -1,0 - \min\left(1,0, \frac{\widehat{JCT}_t - D_i}{D_i}\right), & \widehat{JCT}_t > D_i \quad (\in [-2,0, -1,0]) \end{cases} \quad (4.10)$$

A lacuna mínima de 1,5 unidades entre o maior valor de falha ( $-1,0$ ) e o menor valor de sucesso ( $+0,5$ ) cria uma barreira de *deadline* dominante na função de valor do agente. Quando o prazo é cumprido, a recompensa é contínua e proporcional ao custo ponderado ( $\alpha JCT + \beta E$ ), incentivando eficiência mesmo dentro do regime de sucesso. Quando violado, a penalidade cresce proporcionalmente ao excesso de tempo, evitando o platô de recompensa negativa constante do WSM e ensinando o agente a "falhar por pouco" se inevitável. O objetivo é medir o ganho atribuível *exclusivamente* à função de recompensa, sem alterar o estado nem o espaço de ação.

### SAC-T1 — TOPSIS como Feature de Estado com Ação de 3 Classes

A variante T1 combina o estado compacto 6D calculado *via* TOPSIS (idêntico ao da proposta, Equação 4.3) com a recompensa deadline-aware (Equação 4.10), mas mantém o espaço de ação ternário  $a_t \in \{0 = \text{LOCAL}, 1 = \text{RSU}, 2 = \text{V2V}\}$ . O TOPSIS calcula internamente os escores de todos os candidatos e usa o resultado para construir o vetor de estado — incluindo a vantagem objetiva  $\Delta_{\text{obj}}$  e o JCT normalizado do  $\text{rank}_1$  — mas a decisão final de escolher RSU ou V2V permanece com o agente SAC.

O contraste essencial entre T1 e a proposta completa é portanto:

- **T1:** TOPSIS gera *features* semânticas para o estado; agente decide entre LOCAL, RSU e V2V diretamente (3 ações).
- **SAC-TOPSIS:** TOPSIS seleciona o  $\text{rank}_1$  e define o destino de *offload*; agente decide apenas LOCAL vs. OFFLOAD-PARA-RANK<sub>1</sub> (2 ações).

Essa variante permite quantificar separadamente quanto do ganho do SAC-TOPSIS provém do TOPSIS como *compressor de estado semântico* versus o TOPSIS como *prior de decisão de destino*.

#### 4.6.2 Decomposição Causal

Os resultados da Tabela 11 permitem traçar um caminho de ablação sequencial aditivo, onde cada passo acumula exatamente um conjunto de mudanças:

$$\underbrace{4,6\%}_{\text{SAC-Base}} \xrightarrow{+24,2\text{pp}} \underbrace{28,8\%}_{\text{SAC-S1}} \xrightarrow{+4,3\text{pp}} \underbrace{33,1\%}_{\text{SAC-T1}} \xrightarrow{+12,2\text{pp}} \underbrace{45,3\%}_{\text{SAC-TOPSIS}} \quad (4.11)$$

A soma  $4,6 + 24,2 + 4,3 + 12,2 = 45,3\%$  é exata, confirmando que o caminho  $\text{Base} \rightarrow \text{S1} \rightarrow \text{T1} \rightarrow \text{TOPSIS}$  é perfeitamente aditivo. A Tabela 12 interpreta cada incremento.

**Tabela 12 – Decomposição causal dos ganhos ao longo do caminho de ablação.**

| Componente (transição)                                                    | $\Delta$ taxa   | Interpretação                                                                                                                                                                                                                                        |
|---------------------------------------------------------------------------|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Estado 6D compacto manual (Base $\rightarrow$ S1)                         | +24,2 pp        | Substituir o vetor 11D bruto por 6 <i>features</i> semanticamente compactas — especialmente a urgência relativa $\widehat{\text{JCT}}/D_i$ — reduz a dimensionalidade e melhora a generalização entre cenários                                       |
| TOPSIS como <i>feature</i> + <i>deadline</i> reward (S1 $\rightarrow$ T1) | +4,3 pp         | Incorporar o escore $\Delta_{\text{obj}}$ e o JCT do $\text{rank}_1$ no estado e substituir WSM pela recompensa deadline-aware acrescenta contexto semântico moderado; o ganho é limitado pois o agente ainda precisa resolver a escolha RSU vs. V2V |
| TOPSIS como prior de decisão (T1 $\rightarrow$ SAC-TOPSIS)                | +12,2 pp        | Transferir a escolha de destino do agente para o TOPSIS e reduzir o espaço de ação de 3 para 2 é o maior salto marginal: elimina a ambiguidade RSU/V2V e garante que o destino seja sempre o candidato de menor custo multicritério                  |
| <b>Ganho total</b>                                                        | <b>+40,7 pp</b> | <b>SAC-TOPSIS vs. SAC-Base</b>                                                                                                                                                                                                                       |

Para isolar o efeito da recompensa *deadline-aware* sem alterar o estado, a variante SAC-R1 atinge 38,4% (+33,8 pp sobre o *baseline* com estado 11D e ação ternária). Esse valor é maior que o de S1 (28,8%), evidenciando que o sinal de recompensa assimétrico é individualmente mais poderoso que a compressão de estado quando aplicados em isolamento. Entretanto, no caminho sequencial, a maior parte do ganho de R1 é compartilhada com S1: o estado 6D já codifica urgência temporal em  $\widehat{\text{JCT}}/D_i$ , de modo que acrescentar a recompensa deadline-aware sobre S1 produz um incremento marginal de apenas +4,3 pp (transição S1  $\rightarrow$  T1, que combina as duas mudanças).

#### 4.6.3 Análise dos Resultados

Três achados principais emergem do estudo. Primeiro, a variante SAC-A1 (39,2%) demonstra que binarizar a ação *sem* critério de seleção de destino já supera o *baseline* em +34,6 pp — a simples redução do espaço de busca tem efeito expressivo — mas não alcança a proposta (45,3%) porque a regra estática  $RSU \succ V2V$  ignora condições dinâmicas de fila e distância no momento da decisão. Segundo, a variante SAC-T1 (33,1%) mostra que usar o TOPSIS apenas como *feature* de estado contribui com +4,3 pp sobre S1, enquanto usar o TOPSIS como *prior* de decisão (SAC-TOPSIS) adiciona +12,2 pp sobre T1: a eficácia do TOPSIS é quase três vezes maior quando ele assume o controle do destino do que quando fornece apenas informação semântica ao agente. Terceiro, o JCT médio do SAC-TOPSIS (6,6 s) é  $8,6\times$  menor que o do SAC-Base (57,1 s), indicando que a combinação TOPSIS+estado compacto+reward deadline-aware produz não apenas mais tarefas concluídas no prazo, mas também latências substancialmente menores.

Em suma, a hierarquia de contribuição dos componentes é:

$$\Delta_{\text{estado}} > \Delta_{\text{TOPSIS-decisão}} > \Delta_{\text{reward+feature}} \gg \Delta_{\text{ação-binária-estática}}$$

confirmando que a *compressão de estado via TOPSIS* e o *TOPSIS como prior de destino* são os dois pilares do ganho do SAC-TOPSIS, e que a recompensa deadline-aware, embora poderosa isoladamente, tem contribuição marginal reduzida quando combinada com um estado já semanticamente rico.

#### 4.6.4 Métrica de Efetividade: *Success-Weighted Quality* (SWQ)

A taxa de *deadline* ( $\hat{\tau}$ ) empregada até aqui é uma métrica binária: conta quantas tarefas foram concluídas no prazo, mas ignora *quão bem* essas tarefas foram atendidas. Uma política que cumpre o prazo com folga de 1% é tratada da mesma forma que uma que o cumpre com folga de 40%. De maneira análoga, o JCT médio e a energia total acumulam contribuições de tarefas bem-sucedidas e de tarefas que violaram o prazo, tornando difícil separar eficiência de falha.

Para reunir ambas as dimensões em um único número interpretável, define-se o *Success-Weighted Quality* (SWQ):

$$SWQ(\pi) = \hat{\tau}(\pi) \times \left( \frac{D_j - JCT_j}{D_j} \right)_{\mathcal{J}} \quad (4.12)$$

onde  $\hat{\tau}(\pi) \in [0, 1]$  é a taxa de sucesso da política  $\pi$  e o segundo fator é a **folga normalizada média** calculada exclusivamente sobre o conjunto  $\mathcal{S}$  de tarefas que cumpriram o prazo:

$$\overline{\text{folga}}_{\mathcal{S}} = \frac{1}{|\mathcal{S}|} \sum_{j \in \mathcal{S}} \frac{D_j - \text{JCT}_j}{D_j} \in (0, 1]$$


A folga normalizada vale 1 quando a tarefa é concluída instantaneamente e decresce para 0 quando o JCT se aproxima do prazo. Uma política que jamais erra o prazo e conclui todas as tarefas com folga máxima teria  $\text{SWQ} = 1,0$ ; uma que sempre viola teria  $\text{SWQ} = 0$ . O produto das duas componentes penaliza simultaneamente políticas com baixa taxa de sucesso e políticas que cumprem o prazo por margem ínfima — características indesejadas em contextos veiculares com prazos rígidos.

A Figura 31 apresenta o SWQ médio das vinte políticas avaliadas sobre os 661 cenários de teste. O SAC-TOPSIS alcança o maior valor ( $\text{SWQ} = 0,1484$ ), seguido pelas políticas *Always-Local*, PPO-Base e PPO-Compact (todas em 0,1418). Nota-se que o *greedy-unfair* — que possui conhecimento perfeito das filas em tempo de execução — obtém  $\text{SWQ} = 0,1261$ , inferior ao SAC-TOPSIS: embora o oráculo minimize o JCT por decisão, sua natureza míope acumula pior qualidade agregada do que a política aprendida. Por outro lado, *Always-RSU* e SAC-Base apresentam os menores SWQs (0,003 e 0,012, respectivamente), reflexo de taxas de sucesso irrisórias (1,9% e 4,6%).

#### 4.7 Por que o TOPSIS agrega valor ao SAC mas não ao PPO?

Os resultados experimentais revelam uma assimetria marcante: o TOPSIS eleva a taxa de *deadline* do SAC de 4,6% (SAC-Base) para 45,3% (SAC-TOPSIS), um ganho de +40,7 pontos percentuais, enquanto o PPO com TOPSIS regride. Para isolar a causa desta assimetria, foram realizados dois experimentos controlados. Primeiro, o PPO-TOPSIS original com estado 12D e ação ternária — que permitia ao agente escolher entre  $\text{rank}_1$ ,  $\text{rank}_2$  e  $\text{rank}_3$  — obteve 18,4%, abaixo do PPO-Base (42,4%). Segundo, o PPO-TOPSIS foi refatorado para utilizar *exatamente* o mesmo estado 6D, ação binária  $\{0 = \text{LOCAL}, 1 = \text{rank}_1\}$  e função de recompensa do SAC-TOPSIS, diferindo apenas no algoritmo de otimização (PPO vs. SAC). O resultado deste experimento controlado foi igualmente 18,4%, com a política colapsando para 86% de *offload* via  $\text{rank}_1$  — o oposto do PPO-Compact (100% LOCAL), porém igualmente disfuncional. O PPO-TOPSIS-Compact, que usa o estado 6D mas foi treinado em cenários distintos, apenas





**Figura 31 – SWQ médio por política sobre 661 cenários de teste ( $\alpha = 0,35$ ,  $\beta = 0,35$ ,  $\gamma = 0,30$ ). Barras em cinza representam heurísticas; barras escuras representam políticas DRL. A borda dourada indica a melhor política. Maior é melhor.**

igual a o PPO-Base. Em síntese: **o TOPSIS é uma alavanca decisiva para o SAC e um fator neutro ou prejudicial para o PPO, independentemente do design do estado**. Esta seção analisa as causas estruturais desta assimetria.

#### 4.7.1 O problema do aprendizado redundante no PPO-TOPSIS

O PPO-TOPSIS foi implementado com um estado de 12 dimensões — três alternativas (LOCAL, RSU, V2V) ordenadas pelo escore TOPSIS, cada uma descrita por quatro atributos normalizados (JCT estimado, energia, distância, *link lifetime*) — e um espaço de ação ternário  $a_t \in \{0 = \text{rank}_1, 1 = \text{rank}_2, 2 = \text{rank}_3\}$ . Esse design cria um problema de **aprendizado redundante**: o TOPSIS já determina deterministicamente que o candidato na posição 0 é o melhor segundo critérios multicritério rigorosos. O agente PPO, portanto, é treinado por reforço para redescobrir, por tentativa e erro, o que o TOPSIS já computou de forma ótima. A informação de valor genuíno que o agente deveria aprender — se há benefício em descarregar para o melhor candidato dado o estado da fila e a urgência do *deadline* — está enterrada sob o sinal dominante

de que  $\text{rank}_1$  é sempre superior a  $\text{rank}_2$  e  $\text{rank}_3$  em custo multicritério.

O SAC-TOPSIS resolve este problema por projeto: delega a pergunta “*para onde descarregar?*” inteiramente ao TOPSIS e reserva ao agente apenas a pergunta “*descarregar ou não?*” — uma decisão genuinamente nova, que o TOPSIS não responde, pois envolve a comparação entre o melhor candidato de *offload* e a execução local ponderada pela urgência temporal, pelo congestionamento da fila e pela vantagem objetiva  $\Delta_{\text{obj}}$  codificada no estado 6D.

#### 4.7.2 Colapso de política induzido pelo sinal TOPSIS

O segundo mecanismo de falha do PPO-TOPSIS é o **colapso de política**. Com o estado 12D, a posição  $\text{rank}_1$  exhibe consistentemente JCT menor, energia menor e distância menor que  $\text{rank}_2$  e  $\text{rank}_3$ . Isso gera um gradiente de política fortemente unidirecional desde as primeiras iterações:  $P(a=0) \rightarrow 1$ . O PPO utiliza coeficiente de entropia  $\alpha_{\text{ent}} = 0,01$ , dez vezes menor que o do SAC ( $\alpha_{\text{ent}} = 0,10$  com ajuste automático via gradiente dual). Com entropia tão fraca, uma vez que a distribuição de política colapsa para  $P(\text{rank}_1) \approx 1$ , as trajetórias coletadas nas iterações seguintes são quase exclusivamente de escolhas  $\text{rank}_1$ , reforçando o colapso. O mecanismo de *clipping* do PPO ( $\epsilon = 0,2$ ) não reverte esse estado: ele apenas impede mudanças *grandes* por passo, mas não impede a deriva acumulada durante os 400 episódios de treinamento.

O SAC, ao contrário, opera sobre um espaço de ação binário em que nenhuma das duas opções (LOCAL ou *offload* para  $\text{rank}_1$ ) domina o outro de forma incondicional: há cenários em que a fila do RSU está saturada, ou o V2V está distante, ou o *deadline* é tão apertado que mesmo o melhor candidato de *offload* não chega a tempo. Nesses casos, a resposta correta é LOCAL, e o sinal de recompensa *deadline-aware* — com lacuna mínima de 1,5 entre o melhor valor de falha e o pior valor de sucesso — preserva um gradiente exploratório relevante. A alta temperatura entrópica do SAC garante que ambas as ações recebam probabilidade não nula ao longo do treinamento, evitando o colapso.

#### 4.7.3 Assimetria de eficiência amostral com cenário único

O protocolo de treinamento emprega **um único cenário** (`cenario_v2x_10tps_w01`) durante os 400 episódios, com generalização *zero-shot* para os 661 cenários de teste. Essa escolha é compatível com o SAC, mas estruturalmente adversa ao PPO.

O SAC mantém um *replay buffer* de 50.000 transições e realiza atualizações com *minibatch* de 1024 amostras por passo. Com aproximadamente 100 tarefas por episódio, as

40.000 transições coletadas ao longo dos 400 episódios são amostradas em média  $\approx 40$  vezes cada durante o treinamento — uma reciclagem intensiva que extrai máxima informação de um conjunto de dados limitado. Além disso, a mistura de experiências de diferentes pontos do treinamento (política mais aleatória nos primeiros episódios, mais refinada nos últimos) cria uma diversidade implícita que previne o sobreajuste ao único cenário de treino.

O PPO, sendo *on-policy*, descarta cada lote de trajetórias após as  $k = 8$  épocas de atualização. Com um único cenário, cada episódio gera essencialmente o mesmo padrão de chegada de tarefas, o mesmo volume de tarefas e as mesmas condições de canal. A política converge rapidamente para a estratégia que maximiza a recompensa nesse cenário específico — que, com a salência do sinal TOPSIS, é “*sempre escolha rank<sub>1</sub>*” — e não tem como escapar desse ótimo local por falta de diversidade nos dados on-policy.

A evidência experimental confirma esta hipótese: o PPO-TOPSIS-Compact, que usa o estado 6D do SAC-TOPSIS (idêntico em conteúdo semântico) mas com algoritmo PPO, atinge 42,4% — o mesmo que o PPO-Base, que usa o estado bruto 11D. O estado TOPSIS mais informativo não agrega valor ao PPO porque o gargalo não é a qualidade do estado, mas a ineficiência amostral do algoritmo on-policy com cenário único.

#### 4.7.4 Síntese: complementaridade estrutural SAC–TOPSIS

A superioridade do SAC-TOPSIS não decorre de nenhum componente isolado, mas da **complementaridade estrutural** entre os dois módulos em três dimensões:

1. **Divisão de responsabilidades:** O TOPSIS resolve deterministicamente a pergunta “*qual candidato de offload é melhor?*”; o SAC aprende a resposta à pergunta complementar “*vale a pena descarregar para esse candidato?*”. As duas perguntas são independentes e igualmente necessárias; nenhum dos dois módulos, isoladamente, as responde ambas.
2. **Off-policy + replay buffer:** O SAC recicla cada transição  $\approx 40$  vezes no treinamento com um único cenário, alcançando uma eficiência amostral inacessível ao PPO on-policy. Essa reciclagem é segura porque o SAC aprende uma função de valor  $Q(s, a)$  que é off-policy por construção — ao contrário do PPO, cujo gradiente de política requer dados coletados pela política corrente.
3. **Regularização entrópica intensa:** O SAC mantém  $\alpha_{\text{ent}} = 0,10$  com ajuste automático, dez vezes superior ao coeficiente fixo do PPO. Essa entropia elevada é precisamente o que impede o colapso de política frente ao sinal claro fornecido por  $\Delta_{\text{obj}}$  no estado 6D —

mantendo a exploração ativa mesmo quando o TOPSIS sugere fortemente que *offload* é melhor.

Em contraste, o PPO-TOPSIS sofre das três falhas simétricas: aprende uma pergunta que o TOPSIS já responde (redundância), colapsa para uma estratégia degenerada com entropia insuficiente para resistir ao sinal TOPSIS (colapso), e sobreajusta ao único cenário de treino sem o mecanismo de reciclagem do *replay buffer* (ineficiência amostral). O experimento controlado confirma inequivocamente este diagnóstico: ao trocar *apenas* o algoritmo — mantendo estado 6D, ação binária e recompensa idênticos — o SAC-TOPSIS atinge 45,3% enquanto o PPO-TOPSIS obtém 18,4%, um déficit de 26,9 pontos percentuais atribuível exclusivamente à natureza on-policy do PPO e à sua baixa temperatura entrópica. O TOPSIS, portanto, não é neutro quando mal integrado: *amplifica* as fraquezas do algoritmo hospedeiro.

#### 4.8 Avaliação Comparativa de Políticas

As Tabelas 13 e 14 resumem os resultados de 25 políticas avaliadas em 658 cenários de teste comuns, abrangendo algoritmos de aprendizado por reforço (com e sem TOPSIS) e heurísticas de referência. As métricas reportadas são: taxa de *deadline* (%), SWQ ( $= \hat{\tau} \cdot \overline{(D_j - \text{JCT}_j)} / D_{j_{\text{sucesso}}}$ ), JCT médio em segundos, energia média por tarefa em joules e o objetivo  $J(\pi) = 0,60 \cdot \hat{\tau} - 0,40 \cdot \overline{(0,35 \text{JCT} + 0,35 E)} / (D + 0,35 E_{\text{max}})$  com  $E_{\text{max}} = 432,6\text{J}$  (percentil 99 global).

Tabela 13 – Ranking completo das 25 políticas avaliadas em 658 cenários comuns (ordenado por SWQ decrescente). \* = usa TOPSIS.

| #  | Política               | Cn  | Taxa%        | SWQ           | JCT (s)      | E (J)         | J( $\pi$ )    | % Loc | % V2V | Categoria  |
|----|------------------------|-----|--------------|---------------|--------------|---------------|---------------|-------|-------|------------|
| 1  | sac-topsis *           | 658 | <b>45,21</b> | <b>0,1484</b> | 6,547        | 25,828        | <b>0,2454</b> | 74,1  | 25,9  | RL+TOPSIS  |
| 2  | ppo-topsis *           | 658 | 42,66        | 0,1426        | 5,895        | 21,333        | 0,2344        | 98,7  | 1,3   | RL+TOPSIS  |
| 3  | ppo-base               | 658 | 42,32        | 0,1418        | 6,045        | 24,414        | 0,2295        | 100,0 | 0,0   | RL-Base    |
| 4  | ppo-topsis-compact *   | 658 | 42,32        | 0,1418        | 6,045        | 24,414        | 0,2295        | 100,0 | 0,0   | RL+TOPSIS  |
| 5  | td3-base               | 658 | 42,32        | 0,1418        | 6,045        | 24,414        | 0,2295        | 100,0 | 0,0   | RL-Base    |
| 6  | a2c-topsis *           | 658 | 42,32        | 0,1418        | 6,045        | 24,414        | 0,2295        | 100,0 | 0,0   | RL+TOPSIS  |
| 7  | td3-topsis *           | 658 | 43,91        | 0,1388        | <b>3,703</b> | 22,995        | 0,2424        | 76,5  | 23,5  | RL+TOPSIS  |
| 8  | sac-topsis-9d *        | 658 | 42,82        | 0,1386        | 5,886        | <b>20,985</b> | 0,2348        | 94,7  | 5,3   | RL+TOPSIS  |
| 9  | sac-topsis-manhattan * | 658 | 41,66        | 0,1385        | 11,831       | 23,656        | 0,2211        | 51,1  | 48,9  | RL+TOPSIS  |
| 10 | sac-t1 *               | 658 | 32,96        | 0,1270        | 11,487       | 26,126        | 0,1658        | 22,6  | 77,4  | RL+TOPSIS  |
| 11 | greedy-unfair          | 658 | 41,29        | 0,1262        | 5,613        | 7,396         | 0,2370        | 67,3  | 32,7  | Heurística |
| 12 | sac-a1                 | 658 | 39,11        | 0,1256        | 13,722       | 21,118        | 0,2064        | 82,9  | 17,1  | RL-Base    |
| 13 | sac-r1                 | 658 | 38,26        | 0,1223        | 13,353       | 31,425        | 0,1914        | 58,8  | 41,2  | RL-Base    |
| 14 | sac-s1                 | 658 | 28,69        | 0,1122        | 39,298       | 20,305        | 0,1210        | 38,2  | 61,8  | RL-Base    |
| 15 | gini                   | 658 | 35,24        | 0,1057        | 3,456        | 39,395        | 0,1790        | 61,7  | 38,3  | Heurística |
| 16 | dqn-topsis *           | 658 | 25,90        | 0,0997        | 21,722       | 23,979        | 0,1161        | 20,0  | 80,0  | RL+TOPSIS  |
| 17 | jain                   | 658 | 32,54        | 0,0973        | 3,628        | 39,280        | 0,1627        | 58,6  | 41,4  | Heurística |
| 18 | random                 | 658 | 30,02        | 0,0950        | 17,853       | 27,330        | 0,1427        | 40,7  | 59,3  | Heurística |
| 19 | roundrobin             | 658 | 28,50        | 0,0905        | 17,900       | 31,080        | 0,1315        | 34,9  | 65,1  | Heurística |
| 20 | greedy                 | 658 | 29,03        | 0,0823        | 29,265       | 6,168         | 0,1429        | 42,5  | 57,5  | Heurística |
| 21 | a2c-base               | 658 | 21,74        | 0,0772        | 13,653       | 48,862        | 0,0785        | 20,3  | 79,7  | RL-Base    |
| 22 | dqn-base               | 658 | 22,10        | 0,0686        | 13,599       | 44,445        | 0,0839        | 21,5  | 78,5  | RL-Base    |
| 23 | greedy-fair            | 658 | 20,61        | 0,0528        | 40,754       | <b>5,634</b>  | 0,0823        | 27,9  | 72,1  | Heurística |
| 24 | sac-base               | 658 | 4,52         | 0,0119        | 57,075       | 24,230        | −0,042        | 5,1   | 94,9  | RL-Base    |
| 25 | rsu                    | 658 | 1,86         | 0,0030        | 144,191      | 4,843         | −0,123        | 1,2   | 98,8  | Heurística |

A Tabela 14 isola o efeito do TOPSIS para cada família de algoritmos, comparando a versão base com a versão aumentada pelo ranqueamento multicritério.

**Tabela 14 – Ganho do TOPSIS por família de algoritmo (médias sobre 658 cenários comuns).  $\Delta$ Taxa e  $\Delta$ SWQ representam diferença absoluta;  $\Delta J(\pi)$  é a diferença na função objetivo.**

| Algoritmo | Versão | Taxa % |              | SWQ    |               | J( $\pi$ ) |               | Destaques                                          |
|-----------|--------|--------|--------------|--------|---------------|------------|---------------|----------------------------------------------------|
|           |        | Base   | TOPSIS       | Base   | TOPSIS        | Base       | TOPSIS        |                                                    |
| SAC       | base   | 4,52   | —            | 0,0119 | —             | -0,042     | —             | colapso total (94,9% V2V)<br>+40,7 pp / +1147% SWQ |
|           | topsis | —      | <b>45,21</b> | —      | <b>0,1484</b> | —          | <b>0,2454</b> |                                                    |
| PPO       | base   | 42,32  | —            | 0,1418 | —             | 0,2295     | —             | 100% local<br>+0,3 pp / +0,6% SWQ                  |
|           | topsis | —      | 42,66        | —      | 0,1426        | —          | 0,2344        |                                                    |
| TD3       | base   | 42,32  | —            | 0,1418 | —             | 0,2295     | —             | 100% local<br>+1,6 pp taxa; JCT -44,5%             |
|           | topsis | —      | 43,91        | —      | 0,1388        | —          | 0,2424        |                                                    |
| DQN       | base   | 22,10  | —            | 0,0686 | —             | 0,0839     | —             | 78,5% V2V sem critério<br>+3,8 pp / +45% SWQ       |
|           | topsis | —      | 25,90        | —      | 0,0997        | —          | 0,1161        |                                                    |
| A2C       | base   | 21,74  | —            | 0,0772 | —             | 0,0785     | —             | 79,7% V2V, energia alta<br>+20,6 pp / +84% SWQ     |
|           | topsis | —      | 42,32        | —      | 0,1418        | —          | 0,2295        |                                                    |

## 5 CRONOGRAMA DE PESQUISA E PLANO DE PUBLICAÇÃO

Este capítulo detalha o roteiro para a conclusão da pesquisa de doutorado e a estratégia para a disseminação dos resultados através de publicações de alto impacto, considerando o prazo final em março de 2027.

### 5.1 Cronograma de Pesquisa

As atividades de pesquisa restantes estão estruturadas para garantir a conclusão do modelo Fuzzy-DRL e a validação experimental. A Tabela 15 apresenta o cronograma para o período de 2026 a 2027, culminando na defesa da tese.

**Tabela 15 – Atividades de pesquisa e cronograma de conclusão (2026–2027).**

| Atividade / Ano                              | 2026 |    | 2027 |
|----------------------------------------------|------|----|------|
|                                              | S1   | S2 | Q1   |
| 1. Exame de Qualificação                     | X    |    |      |
| 2. Integração com Simulador (NS-3/SUMO)      | X    | X  |      |
| 3. Refinamento de Algoritmos                 | X    | X  |      |
| 4. Avaliação de Desempenho e Coleta de Dados |      | X  |      |
| 5. Análise dos Resultados                    |      | X  | X    |
| 6. Escrita da Tese Final                     |      | X  | X    |
| 7. Defesa Final                              |      |    | X    |

Fonte: Elaborado pelo autor.

### 5.2 Plano de Publicação

A disseminação das descobertas focará em periódicos e conferências especializadas em redes veiculares, computação de borda e sistemas inteligentes. Os locais planejados priorizados para submissão incluem:

- **Periódicos de Alto Impacto:**

- IEEE Transactions on Intelligent Transportation Systems (T-ITS);
- IEEE Transactions on Vehicular Technology (TVT);
- IEEE Internet of Things Journal.

- **Conferências Relevantes:**

- IEEE Vehicular Technology Conference (VTC);
- IEEE Global Communications Conference (GLOBECOM);
- IEEE International Conference on Communications (ICC).

## 6 CONCLUSÕES

Este texto resume o progresso feito durante a fase de qualificação e destaca a importância do modelo proposto para o futuro das redes veiculares habilitadas por 5G.

### 6.1 Resumo do Progresso

Durante esta etapa da pesquisa, foi realizada uma revisão abrangente da literatura para identificar as lacunas no descarregamento de tarefas multiobjetivo em ambientes VEC altamente dinâmicos. O modelo proposto, combinando Lógica *Fuzzy* para normalização de estado e Aprendizado por Reforço Profundo (PPO) para tomada de decisão otimizada, aborda os desafios críticos de escalabilidade e invariância de escala.

As principais contribuições alcançadas até agora incluem:

- A formulação de um estado triplete invariante à escala;
- O projeto de uma função de recompensa que equilibra latência, eficiência energética e justiça;
- O desenvolvimento de um *framework* de simulação integrado com NS-3 e SUMO.

### 6.2 Considerações Finais

Como um documento de qualificação, este trabalho demonstra a viabilidade da abordagem proposta e fornece uma base teórica e metodológica sólida para a tese final. Os próximos passos envolvem a implementação completa do agente Fuzzy-PPO e uma comparação extensiva de desempenho com baselines do estado da arte. Espera-se que os resultados finais contribuam significativamente para o gerenciamento eficiente de recursos computacionais na próxima geração de sistemas de transporte inteligentes.



## REFERÊNCIAS

- 3GPP. *Release 17 Overview*. [S.l.], 2022. Accessed: 2025-01-01.
- 5G and Beyond for Dummies. [S.l.]: John Wiley & Sons, 2020. Custom For Dummies.
- A state-of-the-art review of offloading mechanisms in fog environments. *Multimedia Tools and Applications*, v. 81, p. 1997–2042, 2022.
- ABBAS, Z.; XU, S.; ZHANG, X. An efficient partial task offloading and resource allocation scheme for vehicular edge computing in a dynamic environment. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, 2024.
- ABD-ELNABY, M. *et al.* Comparative analysis of IEEE 802.11bd and 5G NR-V2X for intelligent transportation systems. **Vehicular Communications**, v. 45, p. 100678, 2024.
- Agência Nacional de Telecomunicações (Anatel). **Ato nº 14158, de 1º de outubro de 2025: Requisitos Técnicos para Avaliação da Conformidade de Equipamentos de Radiocomunicação**. 2025. Disponível em: <https://www.anatel.gov.br/legislacao/atos-de-certificacao-de-produtos/2025/1959-ato-14158>.
- Agência Nacional de Telecomunicações (Anatel). **Resolução nº 772, de 16 de janeiro de 2025: Plano de Atribuição, Destinação e Distribuição de Faixas de Frequências no Brasil**. 2025.
- AHMED, M.; RAZA, S.; MIRZA, M. A.; AZIZ, A.; KHAN, M. A.; KHAN, W. U.; LI, J.; HAN, Z. A survey on vehicular task offloading: Classification, issues, and challenges. **Journal of King Saud University - Computer and Information Sciences**, v. 34, n. 7, p. 4135–4162, 2022. ISSN 1319-1578. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1319157822001653>.
- ALBRECHT, S. V.; CHRISTIANOS, F.; SCHÄFER, L. **Multi-Agent Reinforcement Learning: Foundations and Modern Approaches**. [S.l.]: MIT Press, 2024.
- ANSARI, K. The 5.9 GHz spectrum for safety-related V2X: The battle between DSRC and C-V2X. **IEEE Access**, v. 8, p. 143161–143171, 2020.
- ASPLUND, H.; ASTELY, D.; BUTOVITSCH, P. von; CHAPMAN, T.; FAXÉR, S.; FRENNE, M.; GHASEMZADEH, F.; HAGSTRÖM, M.; HOGAN, B.; JÖNGREN, G.; KARLSSON, J.; KRONESTEDT, F.; LARSSON, E. **Massive MIMO in Practice: From 5G to 6G**. 2nd. ed. [S.l.]: Academic Press (Elsevier), 2025.
- BAKER, T.; AGHBARI, Z. A.; KHEDR, A.; AHMED, N.; GIRIJA, S. Editors: Energy-aware dynamic task offloading using deep reinforcement and transfer learning for sdn-enabled edge cloud. **Internet of Things**, Elsevier, v. 25, p. 101118, 2024.
- BAO, H.; WANG, Y.; LI, P.; NIE, L.; YU, G.; HUO, Y.; WU, L. Joint task offloading, resource allocation, and service caching in mobile edge computing via soft actor-critic learning. **IEEE Transactions on Vehicular Technology**, IEEE, 2025.
- BOUKERCHE, A.; SOTO, V. Computation offloading and retrieval for vehicular edge computing: Algorithms, models and classification. **ACM Computing Surveys**, v. 53, n. 4, p. 1–35, 2020.

- BROCKMAN, G.; CHEUNG, V.; PETTERSSON, L.; SCHNEIDER, J.; SCHULMAN, J.; TANG, J.; ZAREMBA, W. Openai gym. **arXiv preprint arXiv:1606.01540**, 2016.
- CHEN, S.; AL. et. Vehicle-to-everything (v2x) services: Mode 4 communication in lte-v2x. **IEEE Access**, v. 5, p. 22461–22471, 2017.
- CHEN, S.; LI, W.; SUN, J.; PACE, P.; HE, L.; FORTINO, G. An efficient collaborative task offloading approach based on multi-objective algorithm in mec-assisted vehicular networks. **IEEE Transactions on Vehicular Technology**, 2025.
- COX, C. **An Introduction to 5G: The New Radio, 5G Network, 5G Advanced and Beyond**. 2nd. ed. [S.l.]: John Wiley & Sons Ltd, 2025.
- FAN, Y.; CAI, X. A deep reinforcement approach for computation offloading in mec dynamic networks. **EURASIP Journal on Advances in Signal Processing**, Springer, v. 2024, n. 48, 2024.
- FARIMANI, M. K. *et al.* Deadline-aware task offloading in vehicular networks using deep reinforcement learning. **Expert Systems With Applications**, Elsevier, v. 249, p. 123622, 2024.
- Federal Communications Commission (FCC). **Use of the 5.850-5.925 GHz Band: Second Report and Order**. [S.l.], 2024. Adopted November 20, 2024. Establishing sunset for DSRC by December 2025.
- FENG, J.; LIU, Z.; WU, C.; JI, Y. Ave: Autonomous vehicular edge computing framework with aco-based scheduling. **IEEE Transactions on Vehicular Technology**, IEEE, v. 66, n. 12, p. 10660–10675, 2017.
- FOWDUR, T. P.; INDOONUNDON, M.; MILOVANOVIC, D. A.; BOJKOVIC, Z. S. **5G NR Modelling in MATLAB**. [S.l.]: CRC Press, 2025.
- GARCIA, M. H. C.; AL. et. A tutorial on 5g nr v2x communications. **IEEE Communications Surveys & Tutorials**, v. 23, n. 3, p. 1972–2025, 2021.
- HAARNOJA, T. *et al.* Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In: **ICML**. [S.l.: s.n.], 2018.
- HE, C.; WANG, W.; JIANG, W.; HE, Z.; WANG, J.; XIE, X. Security for the internet of vehicles with integration of sensing, communication, computing, and intelligence: A comprehensive survey. **Sensors**, v. 25, n. 16, 2025. ISSN 1424-8220. Disponível em: <https://www.mdpi.com/1424-8220/25/16/5119>.
- HOU, X.; LI, Y.; CHEN, M.; WU, D.; JIN, D.; CHEN, S. Vehicular fog computing: A viewpoint of vehicles as the infrastructures. **IEEE Transactions on Vehicular Technology**, IEEE, v. 65, n. 6, p. 3860–3873, 2016.
- HU, M. **The Art of Reinforcement Learning: Fundamentals, Mathematics, and Implementations with Python**. [S.l.]: Apress, 2024.
- HUANG, X.; YE, Q.; LI, J.; WU, Y. Deep reinforcement learning for offloading and resource allocation in vehicular edge computing. **IEEE Transactions on Vehicular Technology**, v. 69, n. 8, p. 8334–8345, 2020.
- HWANG, C.-L.; YOON, K. **Multiple Attribute Decision Making: Methods and Applications**. Berlin, Heidelberg: Springer-Verlag, 1981.

IOANNOU, I.; VASSILIOU, V.; NAGARADJANE, P.; CHRISTOPHOROU, C.; PITSILLIDES, A. **Distributed Artificial Intelligence for 5G-6G Communications**. [S.l.]: CRC Press, 2025.

ITU-R. **IMT Vision - Framework and overall objectives of the future development of IMT for 2020 and beyond**. Geneva, Switzerland, 2015.

ITU-R. **Minimum requirements related to technical performance for IMT-2020 radio interface(s)**. Geneva, Switzerland, 2017.

ITU-R. **Detailed specifications of the terrestrial radio interfaces of International Mobile Telecommunications-2020 (IMT-2020)**. Geneva, Switzerland, 2021.

KANDALI, K.; NOUH, S.; BENNIS, L.; BENNIS, H. A comprehensive survey on vanet-iot integration toward the internet of vehicles: Architectures, communications, and system challenges. **Data and Metadata**, v. 4, p. 521, 2025.

KESHARI, N.; SINGH, D.; MAURYA, A. K. A survey on vehicular fog computing: Current state-of-the-art and future directions. **Vehicular Communications**, v. 38, p. 100512, 2022. Disponível em: <https://doi.org/10.1016/j.vehcom.2022.100512>.

KHAN, P. W.; ABBAS, K.; SHAIBA, H.; MUTHANNA, A.; ABUARQOUB, A.; KHAYYAT, M. Energy efficient computation offloading mechanism in multi-server mobile edge computing—an integer linear optimization approach. **Electronics**, MDPI, v. 9, n. 6, p. 1010, 2020.

KISHOR, A.; CHAKARBARTY, C. Task offloading in fog computing for using smart ant colony optimization. **Wireless personal communications**, Springer, v. 127, n. 2, p. 1683–1704, 2022.

KUMAR, A. S.; ZHAO, L.; FERNANDO, X. Task offloading and resource allocation in vehicular networks: A lyapunov-based deep reinforcement learning approach. **IEEE Transactions on Vehicular Technology**, IEEE, v. 72, 2023.

KUMARI, S. *et al.* Task offloading in vehicular edge computing network using deep q-network. **International Journal of Intelligent Engineering and Systems**, v. 18, n. 9, p. 659–672, 2025.

LI, X.; PU, Y.; YAN, C.; DUAN, W.; ZHANG, X. Computation offloading and association in mec-assisted v2x network for delay minimization and collision avoidance via deep q-network. **Discover Computing**, Springer, v. 28, n. 302, 2025.

LI, Z.; ZHU, Q. Genetic algorithm-based optimization of offloading and resource allocation in mobile-edge computing. **Information**, MDPI, v. 11, n. 2, p. 83, 2020.

LIN, L. *et al.* A survey on computation offloading and current trends. **IEEE Access**, 202x.

LIU, L.; CHEN, C.; PEI, Q.; MAHARJAN, S.; ZHANG, Y. Vehicular edge computing and networking: A survey. **Mobile Networks and Applications**, v. 26, n. 3, p. 1145–1168, jun. 2021. ISSN 1572-8153. Disponível em: <https://doi.org/10.1007/s11036-020-01624-1>.

LIU, Z.; SU, J.; WEI, J.; CHEN, W.; CHAN, K. Y.; YUAN, Y.; GUAN, X. Joint robust power control and task scheduling for vehicular offloading in cloud-assisted mec networks. **IEEE Transactions on Network Science and Engineering**, 2024.

LONG, Y.; WANG, Z.; LAN, S.; ZHANG, R.; XU, K. Energy-latency tradeoff for task offloading and resource allocation in vehicular edge computing. **Computer Networks**, Elsevier, v. 258, p. 111026, 2025.

LOPEZ, P. A.; BEHRISCH, M.; BIEKER-WALZ, L.; ERDMANN, J.; FLÖTTERÖD, Y.-P.; HILBRICH, R.; LÜCKEN, L.; RUMMEL, J.; WAGNER, P.; WIESSNER, E. Microscopic traffic simulation using sumo. In: **The 21st IEEE International Conference on Intelligent Transportation Systems**. [S.l.]: IEEE, 2018. p. 2575–2582.

LUO, Q.; LUAN, T. H.; SHI, W.; FAN, P. Heterogeneous task oriented data scheduling in vehicular edge computing via deep reinforcement learning. **IEEE Transactions on Vehicular Technology**, v. 73, n. 12, p. 19582–19596, 2024.

MA, R.; ZHOU, J.; WANG, R.; CHEN, H.-H.; LIU, G. Computation offloading and resource allocation in vehicular mec: A parameterized deep reinforcement learning approach. **IEEE Transactions on Vehicular Technology**, IEEE, 2025.

MACH, P.; BECVAR, Z. Mobile edge computing: A survey on architecture and computation offloading. **IEEE Communications Surveys & Tutorials**, v. 19, n. 3, p. 1628–1656, 2017.

MAO, Y.; YOU, C.; ZHANG, J.; HUANG, K.; LETAIEF, K. B. A survey on mobile edge computing: The communication perspective. **IEEE Communications Surveys & Tutorials**, v. 19, n. 4, p. 2322–2358, 2017.

MEGHAMALA, Y.; PAUL, P. J.; KUMAR, M. A. A multi-agent deep reinforcement learning framework for mec resource allocation in 5g networks. **Electrical and Electronics Research (IJEER)**, v. 13, n. 4, p. 909–919, 2025.

MIRIYALA, S.; CHIRRA, V. R. Deep learning approaches for computation offloading in edge computing: A critical review. **Telecommunication Systems**, Springer, v. 89, p. 42, 2026.

MNIH, V. *et al.* Human-level control through deep reinforcement learning. **Nature**, v. 518, n. 7540, p. 529–533, 2015.

MOBILE Edge Computing Task Offloading. **Applied Sciences**, v. 15, 2024.

MOERLAND, T. M.; BROEKENS, J.; PLAAT, A.; JONKER, C. M. Model-based reinforcement learning: A survey. **Foundations and Trends® in Machine Learning**, Now Publishers, v. 16, n. 1, p. 1–118, 2023.

MOGHADDASI, K.; RAJABI, S.; GHAREHCHOPOGH, F. S. Multi-objective secure task offloading strategy for blockchain-enabled iov-mec systems: A double deep q-network approach. **IEEE Access**, 2024.

MOGHADDASI, K.; RAJABI, S.; GHAREHCHOPOGH, F. S.; HOSSEINZADEH, M. An energy-efficient data offloading strategy for 5g-enabled vehicular edge computing networks using double deep q-network. **Wireless Personal Communications**, v. 133, n. 3, p. 2019–2064, 12 2023. ISSN 1572-834X. Disponível em: <https://doi.org/10.1007/s11277-024-10862-5>.

MOHAMMAD, A. A. S.; AL-HAWARY, S. I. S.; HINDIEH, A.; VASUDEVAN, A.; AL-SHORMAN, H. M.; AL-ADWAN, A. S.; ALSHURIDEH, M. T.; ALI, I. Intelligent data-driven task offloading framework for internet of vehicles using edge computing and reinforcement learning. **Data and Metadata**, v. 4, p. 521, 2025.

MOLTCHANOV, D.; SOPIN, E.; BEGISHEV, V.; SAMUYLOV, A.; KOUCHERYAVY, Y.; SAMOUYLOV, K. A tutorial on mathematical modeling of 5g/6g millimeter wave and terahertz cellular systems. **IEEE Communications Surveys & Tutorials**, IEEE, v. 24, n. 2, p. 1072–1116, 2022.

MORAIS, D. H. **5G/5G-Advanced, Wi-Fi 6/7, and Bluetooth 5/6: A Primer on Smartphone Wireless Technologies**. 2nd. ed. [S.l.]: Springer Nature, 2025.

NAIK, G.; CHOUDHURY, B.; PARK, J.-M. J. IEEE 802.11bd & 5g nr v2x: Evolution of radio access technologies for v2x communications. **IEEE Access**, v. 7, p. 70113–70128, 2019.

NAIK, G. *et al.* Next generation vehicular communications: From DSRC to V2X. **IEEE Access**, v. 7, p. 142934–142947, 2019.

NIETO, G.; IGLESIA, I. de la; LOPEZ-NOVOA, U.; PERFECTO, C. Deep reinforcement learning techniques for dynamic task offloading in the 5g edge-cloud continuum. **Journal of Cloud Computing**, v. 13, n. 1, p. 94, 2024. ISSN 2192-113X. Disponível em: <https://doi.org/10.1186/s13677-024-00658-0>.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C. L.; MISHKIN, P.; ZHANG, C.; AGARWAL, S.; SLAMA, K.; RAY, A.; SCHULMAN, J.; HILTON, J.; KELTON, F.; MILLER, L.; SIMENS, M.; ASKELL, A.; WELINDER, P.; CHRISTIANO, P.; LEIKE, J.; LOWE, R. **Training language models to follow instructions with human feedback**. 2022.

PARRA, O. J. S. *et al.* The evolution of VANET: A review of emerging trends in artificial intelligence and software-defined networks. **IEEE Access**, IEEE, v. 13, p. 49195–49212, 2025.

PTV Group. **PTV Vissim - User Manual**. Karlsruhe, Germany: PTV Planung Transport Verkehr AG, 2020.

QIN, X. *et al.* A survey and taxonomy on task offloading for edge-cloud computing. **IEEE Access**, IEEE, v. 8, 2020.

RAGHAVAN, V.; LI, J.; SAMPATH, A.; KOYMEN, O. H.; LUO, T. (Ed.). **Millimeter Wave Communications in 5G and Towards 6G**. [S.l.]: CRC Press, 2025.

RANI, P.; SHARMA, R. Intelligent transportation system for internet of vehicles based vehicular networks for smart cities. **Computers and Electrical Engineering**, v. 105, p. 108543, 2023. ISSN 0045-7906. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0045790622007583>.

REFERENCE architecture for the compute continuum. [S.l.], 2022.

REN, J.; YU, G.; CAI, Y.; HE, Y. Latency optimization for resource allocation in mobile-edge computation offloading. **IEEE Transactions on Wireless Communications**, IEEE, v. 17, n. 8, p. 5506–5519, 2018.

REN, J.; YU, G.; HE, Y.; LI, G. Y. Collaborative cloud and edge computing for latency minimization. **IEEE Transactions on Vehicular Technology**, IEEE, v. 68, n. 5, p. 5031–5044, 2019.

RODRÍGUEZ-PIÑEIRO, J. *et al.* 6g-enabled vehicle-to-everything communications: Current research trends and open challenges. **IEEE Open Journal of Vehicular Technology**, v. 6, p. 1–18, August 2025.

SAE International. **Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles**. Warrendale, PA, USA, 2021. Disponível em: [https://www.sae.org/standards/content/j3016\\_202104/](https://www.sae.org/standards/content/j3016_202104/).

- SCHAUL, T.; QUAN, J.; ANTONOGLOU, I.; SILVER, D. Prioritized experience replay. In: **ICLR**. [S.l.: s.n.], 2016.
- SCHULMAN, J.; LEVINE, S.; ABBEEL, P.; JORDAN, M.; MORITZ, P. Trust region policy optimization. In: **ICML**. [S.l.: s.n.], 2015. p. 1889–1897.
- SCHULMAN, J.; WOLSKI, F.; DHARIWAL, P.; RADFORD, A.; KLIMOV, O. Proximal policy optimization algorithms. **arXiv preprint arXiv:1707.06347**, 2017.
- SHEIKH, J. A.; BHAT, Z. A.; MASOODI, I. S. (Ed.). **Radio Frequency, Communications and Signal Processing for 5G and Beyond 5G Networks**. [S.l.]: CRC Press, 2026.
- SHI, W.; CHEN, L.; ZHU, X. Task offloading decision-making algorithm for vehicular edge computing: A deep-reinforcement-learning-based approach. **Sensors**, v. 23, n. 17, 2023. ISSN 1424-8220. Disponível em: <https://www.mdpi.com/1424-8220/23/17/7595>.
- SIDWINI, S. L.; ROUT, S.; PATNAIK, H. K.; DASH, B. B.; DE, U. C.; PATRA, S. S. Task offloading in edge computing: Energy optimization through sac based reinforcement learning. In: . [S.l.: s.n.], 2024. Preprint / Anais de Conferência.
- SOUZA, A. B. D.; REGO, P. A.; CARNEIRO, T.; RODRIGUES, J. D. C.; FILHO, P. P. R.; SOUZA, J. N. D.; CHAMOLA, V.; ALBUQUERQUE, V. H. C. D.; SIKDAR, B. Computation offloading for vehicular environments: A survey. **IEEE Access**, IEEE, v. 8, p. 198214–198243, 2020.
- SOUZA, A. B. de; REGO, P. A. L.; CARNEIRO, T.; ROCHA, P. H. G.; SOUZA, J. N. de. A context-oriented framework for computation offloading in vehicular edge computing using wave and 5g networks. **Vehicular Communications**, Elsevier, v. 32, p. 100389, 2021.
- STALLINGS, W. **5G Wireless: A Comprehensive Introduction**. [S.l.]: Pearson Education, 2021.
- STUDY on channel model for frequencies from 0.5 to 100 GHz (3GPP TR 38.901 version 16.1.0 Release 16). [S.l.], 2020. Release 16.
- SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning: An Introduction**. 2nd. ed. [S.l.]: The MIT Press, 2018.
- SÁNCHEZ, J. *et al.* The evolution of vehicular communications: From V2V to V2X and beyond. **IEEE Communications Surveys & Tutorials**, v. 27, n. 1, p. 100–145, 2025.
- TANG, H.; DU, M.; WU, H.; JIAO, P. Link topology-adaptive offloading method on vehicular edge computing. **IEEE Transactions on Vehicular Technology**, IEEE, 2024.
- THE Evolution from Cloud Computing to MEC. **Future Internet**, v. 15, p. 391, 2023.
- TIAN, S.; ZHU, X.; FENG, B.; ZHENG, Z.; LIU, H.; LI, Z. Partial offloading strategy based on deep reinforcement learning in the internet of vehicles. **IEEE Transactions on Mobile Computing**, IEEE, 2025.
- TURCANU, I.; AL. et. A hybrid dsrc-pmp communication architecture for vehicular networks. **IEEE Communications Letters**, v. 20, n. 7, p. 1389–1392, 2016.

- UDDIN, A.; ZHANG, N.; SAKR, A. H. Intelligent offloading in vehicular edge computing: A comprehensive review of deep reinforcement learning approaches and architectures. **arXiv preprint arXiv:2502.06963v2**, 2025.
- VIEIRA, A. S. de S.; SOUZA, A. B. de; JÚNIOR, J. C. Foff: an energy-efficient task offloading in vec-enabled vehicular networks using fuzzy topsis. **Cluster Computing**, Springer, v. 28, n. 13, p. 822, 2025.
- WANG, D. *et al.* Iot task offloading in mec: A comprehensive review. **Heliyon**, v. 10, n. e29916, 2024.
- WANG, F.; XU, J.; WANG, X.; CUI, S. Joint offloading and computing optimization in wireless powered mobile-edge computing systems. In: **IEEE International Conference on Communications (ICC)**. [S.l.: s.n.], 2017. p. 1–6.
- WANG, M.; YI, H.; JIANG, F.; LIN, L.; GAO, M. Review on offloading of vehicle edge computing. **Journal of Artificial Intelligence and Technology**, v. 2, n. 4, p. 132–143, 2022. Disponível em: <https://doi.org/10.37965/jait.2022.0120>.
- WANG, T.; OUYANG, X.; SUN, D.; CHEN, Y.; LI, H. Offloading strategy based on graph neural reinforcement learning in mobile edge computing. **Electronics**, MDPI, v. 13, n. 12, p. 2387, 2024.
- WANG, Z.; SCHAUL, T.; HESSEL, M.; HASSELT, H. v.; LANCTOT, M.; FREITAS, N. d. Dueling network architectures for deep reinforcement learning. In: **ICML**. [S.l.: s.n.], 2016.
- WEI, R.; QIN, T.; HUANG, J.; YANG, Y.; REN, J.; YANG, L. Resource allocation scheduling scheme for task migration and offloading in 6g cybertwin internet of vehicles based on drl. **IET Communications**, John Wiley & Sons, v. 18, p. 1244–1265, 2024.
- WHAIDUZZAMAN, M.; SOOKHAK, M.; GANI, A.; BUYYA, R. A survey on vehicular cloud computing. **Journal of Network and Computer Applications**, v. 40, p. 325–344, 2014. Disponível em: <https://doi.org/10.1016/j.jnca.2013.08.004>.
- WILLIAMS, R. J. Simple statistical gradient-following algorithms for connectionist reinforcement learning. **Machine learning**, v. 8, n. 3-4, p. 229–256, 1992.
- WU, H.; GU, A.; LIANG, Y. Federated reinforcement learning-empowered task offloading for large models in vehicular edge computing. **IEEE Transactions on Vehicular Technology**, IEEE, v. 74, n. 2, p. 1979–1991, 2025.
- WU, J. *et al.* Efficient gan-based federated optimization for vehicular task offloading with mobile edge computing in 6g network. **IEEE Internet of Things Journal**, Feb 2025.
- XIE, Y. *et al.* Efficient task offloading in double roadside ris-assisted vehicular edge computing networks using deep reinforcement learning. **IEEE Transactions on Intelligent Transportation Systems**, Aug 2025.
- YOU, Q.; TANG, B. Efficient task offloading using particle swarm optimization algorithm in edge computing for industrial internet of things. **Journal of Cloud Computing**, Springer, v. 10, n. 1, p. 41, 2021.
- ZHANG, K.; MAO, Y.; LENG, S.; HE, L.; ZHANG, Y.; PENG, X.; VINEL, A. Energy-efficient offloading for mobile edge computing in 5g networks. **IEEE Wireless Communications**, v. 25, n. 2, p. 20–27, 2018.

ZHANG, S.; YI, N.; MA, Y. A survey of computation offloading with task types. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, v. 25, n. 8, p. 8313–8333, 2024.

ZHANG, Y.; DU, P.; WANG, J.; BA, T.; DING, R.; XIN, N. Resource scheduling for delay minimization in multi-server cellular edge computing systems. **IEEE Access**, IEEE, v. 7, p. 86265–86273, 2019.

ZHANG, Y. *et al.* A review of the current task offloading algorithms, strategies and approach in edge computing systems. **Computer Modeling in Engineering & Sciences**, v. 134, n. 1, p. 35–88, 2023.

ZHANG, Y. *et al.* A review of the current task offloading algorithms, strategies and approach in edge computing systems. **Computer Modeling in Engineering & Sciences**, v. 134, n. 1, p. 35–88, 2023.

ZHAO, L.; DONG, X.; HAWBANI, A.; BI, Y.; HE, Q.; LIU, Z. Optimizing task offloading in vec: A pdqkm scheme combining deep reinforcement learning and kuhn-munkres matching. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, 2025.

ZHAO, S. **Mathematical Foundations of Reinforcement Learning**. [S.l.]: Tsinghua University Press and Springer, 2024.

ZHENG, K.; ZHENG, Q.; CHATZIMISIOS, P.; XIANG, W.; ZHOU, Y. Heterogeneous vehicular networking: A survey on architecture, challenges, and solutions. **IEEE Communications Surveys & Tutorials**, v. 17, n. 4, p. 2377–2396, 2015.

ZHOU, Z.; CHEN, X.; LI, E.; ZENG, L.; LUO, K.; ZHANG, J. Edge intelligence: Paving the last mile of artificial intelligence with edge computing. **Proceedings of the IEEE**, v. 107, n. 8, p. 1738–1762, 2019.