



Modelo de Decisão Baseado em Lógica *Fuzzy*-TOPSIS e Aprendizado por Reforço Profundo para o *Offloading* de Tarefas em Redes Veiculares

Antônio Sérgio de Sousa Vieira

Doutorado em Ciência da Computação — Redes de Computadores


Orientador: Prof. Dr. Joaquim Celestino Júnior (UECE/CCT)

Co-orientador: Prof. Dr. Alisson Barbosa de Souza

Fortaleza – Ceará, 2026


APRENDIZADO POR REFORÇO

UMA ABORDAGEM DE APRENDIZADO DE MÁQUINA NA QUAL UM AGENTE APRENDE A TOMAR DECISÕES REALIZANDO AÇÕES EM UM AMBIENTE E RECEBENDO RECOMPENSAS OU PENALIDADES, MELHORANDO GRADUALMENTE SEU COMPORTAMENTO PARA MAXIMIZAR A RECOMPENSA ACUMULADA.




AGENTE

UMA ENTIDADE AUTÔNOMA QUE PERCEBE SEU AMBIENTE POR MEIO DE SENSORES, TOMA DECISÕES COM BASE EM SEU ESTADO E POLÍTICA ATUAIS, E REALIZA AÇÕES PARA MAXIMIZAR A RECOMPENSA ACUMULADA AO LONGO DO TEMPO.



AÇÃO


UMA ESCOLHA OU MOVIMENTO ESPECÍFICO DISPONÍVEL PARA O AGENTE NO ESTADO ATUAL, QUE CAUSA UMA TRANSIÇÃO PARA UM NOVO ESTADO NO AMBIENTE.



AMBIENTE

O MUNDO EXTERNO COM O QUAL O AGENTE INTERAGE. RECEBE AS AÇÕES DO AGENTE, REALIZA TRANSIÇÕES PARA NOVOS ESTADOS E FORNECE SINAIS DE RECOMPENSA DE VOLTA AO AGENTE.


-- AMBIENTE DO TETRIS --



ESTADO


UMA DESCRIÇÃO COMPLETA DA SITUAÇÃO OU CONFIGURAÇÃO ATUAL DO AMBIENTE EM UM MOMENTO ESPECÍFICO NO TEMPO.

ESTADO INICIAL DO AMBIENTE DE XADREZ




RECOMPENSA

UM SINAL DE FEEDBACK NUMÉRICO RECEBIDO IMEDIATAMENTE APÓS TOMAR UMA AÇÃO,
INDICANDO O QUÃO BOA OU RUIM FOI AQUELA AÇÃO NO ESTADO ATUAL.



PROPRIEDADE DE MARKOV


UMA PROPRIEDADE QUE AFIRMA QUE O ESTADO FUTURO DE UM PROCESSO DEPENDE APENAS DO ESTADO ATUAL, E NÃO DA SEQUÊNCIA DE EVENTOS QUE LEVOU A ELE.



MDP


PROCESSO DE DECISÃO DE MARKOV

UM FRAMEWORK MATEMÁTICO PARA TOMADA DE DECISÃO SEQUENCIAL SOB INCERTEZA, DEFINIDO POR ESTADOS, AÇÕES, PROBABILIDADES DE TRANSIÇÃO E RECOMPENSAS, COM O OBJETIVO DE ENCONTRAR UMA POLÍTICA QUE MAXIMIZE A RECOMPENSA ACUMULADA ESPERADA.




CICLO DO MDP

A INTERAÇÃO ENTRE AGENTE E AMBIENTE REPETE-SE ITERATIVAMENTE EM 5 PASSOS SEQUENCIAIS.




CICLO DE TREINAMENTO EM RL

DURANTE O TREINAMENTO, O CICLO DE INTERAÇÃO GANHA UMA ETAPA CRUCIAL: A ATUALIZAÇÃO. APÓS AGIR E OBSERVAR (S, A, R, S') , O AGENTE CALCULA O ERRO DE SUA PREVISÃO E ATUALIZA ITERATIVAMENTE SUA POLÍTICA OU FUNÇÃO DE VALOR, MELHORANDO SEU COMPORTAMENTO A CADA PASSO.




EPISÓDIO

UMA TRAJETÓRIA FINITA DE ESTADOS, AÇÕES E RECOMPENSAS QUE COMEÇA EM UM ESTADO INICIAL E TERMINA EM UM ESTADO TERMINAL.



RETORNO


O RETORNO G_t É A SOMA DE TODAS AS RECOMPENSAS FUTURAS QUE O AGENTE RECEBE A PARTIR DO INSTANTE t , ATÉ O FIM DO EPISÓDIO.



$$G_t = R_{t+1} + R_{t+2} + R_{t+3} + \dots = \sum_{k=0}^{\infty} R_{t+k+1}$$

FATOR DE DESCONTO


UM VALOR (γ) ENTRE 0 E 1 QUE DETERMINA O QUANTO AS RECOMPENSAS FUTURAS VALEM EM RELAÇÃO ÀS IMEDIATAS. $\gamma = 0$ SIGNIFICA QUE APENAS A RECOMPENSA IMEDIATA IMPORTA; $\gamma = 1$ SIGNIFICA QUE TODAS AS RECOMPENSAS FUTURAS TÊM O MESMO PESO.



$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

FUNÇÕES DE VALOR

ESTIMAM O RETORNO ESPERADO A LONGO PRAZO - QUÃO BOM É ESTAR EM UM ESTADO OU TOMAR UMA AÇÃO SEGUINDO UMA POLÍTICA π .



VANTAGEM: $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$

EQUAÇÃO DE BELLMAN

UMA RELAÇÃO RECURSIVA QUE EXPRESSA O VALOR DE UM ESTADO COMO A RECOMPENSA IMEDIATA MAIS O VALOR DESCONTADO DO PRÓXIMO ESTADO.

$$V^\pi(s) = R(s) + \gamma \cdot V^\pi(s')$$

- $V^\pi(s)$ = VALOR DO ESTADO ATUAL
- $R(s)$ = RECOMPENSA IMEDIATA
- γ = FATOR DE DESCONTO
- $V^\pi(s')$ = VALOR DO PRÓXIMO ESTADO


EQUAÇÃO DE OTIMALIDADE (Q^*):

$$Q^*(s, a) = R(s, a) + \gamma \cdot \boxed{\max_{a'}} Q^*(s', a')$$

O OPERADOR $\boxed{\max_{a'}}$ ESCOLHE A AÇÃO FUTURA DE MAIOR VALOR, GARANTINDO A POLÍTICA ÓTIMA.

DILEMA EXPLORAÇÃO-EXPLOTAÇÃO



O AGENTE DEVE EQUILIBRAR EXPLORAR O AMBIENTE (DESCOBRIR NOVOS ESTADOS) E EXPLOTAR O CONHECIMENTO ATUAL (MAXIMIZAR RECOMPENSA IMEDIATA).



ABORDAGENS: COM MODELO VS. SEM MODELO



EM ABORDAGENS COM MODELO (MODEL-BASED), O AGENTE USA OU APRENDE UM MODELO DO AMBIENTE PARA SIMULAR FUTUROS E PLANEJAR AÇÕES. MÉTODOS SEM MODELO (MODEL-FREE) APRENDEM DIRETAMENTE POR TENTATIVA E ERRO, SEM CONHECER AS REGRAS INTERNAS DO AMBIENTE.

COM MODELO (MODEL-BASED)




APRENDIZADO: ON-POLICY VS. OFF-POLICY

NO APRENDIZADO ON-POLICY (EX: SARSA), O AGENTE APRENDE E AGE COM A MESMA POLÍTICA. NO OFF-POLICY (EX: Q-LEARNING, DQN), O AGENTE OTIMIZA UMA POLÍTICA ALVO ENQUANTO EXPLORA COM UMA POLÍTICA DIFERENTE, PODENDO REUTILIZAR EXPERIÊNCIAS PASSADAS DE UM REPLAY BUFFER.



ALGORITMOS DE RL



Q-LEARNING

UM ALGORITMO CLÁSSICO SEM MODELO QUE APRENDE A FUNÇÃO DE VALOR ÓTIMA $Q^*(s, a)$ DIRETAMENTE DA EXPERIÊNCIA, ATUALIZANDO UMA TABELA USANDO A EQUAÇÃO DE BELLMAN DE OTIMALIDADE.

Q-TABELA

	a_1	a_2	a_3
s_1	0.2	0.5	0.1
$s_2 \leftarrow$	0.8	0.3	0.6
s_3	0.1	0.7	0.4

$\uparrow$
 $\max_{a'}$

REGRA DE ATUALIZAÇÃO

$$Q(s, a) \leftarrow Q(s, a) + \alpha [R + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$


α : taxa de aprendizado γ : fator de desconto
 $\max_{a'}$: melhor ação futura no estado s'

REPLAY BUFFER

REPETIÇÃO DE EXPERIÊNCIA

PROBLEMA: TREINAR DIRETO NA SEQUÊNCIA $s_t, s_{t+1}, s_{t+2}, \dots$ FAZ A REDE VICIAR NO PADRÃO RECENTE E ESQUECER EXPERIÊNCIAS ANTERIORES, POIS AMOSTRAS CONSECUTIVAS SÃO ALTAMENTE CORRELACIONADAS.


SOLUÇÃO: GUARDAR AS ÚLTIMAS N TUPLAS (S, A, R, S') NUM BUFFER E SORTEAR UM MINI-BATCH ALEATÓRIO A CADA ATUALIZAÇÃO. AMOSTRAS DISTANTES NO TEMPO SÃO MISTURADAS $\Rightarrow$ GRADIENTES ESTÁVEIS E CADA EXPERIÊNCIA É REUTILIZADA VÁRIAS VEZES.



DQN

DEEP Q-NETWORK

ESTENDE O Q-LEARNING SUBSTITUINDO A Q-TABELA POR UMA REDE NEURAL $Q(s, a; \theta)$, PERMITINDO LIDAR COM ESPAÇOS DE ESTADOS CONTÍNUOS E DE ALTA DIMENSÃO (EX.: PIXELS DE JOGOS ATARI).




----- INOVAÇÕES DO DQN SOBRE O Q-LEARNING CLÁSSICO -----

- **REPLAY BUFFER:** armazena (s, a, r, s') e amostra aleatoriamente para quebrar correlações temporais.
- **REDE ALVO (θ^-):** segunda cópia da rede, congelada por K passos. O alvo $y = R + \gamma \max_{a'} Q(s', a'; \theta^-)$ usa θ^- em vez de θ , evitando que o alvo mude a cada passo e cause instabilidade no treinamento.

GRADIENTE DE POLÍTICA

REINFORCE

OTIMIZA DIRETAMENTE A POLÍTICA $\pi_\theta(a|s)$ AJUSTANDO θ (PESOS E VIESES DA REDE NEURAL) NA DIREÇÃO DO GRADIENTE DO RETORNO ESPERADO. NÃO PRECISA ESTIMAR $Q(s, a)$ (APROXIMADOR DE VALOR = REDE QUE APRENDE O QUANTO VALE CADA AÇÃO).




ATUALIZAÇÃO (REINFORCE)

$$\theta \leftarrow \theta + \alpha \cdot G_t \cdot \nabla_\theta \log \pi_\theta(a_t|s_t)$$

- Por que log? Não dá para derivar π_θ diretamente pela amostra. Usa-se $\nabla_\theta \pi = \pi \cdot \nabla_\theta \log \pi$ para reescrever o gradiente como uma esperança - estimável por Monte Carlo.
- G_t : soma de recompensas futuras descontadas. Se $G_t > 0$, θ é ajustado para aumentar $\pi_\theta(a_t|s_t)$; se $G_t < 0$, para diminuir.

ATOR-CRÍTICO

O ATOR APRENDE A POLÍTICA $\pi_{\theta}(a|s)$ ENQUANTO O CRÍTICO ESTIMA A FUNÇÃO DE VALOR $V_{\phi}(s)$. O CRÍTICO USA O ERRO TD $\delta = R_{t+1} + \gamma V_{\phi}(S_{t+1}) - V_{\phi}(S_t)$ PARA AVALIAR SE A AÇÃO FOI MELHOR OU PIOR DO QUE O ESPERADO, ENVIANDO ESSE SINAL PARA GUIAR A ATUALIZAÇÃO DO ATOR E REDUZIR A VARIÂNCIA DO APRENDIZADO.




- CRÍTICO: ESTIMA O RETORNO ESPERADO $V_{\phi}(S_t)$ PARA CALCULAR O ERRO TD (δ).

SE $\delta > 0$: AÇÃO LEVOU A UM ESTADO MELHOR QUE O ESPERADO $\rightarrow$ ATOR REFORÇA A AÇÃO.

SE $\delta < 0$: AÇÃO LEVOU A UM ESTADO PIOR QUE O ESPERADO $\rightarrow$ ATOR INIBE A AÇÃO.


SOFT ACTOR-CRITIC (SAC)

O SAC É UM ALGORITMO ATOR-CRÍTICO AVANÇADO *OFF-POLICY* QUE TREINA UMA POLÍTICA ESTOCÁSTICA. SUA PRINCIPAL INOVAÇÃO É ADICIONAR A ENTROPIA DA POLÍTICA À FUNÇÃO DE VALOR: AO MAXIMIZAR CONJUNTAMENTE RECOMPENSA E ENTROPIA, O SAC GARANTE ALTA EXPLORAÇÃO, ROBUSTEZ E EFICIÊNCIA DE DADOS.



SAC: ARQUITETURA E EFICIÊNCIA

O SAC USA DUAS REDES CRÍTICAS SEPARADAS (DOUBLE Q-LEARNING) PARA EVITAR SUPERESTIMAÇÃO, TOMANDO SEMPRE O VALOR MÍNIMO. O COEFICIENTE α É OTIMIZADO AUTOMATICAMENTE VIA GRADIENTE DURANTE O TREINO, ELIMINANDO A NECESSIDADE DE AJUSTE MANUAL DESTE HIPERPARÂMETRO.





FOFF: an energy-efficient task offloading in VEC-enabled vehicular networks using fuzzy TOPSIS

Antônio Sérgio de Sousa Vieira^{1,2} · Alisson Barbosa de Souza^{1,3} · Joaquim Celestino Júnior¹

Received: 19 February 2025 / Revised: 8 May 2025 / Accepted: 11 May 2025 / Published online: 19 September 2025
© The Author(s), under exclusive licence to Springer Science+Business Media, LLC, part of Springer Nature 2025

Abstract

In modern vehicular network environments, the demand for efficient data processing is crucial. However, this demand can exceed the computational capacity of the vehicles' On-Board Unit Interconnected (OBUI). One way to overcome these limitations is through edge devices with high computational capacity. Vehicular Edge Computing (VEC) facilitates the execution of these processing demands; however, latency remains a critical challenge. With advancements in 5G technology, research efforts have increasingly focused on determining whether tasks should be processed locally or offloaded to edge servers. Beyond latency considerations, energy consumption presents a significant concern for both OBUI and edge devices. This study introduces Fuzzy Offloading (FOFF), an innovative approach designed to balance these competing factors. Experiments show that FOFF reduces energy consumption and latency, achieving 72.11% energy savings and 0.61% lower processing time compared to the best greedy offloading approach considered. These results highlight FOFF's efficiency in vehicular environments.

Keywords Task offloading · Energy optimization · Fuzzy topsis · Vehicular network

FOFF vs. PROPOSTA: DIFERENÇAS FUNDAMENTAIS

Dimensão	FOFF [Vieira et al., 2025]	Proposta (SAC+Fuzzy-TOPSIS)
Decisão de offload	Fuzzy logic (regras estáticas)	SAC -- política estocástica aprendida
Papel do TOPSIS	Ranqueia candidatos para seleção	Comprime estado variável (N) em vetor 6D fixo
Adaptação ao ambiente	Não se adapta após implantação	Aprende continuamente via replay buffer
Robustez à mobilidade	Degradação sob alta densidade variável (visão míope)	Invariante à escala por design
Objetivo principal	Deadline + Eficiência energética	Deadline + Eficiência energética

⇒ O TOPSIS sai do papel de *seletor* (FOFF) para *compressor de estado* (proposta), habilitando um agente DRL com entrada de dimensão fixa e política adaptativa.



Deep learning approaches for computation offloading in edge computing: A critical review

Sapthagiri Miriyala¹ · Venkata Ramireddy Chirra¹

Received: 21 June 2025 / Accepted: 11 February 2026 / Published online: 24 February 2026
© The Author(s), under exclusive licence to Springer Science+Business Media, LLC, part of Springer Nature 2026

Abstract

The paradigm shift from centralized cloud computing to Multi-Access Edge Computing (MEC) has been necessitated by the exponential growth of the Internet of Things (IoT) and the stringent latency requirements of 5G/6G applications. However, the inherent dynamism of edge environments, characterized by fluctuating channel conditions, heterogeneous device capabilities, and finite energy budgets, renders traditional static optimization techniques insufficient. This survey provides a critical review of Deep Learning (DL) and Deep Reinforcement Learning (DRL) as pivotal enablers for autonomous computation offloading. This work systematically dissects the algorithmic trade-offs between Value-Based (e.g., DQN) and Policy-Gradient (e.g., PPO, SAC, A3C) architectures, evaluating their suitability for continuous control, multi-agent coordination, and resource-constrained inference. We further bridge the gap between theoretical algorithms and practical telecommunications deployment by mapping DRL strategies to European Telecommunications Standards Institute (ETSI) MEC specifications and Open Radio Access Network (O-RAN) architectural standards. The review analyzes the "optimization trade-offs" inherent in offloading, specifically the conflict between service immediacy (latency) and resource conservation (energy/security). Finally, we synthesize key challenges hindering large-scale adoption, including the need for lightweight "extreme edge" models, robustness against non-stationary environments, and privacy-preserving federated learning, thereby providing a rigorous roadmap for the evolution of self-optimizing, intelligent edge ecosystems.

Keywords Multi-Access Edge Computing · Deep Reinforcement Learning · Computation Offloading · Resource Allocation · Federated Learning · IoT

LACUNAS ATENDIDAS PELA PROPOSTA [Miriayala & Chirra, 2026]

#	Lacuna (Tabela 9, p. 20)	Como a proposta responde	Status
1	<i>Flat vectors</i> ignoram topologia variável (N nós) e relações estruturais entre dispositivos	TOPSIS comprime N candidatos em vetor 6D fixo -- invariante à escala	Sim
2	Políticas estáticas colapsam sob não-estacionariedade e alta mobilidade	SAC com entropia máxima + replay buffer: adaptação contínua sem retreino completo	Sim
3	Vulnerabilidade a perturbações adversariais nas observações de estado	Estado 6D normalizado via Fuzzy-TOPSIS atenua sensibilidade a outliers e ruído de medição	Parcial
4	Modelos leves para borda extrema (<50 MB, <100 MFLOPS)	MLP $6 \rightarrow 64 \rightarrow 64 \rightarrow 2$: ≈ 8 KB de pesos; inferência em microssegundos	Sim
5	<i>Continual learning</i> sem retreino ao mudar distribuição do ambiente	SAC <i>off-policy</i> + replay buffer: atualização incremental sem catastrophic forgetting	Sim

LACUNAS NÃO COBERTAS -- DIREÇÕES FUTURAS [Miriayala & Chirra, 2026]


#	Lacuna (Tabela 9, p. 20)	Posição da Proposta	Status
6	Benchmarks padronizados (ETSI MEC) para comparação reprodutível	Simulador próprio; migração ao NS-3 (módulo 5G-LENA) planejada	Próximo Passo
7	Otimização quântica híbrida (quantum-classical DRL)	Fora do escopo desta proposta	Não
8	Comunicação semântica integrada à decisão de offload	Fora do escopo desta proposta	Não
9	Digital Twin para treino seguro e transferência Sim-to-Real	Validação de alta fidelidade via NS-3 planejada como próximo passo	Próximo Passo

⇒ Atualmente a proposta cobre 4 de 9 lacunas completamente e 1 parcialmente, o próximo passo será integrar a lógica Fuzzy ao TOPSIS e atender as lacunas 6 e 7.

AMBIENTE DE SIMULAÇÃO


CRUZAMENTO VEICULAR ESTOCÁSTICO COM COMUNICAÇÃO V2I

(VEÍCULO-INFRAESTRUTURA) E V2V (VEÍCULO-VEÍCULO). INCORPORA MOBILIDADE DINÂMICA, CHEGADA ESTOCÁSTICA DE TAREFAS, ATRASOS DE PROPAGAÇÃO E LIMITAÇÕES DE PROCESSAMENTO (*THROTTLING*).



O PROBLEMA: DIMENSIONALIDADE VARIÁVEL EM VEC

O DESCARREGAMENTO EM REDES VEC LIDA COM ALTA MOBILIDADE: O NÚMERO DE NÓS CANDIDATOS MUDA A TODO INSTANTE. COMO REDES NEURASIS DE DRL EXIGEM ENTRADAS DE DIMENSÃO FIXA, AS SOLUÇÕES TRADICIONAIS FALHAM AO GENERALIZAR PARA DIFERENTES DENSIDADES SEM RETREINAMENTOS. O DESAFIO: CRIAR UMA REPRESENTAÇÃO DE ESTADO INVARIANTE À ESCALA.



FORMULAÇÃO DO PROBLEMA

O PROBLEMA É FORMULADO COMO UM POMDP. O OBJETIVO CENTRAL É MAXIMIZAR A TAXA DE TAREFAS CONCLUÍDAS DENTRO DO PRAZO, PONDERADA COM O CUSTO NORMALIZADO DE LATÊNCIA E ENERGIA.

$$\max_{\pi} J(\pi) = \underbrace{w_s \cdot \mathbb{E}_{\pi}[\mathbf{1}(\text{JCT}_i \leq D_i)]}_{\text{taxa de sucesso}} - \underbrace{w_c \cdot \mathbb{E}_{\pi} \left[\frac{1}{2} \left(\frac{\text{JCT}_i}{\text{JCT}_i^{\max}} + \frac{E_i}{E_i^{\text{ref}}} \right) \right]}_{\text{custo normalizado} \in [0,1]}$$

$$w_s = 0,60 > w_c = 0,40$$

$$\mathbf{1}(\text{JCT}_i \leq D_i)$$

Indicador de sucesso: 1 se a tarefa i concluiu dentro do prazo D_i

$$\text{JCT}_i / \text{JCT}_i^{\max}$$

Latência normalizada $\in [0,1]$ (pior caso por tarefa)

$$E_i / E_i^{\text{ref}}$$

Energia normalizada $\in [0,1]$ (pior caso por tarefa)


$$w_s > w_c$$

Violar prazos em segurança veicular é mais grave do que custo energético

RECOMPENSA *DEADLINE*-AWARE

$$r_i = \begin{cases} 1,0 - \frac{1}{4} \left(\frac{\widehat{\text{JCT}}_i}{D_i} + \frac{E_i}{E_i^{\max}} \right), & \widehat{\text{JCT}}_i \leq D_i \quad (\in [0,5, 1,0]) \\ -1,0 - \min \left(1,0, \frac{\widehat{\text{JCT}}_i - D_i}{D_i} \right), & \widehat{\text{JCT}}_i > D_i \quad (\in [-2,0, -1,0]) \end{cases}$$

$E_i^{\max} = \max(E_i^{\ell}, E_i^{\text{rsu}} \cdot \mathbf{1}_{\text{viável}}, E_i^{\text{v}2\text{v}} \cdot \mathbf{1}_{\text{viável}})$ - energia máxima entre os modos viáveis (por tarefa, por instante)



TOPSIS: CRITÉRIOS, ESCORE E ESTADO 6D

CRITÉRIOS DO TOPSIS

Crit.	Descrição	Peso
C_1	$\widehat{JCT}$ (latência estimada)	0,40
C_2	Energia total (J)	0,30
C_3	Distância física (m)	0,30

ESCORE DE PROXIMIDADE

$$C_i^* = \frac{d_i^-}{d_i^+ + d_i^-}$$

rank_1 = candidato de maior C_i^*

VETOR DE ESTADO $S_t \in \mathbb{R}^6$

$$S_t = \left[\Delta_{\text{obj}}, \frac{\widehat{JCT}_\ell}{D_i}, \frac{\widehat{JCT}_{r1}}{D_i}, \frac{|Q_{r1}|}{Q_{\max}}, \frac{|Q_\ell|}{Q_{\max}}, \frac{C_i}{C_{\max}} \right]$$

$$\Delta_{\text{obj}} = (\widehat{JCT}_\ell - \widehat{JCT}_{r1}) / D_i$$


> 0 : offload mais rápido < 0 : local mais rápido

$s_1 = \Delta_{\text{obj}}$	redução relativa de custo (offload vs. local)
$s_2 = \widehat{JCT}_\ell / D_i$	urgência local
$s_3 = \widehat{JCT}_{r1} / D_i$	urgência do offload
$s_4 = Q_{r1} / Q_{\max}$	congestion. do candidato
$s_5 = Q_\ell / Q_{\max}$	congestion. local
$s_6 = C_i / C_{\max}$	complexidade da tarefa

$$\text{modo}_t = \begin{cases} \text{LOCAL} & a_t = 0 \\ \text{rank}_1 \in \{\text{RSU}, \text{V2V}\} & a_t = 1 \end{cases}$$

ATOR SAC: REDE NEURAL MLP

ARQUITETURA $6 \rightarrow 64 \rightarrow 64 \rightarrow 2$ RELU + SOFTMAX




Param.	Descrição	Valor
η	Taxa de aprendizado (Adam)	3×10^{-4}
γ	Fator de desconto	0,99
α_{ent}	Coefficiente de entropia	0,10
$ B $	Tamanho do replay buffer	50 000
batch	Tamanho do mini-batch	1 024

ALGORITMO 1 - TOPSIS (RANQUEAMENTO MULTICRITÉRIO)

```
Entrada: Matriz de decisão  $\mathbf{X} \in \mathbb{R}^{m \times n}$ ; vetor de pesos  $\mathbf{w}$   
Saída : Vetor de proximidade  $\mathbf{C}^*$  (alternativas ranqueadas)  
// Passos 1-2: Normalização  $L_2$  por coluna e ponderação  
1 for  $j = 1$  to  $n$  do  
2   for  $i = 1$  to  $m$  do  
3      $r_{ij} \leftarrow x_{ij} / \sqrt{\sum_{k=1}^m x_{kj}^2}$   
4      $v_{ij} \leftarrow w_j \cdot r_{ij}$   
5   end  
   // Passo 3: Soluções ideal positiva  $A^+$  e negativa  $A^-$   
6   if critério  $j$  é de custo then  
7      $A_j^+ \leftarrow \min_i v_{ij}; \quad A_j^- \leftarrow \max_i v_{ij}$   
8   else  
9      $A_j^+ \leftarrow \max_i v_{ij}; \quad A_j^- \leftarrow \min_i v_{ij}$   
10  end  
11 end  
   // Passos 4-5: Distâncias  $L_2$  (Euclidianas) e coeficiente de  
   proximidade  
12 for  $i = 1$  to  $m$  do  
13    $d_i^+ \leftarrow \sqrt{\sum_{j=1}^n (v_{ij} - A_j^+)^2}; \quad d_i^- \leftarrow \sqrt{\sum_{j=1}^n (v_{ij} - A_j^-)^2}$   
14    $C_i^* \leftarrow d_i^- / (d_i^+ + d_i^-)$   
15 end  
16 return Ordenação decrescente de  $\mathbf{C}^*$ 
```


TOPSIS: REPRESENTAÇÃO GEOMÉTRICA DO RANQUEAMENTO

Critério 2



PRIMEIRO PASSO DA PROPOSTA: PIPELINE SAC-TOPSIS

DIVISÃO DE RESPONSABILIDADES: O TOPSIS RESPONDE “QUAL CANDIDATO?” (ELIMINA A VARIABILIDADE DIMENSIONAL); O SAC RESPONDE “DESCARREGAR?” (DECISÃO BINÁRIA, APRENDIDA COM ENTROPIA MÁXIMA E REPLAY BUFFER).



ALGORITMO 2 - SAC-TOPSIS (INFERÊNCIA)

Entrada: Tarefa i : $C_i, D_i, \mathbf{x}_i$;
 N candidatos $\mathcal{M}$;
MLP π_θ ;
 $Q_\ell, Q_{r1}, Q_{\max}, C_{\max}$
Saída : Ação $a_t \in \{0, 1\}$: local ou offload para rank₁
// Passo 1 - Matriz de decisão ($N \times 3$)

- 1 **for** $k = 1$ **to** N **do**
- 2 | $x_{k1} \leftarrow \widehat{\text{JCT}}(m_k); \quad x_{k2} \leftarrow E(m_k); \quad x_{k3} \leftarrow \|\mathbf{x}_i - \mathbf{x}_{m_k}\|$
- 3 **end**
// Passo 2 - Ranqueamento via Algoritmo 1 (todos critérios de custo)
- 4 $\mathbf{w} \leftarrow [0,40; 0,30; 0,30]; \quad \mathbf{C}^* \leftarrow \text{Algoritmo 1}(\mathbf{X}, \mathbf{w}); \quad \text{rank}_1 \leftarrow \arg \max_k C_k^*$
// Passo 3 - Estado compacto 6D
- 5 $\Delta_{\text{obj}} \leftarrow (\widehat{\text{JCT}}_\ell - \widehat{\text{JCT}}_{r1}) / D_i$
- 6 $\mathbf{S}_t \leftarrow [\Delta_{\text{obj}}, \widehat{\text{JCT}}_\ell / D_i, \widehat{\text{JCT}}_{r1} / D_i, Q_{r1} / Q_{\max}, Q_\ell / Q_{\max}, C_i / C_{\max}]$
// Passo 4 - Inferência e decisão
- 7 $a_t \leftarrow \arg \max_a \pi_\theta(a | \mathbf{S}_t)$
- 8 **if** $a_t = 0$ **then**
- 9 | **return** LOCAL
- 10 **else**
- 11 | **return** OFFLOAD para rank₁
- 12 **end**

ESTUDO DE ABLAÇÃO: DESIGN EXPERIMENTAL

CADA VARIANTE REMOVE OU SUBSTITUI UM ÚNICO COMPONENTE DA PROPOSTA COMPLETA. PERMITE QUANTIFICAR A CONTRIBUIÇÃO CAUSAL ISOLADA DE CADA DECISÃO DE DESIGN: ESPAÇO DE ESTADO, ESPAÇO DE AÇÃO, FUNÇÃO DE RECOMPENSA E PAPEL DO TOPSIS.

POLÍTICA	ESTADO	AÇÃO	RECOMPENSA	TOPSIS
SAC-BASE	11D (bruto)	3 classes	WSM	--
SAC-A1	11D (bruto)	binária	WSM	--
SAC-S1	6D (manual)	3 classes	WSM	--
SAC-R1	11D (bruto)	3 classes	Deadline-aware	--
SAC-T1	6D (TOPSIS)	3 classes	Deadline-aware	Feature
SAC-TOPSIS	6D (TOPSIS)	binária	Deadline-aware	Decisão

3 classes: $a_t \in \{\text{LOCAL}, \text{RSU}, \text{v2v}\}$ Binária: $a_t \in \{\text{LOCAL}, \text{OFFLOAD} \rightarrow \text{rank}_1\}$

WSM: $r \in [-1, 1]$ proporcional ao custo (JCT + energia + fila). Problema: não penaliza violação de prazo - tarefa atrasada com custo baixo recebe recompensa positiva.


DEADLINE-AWARE: dois regimes separados por lacuna de 1,5 unidades:

- $\text{JCT} \leq D_i$ (sucesso): $r \in [0,5; 1,0]$ - quanto menor o custo, maior a recompensa.
- $\text{JCT} > D_i$ (falha): $r \in [-2,0; -1,0]$ - penalidade cresce com o atraso.

Efeito: cumprir o prazo é *sempre* melhor que qualquer falha, independente do custo.

ESTUDO DE ABLAÇÃO: DECOMPOSIÇÃO CAUSAL

POLÍTICA	TAXA DEADLINE (%)	JCT (s)	ENERGIA (J)	Δ pp
SAC-BASE	4,6	57,1	2422	--
SAC-A1	39,2	13,7	2106	+34,6
SAC-S1	28,8	39,3	2028	+24,2
SAC-R1	38,4	13,4	3153	+33,8
SAC-T1	33,1	11,5	2612	+28,5
SAC-TOPSIS	45,29	6,6	2582	+40,7



$$\Delta_{\text{estado}} > \Delta_{\text{TOPSIS-decisão}} > \Delta_{\text{reward+feature}} \gg \Delta_{\text{ação-binária}}$$

ESTUDO DE ABLAÇÃO: ANÁLISE DOS ACHADOS

ACHADO 1 - AÇÃO BINÁRIA ESTÁTICA JÁ SUPERA O BASELINE

SAC-A1 (11D, binária, regra $VEC \succ V2V$): 39,2% $\rightarrow$ +34,6 pp sobre SAC-Base (4,6%).

SIMPLES REDUÇÃO DO ESPAÇO DE BUSCA TEM EFEITO EXPRESSIVO.

PORÉM NÃO ALCANÇA SAC-TOPSIS (45,29%): A REGRA ESTATICA IGNORA CONDIÇÕES DINÂMICAS DE FILA E DISTÂNCIA NO MOMENTO DA DECISÃO.

ACHADO 2 - TOPSIS COMO DECISÃO VALE $3\times$ MAIS QUE COMO FEATURE

SAC-T1 (TOPSIS como feature): +4,3 pp sobre SAC-S1.

SAC-TOPSIS (TOPSIS como prior de destino): +12,2 pp sobre SAC-T1.

EFICÁCIA DO TOPSIS É QUASE $3\times$ MAIOR QUANDO ELE ASSUME O CONTROLE DO DESTINO DO QUE QUANDO APENAS INFORMA O ESTADO DO AGENTE.

ACHADO 3 - GANHO EM LATÊNCIA: $8,6\times$ MENOR

JCT MÉDIO SAC-TOPSIS: 6,6 s $\times$ SAC-BASE: 57,1 s.

A COMBINAÇÃO TOPSIS + ESTADO COMPACTO + REWARD DEADLINE-AWARE

PRODUZ NÃO SÓ MAIS TAREFAS NO PRAZO, MAS LATÊNCIAS SUBSTANCIALMENTE MENORES.

HIERARQUIA: $\Delta_{\text{estado}} > \Delta_{\text{TOPSIS-decisão}} > \Delta_{\text{reward+feature}} \gg \Delta_{\text{ação-binária-estática}}$

AValiação Comparativa - Posições 1-12

658 CENÁRIOS V2X • ORDENADO POR SWQ DECRESCENTE • ★ = USA TOPSIS

$$SWQ(\pi) = \underbrace{\hat{\tau}(\pi)}_{\text{taxa de sucesso}} \times \underbrace{\frac{1}{|S|} \sum_{j \in S} \frac{D_j - JCT_j}{D_j}}_{\text{folga norm. média — só tarefas que cumpriram o prazo}}$$

⇒ política boa = cumpre prazo frequentemente e com margem

#	POLÍTICA	TAXA%	SWQ	JCT(s)	E(J)	CATEG.
1	sac-topsis★	45,29	0,1484	6,5	25,8	RL+TOPSIS
2	ppo-topsis★	42,75	0,1426	5,9	21,3	RL+TOPSIS
3	ppo-base	42,42	0,1418	6,0	24,4	RL-Base
4	ppo-topsis-compact★	42,42	0,1418	6,0	24,4	RL+TOPSIS
5	td3-base	42,42	0,1418	6,0	24,4	RL-Base
6	a2c-topsis★	42,42	0,1418	6,0	24,4	RL+TOPSIS
7	td3-topsis★	44,00	0,1388	3,7	23,0	RL+TOPSIS
8	sac-topsis-9d★	42,91	0,1386	5,9	21,0	RL+TOPSIS
9	sac-topsis-manhattan★	41,75	0,1385	11,8	23,7	RL+TOPSIS
10	sac-t1★	33,06	0,1270	11,5	26,1	RL+TOPSIS
11	greedy-unfair	41,38	0,1262	5,6	7,4	Heurística
12	sac-a1	39,21	0,1256	13,7	21,1	RL-Base

O SAC-TOPSIS LIDERA COM SWQ 0,1484. OS ALGORITMOS PPO, TD3 E A2C

CONVERGEM PARA 100% LOCAL (SWQ $\approx$ 0,1418). O GREEDY-UNFAIR COM

CONHECIMENTO PERFEITO DO ESTADO DA SIMULAÇÃO FICA ABAIXO DO SAC-TOPSIS

(0,1262).

AVALIAÇÃO COMPARATIVA - POSIÇÕES 13-25

658 CENÁRIOS V2X • ORDENADO POR SWQ DECRESCENTE • ★ = USA TOPSIS


#	POLÍTICA	TAXA%	SWQ	JCT(s)	E(J)	CATEG.
13	sac-r1	38,36	0,1223	13,4	31,4	RL-Base
14	sac-s1	28,81	0,1122	39,3	20,3	RL-Base
15	gini	35,34	0,1057	3,5	39,4	Heurística
16	dqn-topsis★	26,02	0,0997	21,7	24,0	RL+TOPSIS
17	jain	32,64	0,0973	3,6	39,3	Heurística
18	random	30,13	0,0950	17,9	27,3	Heurística
19	roundrobin	28,61	0,0905	17,9	31,1	Heurística
20	greedy	29,05	0,0823	29,3	6,2	Heurística
21	a2c-base	21,85	0,0772	13,7	48,9	RL-Base
22	dqn-base	22,15	0,0686	13,6	44,4	RL-Base
23	greedy-fair	20,65	0,0528	40,8	5,6	Heurística
24	sac-base	4,58	0,0119	57,1	24,2	RL-Base
25	rsu	1,93	0,0030	144,2	4,8	Heurística

O SAC-BASE (4,58%) COLAPSA POR USAR ESTADO 11D BRUTO SEM TOPSIS: 94,9% DAS AÇÕES SÃO V2V SEM CRITÉRIO. O DQN-TOPSIS (25,9%) MOSTRA QUE O TOPSIS TAMBÉM AJUDA ALGORITMOS BASEADOS EM VALOR, MAS EM MENOR ESCALA QUE COM O SAC.

O IMPACTO DO TOPSIS NOS ALGORITMOS DRL


O TOPSIS ATUA COMO PRECONDICIONADOR AGNÓSTICO AO ALGORITMO. ACOPLADO AO A2C: +84% EM SWQ. AO DQN: +45%. AO TD3: JCT REDUZIDO EM 44,5%. AO SAC: +1147% (4,58% → 45,29%).

COMPARAÇÃO MAIS JUSTA: SAC-T1 (TOPSIS COMO FEATURE, 3 CLASSES) → SAC-TOPSIS (TOPSIS COMO DECISÃO, BINÁRIA): +12,3 PP, +16,8% SWQ. ISOLANDO O EFEITO DE DELEGAR O DESTINO AO TOPSIS.



PRÓXIMOS PASSOS: FUZZY-TOPSIS E NS-3

O AMBIENTE VEICULAR REAL É CAÓTICO: ESTIMATIVAS DE CANAL CHEGAM COM ATRASO E FILAS SOFREM FLUTUAÇÕES RÁPIDAS. O TOPSIS SERÁ SUBSTITUÍDO PELO FUZZY-TOPSIS: MODELANDO MEDIÇÕES COMO NÚMEROS FUZZY TRIANGULARES (TFNs), A ARQUITETURA ABSORVERÁ INCERTEZA LINGUÍSTICA, EVITANDO INVERSÕES INSTÁVEIS DE RANQUEAMENTO. O MODELO FINAL SAC-FUZZY-TOPSIS SERÁ VALIDADO NO SIMULADOR NS-3 (MÓDULO 5G-LENA), GARANTINDO ALTA FIDELIDADE FÍSICA AOS PADRÕES 3GPP.



ROBUSTEZ SOB INCERTEZA → FIDELIDADE FÍSICA AOS PADRÕES 3GPP