

Representação de Estado Invariante à Escala e Aprendizado por Reforço Profundo de Máxima Entropia para Descarregamento de Tarefas em Computação de Borda Veicular

Antônio Sérgio de Sousa Vieira^{1,2*}, Alisson Barbosa de Souza^{1,3} and Joaquim Celestino Júnior¹

^{1*}Grupo de Redes e Sistemas Inteligentes (INETSYS), Universidade Estadual do Ceará, Fortaleza, Brasil.

²Instituto Federal de Educação, Ciência e Tecnologia, Itapipoca, Brasil.

³Universidade Federal do Ceará, Quixadá, Brasil.

*Corresponding author(s). E-mail(s): sergio.vieira@ifce.edu.br;
Contributing authors: alisson@ufc.br; joaquim.celestino@uece.br;

Resumo

O descarregamento de tarefas em redes de Computação de Borda Veicular (VEC) é um mecanismo crítico para satisfazer as rigorosas restrições de latência e energia de aplicações autônomas avançadas. A alta mobilidade dos veículos cria um ambiente no qual o número de servidores de borda e vizinhos disponíveis muda continuamente, tornando o espaço de observação dimensionalmente variável. Essa variabilidade impede que agentes padrão de Aprendizado por Reforço Profundo (DRL) generalizem entre diferentes densidades veiculares sem retreinamento custoso. Para enfrentar esse desafio, este artigo propõe o **SAC-TOPSIS**, uma arquitetura híbrida de tomada de decisão que integra a Técnica de Ordenação por Preferência à Similaridade com a Solução Ideal (Técnica de Ordenação por Preferência à Similaridade com a Solução Ideal (TOPSIS)) ao algoritmo Soft Actor-Critic (SAC). O módulo TOPSIS avalia cada nó candidato ao descarregamento, caracterizado por Tempo de Conclusão de Tarefa (JCT), consumo de energia e distância física, usando distâncias L_1 -Manhattan com pesos **[0,4; 0,3; 0,3]**, e comprime a observação de tamanho variável em um vetor de estado fixo de 6 dimensões, invariante à escala. Um agente SAC recebe essa representação compacta e aprende uma política binária: executar localmente ou descarregar para o candidato melhor ranqueado. A regularização por entropia impede que a política colapse em modos puramente locais ou puramente de descarregamento. Simulações extensivas em 601 cenários heterogêneos Vehicle-to-Everything (V2X) e 5G demonstram que a integração do TOPSIS melhora consistentemente todas as famílias de DRL testadas: SAC melhora de **4,47%** para **44,36%** (+**39,9** pp), Twin Delayed DDPG (TD3) de **41,62%** para **43,01%** (+**1,4** pp) e Proximal Policy Optimization (PPO) de **41,61%** para **41,95%** (+**0,3** pp) na taxa de cumprimento de prazo. Entre todas as políticas avaliadas, o SAC-TOPSIS alcança a maior taxa de cumprimento (**44,36%**) e o maior índice de Qualidade Ponderada pelo Sucesso (SWQ) (**0,1450**). Fundamentalmente, o modelo é treinado em um único regime de densidade e generaliza zero-shot para densidades veiculares inéditas de 10 a 30 tasks/s.

Keywords: Descarregamento de tarefas, Computação de Borda Veicular, Soft Actor-Critic, TOPSIS, Compressão de estado multicritério, Generalização zero-shot

1 Introdução

A evolução das redes de comunicação veicular é marcada por uma transição clara entre paradigmas tecnológicos. Inicialmente, o foco concentrava-se nas Redes Veiculares *Ad hoc* (VANETs), que priorizavam a conectividade direta entre veículos, mas impunham desafios rigorosos de latência e conectividade devido à alta mobilidade dos nós [1]. Com o amadurecimento da Internet das Coisas (IoT) e a expansão de sensores embarcados na infraestrutura urbana, iniciou-se um processo de convergência que resultou no ecossistema da *Internet of Vehicles* (IoV), uma rede heterogênea de grande escala que integra veículos, infraestrutura, pedestres e a nuvem [1], viabilizando o Sistema de Transporte Inteligente (ITS) verdadeiramente autônomo e conectado. Esse ecossistema impõe às aplicações veiculares exigências simultâneas de eficiência, confiabilidade e segurança [2].

A viabilização da IoV depende da maturidade das tecnologias de rádio. O marco histórico inicial ocorreu com a alocação de 75 MHz na banda de 5.9 GHz para o padrão *Dedicated Short-Range Communications* (DSRC), que consolidou os parâmetros fundamentais para comunicação Vehicle-to-Vehicle (V2V) e Vehicle-to-Infrastructure (V2I) nas primeiras VANETs [3]. A partir desse legado, a evolução ramificou-se em dois eixos. O primeiro, o IEEE 802.11bd (*Next-Generation V2X*), estendeu o IEEE 802.11p incorporando robustez contra desvanecimento rápido e suporte a velocidades de até 250 km h^{-1} [4]. O segundo representa uma mudança de paradigma, pois as limitações do DSRC em escalabilidade e custo de implantação impulsionaram o desenvolvimento do *Cellular V2X* (C-V2X) pelo 3GPP [5], que evoluiu para o 5G NR-V2X com as interfaces Uu (V2I/Vehicle-to-Network - V2N) e *Sidelink* PC5 (V2V/Vehicle-to-Pedestrian - V2P) [6]. Sob perspectiva regulatória, a disputa foi amplamente resolvida, e a *Federal Communications Commission* (FCC) estabeleceu o C-V2X como padrão obrigatório para segurança ITS, com descontinuação oficial do DSRC em dezembro de 2026 [7].

A Computação de Borda Móvel (MEC) e sua especialização veicular, a VEC, viabilizam o funcionamento de aplicações sensíveis à latência posicionando recursos computacionais próximos à rede de acesso por rádio [8]. Veículos podem descarregar tarefas computacionalmente intensivas a servidores de borda (VEC) via 5G C-V2X ou a veículos vizinhos por enlace direto V2V, reduzindo drasticamente o tempo de resposta e o consumo de energia a bordo [9, 10].

Em ambientes veiculares, as capacidades computacionais das OBUs geralmente são heterogêneas, já que veículos equipados com unidades de processamento poderosas (Graphics Processing Units - GPUs, ? NPUs) podem temporariamente dispor de capacidade ociosa para auxiliar veículos com capacidades computacionais modestas [11]. Veículos com alta capacidade de processamento podem, portanto, auxiliar nós com restrições, melhorando a Qualidade de Serviço (QoS) de todo o ITS [12]. Entretanto, explorar esse potencial exige políticas de descarregamento que estejam cientes da topologia dinâmica da rede e que possam traçar estratégias que levem em conta múltiplos critérios em tempo real.

Cenários de avaliação simplificados, com número fixo de veículos, distribuições de tarefas uniformes e modelos de canal idealizados, não capturam o alto dinamismo das redes veiculares reais [13]. Políticas avaliadas nesses ambientes tendem a degradar acentuadamente quando a densidade veicular ou o regime de tráfego muda [13], revelando uma lacuna crítica entre benchmarks sintéticos e ambientes operacionais reais.

O descarregamento de tarefas é fundamentalmente um problema de otimização multiobjetivo. Heurísticas baseadas em regras lógicas temporais de Tomada de Decisão Multicritério (MCDM), como estratégias gulosas, são amplamente utilizadas por sua simplicidade [14], mas avaliam apenas o instantâneo atual da rede e são incapazes de antecipar saturação de filas ou chegadas futuras de tarefas. Meta-heurísticas (algoritmos genéticos, otimização por enxame de partículas, colônia de formigas) oferecem garantias mais sólidas de busca global e têm sido aplicadas ao descarregamento

estático [15, 16, 17], porém são fundamentalmente inadequadas para ambientes veiculares, pois sua busca baseada em população exige dezenas a centenas de avaliações de aptidão por instante de decisão, incompatível com prazos sub-segundo; devem ser reiniciadas do zero a cada mudança de topologia; e sua complexidade de inicialização cresce com o tamanho da rede.

O DRL é uma solução natural para o descarregamento de tarefas porque aprende uma política, um mapeamento de observações a ações, que considera implicitamente consequências futuras, não apenas o estado atual [9, 18]. Diferentemente de heurísticas e meta-heurísticas, um agente DRL pode explorar correlações temporais nos padrões de tráfego e na dinâmica das filas aprendidas a partir da experiência. Não obstante, arquiteturas DRL padrão compartilham uma fraqueza crítica, pois exigem retreinamento sempre que o cenário operacional muda [13], que identifica como desafio aberto a robustez a ambientes não-estacionários. Como a entrada da rede neural é um vetor de tamanho fixo, qualquer alteração no número de nós candidatos ao descarregamento, causada por veículos entrando ou saindo do alcance de comunicação, invalida o modelo treinado [2]. O preenchimento com zeros de candidatos ausentes é um contorno comum, mas introduz entradas espúrias que desestabilizam o aprendizado e reduzem a capacidade de generalização da política [13].

Em trabalho anterior, propusemos o FOFF [19], um framework Fuzzy-TOPSIS que ranqueia o servidor de borda (VEC) e veículos vizinhos em cenários VEC estáticos usando pesos linguísticos de critérios para tratar incertezas. O FOFF demonstrou que métodos multicritério podem alcançar forte eficiência energética e QoS sem qualquer fase de treinamento. Sua limitação é precisamente a falta de adaptação, visto que o Fuzzy-TOPSIS seleciona o melhor candidato por uma regra de pontuação fixa e não pode melhorar com a experiência ou ajustar-se a tráfego não estacionário. Com base nesses aprendizados, propomos o **SAC-TOPSIS**, uma arquitetura híbrida que delega a avaliação multicritério de candidatos ao TOPSIS e a otimização de política de longo prazo ao algoritmo SAC, combinando a otimalidade local do MCDM com a capacidade prospectiva do DRL.

As principais contribuições deste artigo são:

1. **Cenário de avaliação desafiador e realista.** Avaliamos todas as políticas em 601 cenários VEC heterogêneos cobrindo cinco regimes de densidade veicular (10–30 tasks/s), com modelos de canal 5G e V2V realistas, frequências de On-Board Unit (OBU) heterogêneas e prazos por tarefa extraídos de uma distribuição contínua, abordando diretamente a lacuna de cenários simplificados apontada por [13].
2. **Representação de estado invariante à escala.** O TOPSIS comprime o conjunto de candidatos de tamanho variável em um vetor fixo de 6D cujos componentes são razões normalizadas e diferenças relativas, tornando-o válido independentemente do número de candidatos disponíveis. Essa representação permite generalização zero-shot, um modelo treinado em um regime de densidade transfere-se diretamente para regimes inéditos sem retreinamento.
3. **Arquitetura de decisão de baixa complexidade.** Ao reduzir o espaço de ações a um único bit (local vs. melhor descarregamento), o agente evita crescimento exponencial do espaço de ações e executa inferência em $O(1)$ passagens diretas de rede neural por tarefa, adequado para implantação embarcada em tempo real.
4. **Modelagem de recompensa fundamentada.** A função de recompensa ciente do prazo fornece um sinal de gradiente contínuo em ambos os regimes de sucesso e falha, evitando esparsidade de recompensa e ensinando o agente a minimizar o atraso em vez de meramente evitá-lo.
5. **Horizontes de decisão complementares.** O TOPSIS fornece a melhor solução local dadas as condições atuais da rede; o SAC aprende a melhor política de longo prazo por meio da experiência acumulada. A combinação produz resultados que nenhum componente isolado consegue alcançar.

Avaliado em 601 cenários, o SAC-TOPSIS alcança taxa de cumprimento de prazo de 44,36% e SWQ de 0,1450, o melhor entre todas as linhas de base DRL e heurísticas, enquanto o SAC-Base com estado bruto alcança apenas 4,47% com o mesmo orçamento de treinamento.

O restante do artigo está estruturado da seguinte forma. A Seção 2 revisa trabalhos relacionados. A Seção 3 formaliza o modelo de sistema

e o objetivo de otimização. A Seção 4 descreve em detalhe a arquitetura SAC-TOPSIS. A Seção 5 apresenta a avaliação experimental. A Seção 6 conclui o artigo.

2 Trabalhos Relacionados

A otimização do descarregamento de tarefas em redes veiculares tem sido tradicionalmente abordada como um compromisso multiobjetivo entre o JCT e o consumo de energia da rede [20, 10]. Trabalhos iniciais buscaram equilibrar essas métricas por meio de métodos determinísticos baseados em MCDM. O framework FOFF [19], por exemplo, aplicou a técnica Fuzzy-TOPSIS para ranquear servidores de borda baseando-se em suas capacidades instantâneas, obtendo economias significativas de energia sem a necessidade de uma fase de treinamento prévio. Contudo, modelos fundamentados exclusivamente em regras lógicas ou avaliações heurísticas instantâneas falham diante de cenários veiculares não estacionários, já que não conseguem antecipar flutuações nas dinâmicas de fila ou aprender com o histórico contínuo de desempenho. Para superar essa rigidez adaptativa, a comunidade passou a investigar abordagens híbridas que combinam filtros quantitativos com estratégias de aprendizado de máquina, sendo essa uma ramificação ativa na literatura contemporânea [2].

Com o amadurecimento das arquiteturas de aprendizado, o DRL ganhou tração substancial devido à sua capacidade inata de adaptação online em ambientes de decisão markovianos. Dentro do escopo de alocação veicular, redes Q Profundas (Deep Q-Network (DQN)) e suas variantes de vantagem são comumente aplicadas aos problemas de seleção com espaços de ação discretos [21?]. Em contrapartida, configurações contínuas e de alta dimensionalidade exigem arquiteturas baseadas no paradigma ator-crítico, como PPO, Deep Deterministic Policy Gradient (DDPG) e TD3 [22?]. Apesar de estabelecerem o estado da arte em cenários controlados, os métodos atuais de DRL enfrentam desafios consideráveis na transição para o mundo real. Uma limitação estrutural amplamente difundida é a dependência de um espaço de observação com tamanho rigorosamente fixo, pois a grande maioria dos modelos utiliza preenchimento com zeros (zero-padding) ou truncamento para adequar ambientes com número variável de candidatos [13]. Essa prática de vetorização plana

obriga as redes neurais a aprenderem artefatos espúrios e ruídos decorrentes da quebra de simetria geométrica das entradas, degradando drasticamente o desempenho de generalização e impedindo a adaptação zero-shot perante variações de densidade do tráfego.

Algoritmos off-policy com máximo de entropia, como o SAC, mitigam parte desse desafio oferecendo uma exploração mais robusta e superior eficiência de amostragem em relação a métodos on-policy convencionais. Porém, mesmo modelos de alta capacidade permanecem amplamente suscetíveis à instabilidade temporal e ao colapso de representação quando submetidos a descrições de estado mal formuladas ou pouco informativas [23].

Na tentativa de fortalecer a representação do ambiente, trabalhos recentes acoplaram pré-processamento por métodos MCDM às decisões de DRL, mas quase invariavelmente tratam a filtragem multicritério como um elemento de pós-processamento desenvolvido para ranquear conjuntos finitos de ações já emitidas pelo agente. O SAC-TOPSIS difere substancialmente dessas abordagens, uma vez que consolida a técnica TOPSIS internamente na borda de observação, agindo estritamente como um módulo de engenharia de estado. A saída computada por esse módulo não dita a decisão final, mas condensa as características locais em uma codificação de estado contínua estritamente compacta (vetor 6D) e perfeitamente invariante à escala, eliminando a dependência do famigerado preenchimento com zeros e extinguindo qualquer suposição de topologia rígida. Fundamentalmente, o processo de compressão estabelecido pelo TOPSIS possui natureza agnóstica ao algoritmo de controle, já que nossa avaliação experimental atesta que o emparelhamento desse espaço estruturado com os algoritmos SAC, TD3 e PPO produz ganhos diretos e consistentes sobre suas variantes tradicionais alimentadas com observações brutas. Isso valida a tese central de que a engenharia composicional do estado elaborada via TOPSIS, e não a estrutura particular da política DRL, atua como o principal motor impulsionador da capacidade de generalização espacial apresentada pelo agente inteligente.

3 Modelo de Sistema e Formulação do Problema

3.1 Modelo de Rede

Consideramos um ambiente VEC heterogêneo com um veículo cliente v_0 , um servidor Roadside Unit (RSU) acessível via 5G C-V2X (largura de banda de uplink B_{V2I}) e um conjunto variante no tempo $\mathcal{V}(t)$ de veículos vizinhos acessíveis via sidelink V2V (largura de banda B_{V2V}). O RSU possui uma fila de serviço de capacidade Q_{RSU} ; cada veículo $v \in \mathcal{V}(t)$ possui uma fila local Q_v .

3.2 Modelo de Tarefa

Cada tarefa $\tau_j = (C_j, D_j, s_j)$ é caracterizada por sua complexidade de CPU C_j (ciclos), prazo D_j (segundos) e tamanho de dados de entrada s_j (bits). Três modos de execução estão disponíveis:

- **Local** ($m = 0$): executado em v_0 com frequência f_{loc} .
- **RSU** ($m = 1$): carregado ao RSU e executado em f_{RSU} .
- **V2V** ($m = 2$): descarregado a um veículo vizinho $v^* \in \mathcal{V}(t)$.

Um modo m é viável se o par correspondente estiver dentro do alcance de comunicação e sua fila não estiver cheia.

3.3 Modelo de Latência

O Tempo de Conclusão de Tarefa do modo m para a tarefa τ_j é

$$JCT_j^{(m)} = t_j^{tx,(m)} + t_j^{fila,(m)} + \frac{C_j}{f^{(m)}}, \quad (1)$$

onde $t_j^{tx,(m)}$ é o tempo de transmissão (upload) e $t_j^{fila,(m)}$ é o tempo de espera residual na fila do destino, estimado como o tempo de execução restante das tarefas já na fila.

3.4 Modelo de Energia

A energia consumida pelo modo m é

$$E_j^{(m)} = \alpha_c^{(m)} [V^{(m)}]^2 C_j + P_{TX}^{(m)} t_j^{tx,(m)}, \quad (2)$$

onde $\alpha_c^{(m)}$ é a capacitância do chip, $V^{(m)}$ é a tensão de alimentação na frequência $f^{(m)}$ e $P_{TX}^{(m)}$

SAC-TOPSIS Architecture: TOPSIS State Compression + Maximum-Entropy Policy




Figura 1 Arquitetura SAC-TOPSIS. O TOPSIS comprime o conjunto de candidatos de tamanho variável em um vetor de estado fixo 6D invariante à escala. O SAC aprende uma política binária (local vs. melhor descarregamento) sobre essa representação com regularização de máxima entropia.

é a potência de transmissão. Para o modo local, o termo de transmissão é nulo.

3.5 Objetivo de Otimização

A contribuição de QoS por tarefa é

$$\Phi_j = \alpha JCT_j + \beta E_j + \gamma \mathbf{1}[JCT_j > D_j] JCT_j, \quad (3)$$

com $\alpha = \beta = 0,5$ e coeficiente de penalidade por violação de prazo $\gamma = 0,015$. O objetivo do sistema é minimizar $\sum_j \Phi_j$ maximizando a taxa de cumprimento de prazo $\hat{\tau} = |\{j : JCT_j \leq D_j\}|/N$.

4 A Arquitetura SAC-TOPSIS

A Figura 1 ilustra a arquitetura completa. A cada instante de decisão, o módulo TOPSIS processa as informações multicritério sobre todos os candidatos viáveis e produz o vetor de estado 6D que é passado ao agente SAC.

4.1 Compressão de Estado Baseada em TOPSIS

Matriz de decisão.

Para a tarefa τ_j , construímos uma matriz de decisão $\mathbf{X} \in \mathbb{R}_{\geq 0}^{3 \times 3}$ cujas linhas correspondem aos três modos candidatos (local, RSU, V2V) e cujas

colunas são os três critérios de custo:

$$\mathbf{X} = \begin{bmatrix} \text{JCT}_j^{(0)} & E_j^{(0)} & 0 \\ \text{JCT}_j^{(1)} & E_j^{(1)} & d_{\text{RSU}} \\ \text{JCT}_j^{(2)} & E_j^{(2)} & d_{\text{V2V}} \end{bmatrix}, \quad (4)$$

onde d_{RSU} e d_{V2V} são as distâncias euclidianas ao RSU e ao par V2V selecionado, respectivamente. Se um modo for inviável, sua linha é definida como 10^6 para excluí-lo das soluções ideais.

Normalização ponderada.

Cada coluna j é normalizada por sua norma euclidiana $\|\mathbf{X}_{:,j}\|_2$ e depois multiplicada pelo peso $w_j \in \{0,4; 0,3; 0,3\}$ (JCT, energia, distância), resultando na matriz normalizada ponderada $\tilde{\mathbf{X}}$.

TOPSIS L_1 -Manhattan.

Diferimos do TOPSIS clássico medindo distâncias à solução ideal positiva (PIS) A^+ e à solução ideal negativa (NIS) A^- usando a norma Manhattan (L_1):

$$D_i^+ = \sum_k |\tilde{x}_{ik} - A_k^+|, \quad D_i^- = \sum_k |\tilde{x}_{ik} - A_k^-|. \quad (5)$$

O escore de proximidade é então $\mathcal{C}_i = D_i^- / (D_i^+ + D_i^-)$. Como todos os critérios são objetivos de minimização de custo, A^+ é o mínimo coluna a coluna e A^- é o máximo coluna a coluna de $\tilde{\mathbf{X}}$. A métrica L_1 é menos sensível a valores extremos, propriedade crítica quando as estimativas de fila são ruidosas, e é computacionalmente mais leve que L_2 .

Seleção do rank-1.

O candidato de descarregamento rank-1 é o modo não local viável com o maior $\mathcal{C}_i$:

$$m^* = \operatorname{argmax}_{i \in \{1,2\}} \mathcal{C}_i \text{ s.t. modo } i \text{ é viável.} \quad (6)$$

Empates são resolvidos em favor do V2V para estimular balanceamento de carga. Se nenhum modo de descarregamento for viável, m^* recorre à execução local independentemente da ação do agente.

Vetor de estado 6D.

O estado $\mathbf{s} \in \mathbb{R}^6$ é montado como:

$$\begin{aligned} s_1 &= C_j / 10^{10} && (\text{complexidade da tarefa, norma}) \\ s_2 &= \operatorname{clip}\left(1 - \frac{\text{custo}_{m^*}}{\text{custo}_{\text{loc}}}, -1, 1\right) && (\text{vantagem objetiva do descarregamento}) \\ s_3 &= \min\left(1, \text{JCT}^{(0)} / D_j\right) && (\text{razão de urgência local}) \\ s_4 &= \min\left(1, \text{JCT}^{(m^*)} / D_j\right) && (\text{razão de urgência rank-1}) \\ s_5 &= \min(1, |Q_{\text{RSU}}| / 25) && (\text{ocupação da fila RSU}) \\ s_6 &= \min(1, |Q_{v_0}| / 25) && (\text{ocupação da fila local do veículo}) \end{aligned} \quad (7)$$

onde $\text{custo}_m = \alpha \text{JCT}^{(m)} + \beta E^{(m)}$. Todos os componentes pertencem a $[0, 1]$ ou $[-1, 1]$, tornando $\mathbf{s}$ invariante à escala, pois não depende do número de candidatos disponíveis, apenas da qualidade relativa do melhor deles.

4.2 Soft Actor-Critic de Máxima Entropia

O agente SAC otimiza o objetivo de máxima entropia [23]:

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_t \gamma^t (r_t + \alpha_T \mathcal{H}[\pi(\cdot | s_t)]) \right], \quad (8)$$

onde α_T é o parâmetro de temperatura ajustado automaticamente. As redes ator e crítico são MLPs com duas camadas ocultas de 256 unidades e ativações ReLU. O ator gera logits para a distribuição de ação de Bernoulli; a temperatura α_T é adaptada para uma entropia alvo de $\log 2/2$ nats. O buffer de replay armazena 10^5 transições; o tamanho do mini-lote é 256; a taxa de aprendizado é 3×10^{-4} para todas as redes.

Por que ação binária?

Delegar a seleção do destino de descarregamento ao TOPSIS reduz o espaço de ações de $|\mathcal{V}(t)| + 2$ dimensões a um único bit. Essa simplificação é sem perda da perspectiva do agente, pois a ordenação relativa dos candidatos já está codificada em s_2 – s_4 .

4.3 Função de Recompensa Ciente do Prazo

A recompensa r_j para a tarefa τ_j é projetada para guiar o agente ao cumprimento do prazo enquanto fornece um sinal de gradiente contínuo:

$$r_j = \begin{cases} 1,0 - 0,5 \cdot \rho_j & \text{se } \text{JCT}_j \leq D_j, \\ -1,0 - \min(1, \delta_j) & \text{caso contrário,} \end{cases} \quad (9)$$

onde

$$\rho_j = \frac{1}{2} \left(\frac{\text{JCT}_j}{D_j} + \frac{E_j}{E_{\max,j}} \right) \in [0, 1] \quad (10)$$

é uma razão de custo normalizada, e $\delta_j = (\text{JCT}_j - D_j)/D_j$ é a violação relativa do prazo. Execuções bem-sucedidas rendem $r_j \in [0,5, 1,0]$: tarefas mais rápidas e eficientes recebem recompensas maiores. Execuções com falha rendem $r_j \in [-2, -1]$: a penalidade cresce com o grau de atraso, fornecendo um gradiente que ensina o agente a falhar pelo menor tempo possível.

5 Avaliação de Desempenho

5.1 Configuração da Simulação

Todos os algoritmos executam em um simulador de eventos discretos VEC customizado escrito em C++20 com `simcpp20` e a biblioteca de álgebra linear `Armadillo`. As redes neurais são treinadas e exportadas usando `LibTorch` (API C++ do `PyTorch`). Os cenários de mobilidade são gerados com parâmetros V2X realistas, com velocidades veiculares de 30 km h^{-1} a 120 km h^{-1} , largura de banda de uplink 5G de 20 MHz, sidelink V2V de 10 MHz, frequência do RSU $f_{\text{RSU}} = 2 \text{ GHz}$ e frequência embarcada $f_{\text{loc}} \in [0,5; 1,0] \text{ GHz}$. Os prazos das tarefas seguem uma Gaussiana truncada em $[0,05; 2,0] \text{ s}$; complexidade de CPU $C_j \sim \text{Uniforme}[10^8, 10^{10}]$ ciclos.

Treinamento.

Todos os agentes DRL são treinados por 400 episódios em cenários com densidade veicular fixa de 10 tasks/s. Cada episódio de treinamento simula 100 chegadas de tarefas com uma nova realização de mobilidade extraída da mesma distribuição.

Teste.

Após o treinamento, os agentes são avaliados zero-shot em 601 cenários de teste cobrindo cinco regimes de densidade: $\{10, 15, 20, 25, 30\}$ tasks/s. Nenhum aprendizado ou adaptação adicional ocorre durante os testes.

Linhas de base.

Comparamos com: Always-Local (nunca descarrega), Greedy (sempre descarrega ao par V2V com menor JCT estimado, uma linha de base oráculo otimista), Greedy-Fair (greedy com restrição de equidade de Jain), Random (descarrega a um par aleatório), SAC-Base (SAC com vetor de estado bruto de 11 dimensões, sem TOPSIS), PPO-TOPSIS (PPO on-policy com o mesmo estado TOPSIS 6D) e TD3-TOPSIS (TD3 off-policy com o mesmo estado TOPSIS 6D).

Métricas.

- **Taxa de cumprimento de prazo:** fração de tarefas com $\text{JCT}_j \leq D_j$.
- **SWQ:** $\text{SWQ} = \hat{\tau} \cdot \frac{[(D_j - \text{JCT}_j)/D_j]_{\text{sucesso}}}{\text{grande folga}}$, que recompensa o cumprimento do prazo com grande folga.
- **JCT médio e energia total consumida.**

5.2 Comparação Geral de Desempenho

A Figura 2 e a Tabela 1 resumem o desempenho agregado em todos os 601 cenários de teste.

O TOPSIS melhora consistentemente todas as famílias DRL.

A Tabela 1 revela um resultado central deste artigo: parear o TOPSIS com qualquer algoritmo DRL testado melhora a taxa de cumprimento de prazo em relação à versão base correspondente. A magnitude do ganho, contudo, varia substancialmente entre as famílias de algoritmos e reflete a interação entre o estado TOPSIS e a estratégia de exploração de cada algoritmo.

SAC experimenta a melhoria mais dramática: o SAC-Base alcança apenas 4,47% de cumprimento porque converge para uma política quase sempre de descarregamento (94,9% V2V), incorrendo em atrasos proibitivos de fila quando os vizinhos estão congestionados. Adicionar o estado TOPSIS resgata a política para 44,36%




Figura 2 Comparação de desempenho entre as principais métricas. O SAC-TOPSIS (azul escuro) alcança a maior taxa de cumprimento de prazo e o maior índice SWQ. A borda dourada marca o melhor valor em cada gráfico.

Tabela 1 Desempenho agregado em 601 cenários de teste (média por cenário, densidades {10, 15, 20, 25, 30} tasks/s). As setas ($\uparrow$) indicam o ganho ao adicionar Topsis à cada algoritmo base. Negrito indica o melhor valor DRL; $\dagger$ indica a linha de base oráculo.

Política	Prazo (%)	SWQ	JCT (s)	Energia (J)
SAC-Base	4,47	0,0116	54,76	2047
SAC-TOPSIS (proposto) $\uparrow +39,9$	44,36	0,1450	6,18	2337
TD3-Base	41,62	0,1391	3,53	2222
TD3-TOPSIS $\uparrow +1,4$	43,01	0,1357	3,56	2077
PPO-Base	41,61	0,1399	5,67	2222
PPO-TOPSIS $\uparrow +0,3$	41,95	0,1399	5,63	1942
Always-Local	41,61	0,1391	3,56	2222
Greedy-Oracle $\dagger$	40,31	0,1225	5,16	696
Greedy	29,54	0,0842	21,21	589
Greedy-Fair	20,26	0,0517	33,85	529
Random	29,61	0,0931	16,29	2455

($+39,9$ pp), o melhor resultado entre todas as políticas avaliadas. A representação 6D fornece o sinal semântico, com razões de urgência e ocupações de fila, necessário para que o SAC precisa para distinguir decisões de descarregamento benéficas das prejudiciais.

TD3 já colapsa para always-local em sua forma base (41,62%, idêntico ao Always-Local), pois sua política determinística evita o caminho arriscado V2V sem pressão de exploração. Com o estado

TOPSIS, o TD3 aprende a explorar V2V oportunisticamente (23,4%), elevando o cumprimento para 43,01% (+1,4 pp) e alcançando o menor JCT médio (3,56 s) de todas as políticas.

PPO também colapsa para always-local em sua forma base (41,61%) devido à alta variância do gradiente on-policy. O estado TOPSIS proporciona melhora marginal para 41,95% (+0,3 pp). O ganho é limitado porque a natureza on-policy do PPO o impede de explorar plenamente o estado mais rico, pois a variância nas estimativas de gradiente ainda empurra a política para a ação local segura, apesar do sinal informativo s_2 (vantagem de descarregamento).

No geral, o SAC-TOPSIS alcança a maior taxa de cumprimento de prazo (44,36%) e SWQ (0,1450) entre todas as políticas, incluindo a linha de base oráculo Greedy (40,31%). Os resultados confirmam que o estado TOPSIS é o principal motor de desempenho, e não da escolha do algoritmo DRL, pois as três famílias se beneficiam, e as diferenças residuais entre elas são efeitos secundários de seus respectivos mecanismos de exploração.

5.3 Generalização Zero-Shot

A Figura 3 mostra a taxa de cumprimento de prazo em função da densidade veicular. O SAC-TOPSIS lidera consistentemente em todas as densidades, mantendo $> 34\%$ de cumprimento mesmo no regime de congestionamento inédito mais severo (30 tasks/s), onde Greedy heurístico cai para apenas 14%. A diferença sobre o Always-Local varia de +1,73 pp em 25 tasks/s a +4,15 pp em 10 tasks/s, confirmando que o benefício de aprender uma política adaptativa é mais pronunciado em menor congestionamento, onde o descarregamento V2V oportunista é mais confiável.

A invariância à escala do vetor de estado 6D é o habilitador fundamental: como s_3-s_4 são razões relativas ao prazo e s_5-s_6 são ocupações de fila normalizadas, a política aprendida pelo agente transfere-se diretamente para ambientes com mais ou menos candidatos. O SAC-Base, em contraste, codifica tamanhos absolutos de fila e valores brutos de frequência que perdem seu significado sob mudança de distribuição.




Figura 3 Taxa de cumprimento de prazo em função da densidade veicular. Todos os agentes foram treinados apenas em 10 tasks/s (linha vertical tracejada). O SAC-TOPSIS (círculos sólidos) supera todas as linhas de base consistentemente sem retreinamento específico por densidade.




Figura 4 Distribuição dos modos de execução. O SAC-TOPSIS equilibra adaptativamente execução local e V2V, enquanto o SAC-Base sobrecarrega o RSU com descarregamentos.

5.4 Distribuição dos Modos de Execução

A Figura 4 mostra a proporção média de execuções locais, RSU e V2V por política. O SAC-TOPSIS explora o descarregamento V2V (25,9%), que oferece menor latência que o RSU quando um veículo par está próximo. Crucialmente, o módulo TOPSIS garante que o V2V seja escolhido apenas quando oferece uma pontuação TOPSIS melhor que o RSU, impedindo a migração de carga para pares sobrecarregados.




Figura 5 Convergência do treinamento ao longo de 400 episódios. (a) Recompensa média (suavizada com janela de 20 episódios); (b) taxa de cumprimento de prazo durante o treinamento. O SAC-TOPSIS alcança convergência estável em ambas as métricas.

5.5 Convergência do Treinamento

A Figura 5 compara as curvas de treinamento do SAC-TOPSIS, SAC-Base, TD3-TOPSIS e PPO-TOPSIS. Todos os agentes são treinados por 400 episódios no cenário de 10 tasks/s. SAC-TOPSIS e TD3-TOPSIS exibem melhoria de recompensa mais rápida e menor variância que o SAC-Base, confirmando que o estado TOPSIS fornece um sinal de aprendizado mais informativo. O PPO-TOPSIS converge para um ótimo local com menor recompensa média, consistente com sua política always-local no tempo de teste.

5.6 Estudo de Ablação: TOPSIS como Primitiva Universal de Engenharia de Estado

A Figura 6 apresenta uma ablação cross-família na qual cada algoritmo DRL é avaliado com seu estado base bruto e com o estado TOPSIS 6D, mantendo todos os demais hiperparâmetros idênticos. As setas que anotam cada par quantificam o ganho atribuível exclusivamente à mudança de representação de estado.

Três achados se destacam. Primeiro, o ganho é monótono, pois o TOPSIS nunca prejudica nenhum algoritmo. Segundo, o ganho é maior para a política base mais instável (SAC-Base colapsa, SAC-TOPSIS recupera), o que confirma que o estado TOPSIS resolve o problema de colapso de representação em vez de apenas ajustar uma política já razoável. Terceiro, o ganho é agnóstico ao algoritmo, pois mesmo o TD3, que tem uma política base bem comportada (ainda que conservadora), melhora +1,4pp após a mudança de estado. Este último ponto é fundamental, pois




Figura 6 Ablação cross-familia: Base (sem TOPSIS, barras mais claras) vs. +TOPSIS (barras mais escuras com borda preta) para SAC, TD3 e PPO. As setas curvas mostram o ganho ao adicionar TOPSIS a cada família. O ganho é consistente em todas as famílias, confirmando que a compressão de estado TOPSIS é um motor de desempenho universal.

Tabela 2 Ablação interna do SAC. Cada linha adiciona uma escolha de projeto sobre o SAC-Base. Δ é o ganho na taxa de prazo em relação ao SAC-Base.

Variante	Mudança vs. SAC-Base	de prazo (%) igualmente crítica (+33,2 pp, SAC-R1).
SAC-Base	— (linha de base)	4,47
SAC-A1	Somente ação binária	38,59
SAC-R1	Somente recompensa ciente de prazo	37,04
SAC-S1	Somente estado manual compacto 6D	28,32
SAC-T1	Estado TOPSIS 6D, 3 ações	32,10
SAC-TOPSIS	Completo (TOPSIS 6D + binário + prazo)	44,36

mostra que o estado TOPSIS carrega informação útil além do que qualquer algoritmo base pode inferir a partir de observações brutas, e que essa informação é explorável por diferentes paradigmas de aprendizado.

5.7 Ablação Interna do SAC: Decomposição Causal

Para entender quais escolhas de projeto dentro do SAC-TOPSIS mais contribuem para seu desempenho, conduzimos uma ablação refinada na qual cada variante adiciona exatamente um componente em relação ao SAC-Base. A Tabela 2 e a Figura 7 resumem os resultados.

Três perspectivas complementares emergem dessa decomposição.

(1) **A ação binária é a maior alavanca individual (+34,1 pp, SAC-A1).** Reduzir o espaço de ações de três classes




Figura 7 Decomposição causal interna do SAC. Cada barra corresponde a uma variante que isola uma escolha de projeto. Todos os ganhos são reportados em relação ao SAC-Base (4,47%). O SAC-TOPSIS completo combina os três componentes e alcança a maior taxa de cumprimento.

(LOCAL/RSU/V2V) para uma decisão binária (LOCAL vs. melhor descarregamento rank-1) resolve em grande parte o colapso do SAC-Base. Sem TOPSIS, o agente ainda deve avaliar os candidatos com base em características brutas, mas a simplificação da fronteira de decisão já impede a política degenerar sempre-V2V.

(2) **A modelagem de recompensa ciente de prazo é igualmente crítica (+33,2 pp, SAC-R1).** Substituir a recompensa do Método da Soma Ponderada (WSM) pela recompensa contínua proporcional ao prazo da Equação (9) fornece um sinal de gradiente mesmo no regime de falha, permitindo o agente aprender a minimizar o tempo de apenas evitá-lo. Esse ganho é independente da representação de estado, demonstrando que a engenharia de recompensa é uma contribuição autônoma.

(3) **O estado TOPSIS proporciona ganhos compostos sobre qualquer componente isolado.** O SAC-S1 mostra que compactar o estado para 6D manualmente (sem TOPSIS) já rende +23,8 pp sobre o SAC-Base, confirmando que a engenharia de features importa. O SAC-T1 mostra que usar o TOPSIS para construir o estado 6D (em vez de features ad-hoc) eleva isso para +27,6 pp, mesmo quando o espaço de ações ainda tem 3 classes. O SAC-TOPSIS completo, que combina o estado TOPSIS com a ação binária e a recompensa de prazo, alcança +39,9 pp, mais que qualquer componente individual, confirmando que as três escolhas de projeto são sinérgicas em vez de meramente aditivas.

6 Conclusão e Trabalhos Futuros

Este artigo apresentou o SAC-TOPSIS, uma arquitetura híbrida para descarregamento de tarefas ciente de prazo em redes VEC. A inovação central é usar o TOPSIS não como tomador de decisão autônomo, mas como um módulo de engenharia de estado que converte um conjunto de candidatos de tamanho variável e multicritério em uma representação fixa 6D invariante à escala. Um agente SAC de máxima entropia treinado sobre essa representação aprende uma política binária local/descarregamento que: (i) alcança uma taxa de cumprimento de prazo de 44,36%, a maior entre todas as políticas DRL e heurísticas avaliadas em 601 cenários de teste; (ii) atinge um índice SWQ de 0,1450; (iii) generaliza zero-shot para densidades veiculares inéditas (10–30 tasks/s) sem retreinamento; e (iv) evita os colapsos de modo do PPO-TOPSIS (always-local) e do SAC-Base (always-V2V).

Um estudo de ablação cross-família confirma que a compressão de estado TOPSIS é o principal motor de desempenho, pois melhora o cumprimento de prazo para todas as famílias DRL testadas: SAC (+39,9 pp), TD3 (+1,4 pp) e PPO (+0,3 pp), independentemente de seu algoritmo de aprendizado base. A vantagem residual do SAC sobre o TD3 (+1,35 pp) é um efeito secundário da exploração regularizada por entropia, que impede a política de colapsar para a estratégia conservadora always-local que afeta os métodos determinísticos off-policy em densidades mais altas.

Trabalhos futuros.

Planejamos estender o módulo TOPSIS para Fuzzy-TOPSIS, incorporando incerteza linguística nos pesos dos critérios para lidar com telemetria atrasada e estimativas ruidosas de canal. Também investigaremos extensões multi-agente nas quais cada veículo em $\mathcal{V}(t)$ executa seu próprio agente SAC-TOPSIS com coordenação descentralizada. Por fim, a avaliação hardware-in-the-loop com rádios sidelink 5G reais está planejada para validar o modelo de energia sob condições físicas de canal.

Referências

- [1] Kandali, K., Nouh, S., Bennis, L., Bennis, H.: A comprehensive survey on vanet-iot integration toward the internet of vehicles: Architectures, communications, and system challenges. *Data and Metadata* **4**, 521 (2025) <https://doi.org/10.56294/dm2025521>
- [2] Uddin, A., Zhang, N., Sakr, A.H.: Intelligent offloading in vehicular edge computing: A comprehensive review of deep reinforcement learning approaches and architectures. *arXiv preprint arXiv:2502.06963* (2025). Comprehensive Survey on DRL-based offloading for VEC: single-agent, multi-agent, latency, energy, fairness
- [3] Zheng, K., Zheng, Q., Chatzimisios, P., Xiang, W., Zhou, Y.: Heterogeneous vehicular networking: A survey on architecture, challenges, and solutions. *IEEE Communications Surveys & Tutorials* **17**(4), 2377–2396 (2015) <https://doi.org/10.1109/COMST.2015.2440103>
- [4] Naik, G., Choudhury, B., Park, J.-M.J.: IEEE 802.11bd & 5g nr v2x: Evolution of radio access technologies for v2x communications. *IEEE Access* **7**, 70113–70128 (2019) <https://doi.org/10.1109/ACCESS.2019.2918458>
- [5] Chen, S., al.: Vehicle-to-everything (v2x) services: Mode 4 communication in lte-v2x. *IEEE Access* **5**, 22461–22471 (2017)
- [6] 3GPP: Release 17 overview. Technical Report Technical Specification Group Services and System Aspects, 3rd Generation Partnership Project (3GPP) (2022). Accessed: 2025-01-01
- [7] Federal Communications Commission (FCC): Use of the 5.850-5.925 ghz band: Second report and order. Technical Report FCC 24-110, FCC (November 2024). Adopted November 20, 2024. Establishing sunset for DSRC by December 2025.
- [8] Mao, Y., You, C., Zhang, J., Huang, K., Letaief, K.B.: A survey on mobile edge computing: The communication perspective. *IEEE Communications Surveys & Tutorials* **19**(4), 2322–2358 (2017) <https://doi.org/10.1109/COMST.2017.2745201>
- [9] Huang, X., Ye, Q., Li, J., Wu, Y.: Deep

- reinforcement learning for offloading and resource allocation in vehicular edge computing. *IEEE Transactions on Vehicular Technology* **69**(8), 8334–8345 (2020) <https://doi.org/10.1109/TVT.2020.2996652>
- [10] Fang, J., Shi, J., Lu, S., Zhang, M.: An efficient computation offloading strategy with mobile edge computing for iot. *Micromachines* **12**(2), 204 (2021) <https://doi.org/10.3390/mi12020204>
- [11] Luo, Q., Luan, T.H., Shi, W., Fan, P.: Heterogeneous task oriented data scheduling in vehicular edge computing via deep reinforcement learning. *IEEE Transactions on Vehicular Technology* **73**(12), 19582–19596 (2024) <https://doi.org/10.1109/TVT.2024.3444815>
- [12] He, Y., Ren, J., Yu, G., Cai, Y.: D2D Communications Meet Mobile Edge Computing for Enhanced Computation Capacity in Cellular Networks. *IEEE Transactions on Wireless Communications* **18**(3), 1750–1763 (2019) <https://doi.org/10.1109/TWC.2019.2896999>
- [13] Miriyala, S., Chirra, V.R.: Deep learning approaches for computation offloading in edge computing: A critical review. *Telecommunication Systems* **89**(42) (2026) <https://doi.org/10.1007/s11235-026-01426-y>
- [14] Ahmed, M., et al.: A survey on vehicular task offloading: Classification, issues and future challenges. *Journal of King Saud University – Computer and Information Sciences* (2022). Elsevier / ScienceDirect
- [15] Li, Z., Zhu, Q.: Genetic algorithm-based optimization of offloading and resource allocation in mobile-edge computing. *Information* **11**(2), 83 (2020)
- [16] You, Q., Tang, B.: Efficient task offloading using particle swarm optimization algorithm in edge computing for industrial internet of things. *Journal of Cloud Computing* **10**(1), 41 (2021)
- [17] Kishor, A., Chakarbarty, C.: Task offloading in fog computing for using smart ant colony optimization. *Wireless personal communications* **127**(2), 1683–1704 (2022)
- [18] Shi, W., Chen, L., Zhu, X.: Task offloading decision-making algorithm for vehicular edge computing: A deep-reinforcement-learning-based approach. *Sensors* **23**(17) (2023) <https://doi.org/10.3390/s23177595>
- [19] Sousa Vieira, A.S., Souza, A.B., Celestino Júnior, J.: FOFF: an energy-efficient task offloading in VEC-enabled vehicular networks using fuzzy TOPSIS. *Cluster Computing* (2025) <https://doi.org/10.1007/s10586-025-05027-3>
- [20] Liu, J., Liu, X.: Energy-efficient allocation for multiple tasks in mobile edge computing. *Journal of Cloud Computing* **11**, 71 (2022) <https://doi.org/10.1186/s13677-022-00342-1>
- [21] Mnih, V., *et al.*: Human-level control through deep reinforcement learning. *Nature* **518**(7540), 529–533 (2015)
- [22] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O.: Proximal policy optimization algorithms. (2017)
- [23] Haarnoja, T., Zhou, A., Abbeel, P., Levine, S.: Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In: *Proceedings of the 35th International Conference on Machine Learning (ICML)*. *Proceedings of Machine Learning Research*, vol. 80, pp. 1861–1870. PMLR, ??? (2018)